(19)国家知识产权局

(12)发明专利申请

(10)申请公布号 CN 122864454 A
(43)申请公布日 2026.10.02

(21)申请号 202611220146.6

(22)申请日 2026.08.12

(71)申请人 厦门四信通信科技有限公司
地址 361000 福建省厦门市厦门火炬高新区软件园创新大厦C区3F-A129

(72)发明人 彭府 曾原野 陈珏 陈祥树

(74)专利代理机构 厦门原创专利事务所(普通合伙) 35101
专利代理师 雷鹏达

(51)Int.Cl.
G06F 40/35(2020.01)
H03M 7/30(2006.01)
G06F 16/383(2019.01)
G06F 18/22(2023.01)

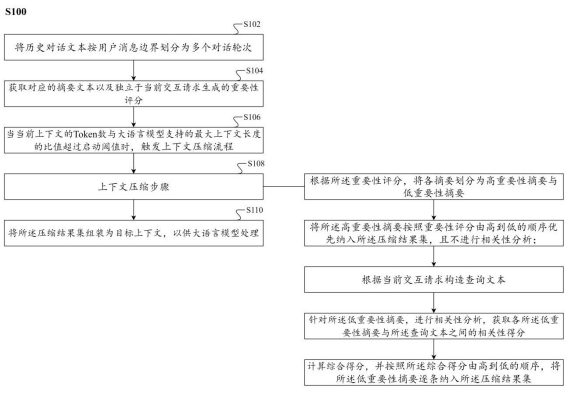
权利要求书3页 说明书15页 附图4页

(54)发明名称

一种基于重要性与相关性的对话上下文压缩方法及装置

(57)摘要

本公开属于语义分析技术领域,本公开提供了一种基于重要性与相关性的对话上下文压缩方法及装置,所述方法包括:将历史对话文本划分为多个对话轮次;针对每个所述对话轮次,获取对应的摘要文本以及重要性评分;当当前上下文的Token数与大语言模型支持的最大上下文长度的比值超过预设的启动阈值时,触发上下文压缩流程;将各摘要划分为高重要性摘要与低重要性摘要;将所述高重要性摘要优先纳入压缩结果集;根据当前交互请求构造查询文本;针对所述低重要性摘要,进行相关性分析;计算综合得分,并按照所述综合得分由高到低的顺序,将所述低重要性摘要逐条纳入所述压缩结果集;将所述压缩结果集组装为目标上下文。



CN 122864454 A

1.一种基于重要性与相关性的对话上下文压缩方法,其特征在于,所述方法包括:

对话轮次切分步骤:将历史对话文本按用户消息边界划分为多个对话轮次;

摘要提取步骤:针对每个所述对话轮次,获取对应的摘要文本以及独立于当前交互请求生成的重要性评分,所述重要性评分用于表征该对话轮次所含信息的长期重要性及其在会话全局中的核心程度;

压缩流程触发步骤:当当前上下文的Token数与大语言模型支持的最大上下文长度的比值超过预设的启动阈值时,触发上下文压缩流程;

上下文压缩步骤:根据所述重要性评分,将各摘要划分为高重要性摘要与低重要性摘要;其中,所述高重要性摘要的重要性评分大于等于预设的重要性阈值,所述低重要性摘要的重要性评分小于所述重要性阈值;

将所述高重要性摘要按照重要性评分由高到低的顺序优先纳入所述压缩结果集,且不进行相关性分析;

根据当前交互请求构造查询文本;

针对所述低重要性摘要,基于所述查询文本进行相关性分析,获取各所述低重要性摘要与所述查询文本之间的相关性得分,包括:

粗筛阶段:获取各所述低重要性摘要的语义向量,利用部署于本地计算环境的Embedding模型,计算各所述低重要性摘要与所述查询文本之间的语义相似度,筛选出语义相似度超过预设的筛选阈值的摘要作为候选摘要;

精排阶段:将所述候选摘要集与所述查询文本输入部署于云端计算环境的重排序模型,执行语义交互匹配,获取各所述候选摘要与所述查询文本之间的相关性得分;

根据各所述低重要性摘要的重要性评分及对应的相关性得分,计算综合得分,并按照所述综合得分由高到低的顺序,将所述低重要性摘要逐条纳入所述压缩结果集,使所述压缩结果集的累计Token数不超过所述大语言模型支持的最大上下文长度与预设的截止阈值的乘积;

上下文组装步骤:将所述压缩结果集组装为目标上下文,以供大语言模型处理。

2.如权利要求1所述的方法,其特征在于,所述方法还包括:

最近轮次保护步骤:针对最近N个对话轮次,保留其原始内容,且不参与所述高重要性摘要与低重要性摘要的分类及后续相关性分析;

所述上下文组装步骤包括:将所述最近N个对话轮次的原始内容与所述压缩结果集进行拼接,生成所述目标上下文;

其中,所述最近N个对话轮次为距离当前交互请求最近的N个对话轮次。

3.如权利要求1所述的方法,其特征在于,所述对话轮次切分步骤包括:

识别助手消息中的工具调用指令;

基于预设的工具调用标识符,将所述工具调用指令及其对应的工具返回消息,与所述助手消息归入同一对话轮次。

4.如权利要求1所述的方法,其特征在于,所述摘要提取步骤在对话轮次结束后异步执行,包括:

调用大语言模型生成所述摘要文本及对应的所述重要性评分;

调用部署于本地计算环境的Embedding模型计算所述摘要文本的语义向量;

将所述摘要文本、所述重要性评分及所述语义向量关联存储至缓存。

5.根据权利要求1所述的方法,其特征在于,将所述高重要性摘要按照重要性评分由高到低的顺序优先纳入所述压缩结果集,且不进行相关性分析,包括:

对所述高重要性摘要进行语义相似度检测,当相似度超过预设的去重阈值时,保留重要性评分更高的摘要;重要性评分相同时,保留轮次靠后的摘要;

将去重后的所述高重要性摘要按照重要性评分由高到低的顺序优先纳入所述压缩结果集,且不进行相关性分析,并使其累计Token数不超过所述大语言模型支持的最大上下文长度、所述截止阈值和预设比例三者的乘积。

6.如权利要求1所述的方法,其特征在于,根据当前交互请求构造查询文本,包括:

根据当前交互请求以及当前会话的阶段意图和长期意图构造所述查询文本。

7.如权利要求1所述的方法,其特征在于,所述上下文组装步骤包括:

将位于启动压缩流程时对应的上下文边界之前的对话轮次的原始内容、所述压缩结果集以及最近N个对话轮次的原始内容,按照以下顺序拼接生成所述目标上下文:

系统提示词、所述位于所述上下文边界之前的对话轮次的原始内容、所述压缩结果集、所述最近N个对话轮次的原始内容;

其中,所述最近N个对话轮次为距离当前交互请求最近的N个对话轮次。

8.一种基于重要性与相关性的对话上下文压缩装置,其特征在于,所述装置包括:

对话轮次切分模块,用于将历史对话文本按用户消息边界划分为多个对话轮次;

摘要提取模块,用于针对每个所述对话轮次,获取对应的摘要文本以及独立于当前交互请求生成的重要性评分,所述重要性评分用于表征该对话轮次所含信息的长期重要性及其在会话全局中的核心程度;

压缩流程触发模块,用于当当前上下文的Token数与大语言模型支持的最大上下文长度的比值超过预设的启动阈值时,触发上下文压缩流程;

上下文压缩模块,用于根据所述重要性评分,将各摘要划分为高重要性摘要与低重要性摘要;其中,所述高重要性摘要的重要性评分大于等于预设的重要性阈值,所述低重要性摘要的重要性评分小于所述重要性阈值;

将所述高重要性摘要按照重要性评分由高到低的顺序优先纳入所述压缩结果集,且不进行相关性分析;

根据当前交互请求构造查询文本;

针对所述低重要性摘要,基于所述查询文本进行相关性分析,获取各所述低重要性摘要与所述查询文本之间的相关性得分,包括:

粗筛阶段:获取各所述低重要性摘要的语义向量,利用部署于本地计算环境的Embedding模型,计算各所述低重要性摘要与所述查询文本之间的语义相似度,筛选出语义相似度超过预设的筛选阈值的摘要作为候选摘要;

精排阶段:将所述候选摘要集与所述查询文本输入部署于云端计算环境的重排序模型,执行语义交互匹配,获取各所述候选摘要与所述查询文本之间的相关性得分;

根据各所述低重要性摘要的重要性评分及对应的相关性得分,计算综合得分,并按照所述综合得分由高到低的顺序,将所述低重要性摘要逐条纳入所述压缩结果集,使所述压缩结果集的累计Token数不超过所述大语言模型支持的最大上下文长度与预设的截止阈值

的乘积;

上下文组装模块,用于将所述压缩结果集组装为目标上下文,以供大语言模型处理。

9. 一种电子设备,其特征在于,包括:

存储器,所述存储器存储执行指令;以及

处理器,所述处理器执行所述存储器存储的执行指令,使得所述处理器执行权利要求1-7任一项所述的方法。

10.一种可读存储介质,其特征在于,所述可读存储介质中存储有执行指令,所述执行指令被处理器执行时用于实现权利要求1-7任一项所述的方法。

一种基于重要性与相关性的对话上下文压缩方法及装置

技术领域

[0001] 本公开属于语义分析技术领域,尤其涉及一种基于重要性与相关性的对话上下文压缩方法及装置。

背景技术

[0002] 随着大语言模型(LLM)技术的快速发展,基于多轮对话的AI应用日益普及。然而,LLM普遍存在上下文长度限制,当对话历史超过模型上限时,必须对历史对话进行压缩或截断处理。现有技术主要存在以下问题:一是简单截断或滑动窗口方式导致关键信息丢失,用户早期设定的核心需求、技术选型决策等长期重要信息被彻底丢弃,导致后续回复出现偏差或反复询问已确认内容。二是摘要压缩缺乏有效区分机制。现有方案通常对所有历史内容一视同仁或仅依赖实时语义相关性进行筛选,未对信息的固有重要程度进行预分类。一方面,具有全局指导意义的核心背景信息(如系统架构选型、业务约束、用户核心需求)在字面上往往与当前具体查询的相关性较低,若完全依赖动态相关性筛查,此类信息极易被归为“不相关”而被过度压缩甚至错误剔除,导致上下文信息断层或生成内容出现事实性偏差;另一方面,由于上述方案需对每一段历史都执行相关性计算,当对话轮次极长时,这种全量动态计算会带来不可忽视的响应延迟和算力损耗。三是压缩策略单一且时机不合理,难以兼顾隐私保护、计算效率与长程对话的连贯性。

[0003] 上述纯相关性驱动的压缩方案的本质缺陷在于:将“与当前提问的相关性”作为衡量历史信息价值的唯一尺度,忽视了对话历史中具有持久支撑作用的核心信息。当用户发出语义稀疏的弱提问(如“继续”、“然后呢”)时,此类信息极易因相关性偏低而被误过滤。此外,现有方案对高重要性与低重要性信息不加区分地执行全量相关性计算,无论信息是否具有长期核心价值,均需经历完整的语义匹配流程,算力消耗与对话轮次成正比。

[0004] 因此,亟需一种能够对核心信息进行确定性保护、同时兼顾压缩效率与当前任务相关性精度的对话上下文智能压缩方法。

发明内容

[0005] 本公开提供了一种基于重要性与相关性的对话上下文压缩方法及装置,可以有效解决上述问题。

[0006] 本公开是这样实现的:

第一方面,本公开提供一种基于重要性与相关性的对话上下文压缩方法,所述方法包括:

对话轮次切分步骤:将历史对话文本按用户消息边界划分为多个对话轮次;

摘要提取步骤:针对每个所述对话轮次,获取对应的摘要文本以及独立于当前交互请求生成的重要性评分,所述重要性评分用于表征该对话轮次所含信息的长期重要性及其在会话全局中的核心程度;

压缩流程触发步骤:当当前上下文的Token数与大语言模型支持的最大上下文长

度的比值超过预设的启动阈值时,触发上下文压缩流程;

上下文压缩步骤:根据所述重要性评分,将各摘要划分为高重要性摘要与低重要性摘要;其中,所述高重要性摘要的重要性评分大于等于预设的重要性阈值,所述低重要性摘要的重要性评分小于所述重要性阈值;

将所述高重要性摘要按照重要性评分由高到低的顺序优先纳入所述压缩结果集,且不进行相关性分析;

根据当前交互请求构造查询文本;

针对所述低重要性摘要,基于所述查询文本进行相关性分析,获取各所述低重要性摘要与所述查询文本之间的相关性得分,包括:

粗筛阶段:获取各所述低重要性摘要的语义向量,利用部署于本地计算环境的Embedding模型,计算各所述低重要性摘要与所述查询文本之间的语义相似度,筛选出语义相似度超过预设的筛选阈值的摘要作为候选摘要;

精排阶段:将所述候选摘要集与所述查询文本输入部署于云端计算环境的重排序模型,执行语义交互匹配,获取各所述候选摘要与所述查询文本之间的相关性得分;

根据各所述低重要性摘要的重要性评分及对应的相关性得分,计算综合得分,并按照所述综合得分由高到低的顺序,将所述低重要性摘要逐条纳入所述压缩结果集,使所述压缩结果集的累计Token数不超过所述大语言模型支持的最大上下文长度与预设的截止阈值的乘积;

上下文组装步骤:将所述压缩结果集组装为目标上下文,以供大语言模型处理。

[0007] 第二方面,本公开提供一种基于重要性与相关性的对话上下文压缩装置,所述装置包括:

对话轮次切分模块,用于将历史对话文本按用户消息边界划分为多个对话轮次;

摘要提取模块,用于针对每个所述对话轮次,获取对应的摘要文本以及独立于当前交互请求生成的重要性评分,所述重要性评分用于表征该对话轮次所含信息的长期重要性及其在会话全局中的核心程度;

压缩流程触发模块,用于当当前上下文的Token数与大语言模型支持的最大上下文长度的比值超过预设的启动阈值时,触发上下文压缩流程;

上下文压缩模块,用于根据所述重要性评分,将各摘要划分为高重要性摘要与低重要性摘要;其中,所述高重要性摘要的重要性评分大于等于预设的重要性阈值,所述低重要性摘要的重要性评分小于所述重要性阈值;

将所述高重要性摘要按照重要性评分由高到低的顺序优先纳入所述压缩结果集,且不进行相关性分析;

根据当前交互请求构造查询文本;

针对所述低重要性摘要,基于所述查询文本进行相关性分析,获取各所述低重要性摘要与所述查询文本之间的相关性得分,包括:

粗筛阶段:获取各所述低重要性摘要的语义向量,利用部署于本地计算环境的Embedding模型,计算各所述低重要性摘要与所述查询文本之间的语义相似度,筛选出语义相似度超过预设的筛选阈值的摘要作为候选摘要;

精排阶段:将所述候选摘要集与所述查询文本输入部署于云端计算环境的重排序

模型,执行语义交互匹配,获取各所述候选摘要与所述查询文本之间的相关性得分;

根据各所述低重要性摘要的重要性评分及对应的相关性得分,计算综合得分,并按照所述综合得分由高到低的顺序,将所述低重要性摘要逐条纳入所述压缩结果集,使所述压缩结果集的累计Token数不超过所述大语言模型支持的最大上下文长度与预设的截止阈值的乘积;

上下文组装模块,用于将所述压缩结果集组装为目标上下文,以供大语言模型处理。

[0008] 第三方面,本公开提供一种电子设备,包括:

存储器,所述存储器存储执行指令;以及

处理器,所述处理器执行所述存储器存储的执行指令,使得所述处理器执行第一方面所述的方法。

[0009] 第四方面,本公开提供一种可读存储介质,所述可读存储介质中存储有执行指令,所述执行指令被处理器执行时用于实现第一方面所述的方法。

[0010] 与现有技术相比,本公开的有益效果是:

1. 本公开将高重要性摘要按照重要性评分由高到低的顺序优先纳入压缩结果集,且不进行相关性分析;低重要性摘要则依次执行Embedding粗筛和重排序精排。由此,后续相关性处理仅面向经重要性分层后的低重要性摘要,高重要性摘要被免于相关性分析,从而减少了进入重排序模型的候选摘要数量,降低了算力消耗。上述特征相互配合:重要性分层提供确定性保护,两阶段分析兼顾效率与精度,截止阈值机制保障操作空间。

[0011] 2. 对低重要性摘要进行相关性分析,并根据重要性评分和相关性得分进行综合排序,以使低重要性摘要的筛选同时考虑其重要性和与当前交互请求的相关性。

[0012] 3. 采用本地部署的Embedding模型计算语义向量,对话原文不离开本地环境,有效保护数据隐私。

[0013] 4. 在对话轮次结束后异步生成摘要、重要性评分和语义向量并形成轮次级缓存记录;在压缩触发时读取所述缓存记录,使相关性分析不必重新生成历史摘要和历史摘要向量。

[0014] 5. 基于当前交互请求以及缓存的阶段意图和长期意图构造查询文本,使低重要性摘要的相关性分析除当前交互请求外还使用当前任务阶段和长期任务信息。

[0015] 6. 多专家模型并行评分并融合,有效规避单一模型偏差,提高重要性评分的稳定性。

附图说明

[0016] 图1是本公开实施例提供的基于重要性与相关性的对话上下文压缩方法S100的流程图。

[0017] 图2是本公开实施例提供的多专家模型重要性评分流程图。

[0018] 图3是本公开实施例提供的异步预处理流程图。

[0019] 图4是本公开实施例提供的双阈值机制示意图。

[0020] 图5是本公开实施例提供的压缩流程图。

[0021] 图6是本公开实施例提供的阶段意图生成流程图。

[0022] 图7是本公开实施例提供的综合得分排序示意图。

[0023] 图8是本公开实施例提供的基于重要性与相关性的对话上下文压缩装置1000的结构示意图。

具体实施方式

[0024] 下面结合附图和实施方式对本公开作进一步的详细说明。可以理解的是,此处所描述的具体实施方式仅用于解释相关内容,而非对本公开的限定。另外还需要说明的是,为了便于描述,附图中仅示出了与本公开相关的部分。

[0025] 需要说明的是,在不冲突的情况下,本公开中的实施方式及实施方式中的特征可以相互组合。下面将参考附图并结合实施方式来详细说明本公开的技术方案。

[0026] 除非另有说明,否则示出的示例性实施方式/实施例将被理解为提供可以在实践中实施本公开的技术构思的一些方式的各种细节的示例性特征。因此,除非另有说明,否则在不脱离本公开的技术构思的情况下,各种实施方式/实施例的特征可以另外地组合、分离、互换和/或重新布置。

[0027] 在本文中使用的术语是仅仅出于描述特定实施例的目的,而非旨在限制本公开。在本公开实施例和所附权利要求书中所使用的单数形式的“一种”、“所述”和“该”也旨在包括多数形式,除非上下文清楚地表示其他含义。

[0028] 应当理解,本文中使用的术语“和/或”仅仅是一种描述关联对象的关联关系,表示可以存在三种关系,例如,A和/或B,可以表示:单独存在A,同时存在A和B,单独存在B这三种情况。另外,本文中字符“/”,一般表示前后关联对象是一种“或”的关系。

[0029] 取决于语境,如在此所使用的词语“如果”可以被解释成为“在……时”或“当……时”或“响应于确定”或“响应于检测”。类似地,取决于语境,短语“如果确定”或“如果检测(陈述的条件或事件)”可以被解释成为“当确定时”或“响应于确定”或“当检测(陈述的条件或事件)时”或“响应于检测(陈述的条件或事件)”。

[0030] 本文中提及的“第一\第二”仅仅是是区别类似的对象,不代表针对对象的特定排序,可以理解地,“第一\第二”在允许的情况下可以互换特定的顺序或先后次序。应该理解“第一\第二”区分的对象在适当情况下可以互换,以使这里描述的实施例能够以除了在这里图示或描述的那些以外的顺序实施。

[0031] 实施例一

请参考图1,本公开实施例提供一种基于重要性与相关性的对话上下文压缩方法S100。

[0032] 具体的,所述方法S100包括:

S102,对话轮次切分步骤:将历史对话文本按用户消息边界划分为多个对话轮次;

S104,摘要提取步骤:针对每个所述对话轮次,获取对应的摘要文本以及独立于当前交互请求生成的重要性评分,所述重要性评分用于表征该对话轮次所含信息的长期重要性及其在会话全局中的核心程度;

S106,压缩流程触发步骤:当当前上下文的Token数与大语言模型支持的最大上下文长度的比值超过预设的启动阈值时,触发上下文压缩流程;

S108,上下文压缩步骤:根据所述重要性评分,将各摘要划分为高重要性摘要与低

重要性摘要;其中,所述高重要性摘要的重要性评分大于等于预设的重要性阈值,所述低重要性摘要的重要性评分小于所述重要性阈值;

将所述高重要性摘要按照重要性评分由高到低的顺序优先纳入所述压缩结果集,且不进行相关性分析;

根据当前交互请求构造查询文本;

针对所述低重要性摘要,基于所述查询文本进行相关性分析,获取各所述低重要性摘要与所述查询文本之间的相关性得分,包括:

粗筛阶段:获取各所述低重要性摘要的语义向量,利用部署于本地计算环境的Embedding模型,计算各所述低重要性摘要与所述查询文本之间的语义相似度,筛选出语义相似度超过预设的筛选阈值的摘要作为候选摘要;

精排阶段:将所述候选摘要集与所述查询文本输入部署于云端计算环境的重排序模型,执行语义交互匹配,获取各所述候选摘要与所述查询文本之间的相关性得分;

根据各所述低重要性摘要的重要性评分及对应的相关性得分,计算综合得分,并按照所述综合得分由高到低的顺序,将所述低重要性摘要逐条纳入所述压缩结果集,使所述压缩结果集的累计Token数不超过所述大语言模型支持的最大上下文长度与预设的截止阈值的乘积;

S110,上下文组装步骤:将所述压缩结果集组装为目标上下文,以供大语言模型处理。

[0033] 步骤102中,获取需要进行上下文压缩(超过启动阈值时触发压缩流程)的历史对话文本。历史对话文本可以是一个多轮对话会话中的全部或部分消息记录。将历史对话文本按用户消息边界划分为多个独立的对话轮次。具体的,遍历对话消息列表,每当遇到一条角色为“user”的消息时,即将其作为一个新轮次的起始边界。该用户消息及其后连续的、直到遇到下一个用户消息之前的所有助手消息(角色为“assistant”)、工具调用消息(角色为“tool”)和工具返回消息,共同构成一个完整的对话轮次。这样做可以保证每个轮次都是一个完整的“提问-回答/操作”单元。

[0034] 在一些实施方式中,所述对话轮次切分步骤S102包括:

识别助手消息中的工具调用指令;

基于预设的工具调用标识符,将所述工具调用指令及其对应的工具返回消息,与所述助手消息归入同一对话轮次。

[0035] AI智能体(AI Agent)场景下的单次交互往往并非简单的用户提问与助手回复,而是包含用户意图表达、助手决策调用外部工具、工具执行反馈、助手基于反馈生成最终结论的完整闭环。若机械地按消息角色切分,可能将一次完整的工具调用拆散为多个孤立的轮次片段,导致后续摘要生成时无法还原“问题诊断—工具执行—结果反馈—方案输出”的因果链条,进而使得语义向量表征失真、相关性分析失准。通过工具调用标识符建立调用与返回之间的唯一对应关系,能够确保无论单次交互中嵌套了多少层工具调用,其完整的上下文链条始终被封装在同一个对话轮次内。这不仅为异步摘要生成提供了结构化的输入单元,也为后续基于语义向量的相关性筛选保留了连贯的语义信息,是整个多阶段压缩流程在AI智能体场景下得以正确运行的基础工程保障。

[0036] 针对由步骤S102划分出的每一个对话轮次,步骤S104为其原始内容生成一个对应

的摘要文本,并同时为其分配一个用于表征该对话轮次重要程度的重要性评分。摘要文本是对对话轮次原始内容的精炼概括,包含但不限于关键数据、操作步骤、技术决策、问题现象和解决方案等核心信息。重要性评分可以是一个数值范围,例如,0-9分,分数越高代表该轮次的信息越重要、越具有长期价值。评分标准可以是:9分代表核心设定(如用户身份、硬件配置),7-8分代表关键决策(如技术选型、最终方案),4-6分代表事实细节(如代码实现、报错分析),1-3分代表临时信息(如调试步骤、寒暄),0分代表噪音。摘要和重要性评分的生成可以通过调用大语言模型(LLM)API来实现。

[0037] 本公开中重要性评分的获取支持单专家联合生成模式与多专家融合裁决模式的动态切换,以适应不同场景下对成本与精度的差异化需求。在单专家联合生成模式下,系统调用一个大语言模型,通过精心设计的提示词,要求模型在单次API调用中以结构化JSON格式联合输出摘要文本与重要性评分,例如{"summary": "用户确定使用MyBatis-Plus作为ORM框架", "importance_score": 7}。该模式在一次调用中同时完成摘要生成与评分赋值,具有成本低、延迟小的优势,适用于对评分精度要求适中、对话轮次频繁的大规模应用场景。请参考图2,在多专家融合裁决模式下,系统调用多个不同参数量或不同架构的大语言模型(例如同时调用7B、13B和70B参数量级的模型,或同时调用GPT、Claude、Llama等不同家族的模型)对同一摘要进行并行独立评分,获取多个评分结果后,通过均值融合、加权融合或共识融合策略输出最终评分;同时,系统计算各模型评分的标准差,自动剔除偏离度超过预设标准差阈值的异常评分值,以避免单一模型评分偏差或极端值对融合结果的干扰。该模式显著提高了评分稳定性和抗干扰能力,适用于对关键决策信息准确度要求较高的场景。两种模式可根据实际需要动态切换,例如默认采用单专家联合生成模式以控制运营成本,当检测到某轮次摘要的重要性评分置信度较低或该轮次涉及技术选型等关键决策时,自动升级为多专家融合裁决模式进行复核。通过这种动态切换机制,本公开在保证评分质量的前提下实现了成本与精度的灵活平衡。

[0038] 在一些实施方式中,所述摘要提取步骤在对话轮次结束后异步执行,包括:

调用大语言模型生成所述摘要文本及对应的所述重要性评分;

调用部署于本地计算环境的Embedding模型计算所述摘要文本的语义向量;

将所述摘要文本、所述重要性评分及所述语义向量关联存储至缓存。

[0039] 请参考图3,当一轮对话完成、用户已收到助手回复后,系统利用后续请求到达前的空闲窗口,在后台静默启动对该轮次的后处理,而无需阻塞用户的实时交互。该异步处理首先调用大语言模型生成该轮次的摘要文本,并同步输出对该摘要重要性的量化评分。与同步处理不同,此过程不占用用户等待时间,即便单轮摘要生成需要数秒,也不会造成前端卡顿。随后,系统调用部署于本地计算环境的Embedding模型计算该摘要的语义向量,使文本转化为可用于相似度比对的高维数值表示。最后,将摘要文本、重要性评分和语义向量作为一组关联要素写入本地缓存,建立以轮次标识符为键、以这些要素为值的结构化存储。这种异步离线预处理的设计,使得当后续新请求到达并触发双阈值压缩流程时,所有历史轮次的摘要、评分和向量均已提前就绪。系统只需直接读取缓存,即可进入相关性分析和综合排序阶段,将原本可能长达数十秒的串行处理开销压缩为毫秒级的缓存查询。由此,上下文压缩的延迟被彻底解耦于用户交互路径之外,整个压缩流程对用户而言近乎无感知,显著提升了AI智能体在长对话场景下的实时响应体验。

[0040] 在一些实施方式中,缓存结果设置有效期,旨在平衡历史摘要的可用性与存储资源的可控性,避免因缓存无限累积导致的存储膨胀与数据失效问题。具体而言,缓存中存储的摘要文本、重要性评分、语义向量及阶段意图等数据,均绑定于特定对话会话标识。当会话处于活跃状态时,缓存持续命中并更新;当会话超过预设时长无新交互时,系统自动判定该缓存过期并予以清理。有效期可根据应用场景动态设定,例如在标准对话场景中设为7天,在长期项目协作场景中适当延长。该机制的技术效果在于:一方面确保活跃会话的历史摘要始终可用,支撑上下文压缩的实时响应;另一方面及时释放失效会话的存储资源,防止冷数据堆积。同时,有效期策略与异步预处理机制协同,使缓存始终维持在热数据状态,避免过期数据被误用于后续相关性分析,从而保障压缩结果的时效准确性。

[0041] 在一些实施方式中,所述大语言模型部署于云端计算环境。系统通过调用云端大语言模型API生成摘要文本及对应的所述重要性评分。将大语言模型部署于云端可利用云端充沛的算力资源,在处理长对话轮次或复杂技术内容时能够生成更高质量的摘要。在其他一些实施方式中,所述大语言模型亦可部署于本地服务器或边缘计算设备。

[0042] 所述步骤S104还包括实体提取子步骤:调用命名实体识别模型或通过预设的规则模板,从摘要文本中提取关键实体。所述命名实体识别模型采用基于BERT的序列标注模型,将摘要文本中的每个Token标注为实体边界和类型,以识别出关键实体的边界和类型。该模型可选用公开的预训练模型,在具体应用场景中亦可针对代码文本和配置文本进行定制化微调,以提升对文件路径、配置参数、端口号等代码领域实体的识别准确率。或者,所述预设的规则模板基于正则表达式进行匹配。例如,通过匹配目录层级和文件扩展名来识别文件路径,通过匹配冒号后的数字序列来识别端口号,通过匹配以/api/开头的路径层级来识别API端点。规则模板提取方式无需额外模型调用,适用于实体格式相对固定的场景,具有更低的运行开销。具体匹配规则可根据应用场景的实体格式特征进行预先配置,不限于特定正则表达式形式。所述关键实体包括但不限于文件路径(如/etc/nginx/nginx.conf或application.yml)、配置参数(如max_connections)、端口号(如8080)、函数名(如getOrderById)、API端点(如/api/v1/orders)、数据库表名(如order_table)等。提取的实体列表与所述摘要文本、重要性评分、语义向量关联存储至缓存。

[0043] 步骤S106中,请参考图4,在每次接收到新的用户交互请求时,或在每个对话轮次结束后,系统可检查当前上下文的长度利用率。所述上下文长度利用率为当前已累积的上下文总Token数与大语言模型所支持的最大上下文长度Token数的比值。当所述利用率超过预设的启动阈值时,触发上下文压缩流程。在逐条填充低重要性摘要的过程中,实时监测压缩结果集的累计Token数;当待纳入摘要纳入后将使所述累计Token数超过预设Token限额时,停止纳入该待纳入摘要。所述预设Token限额为所述最大上下文长度与所述截止阈值的乘积。

[0044] 在一些实施方式中,本公开的压缩机制并非对全部历史对话进行全量压缩,而是采用渐进式、增量式的选择性压缩策略。具体而言,系统仅对超出启动阈值的那部分上下文进行压缩处理,而位于启动阈值边界线之前的早期对话轮次,其原始消息文本被完整保留。当上下文利用率达到启动阈值时,早期轮次所累积的Token总数相对有限,以128K Token上下文窗口为例,30%利用率对应约38K Token,这部分原始内容体量较小,保留它们对上下文空间造成的压力可忽略不计。更为重要的是,这些最早的轮次往往承载着整个会话最根本

的“元设定”,包括用户的第一句话、项目的核心需求、初始环境约束等关键信息。任何摘要化处理都可能造成不可逆的信息衰减,因此,在体量小、价值高的前提下,保留原始形式是最优选择。这部分被保留的原始内容能够作为后续所有压缩摘要的“参照系”,确保核心上下文在整个对话生命周期中永不丢失。对于触发压缩流程后新产生的对话轮次(包括触发时刻所在的当前轮次),系统则按照前述步骤进行摘要生成、相关性分析与择优填充,从而实现历史信息的高密度压缩与动态更新。

[0045] 步骤S108是压缩方法的核心。请参考图5,首先,根据步骤S104中得到的重要性评分,将所有摘要划分为两类:重要性评分大于等于重要性阈值(例如7分)的为高重要性摘要,其余为低重要性摘要。其次,对于高重要性摘要,出于保护核心关键信息的考虑,将其优先纳入最终的压缩结果集中,而不对其进行任何与当前用户需求相关的相关性分析。

[0046] 在一些实施方式中,将所述高重要性摘要优先纳入压缩结果集,包括:

在将所述高重要性摘要优先纳入压缩结果集之前,对所述高重要性摘要进行两两语义相似度检测;当相似度超过预设的去重阈值时,仅保留重要性评分更高的摘要;重要性评分相同时,保留轮次靠后的摘要;

将去重后的高重要性摘要按重要性评分降序纳入所述压缩结果集,使其累计Token数不超过所述大语言模型支持的最大上下文长度、所述截止阈值和预设比例三者的乘积。所述预设比例用于控制高重要性摘要在压缩结果集中的最大占用比例,在一些实施方式中,所述预设比例为10%。

[0047] 上述去重和Token限额用于控制高重要性摘要在压缩结果集中的占用空间。

[0048] 然后,针对当前交互请求,构造一个用于查询的文本。该查询文本可以是当前的用户提问本身,也可以结合对话的阶段意图、长期意图等进行增强。在一些实施方式中,根据当前交互请求构造查询文本,包括:

根据所述当前交互请求以及当前会话的阶段意图和长期意图构造所述查询文本。

[0049] 具体的,参考图6,在一些实施方式中,所述方法还包括阶段意图生成步骤:

基于最近若干轮对话的原始内容和/或摘要文本,以及上一次生成的所述阶段意图和所述长期意图生成当前会话的阶段意图和长期意图。

[0050] 将当前会话的阶段意图和长期意图关联存储至缓存。

[0051] 该步骤可以在后台异步执行。每当对话进行到一个阶段(例如,完成几轮对话后,或每次用户提问后),系统会基于最近几轮的对话原文、更早历史对话的摘要、以及上一次生成的阶段意图和长期意图,异步调用LLM生成两个层次的意图信息:一是当前会话的阶段意图(Stage Intent),用于描述当前对话所处的具体任务阶段;二是当前会话的长期意图(Long Term Intent),用于表示整个对话过程中相对稳定的主线任务,主要服务于历史摘要的召回。两者协同作用,使后续构造的推理查询能够同时兼顾短期任务焦点与长期目标锚定。当新的用户请求到达,触发压缩流程时,在构造查询文本的步骤中,系统会从缓存中读取当前有效的阶段意图和长期意图,然后将最新的用户提问、阶段意图和长期意图这三者拼接组合,形成一个内容更丰富的查询文本。这主要是因为在AI智能体的长程对话中,用户当前输入往往存在语义稀疏性,仅依赖最新交互请求进行相关性匹配,容易导致检索失准。查询文本融合多维度意图信息形成复合检索查询,具体而言,当前交互请求提供即时的显式需求;阶段意图描述当前会话所处任务阶段,如从需求分析转入数据库调优;长期意图

则锚定整个会话的主线目标,如电商订单系统开发。三者拼接后,查询文本从孤立的关键词扩展为包含任务背景与阶段上下文的结构化语义表达。

[0052] 在一些实施方式中,在构造所述查询文本时,若检测到缓存中不存在阶段意图或长期意图(例如首次触发压缩时异步任务尚未完成),则自动降级,仅以当前交互请求的原始内容作为所述查询文本,以确保压缩流程的连续性。

[0053] 在一些实施方式中,为进一步提升意图增强的鲁棒性,本公开还引入了意图优先级处理机制和缓存命中规则机制。所述意图优先级处理机制是指:在生成阶段意图时,系统对输入信息的优先级进行划分,具体地,最近P(例如P=5)轮对话原文具有最高优先级,历史摘要次之,旧意图的优先级最低。所述缓存命中规则机制是指:生成的意图与当前对话上下文的哈希值绑定存储;当新的用户请求到达时,系统首先比较当前上下文的哈希值与缓存中的哈希值,若两者一致,则直接复用缓存的意图;若不一致,但当前触发压缩的轮次索引仍然落在最近Q(例如Q=5)轮范围内,则原有意图可继续复用;若两者均不满足,则判定意图失效,需重新生成。在实际对话场景中,用户有时会发出诸如“继续”、“然后呢”等语义依赖前文的简短提问,这类弱提问本身携带的信息量极少,若单独作为查询文本进行相关性分析,往往难以准确召回历史摘要。为此,本公开还提供一种弱提问降级处理机制。具体的,在构造推理查询文本时,系统首先监测当前请求的用户提问文本:若其长度低于预设的字数阈值(例如5个字符),或命中预设的弱语气词表(例如“继续”、“然后”、“再说”、“那它呢”、“还有吗”等),则判定为弱提问。一旦触发弱提问判定,系统将调整推理查询文本的权重组合,即相对降低用户提问文本的权重,同时调高阶段意图和长期意图的特征权重,使推理查询文本的核心语义更多地依赖于当前会话的稳定阶段意图和长期主线任务,从而弥补用户提问信息量不足的缺陷,确保即使缺乏显性指令,也能精准召回历史相关摘要。由此构造的查询文本输入至后续相关性分析流程,驱动Embedding相似度计算和Rerank精排。相较于单一关键词匹配,复合意图查询使相关性分析从字面相似跃迁为任务语义相似,显著提升了在话题漂移、弱提问、多轮追问等复杂场景下的上下文召回精度。此外,系统还需处理意图读取失败的情形:当阶段意图或长期意图因缓存失效、尚未生成或其他异常原因无法读取时,为确保压缩流程不中断,系统直接降级采用用户提问文本(即便其为弱提问)作为查询文本,以原始用户输入进行相关性分析。该降级处理保证了在意图增强功能不可用的情况下,压缩流程仍能继续执行,提升了系统的鲁棒性。

[0054] 接着,仅针对低重要性摘要,读取其缓存的语义向量,并基于由当前交互请求、阶段意图和长期意图构成的查询文本进行相关性分析,以获取各低重要性摘要与该查询文本之间的相关性得分。

[0055] 针对低重要性摘要的相关性分析采用两阶段递进架构。第一阶段从缓存读取低重要性摘要的语义向量,并基于Embedding模型计算查询文本与各低重要性摘要之间的语义相似度以筛选候选摘要;第二阶段将候选摘要集与查询文本输入重排序模型,获取候选摘要的相关性得分,作为后续综合排序的依据。所述查询文本由当前交互请求以及缓存的阶段意图和长期意图构成。

[0056] 在一些实施方式中,Rerank精排阶段面临低重要性摘要数量超过单次API调用上限的工程约束。此时系统采用分组并发与归一化融合策略,确保大规模候选集的处理效率与评分可比性。具体而言,当粗筛后的候选摘要数量超过单次Rerank API调用上限时,系统

将候选集划分为多个不超过上限的子集,通过多线程或协程技术并发调用各组的Rerank API。由于不同子集独立评分,其得分分布可能存在系统性偏移,直接比较会导致跨组不公平。因此,对各组返回的相关性得分进行Min-Max归一化处理,将原始分数映射至统一量纲后再合并排序。该机制的技术效果在于:分组并发突破了单次调用的数量瓶颈,将线性处理转化为并行处理,显著降低高候选量场景下的端到端延迟;归一化处理消除了不同子集间的评分尺度差异,确保综合得分排序的公平性与准确性。两者协同,使Rerank精排在大规模历史摘要场景下仍能保持高效稳定的处理能力。

[0057] 在一些实施方式中,为了进一步提高压缩结果与当前查询的相关性精度,本公开还引入了相关性阈值过滤机制。具体而言,在通过重排序精排获得各低重要性摘要的相关性得分后,可设置相关性阈值,仅保留相关性得分大于或等于该阈值的摘要进入后续的综合得分排序与填充步骤。该阈值可根据应用场景动态调整:在高精度模式下,阈值设为0.7,只保留高度相关的摘要;在平衡模式下,阈值设为0.5,在相关性与信息量之间取得折中;在宽松模式下,阈值设为0.3,保留更多潜在相关的摘要。若不进行相关性阈值过滤,则所有经过重排序的低重要性摘要均参与后续的综合得分排序与填充。

[0058] 最后,请参考图7,对于低重要性摘要,根据其重要性评分和相关性得分计算综合得分,例如综合得分=重要性评分×相关性得分。所有低重要性摘要按照综合得分由高到低的顺序排序,并逐条纳入压缩结果集,使压缩结果集的累计Token数不超过所述大语言模型支持的最大上下文长度与所述截止阈值的乘积。当综合得分相同时,在历史对话中轮次位置靠后的摘要优先填充。

[0059] 在步骤S108中得到了压缩结果集(包含高重要性摘要和筛选排序后的低重要性摘要)后,步骤S110将其与一些必要的内容进行拼接,组装成最终可供大语言模型处理的目标上下文。

[0060] 在一些实施方式中,所述方法还包括:

最近轮次保护步骤:针对最近N个对话轮次,保留其原始内容,且不参与所述高重要性摘要与低重要性摘要的分类及后续相关性分析;

所述上下文组装步骤包括:将所述最近N个对话轮次的原始内容与所述压缩结果集进行拼接,生成所述目标上下文;

其中,所述最近N个对话轮次为距离当前交互请求最近的N个对话轮次。

[0061] 最近N个对话轮次的原始内容不参与高重要性摘要与低重要性摘要的分类及后续相关性分析;在组装目标上下文时,将其原始消息文本与压缩结果集拼接,以保留近期交互的原始内容。

[0062] 在一些实施方式中,所述方法还包括:

头部轮次保护步骤:针对位于所述启动阈值边界线之前的对话轮次,保留其原始内容,且不参与所述高重要性摘要与低重要性摘要的分类及后续相关性分析;

所述上下文组装步骤包括:将位于所述启动阈值边界线之前的对话轮次的原始内容、所述压缩结果集以及所述最近N个对话轮次的原始内容进行拼接,生成所述目标上下文。

[0063] 在一些实施方式中,所述上下文组装步骤S110包括:

将位于启动压缩流程时对应的上下文边界之前的对话轮次的原始内容、所述压缩

结果集以及最近N个对话轮次的原始内容,按照以下顺序拼接生成所述目标上下文:

系统提示词、所述位于所述上下文边界之前的对话轮次的原始内容、所述压缩结果集、所述最近N个对话轮次的原始内容;

其中,所述最近N个对话轮次为距离当前交互请求最近的N个对话轮次。

[0064] 具体的,所述目标上下文采用如下线性拓扑排列结构:头部区域:配置系统提示词(System Prompt);过渡区域:配置所述启动阈值边界线之前的早期对话轮次的原始消息文本;核心摘要区:依次配置经过去重和排序的所述高重要性摘要,以及按综合得分降序排列的低重要性摘要;尾部区域:完整保留所述预设数量的最近对话轮次的原始上下文。

[0065] 上述线性拓扑排列结构依据信息优先级对上下文各功能区域的物理顺序进行编排。其中,系统提示词包含模型的角色定位、行为约束、输出格式规范等元指令,为整个对话上下文中优先级最高的控制信息,置于头部区域可确保模型在生成每个响应时首先感知并遵循这些全局约束。早期对话轮次的原始消息文本虽然在时序上距离当前最远,但承载着会话初始阶段确立的核心背景,以原始形态置于过渡区域,既避免了摘要化处理可能带来的信息衰减,又不会干扰头部系统提示词的优先级。核心摘要区中,高重要性摘要置于最前端,使其紧邻过渡区域,确保模型在读取早期背景信息后能够立即获取整个会话中最重要的关键决策和核心约束;低重要性摘要紧随其后,按综合得分由高到低排列,使与当前任务最相关的动态信息优先被模型捕获。上述“先全局核心、后动态相关”的排列顺序,与Transformer架构中注意力机制的位置编码特性相符——位于序列前部的信息在自注意力计算中具有更高的可见性和保留概率。尾部区域保留最近对话轮次的原始上下文,其包含与用户当前意图最直接、最完整的交互细节,置于末尾使其最接近模型生成响应时的即时工作记忆区,便于模型快速索引,同时避免摘要化处理可能导致的细节丢失。通过上述头部、过渡、核心、尾部四个区域的线性拓扑排列,本实施方式实现了对不同类型、不同优先级信息在上下文序列中物理位置的差异化配置,使大语言模型在处理压缩后的上下文时,按照“全局指令→早期背景→核心记忆→动态信息→近期细节”的信息处理顺序进行特征提取,从而在有限的Token窗口内获得优化后的生成质量。位于所述上下文边界之前的对话轮次的原始内容与最近N个对话轮次的原始内容存在重叠时,重叠部分仅在最近N个对话轮次的原始内容中保留一次,在拼接上下文边界之前的对话轮次的原始内容时跳过该重叠部分。

[0066] 通过上述步骤的配合,系统可在对话轮次结束后缓存摘要、重要性评分和语义向量,并在压缩触发时基于缓存的阶段意图和长期意图构造查询文本;高重要性摘要优先纳入压缩结果集,低重要性摘要经向量粗筛和重排序精排后参与综合排序。

[0067] 上述处理可用于在有限上下文窗口内对较长对话历史进行压缩,并使高重要性摘要和经综合排序选出的低重要性摘要进入目标上下文。

[0068] 实施例二

本公开实施例通过一个完整的AI辅助编程场景,说明实施例一所述的方法从对话开始到多次压缩的全流程运作。

[0069] 场景设定:用户正在开发一个电商系统,需要对订单模块进行性能调优。模型上下文上限为128K Token,启动阈值30%(约38K Token),截止阈值80%(约102K Token),最近轮次保护N=5,设定摘要阈值7分。

[0070] 第1-10轮(启动期):用户描述项目需求和架构。各已结束对话轮次在后台异步生成摘要、重要性评分和语义向量,并以轮次标识符关联缓存;在摘要缓存完成后,基于最近对话原文和历史摘要异步生成阶段意图和长期意图并缓存。

[0071] 第11轮(首次触发压缩):用户发送新的代码调试请求,上下文利用率超过30%,首次触发压缩流程:

1. 双阈值检查:当前Token数约40K(超过38K启动阈值),启动压缩。

[0072] 2. 摘要分类:遍历缓存,识别出“需要支持MySQL+Redis”(importance=8)和“确定使用MyBatis-Plus作为ORM”(importance=7)等设定摘要(高重要性摘要),其余为普通摘要(低重要性摘要)。

[0073] 3. 设定摘要优先填充:将importance≥7的摘要按重要性评分由高到低优先纳入。本例中纳入的设定摘要占用约4K Token,低于128K×80%×10%=10.2K Token。

[0074] 4. Embedding粗筛:从缓存读取15条低重要性摘要的语义向量,并以当前交互请求“订单查询慢,如何优化MySQL索引”、缓存的阶段意图“订单模块性能调优”和长期意图构成推理查询;对所述低重要性摘要计算语义相似度,阈值0.1,过滤掉“前端页面布局讨论”等7条不相关摘要,8条候选进入Rerank。

[0075] 5. Rerank精排:对8条候选调用云端Rerank,获得精确相关性得分,过滤相关性<0.5的3条,剩余5条。

[0076] 6. 综合得分排序:5条普通摘要按importance×relevance排序后按Token截断填充。

[0077] 7. 上下文组装:将系统提示词、第1-6轮原始对话、设定摘要、普通摘要和第7-11轮原始对话进行拼接。以本例数值计算,各部分分别约为2K Token、10K Token、4K Token、40K Token和24K Token,目标上下文总计约80K Token。

[0078] 第50轮(稳定期):此时对话已进行50轮,上下文在截止阈值附近稳定波动。用户提问“如何做Redis缓存预热”,推理查询结合阶段意图“订单模块性能调优”,优先召回与Redis缓存和MySQL性能相关的历史摘要,而30轮之前关于“用户鉴权模块”的讨论摘要因综合得分低被正常截断。由于核心设定摘要“MySQL+Redis双存储”始终被早期轮次规则保护,模型持续知晓这一架构前提。

[0079] 本公开实施例证明,在128K Token的物理限制下,所述方法通过智能压缩,使得跨越50轮、累计可能超过300K Token的对话历史被有效压缩至约102K Token的窗口内,同时保证核心设定不丢失、当前任务相关信息优先保留。

[0080] 实施例三

本公开实施例提供一种基于重要性与相关性的对话上下文压缩装置1000。

[0081] 所述压缩装置1000可以包括执行上述的基于重要性与相关性的对话上下文压缩方法的流程图中各个或几个步骤的相应模块。因此,可以由相应模块执行上述流程图中的每个步骤或几个步骤,并且所述压缩装置1000可以包括这些模块中的一个或多个模块。模块可以是专门被配置为执行相应步骤的一个或多个硬件模块、或者由被配置为执行相应步骤的处理器来实现、或者存储在可读存储介质内用于由处理器来实现、或者通过某种组合来实现。

[0082] 具体的,如图8所示,所述压缩装置1000包括:

对话轮次切分模块1002,用于对话轮次切分步骤:将历史对话文本按用户消息边界划分为多个对话轮次;

摘要提取模块1004,用于针对每个所述对话轮次,获取对应的摘要文本以及独立于当前交互请求生成的重要性评分,所述重要性评分用于表征该对话轮次所含信息的长期重要性及其在会话全局中的核心程度;

压缩流程触发模块1006,用于当当前上下文的Token数与大语言模型支持的最大上下文长度的比值超过预设的启动阈值时,触发上下文压缩流程;

上下文压缩模块1008,用于根据所述重要性评分,将各摘要划分为高重要性摘要与低重要性摘要;其中,所述高重要性摘要的重要性评分大于等于预设的重要性阈值,所述低重要性摘要的重要性评分小于所述重要性阈值;

将所述高重要性摘要按照重要性评分由高到低的顺序优先纳入所述压缩结果集,且不进行相关性分析;

根据当前交互请求构造查询文本;

针对所述低重要性摘要,基于所述查询文本进行相关性分析,获取各所述低重要性摘要与所述查询文本之间的相关性得分,包括:

粗筛阶段:获取各所述低重要性摘要的语义向量,利用部署于本地计算环境的Embedding模型,计算各所述低重要性摘要与所述查询文本之间的语义相似度,筛选出语义相似度超过预设的筛选阈值的摘要作为候选摘要;

精排阶段:将所述候选摘要集与所述查询文本输入部署于云端计算环境的重排序模型,执行语义交互匹配,获取各所述候选摘要与所述查询文本之间的相关性得分;

根据各所述低重要性摘要的重要性评分及对应的相关性得分,计算综合得分,并按照所述综合得分由高到低的顺序,将所述低重要性摘要逐条纳入所述压缩结果集,使所述压缩结果集的累计Token数不超过所述大语言模型支持的最大上下文长度与预设的截止阈值的乘积;

上下文组装模块1010,用于将所述压缩结果集组装为目标上下文,以供大语言模型处理。

[0083] 本公开实施例还提供一种电子设备,包括:存储器,存储器存储执行指令;以及处理器或其他硬件模块,处理器或其他硬件模块执行存储器存储的执行指令,使得处理器或其他硬件模块执行上述的基于重要性与相关性的对话上下文压缩方法。

[0084] 本公开实施例还提供一种可读存储介质,可读存储介质中存储有执行指令,执行指令被处理器执行时用于实现上述的基于重要性与相关性的对话上下文压缩方法。

[0085] 其中,本公开的基于采用处理器的硬件实现方式实现的所述压缩装置1000所采用的硬件结构可以利用总线架构来实现。总线架构可以包括任何数量的互连总线和桥接器,这取决于硬件的特定应用和总体设计约束。总线1100将包括一个或多个处理器1200、存储器1300和/或硬件模块的各种电路连接到一起。总线1100还可以将诸如外围设备、电压调节器、功率管理电路、外部天线等的各种其他电路1400连接。

[0086] 总线1100可以是工业标准体系结构(ISA,IndustryStandardArchitecture)总线、外部设备互连(PCI,PeripheralComponent)总线或扩展工业标准体系结构(EISA,ExtendedIndustryStandardComponent)总线等。总线1100可以分为地址总线、数据总线、控制总线

等。为便于表示,该图中仅用一条连接线表示,但并不表示仅有一根总线或一种类型的总线。

[0087] 流程图中或在此以其他方式描述的任何过程或方法描述可以被理解为,表示包括一个或更多个用于实现特定逻辑功能或过程的步骤的可执行指令的代码的模块、片段或部分,并且本公开的优选实施方式的范围包括另外的实现,其中可以不按所示出或讨论的顺序,包括根据所涉及的功能按基本同时的方式或按相反的顺序,来执行功能,这应被本公开的实施方式所属技术领域的技术人员所理解。处理器执行上文所描述的各个方法和处理。例如,本公开中的方法实施方式可以被实现为软件程序,其被有形地包含于机器可读介质,例如存储器。在一些实施方式中,软件程序的部分或者全部可以经由存储器和/或通信接口而被载入和/或安装。当软件程序加载到存储器并由处理器执行时,可以执行上文描述的方法中的一个或多个步骤。备选地,在其他实施方式中,处理器可以通过其他任何适当的方式(例如,借助于固件)而被配置为执行上述方法之一。

[0088] 在流程图中表示或在此以其他方式描述的逻辑和/或步骤,可以具体实现在任何可读存储介质中,以供指令执行系统、装置或设备(如基于计算机的系统、包括处理器的系统或其他可以从指令执行系统、装置或设备取指令并执行指令的系统)使用,或结合这些指令执行系统、装置或设备而使用。

[0089] 就本说明书而言,“可读存储介质”可以是任何可以包含、存储、通信、传播或传输程序以供指令执行系统、装置或设备或结合这些指令执行系统、装置或设备而使用的装置。可读存储介质的更具体的示例(非穷尽性列表)包括以下:具有一个或多个布线的电连接部(电子装置),便携式计算机盘盒(磁装置),随机存取存储器(RAM),只读存储器(ROM),可擦除可编辑只读存储器(EPROM或闪速存储器),光纤装置,以及便携式只读存储器(CDROM)。另外,可读存储介质甚至可以是可在其上打印程序的纸或其他合适的介质,因为可以例如通过对纸或其他介质进行光学扫描,接着进行编辑、解译或必要时以其他合适方式进行处理来以电子方式获得程序,然后将其存储在存储器中。

[0090] 应当理解,本公开的各部分可以用硬件、软件或它们的组合来实现。在上述实施方式中,多个步骤或方法可以用存储在存储器中且由合适的指令执行系统执行的软件来实现。例如,如果用硬件来实现,和在另一实施方式中一样,可用本领域公知的下列技术中的任一项或他们的组合来实现:具有用于对数据信号实现逻辑功能的逻辑门电路的离散逻辑电路,具有合适的组合逻辑门电路的专用集成电路,可编程门阵列(PGA),现场可编程门阵列(FPGA)等。

[0091] 本技术领域的普通技术人员可以理解实现上述实施方式的全部或部分步骤是可以通过程序来指令相关的硬件完成,程序可以存储于一种可读存储介质中,该程序在执行时,包括方法实施方式的步骤之一或其组合。

[0092] 此外,在本公开各个实施方式中的各功能单元可以集成在一个处理模块中,也可以是各个单元单独物理存在,也可以两个或两个以上单元集成在一个模块中。上述集成的模块既可以采用硬件的形式实现,也可以采用软件功能模块的形式实现。集成的模块如果以软件功能模块的形式实现并作为独立的产品销售或使用时,也可以存储在一个可读存储介质中。存储介质可以是只读存储器,磁盘或光盘等。

[0093] 本领域的技术人员应当理解,上述实施方式仅仅是为了清楚地说明本公开,而并

非是对本公开的范围进行限定。对于所属领域的技术人员而言,在上述公开的基础上还可以做出其它变化或变型,并且这些变化或变型仍位于本公开的范围内。

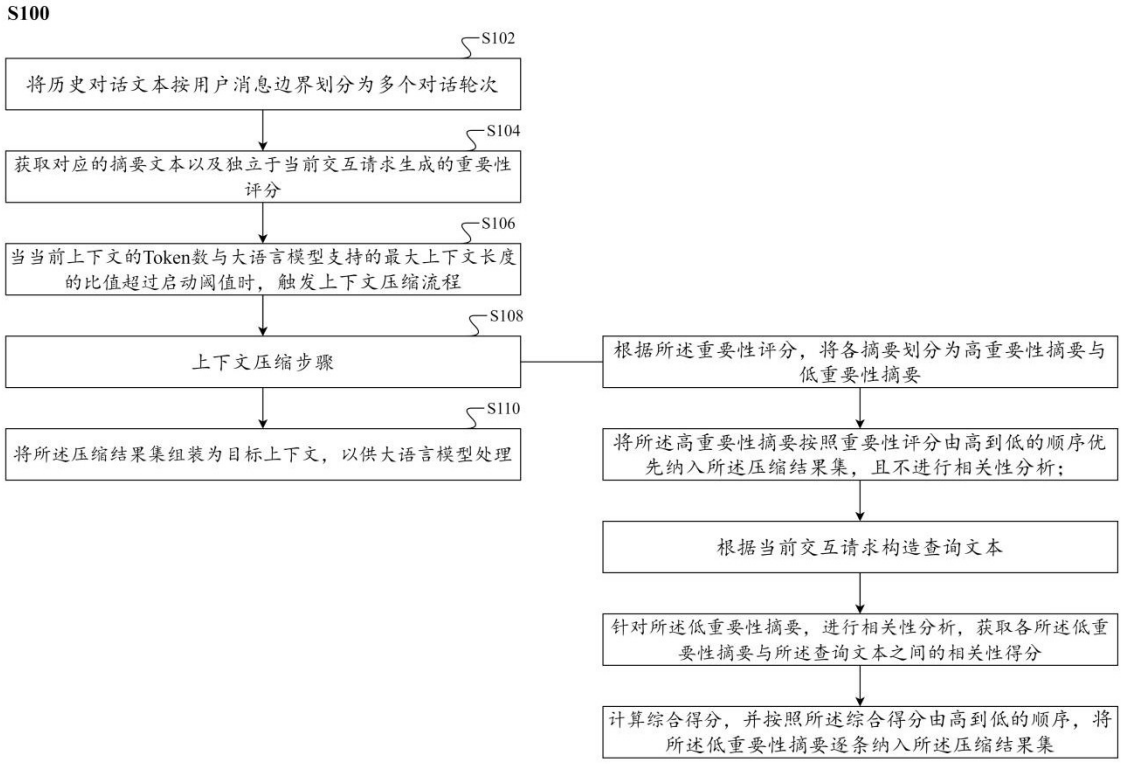

S100
S102
将历史对话文本按用户消息边界划分为多个对话轮次
S104
获取对应的摘要文本以及独立于当前交互请求生成的重要性评分
S106
当当前上下文的Token数与大语言模型支持的最大上下文长度的比值超过启动阈值时，触发上下文压缩流程
S108
上下文压缩步骤
S110
将所述压缩结果集组装为目标上下文，以供大语言模型处理
根据所述重要性评分，将各摘要划分为高重要性摘要与低重要性摘要
将所述高重要性摘要按照重要性评分由高到低的顺序优先纳入所述压缩结果集，且不进行相关性分析；
根据当前交互请求构造查询文本
针对所述低重要性摘要，进行相关性分析，获取各所述低重要性摘要与所述查询文本之间的相关性得分
计算综合得分，并按照所述综合得分由高到低的顺序，将所述低重要性摘要逐条纳入所述压缩结果集

图1

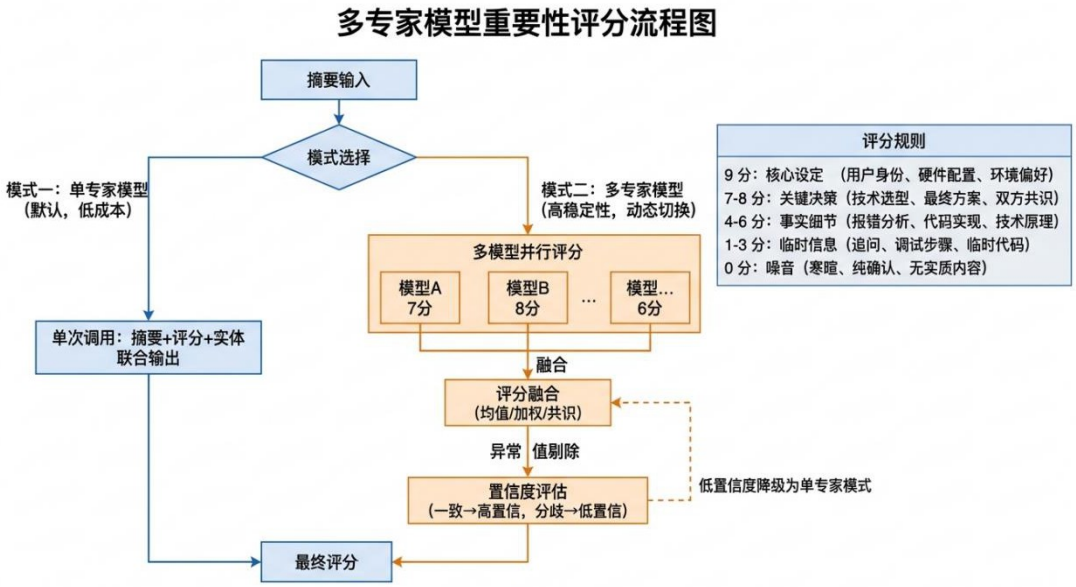

多专家模型重要性评分流程图
摘要输入
模式选择
模式一：单专家模型
（默认，低成本）
模式二：多专家模型
（高稳定性，动态切换）
单次调用：摘要+评分+实体联合输出
多模型并行评分
模型A
7分
模型B
8分
...
模型...
6分
融合
评分融合
（均值/加权/共识）
异常 值剔除
置信度评估
（一致→高置信，分歧→低置信）
低置信度降级为单专家模式
最终评分
评分规则
9 分：核心设定 （用户身份、硬件配置、环境偏好）
7-8 分：关键决策（技术选型、最终方案、双方共识）
4-6 分：事实细节（报错分析、代码实现、技术原理）
1-3 分：临时信息（追问、调试步骤、临时代码）
0 分：噪音（寒暄、纯确认、无实质内容）

图2

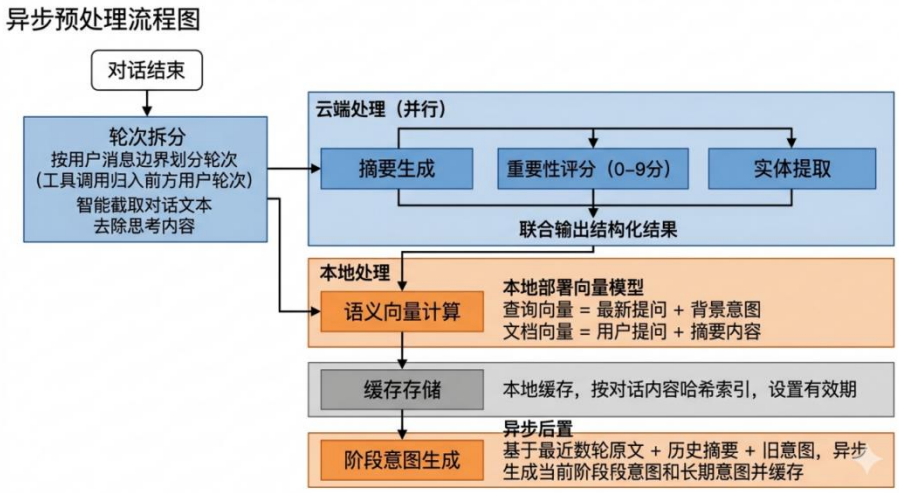

异步预处理流程图
对话结束
轮次拆分
按用户消息边界划分轮次
(工具调用归入前方用户轮次)
智能截取对话文本
去除思考内容
云端处理（并行）
摘要生成
重要性评分（0-9分）
实体提取
联合输出结构化结果
本地处理
语义向量计算
本地部署向量模型
查询向量 = 最新提问 + 背景意图
文档向量 = 用户提问 + 摘要内容
缓存存储
本地缓存，按对话内容哈希索引，设置有效期
阶段意图生成
异步后置
基于最近数轮原文 + 历史摘要 + 旧意图，异步
生成当前阶段段意图和长期意图并缓存

图3

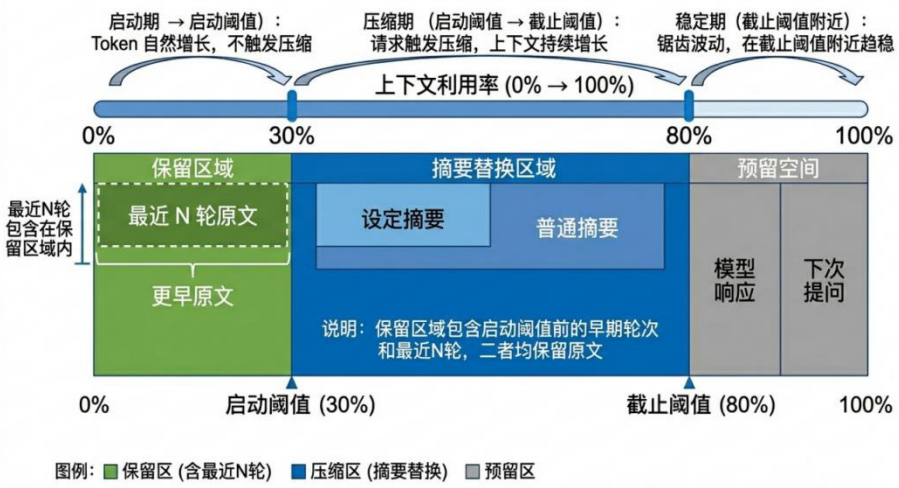

启动期 → 启动阈值）：
Token 自然增长，不触发压缩
压缩期（启动阈值 → 截止阈值）：
请求触发压缩，上下文持续增长
稳定期（截止阈值附近）：
锯齿波动，在截止阈值附近趋稳
上下文利用率 (0% → 100%)
0%
30%
80%
100%
保留区域
摘要替换区域
预留空间
最近N轮
包含在保
留区域内
最近 N 轮原文
更早原文
设定摘要
普通摘要
模型
响应
下次
提问
说明：保留区域包含启动阈值前的早期轮次
和最近N轮，二者均保留原文
0%
启动阈值 (30%)
截止阈值 (80%)
100%
图例：保留区 (含最近N轮) 压缩区 (摘要替换) 预留区

图4

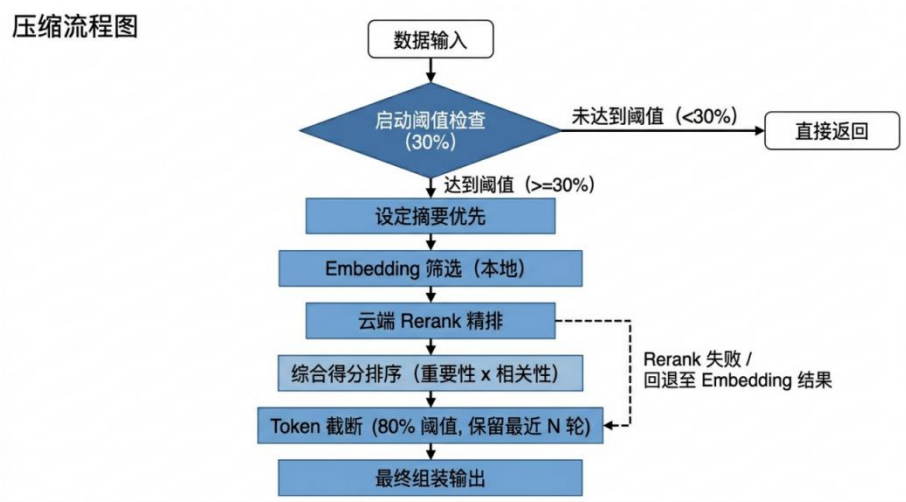

压缩流程图
数据输入
启动阈值检查 (30%)
未达到阈值（<30%）
直接返回
达到阈值（>=30%）
设定摘要优先
Embedding 筛选（本地）
云端 Rerank 精排
综合得分排序（重要性 x 相关性）
Token 截断（80% 阈值，保留最近 N 轮）
最终组装输出
Rerank 失败 / 回退至 Embedding 结果

图5

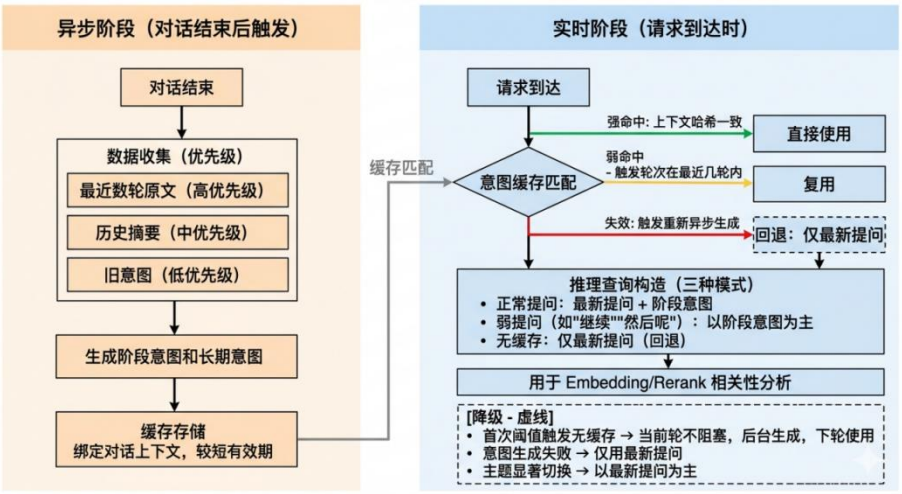

异步阶段（对话结束后触发）
对话结束
数据收集（优先级）
最近数轮原文（高优先级）
历史摘要（中优先级）
旧意图（低优先级）
生成阶段意图和长期意图
缓存存储
绑定对话上下文，较短有效期
缓存匹配
实时阶段（请求到达时）
请求到达
意图缓存匹配
强命中：上下文哈希一致
直接使用
弱命中
- 触发轮次在最近几轮内
复用
失效：触发重新异步生成
回退：仅最新提问
推理查询构造（三种模式）
• 正常提问：最新提问 + 阶段意图
• 弱提问（如"继续""然后呢"）：以阶段意图为主
• 无缓存：仅最新提问（回退）
用于 Embedding/Rerank 相关性分析
[降级 - 虚线]
• 首次阈值触发无缓存 → 当前轮不阻塞，后台生成，下轮使用
• 意图生成失败 → 仅用最新提问
• 主题显著切换 → 以最新提问为主

图6

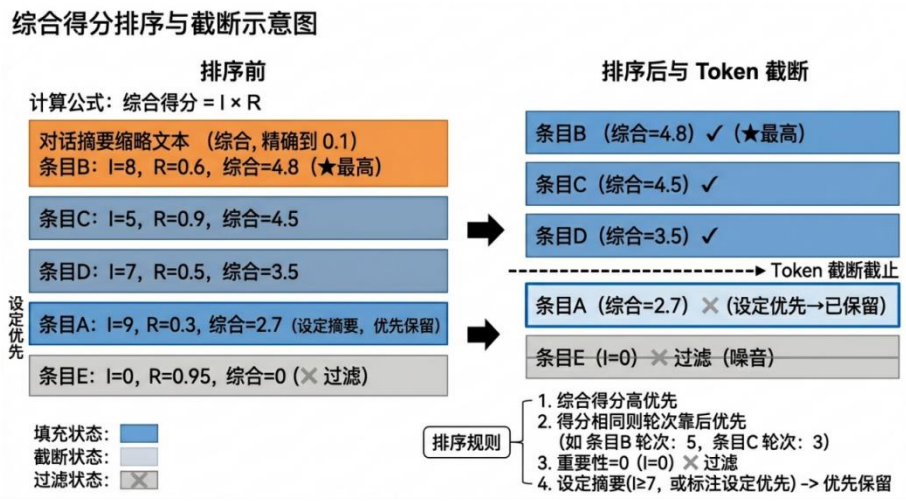

综合得分排序与截断示意图
排序前
计算公式：综合得分 = I × R
对话摘要缩略文本 （综合，精确到 0.1）
条目B：I=8，R=0.6，综合=4.8（★最高）
条目C：I=5，R=0.9，综合=4.5
条目D：I=7，R=0.5，综合=3.5
设定优先
条目A：I=9，R=0.3，综合=2.7（设定摘要，优先保留）
条目E：I=0，R=0.95，综合=0（✕过滤）
排序后与 Token 截断
条目B （综合=4.8）✓（★最高）
条目C（综合=4.5）✓
条目D（综合=3.5）✓
Token 截断截止
条目A（综合=2.7）✕（设定优先→已保留）
条目E（I=0）✕过滤（噪音）
填充状态：
截断状态：
过滤状态：
排序规则
1. 综合得分高优先
2. 得分相同则轮次靠后优先
（如 条目B 轮次：5，条目C 轮次：3）
3. 重要性=0（I=0）✕过滤
4. 设定摘要(I≥7，或标注设定优先) -> 优先保留

图7

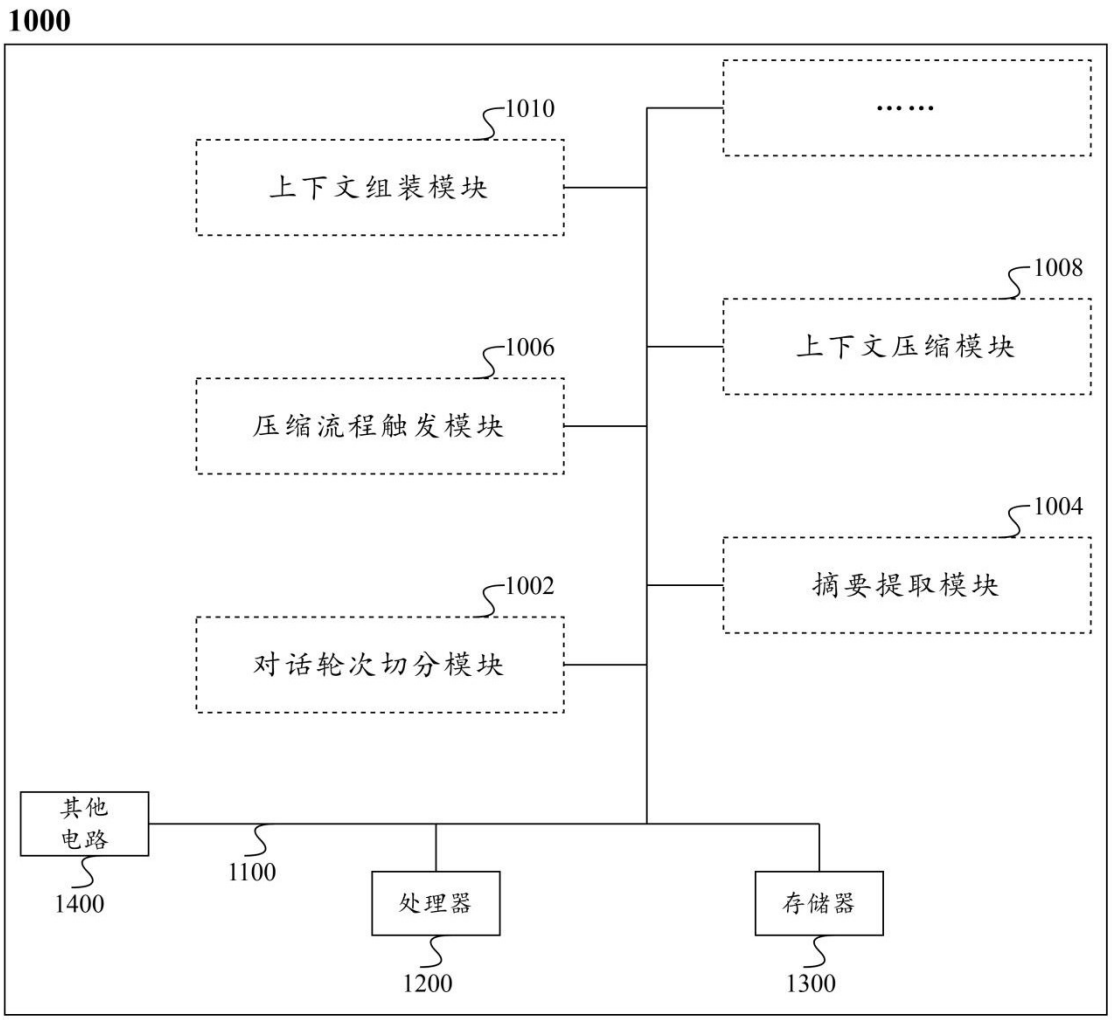

1000
1010
上下文组装模块
……
1008
上下文压缩模块
1006
压缩流程触发模块
1004
摘要提取模块
1002
对话轮次切分模块
其他电路
1400
1100
处理器
1200
存储器
1300

图8