(19)国家知识产权局

(12)发明专利申请

(10)申请公布号 CN 121031616 A
(43)申请公布日 2025.11.28

(21)申请号 202510958687.8

(22)申请日 2025.07.11

(71)申请人 黑龙江省网络空间研究中心(黑龙江省网络安全应急中心、黑龙江省国防科学技术研究院)
地址 150090 黑龙江省哈尔滨市南岗区华山路12号
申请人 中国科学院信息工程研究所
哈尔滨工业大学

(72)发明人 杨霄璇 白瑞 孟鸽 马灿 罗桐 余翔湛 张宏莉

(74)专利代理机构 北京君尚知识产权代理有限公司 11200
专利代理师 邱晓锋

(51)Int.Cl.
G06F 40/35(2020.01)
G06F 18/24(2023.01)
G06N 3/045(2023.01)
G06N 3/08(2023.01)

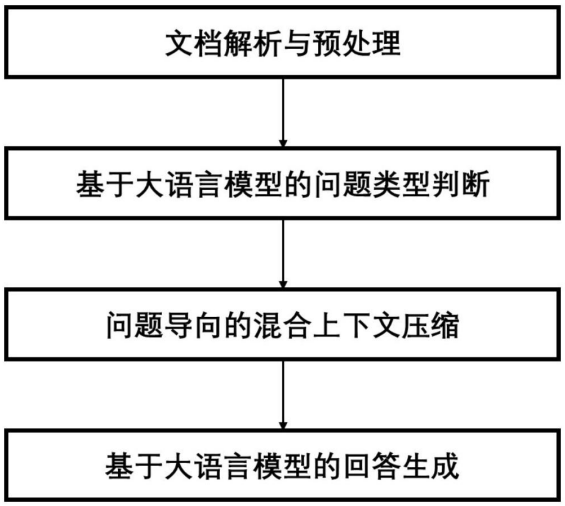
权利要求书2页 说明书7页 附图1页

(54)发明名称

基于混合上下文压缩技术的大语言模型长文本问答方法与系统

(57)摘要

本发明属于文本问答领域,涉及一种基于混合上下文压缩技术的大语言模型长文本问答方法与系统。该方法包括:进行文档解析与预处理,将非结构化的原始文本转换为规范化的文本段落集合;基于大语言模型将长文本问答场景的问题进行分类;根据问题类型和预处理后的文本,自适应选择最适合的上下文压缩方法对长文本进行压缩,得到压缩后的上下文;利用压缩后的上下文,基于大语言模型生成问题的答案。本发明综合了两种上下文压缩技术的优势,有效解决了大语言模型处理长文本的上下文窗口限制问题,在降低压缩技术的计算资源消耗和处理延迟的同时,保持了高质量的问答性能,缓解了单一压缩方法在不同类型问题上的局限性。



CN 121031616 A

1.一种基于混合上下文压缩技术的大语言模型长文本问答方法,其特征在于,包括以下步骤:

进行文档解析与预处理,将非结构化的原始文本转换为规范化的文本段落集合;

基于大语言模型将长文本问答场景的问题进行分类;

根据问题类型和预处理后的文本,自适应选择最适合的上下文压缩方法对长文本进行压缩,得到压缩后的上下文;

利用压缩后的上下文,基于大语言模型生成问题的答案。

2.根据权利要求1所述的方法,其特征在于,所述进行文档解析与预处理支持多种文档格式的输入处理,包括纯文本、PDF和Word格式,预处理包括去除多余的空白字符、分割段落、识别章节结构。

3.根据权利要求1所述的方法,其特征在于,所述基于大语言模型将长文本问答场景的问题进行分类,包括:当接收用户输入的问题时,通过大语言模型将问题分类为事实性问答问题和非事实性问答问题两种类型;事实性问答问题是指需要从文本中检索、提取或综合客观事实信息,通常需要建立完整推理链条的问题;非事实性问答问题是注重思想表达、观点阐述或内容创造的问题。

4.根据权利要求1所述的方法,其特征在于,所述根据问题类型和预处理后的文本,自适应选择最适合的上下文压缩方法,得到压缩后的上下文,包括:

对于事实性问答问题,采用基于语义关系图的上下文压缩方法捕捉长文本中的语义关联和多跳关系;

对于非事实性问答问题,采用基于问题相关语句筛选的上下文压缩方法高效提取相关信息;

如果基于语义关系图的上下文压缩方法未能形成完整的逻辑链条或图搜索跳数超过预设阈值,则自动切换至基于问题相关语句筛选的上下文压缩方法,并将两种方法的结果合并,以最大化保留关键信息。

5.根据权利要求4所述的方法,其特征在于,所述基于语义关系图的上下文压缩方法,包括:

对长文本按语义进行分块,然后利用语义块信息构建图结构,每个节点表示一个关键元素及其相关原子事实,节点间的边表示语义关联;

基于用户问题进行智能规划检索,采用链式思维在图中搜索与问题相关的信息路径,将检索到的关键信息汇总为压缩后的上下文。

6.根据权利要求4所述的方法,其特征在于,所述基于问题相关语句筛选的上下文压缩方法,包括:

利用轻量级transformer编码器对文本中的每个句子与问题的相关性进行评分,将句子分类为直接相关、间接相关和不相关三类;

保留直接相关和间接相关的句子,并按照“先直接相关,后间接相关”的顺序重组这些句子,形成压缩后的上下文。

7.根据权利要求1所述的方法,其特征在于,所述利用压缩后的上下文,基于大语言模型生成问题的答案,包括:

将压缩后的上下文与用户问题整合为标准格式的提示词,通过统一的API接口传入选

定的大语言模型;

基于大语言模型的推理结果,将压缩后的文本与最终答案呈现给用户。

8.一种基于混合上下文压缩技术的大语言模型长文本问答系统,其特征在于,包括:

文档解析与预处理模块,用于进行文档解析与预处理,将非结构化的原始文本转换为规范化的文本段落集合;

基于大语言模型的问题类型判断模块,用于基于大语言模型将长文本问答场景的问题进行分类;

问题导向的混合上下文压缩模块,用于根据问题类型和预处理后的文本,自适应选择最适合的上下文压缩方法对长文本进行压缩,得到压缩后的上下文;

基于大语言模型的回答生成模块,用于利用压缩后的上下文,基于大语言模型生成问题的答案。

9.一种计算机设备,其特征在于,包括存储器和处理器,所述存储器存储计算机程序,所述计算机程序被配置为由所述处理器执行,所述计算机程序包括用于执行权利要求1~7中任一项所述方法的指令。

10.一种计算机可读存储介质,其特征在于,所述计算机可读存储介质存储计算机程序,所述计算机程序被计算机执行时,实现权利要求1~7中任一项所述的方法。

基于混合上下文压缩技术的大语言模型长文本问答方法与系统

技术领域

[0001] 本发明属于文本问答领域,具体涉及一种集成两种上下文压缩技术解决大语言模型长文本问答的技术,旨在改善单一大模型在超长文本处理时的上下文窗口大小局限性,增强了模型在涉及跨段落、多跳推理等特性的长文本问答上的表现。

背景技术

[0002] 本发明旨在通过结合两种上下文压缩技术解决大语言模型进行长文本问答时的上下文窗口限制与性能表现问题,与本发明最接近的实现方案包括检索增强生成系统LightRAG和单一上下文压缩策略系统LongLLMLingua,下面是两种方案的详细的介绍。

[0003] LightRAG提出了一种集成图谱构建与双层检索的检索增强生成系统。该系统首先利用预训练的大型语言模型对原始文本进行分块处理,并自动提取出其中的实体及其关联关系,进而构建出具有全局语义联系的知识图谱,同时生成便于高效检索的键值对索引。在用户提出问题后,系统采用关键词抽取技术,将查询拆分为针对具体细节和整体概念的两类检索请求:一方面通过低层次检索定位文本中具体的实体信息和关系数据;另一方面通过高层次检索捕捉全局主题和抽象语境。随后,系统将这些多维度的检索结果进行整合,并由预训练的大型语言模型对上下文进行深度理解,最终生成符合用户意图的回答。为了适应动态变化的信息环境,LightRAG还设计了增量更新机制,使得新数据能在不重建整个索引图谱的情况下快速融入系统。各个模块均经过专门的数据预处理与定向微调:图谱构建模块通过大量模板化的实体关系标注数据进行训练,而问答生成模块则利用精心挑选的高质量问答样本不断优化生成效果。LightRAG的整体流程如图1所示。

[0004] LongLLMLingua提出了一种针对长文本场景下大语言模型性能下降、计算成本高昂及位置信息偏差问题的上下文压缩系统。该系统主要由两个模块组成:一是问题感知型上下文压缩模块,二是信息重排序与子序列恢复模块。上下文压缩模块首先基于预训练的小型语言模型,通过问题感知的粗到细压缩策略,对原始长提示进行初步筛选和压缩。在粗粒度阶段,系统依据问题相关性和文档中关键信息的分布,动态确定压缩比例,并利用对比困惑度评估每个文档的重要性;随后在细粒度阶段,采用迭代的词元级压缩方法,动态分配压缩预算,确保在大幅减少词元数量的同时,最大程度保留对问题至关重要的信息。接下来,信息重排序与子序列恢复模块将压缩后的文档按照关键信息密度进行重排序,缓解因提示过长引起的位置信息偏差,并通过子序列恢复策略确保大语言模型在生成回答时能够准确还原原始提示中的关键细节。LongLLMLingua的整体流程如图2所示。这种方法在训练过程中,通过对粗粒度与细粒度压缩策略分别进行指令调优和数据蒸馏预训练,实现了在多种长文本应用场景下既能显著提升推理精度,又能大幅降低计算成本和响应延时的目标。

[0005] 现有技术采用的解决大模型长文本问答方法包含了基于检索增强生成的方法和基于上下文压缩的方法。检索增强生成系统通常依赖于简单的文本分块和向量匹配,通过

检索到长文本中与问题的相关信息实现长文本的精简,以完成大语言模型长文本问答。但是这种方法难以充分捕捉文本中各实体间的复杂语义关联,导致在多步推理任务中信息获取不全面,推理链条易出现断裂。上下文压缩系统通常采用基于信息熵或摘要生成的策略,能够直接缩短文本长度,从而将长文本问答转变为常规的文本问答任务。但上下文压缩容易造成关键信息丢失或引入不必要的冗余,难以满足长文本问答的需求。

发明内容

[0006] 针对现有技术存在的问题,本发明提出了一种基于混合上下文压缩技术的大语言模型长文本问答方法。本发明通过问题导向的混合上下文压缩策略,结合基于语义关系图和基于问题相关语句筛选两种不同的压缩技术,能够根据问题类型自动选择最适合的压缩方法。对于事实性问答问题,采用基于语义关系图的方法捕捉长文本中的语义关联和多跳关系;对于非事实性问答问题,则采用基于问题相关语句筛选的方法高效提取相关信息。在特殊情况下,还能组合两种方法的结果。本发明提出的方法综合了两种上下文压缩技术的优势,有效解决了大语言模型处理长文本的上下文窗口限制问题,在降低压缩技术的计算资源消耗和处理延迟的同时,保持了高质量的问答性能,缓解了单一压缩方法在不同类型问题上的局限性。

[0007] 本发明采用的技术方案如下:

[0008] 一种基于混合上下文压缩技术的大语言模型长文本问答方法,包括以下步骤:

[0009] 进行文档解析与预处理,将非结构化的原始文本转换为规范化的文本段落集合;

[0010] 基于大语言模型将长文本问答场景的问题进行分类;

[0011] 根据问题类型和预处理后的文本,自适应选择最适合的上下文压缩方法对长文本进行压缩,得到压缩后的上下文;

[0012] 利用压缩后的上下文,基于大语言模型生成问题的答案。

[0013] 进一步地,所述进行文档解析与预处理支持多种文档格式的输入处理,包括纯文本、PDF和Word格式,预处理包括去除多余的空白字符、分割段落、识别章节结构。

[0014] 进一步地,所述基于大语言模型将长文本问答场景的问题进行分类,包括:当接收用户输入的问题时,通过大语言模型将问题分类为事实性问答问题和非事实性问答问题两种类型;事实性问答问题是指需要从文本中检索、提取或综合客观事实信息,通常需要建立完整推理链条的问题;非事实性问答问题是注重思想表达、观点阐述或内容创造的问题。

[0015] 进一步地,所述根据问题类型和预处理后的文本,自适应选择最适合的上下文压缩方法,得到压缩后的上下文,包括:

[0016] 对于事实性问答问题,采用基于语义关系图的上下文压缩方法捕捉长文本中的语义关联和多跳关系;

[0017] 对于非事实性问答问题,采用基于问题相关语句筛选的上下文压缩方法高效提取相关信息;

[0018] 如果基于语义关系图的上下文压缩方法未能形成完整的逻辑链条或图搜索跳数超过预设阈值,则自动切换至基于问题相关语句筛选的上下文压缩方法,并将两种方法的结果合并,以最大化保留关键信息。

[0019] 进一步地,所述基于语义关系图的上下文压缩方法,包括:

[0020] 对长文本按语义进行分块,然后利用语义块信息构建图结构,每个节点表示一个关键元素及其相关原子事实,节点间的边表示语义关联;

[0021] 基于用户问题进行智能规划检索,采用链式思维在图中搜索与问题相关的信息路径,将检索到的关键信息汇总为压缩后的上下文。

[0022] 进一步地,所述基于问题相关语句筛选的上下文压缩方法,包括:

[0023] 利用轻量级transformer编码器对文本中的每个句子与问题的相关性进行评分,将句子分类为直接相关、间接相关和不相关三类;

[0024] 保留直接相关和间接相关的句子,并按照“先直接相关,后间接相关”的顺序重组这些句子,形成压缩后的上下文。

[0025] 进一步地,所述利用压缩后的上下文,基于大语言模型生成问题的答案,包括:

[0026] 将压缩后的上下文与用户问题整合为标准格式的提示词,通过统一的API接口传入选定的大语言模型;

[0027] 基于大语言模型的推理结果,将压缩后的文本与最终答案呈现给用户。

[0028] 一种基于混合上下文压缩技术的大语言模型长文本问答系统,其包括:

[0029] 文档解析与预处理模块,用于进行文档解析与预处理,将非结构化的原始文本转换为规范化的文本段落集合;

[0030] 基于大语言模型的问题类型判断模块,用于基于大语言模型将长文本问答场景的问题进行分类;

[0031] 问题导向的混合上下文压缩模块,用于根据问题类型和预处理后的文本,自适应选择最适合的上下文压缩方法对长文本进行压缩,得到压缩后的上下文;

[0032] 基于大语言模型的回答生成模块,用于利用压缩后的上下文,基于大语言模型生成问题的答案。

[0033] 本发明的有益效果如下:

[0034] 与现有技术相比,本发明的一个优点是不需要额外的基座模型预训练或微调,仅通过轻量级的提示词工程和上下文压缩模型训练,就能显著提升大语言模型处理长文本的能力。这使得系统易于部署和维护,且可以灵活兼容各种基座模型。此外,本发明的混合压缩架构能够智能选择最适合特定问题类型的压缩策略,相比单一压缩方法具有更强的通用性和适应性。在另一方面,本发明提出的混合上下文压缩技术的大语言模型长文本问答方法在常规长文本问答数据集LongBench上实现了更有益的效果。

附图说明

[0035] 图1是现有的检索增强生成系统LightRAG的工作流程图。

[0036] 图2是现有的单一上下文压缩策略系统LongLLMLingua的工作流程图。

[0037] 图3是本发明的基于混合上下文压缩技术的大语言模型长文本问答方法的工作流程图。

具体实施方式

[0038] 为使本发明的上述目的、特征和优点能够更加明显易懂,下面通过具体实施例和附图,对本发明做进一步详细说明。

[0039] 本发明的技术方案如图3所示,主要包括文档解析与预处理、基于大语言模型的问题类型判断、问题导向的混合上下文压缩、基于大语言模型的回答生成四个核心步骤。

[0040] 本发明旨在解决大语言模型处理超长文本时的上下文窗口限制与性能表现问题,通过自适应选择最适合的上下文压缩策略,将长文本压缩为更精简的提示词,同时保留关键信息,使大语言模型能够基于压缩后的上下文高效地回答问题。本发明选择性地采用两种不同的上下文压缩技术:基于语义关系图的上下文压缩方法和基于问题相关语句筛选的上下文压缩方法,并通过问题类型分析来决定使用哪种技术,最后根据上下文压缩得到的结果进行长文本问答的结果生成。在具体实现技术中,语义关系图构建与智能规划探索采用现有的大语言模型实现。如下是具体的技术方案。

[0041] 步骤1、文档解析与预处理。

[0042] 本步骤处理的文本是指用户提供的、需要进行问答分析的文本。该文本通常来源于用户上传的文档文件或直接输入的长文本内容,文本长度通常超过大语言模型的上下文窗口限制。这些文本与用户问题构成问答对,即用户希望基于这些长文本内容来回答特定的问题。例如,用户可能上传一份技术报告文档,然后询问“该报告中提到的主要技术创新点有哪些?”,此时该技术报告就是需要处理的“文本”。本发明基于现有的文档解析技术提取文本内容,支持多种文档格式的输入处理,包括纯文本、PDF和Word等格式。对于PDF文档,系统采用pdfplumber进行解析;对于Word文档,系统使用python-docx进行内容提取;对于纯文本文件,系统直接进行读取。随后,系统对提取的文本内容进行预处理,包括去除多余的空白字符、分割段落、识别章节结构等,将非结构化的原始文本转换为规范化的文本段落集合,为后续的上下文压缩环节做准备。

[0043] 步骤2、基于大语言模型的问题类型判断。

[0044] 本发明基于大语言模型将不同长文本问答场景的问题进行分类。当接收用户输入的问题时,通过大语言模型将问题分为事实性问答问题与非事实性问答问题。事实性问答问题是指需要从文本中检索、提取或综合客观事实信息的查询,这类问题通常具有明确的、基于事实的答案,且答案可以通过对文本进行分析和推理得出;非事实性问答问题则更注重思想表达、观点阐述或内容创造。该分类器是由提示词引导大模型进行问题分类来实现的。在该步骤中,可选择的大语言模型可以是任意规模的大语言模型。

[0045] 步骤3、问题导向的混合上下文压缩技术。

[0046] 本发明中的混合上下文压缩技术中的“压缩”是指对步骤1中预处理后的标准化文本段落集合进行信息提取和精简,将长文本转换为保留关键信息的短文本,以适应大语言模型的上下文窗口限制。

[0047] 本发明根据步骤2中大语言模型对问题类型的分类结果,自适应选择最适合的上下文压缩策略:

[0048] (1)当问题为事实性问答时,系统调用基于语义关系图的上下文压缩方法。该方法首先对长文本按语义进行分块,然后利用语义块信息构建图结构,每个节点表示一个关键元素及其相关原子事实,节点间的边表示语义关联。随后,系统基于用户问题进行智能规划检索,采用链式思维在图中搜索与问题相关的信息路径,最终将检索到的关键信息汇总为压缩上下文。

[0049] (2)当问题为非事实性问答时,系统调用基于问题相关语句筛选的上下文压缩方

法。该方法利用轻量级transformer编码器对文本中的每个句子与问题的相关性进行评分，将句子分类为直接相关、间接相关和不相关三类。系统保留直接相关和间接相关的句子，并按照优化后的顺序(先直接相关，后间接相关)重组这些句子，形成压缩后的上下文。

[0050] (3)在特殊情况下，如果基于语义关系图的方法未能形成完整的逻辑链条(图搜索跳数超过预设阈值)，系统会自动切换至基于问题相关语句筛选的方法，并将两种方法的结果合并，以最大化保留关键信息。最后得到的文本即经过上下文压缩的较短参考文本。该步骤中使用的大语言模型可以是任意的预训练大语言模型。

[0051] 步骤4、基于大语言模型的回答生成。

[0052] 本发明基于大语言模型对经过上下文压缩处理后的文本进行回答生成。在生成阶段，系统将压缩后的上下文与用户问题整合为标准格式的提示词，通过统一的API接口传入选定的大语言模型。基于大语言模型的推理结果，系统将压缩后的文本与最终答案呈现给用户。系统也支持使用原始的长文本直接传入大语言模型进行问答。在该步骤中，可选择的大语言模型可以是任意规模的大语言模型。

[0053] 以下通过一个企业年度报告问答的实例来说明本发明的技术方案。

[0054] 假设用户上传了一份15000字的某科技公司年度报告，并提出问题：“该公司在人工智能领域的投资策略和技术布局是什么?”

[0055] 步骤1：文档解析与预处理

[0056] 系统使用PDF解析技术提取年度报告的文本内容，去除页眉页脚、图表标题等冗余信息，将文档分割为87个标准化段落，包括公司概况、业务发展、财务状况、技术投资等章节。

[0057] 步骤2：基于大语言模型的问题类型判断

[0058] 系统将用户问题“该公司在人工智能领域的投资策略和技术布局是什么?”输入大语言模型进行分析，判断结果为事实性问答问题，因为该问题需要从文档中提取客观的投资数据、技术信息等事实性内容。

[0059] 步骤3：问题导向的混合上下文压缩技术

[0060] 由于问题被判断为事实性问答，系统调用基于语义关系图的上下文压缩方法：

[0061] 将87个段落按语义分为包含“技术投资”、“研发布局”、“合作伙伴”、“未来规划”等信息共16个语义块；从语义块中提取关键元素与相应的原子事实，构建语义关系图，其中包含“人工智能投资”、“研发预算”、“技术团队”、“产品线”等相关节点；基于用户问题进行图搜索，识别出包含“AI投资金额”、“技术研发方向”、“合作伙伴关系”等多个相关节点；将相关信息汇总，形成约800字的压缩上下文。

[0062] 步骤4：基于大语言模型的回答生成

[0063] 系统将压缩后的800字上下文与用户问题组合成提示词，输入大语言模型生成最终答案：“根据年度报告，该公司在人工智能领域投资约2.3亿元，主要布局包括：1)自然语言处理技术研发；2)计算机视觉应用；3)与三所重点大学建立AI实验室...”

[0064] 通过本发明的技术方案，原本15000字的长文档被压缩为800字的关键信息，在保留核心内容的同时，使大语言模型能够高效准确地回答用户问题。

[0065] 本发明的关键点和创新点在于提出了一种问题导向的混合上下文压缩方法，该方法包含了基于语义关系图的上下文压缩和基于问题相关语句筛选的上下文压缩两种方法，

并根据问题类型自适应选择最适合的压缩策略。混合上下文压缩策略创新性地结合了基于语义关系图和基于问题相关语句筛选两种互补的上下文压缩方法。前者擅长处理需要多跳推理的事实性问题,后者则在通用问答场景中具有更高的效率和通用性。通过智能选择和组合这两种方法,系统能够适应更广泛的问题类型。自适应压缩方法选择能够自动选择最适合当前问题的压缩方法,无需用户手动设置参数或选择策略,大幅提升了系统的易用性和智能化水平。

[0066] 与现有技术相比,本发明的一个优点是不需要额外的基座模型预训练或微调,仅通过轻量级的提示词工程和上下文压缩模型训练,就能显著提升大语言模型处理长文本的能力。这使得系统易于部署和维护,且可以灵活兼容各种基座模型。此外,本发明的混合压缩架构能够智能选择最适合特定问题类型的压缩策略,相比单一压缩方法具有更强的通用性和适应性。在另一方面,本发明提出的混合上下文压缩技术的大语言模型长文本问答方法在常规长文本问答数据集LongBench上实现了更有益的效果。为了充分分析本发明的有益效果,在表1进行不同方法的性能对比。

[0067] 表1.不同方法的效果在LongBench上的性能对比

[0068]

方法	LongBench						
	SingleDoc	MultiDoc	Summ	FewShot	Synth.	Code	AVG
LightRAG(GPT-4)	56.8	49.7	21.4	55.3	42.6	50.2	46.0
LongLLMLingua (LLaMA-2-7B-Chat+GPT-4)	40.7	46.2	27.2	70.6	53.0	55.2	48.8
Ours(GPT-4)	58.7	52.9	23.5	63.7	50.8	53.7	50.6

[0069] 相比于现有方法LightRAG和LongLLMLingua,本发明的方法在LongBench上实现了更有益的平均性能。在单文档问答和多文档问答两个需要较强推理能力的子集——SingleDoc和MultiDoc上,本发明的方法显著优于其他的相关技术,这是因为设计的基于文本关系图的上下文压缩技术擅长处理长文本多跳推理任务。对于其他的总结、少样本学习、定位和代码合成子集——Summ、FewShot、Synth和Code上,本发明的方法与其他两种方法互有优劣,一个主要原因是混合上下文压缩策略的两种压缩技术擅长不同的任务,基于大语言模型的问题类型判断不能完全将不同的问题分配给较为适合的方法。

[0070] 在本发明的技术实现中,目前采用了问题导向的混合上下文压缩方法,通过自适应选择压缩策略来处理不同类型的问题,这需要上下文压缩技术适用于不同领域的问答任务。该部分可以使用通用领域的上下文压缩技术进行替代,通过训练自适应的上下文压缩模型,并针对不同种类的任务进行微调优化,能够提供单一压缩方法的大语言模型长文本问答解决方案。

[0071] 本发明的另一实施例提供一种基于混合上下文压缩技术的大语言模型长文本问答系统,其包括:

[0072] 文档解析与预处理模块,用于进行文档解析与预处理,将非结构化的原始文本转换为规范化的文本段落集合;

[0073] 基于大语言模型的问题类型判断模块,用于基于大语言模型将长文本问答场景的问题进行分类;

[0074] 问题导向的混合上下文压缩模块,用于根据问题类型和预处理后的文本,自适应选择最适合的上下文压缩方法对长文本进行压缩,得到压缩后的上下文;

[0075] 基于大语言模型的回答生成模块,用于利用压缩后的上下文,基于大语言模型生成问题的答案。

[0076] 上述各模块的划分仅是举例说明,实际应用中可以根据需要而将上述功能分配由不同的功能模块完成,以完成前述方法中描述的全部或者部分功能。上述各模块的具体工作过程,可以参考前述方法实施例中的对应过程,在此不再赘述。

[0077] 本发明的另一实施例提供一种计算机设备(计算机、服务器、智能手机等),其包括存储器和处理器,所述存储器存储计算机程序,所述计算机程序被配置为由所述处理器执行,所述计算机程序包括用于执行本发明方法中各步骤的指令。

[0078] 本发明的另一实施例提供一种计算机可读存储介质(如ROM/RAM、磁盘、光盘),所述计算机可读存储介质存储计算机程序,所述计算机程序被计算机执行时,实现本发明方法的各个步骤。

[0079] 以上公开的本发明的具体实施例,其目的在于帮助理解本发明的内容并据以实施,本领域的普通技术人员可以理解,在不脱离本发明的精神和范围内,各种替换、变化和修改都是可能的。本发明不应局限于本说明书的实施例所公开的内容,本发明的保护范围以权利要求书界定的范围为准。

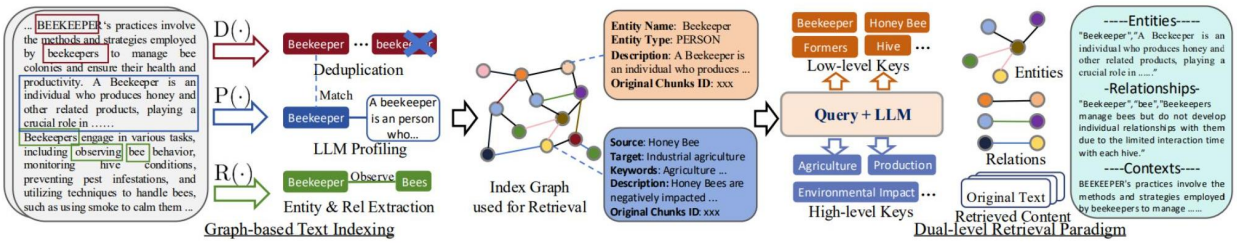

D(·)
P(·)
R(·)
Deduplication
LLM Profiling
Entity & Rel Extraction
Graph-based Text Indexing
Index Graph used for Retrieval
Low-level Keys
High-level Keys
Query + LLM
Entities
Relations
Original Text
Retrieved Content
Dual-level Retrieval Paradigm

图1

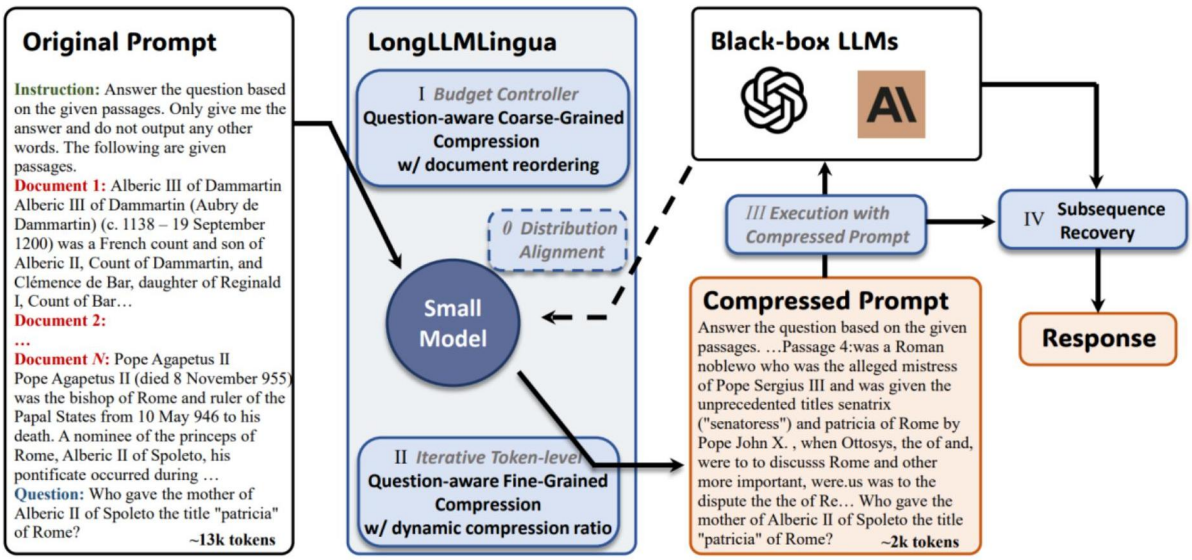

Original Prompt
LongLLMLingua
I Budget Controller
Question-aware Coarse-Grained Compression
w/ document reordering
0 Distribution Alignment
Small Model
II Iterative Token-level
Question-aware Fine-Grained Compression
w/ dynamic compression ratio
Black-box LLMs
III Execution with Compressed Prompt
IV Subsequence Recovery
Compressed Prompt
Response
~13k tokens
~2k tokens

图2

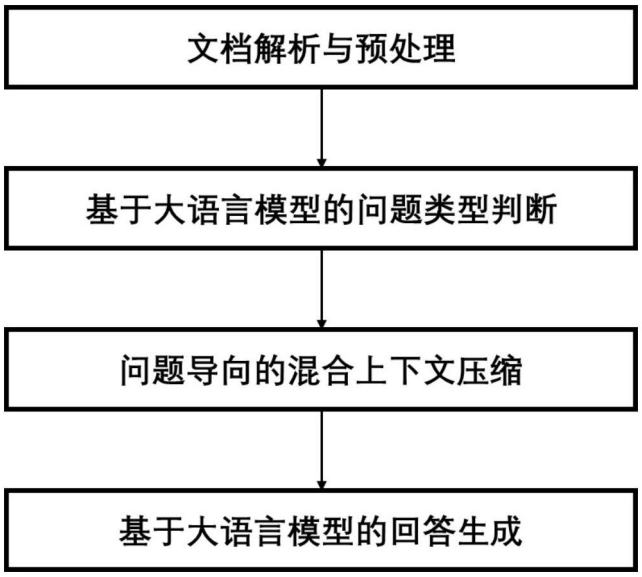

文档解析与预处理
基于大语言模型的问题类型判断
问题导向的混合上下文压缩
基于大语言模型的回答生成

图3