(19)国家知识产权局

(12)发明专利申请

(10)申请公布号 CN 122654297 A
(43)申请公布日 2026.08.28

(21)申请号 202611162638.4
(22)申请日 2026.08.03
(71)申请人 杭州数云信息技术有限公司
地址 310007 浙江省杭州市西湖区文三路478号华星时代广场A座1902号
(72)发明人 姜华军 宋向平
(74)专利代理机构 深圳市精英专利事务所 44242
专利代理师 叶冬青
(51)Int.Cl.
G06F 16/334(2025.01)
G06F 16/3329(2025.01)
G06N 5/04(2023.01)
G06N 5/022(2023.01)
G06N 3/045(2023.01)
H03M 7/30(2006.01)

权利要求书2页 说明书14页 附图3页

(54)发明名称

大语言模型的上下文压缩方法、装置、设备及介质

(57)摘要

本申请实施例公开了大语言模型的上下文压缩方法、装置、设备及介质。方法包括:基于查询信息从知识库中召回多个文档片段;分别计算每个文档片段的文档相关性得分;分别将每个文档片段切分为多个句子,并计算每个句子的句子相关性得分;根据句子相关性得分以及句子得分阈值从文档片段中选取关键句,得到每个文档片段的关键句集;在上下文预算的约束下,根据文档相关性得分将各文档片段对应的关键句集依次纳入大语言模型的上下文,形成关键句基线;在关键句基线占用的预算未超过上下文预算的情况下,按照文档相关性得分从高到低的顺序,依次将已纳入关键句基线的关键句集替换为对应的文档片段,直至下一关键句集的替换将导致超出上下文预算时停止。



CN 122654297 A

1.一种大语言模型的上下文压缩方法,其特征在于,包括:

获取用户输入的查询信息,基于所述查询信息从知识库中召回多个文档片段;

分别计算每个所述文档片段与所述查询信息的文档相关性得分;

分别将每个所述文档片段切分为多个句子,并分别计算每个句子与所述查询信息的句子相关性得分;

针对每个所述文档片段,根据所述句子相关性得分以及预设的句子得分阈值从所述文档片段中选取关键句,得到每个所述文档片段分别对应的关键句集;

在预设的上下文预算的约束下,根据所述文档相关性得分将各文档片段对应的关键句集依次纳入所述大语言模型的上下文,形成关键句基线;

在所述关键句基线占用的预算未超过所述上下文预算的情况下,按照所述文档相关性得分从高到低的顺序,依次将已纳入所述关键句基线的关键句集替换为对应的文档片段,直至下一关键句集的替换将导致超出所述上下文预算时停止。

2.根据权利要求1所述的方法,其特征在于,所述分别计算每个所述文档片段与所述查询信息的文档相关性得分,包括:

分别计算每个所述文档片段与所述查询信息的向量语义相似度得分、词法相关度得分以及交叉编码器精排得分中的至少一个;

根据所述向量语义相似度得分、所述词法相关度得分以及所述交叉编码器精排得分中的至少一个确定每个所述文档片段的文档相关性得分。

3.根据权利要求1所述的方法,其特征在于,所述分别计算每个句子与所述查询信息的句子相关性得分,包括:

分别计算每个句子与所述查询信息的语义相关度;

提取所述查询信息中的查询要素,分别计算每个句子对所述查询要素的要素覆盖得分;

根据所述语义相关度和所述要素覆盖得分,分别计算每个句子的所述句子相关性得分。

4.根据权利要求1所述的方法,其特征在于,所述在预设的上下文预算的约束下,根据所述文档相关性得分将各文档片段对应的关键句集依次纳入所述大语言模型的上下文,形成关键句基线,包括:

按照所述文档相关性得分对每个关键句集从高到低进行排序;

将排序后的所述关键句集依次纳入所述大语言模型的上下文,直至下一关键句集的纳入将导致超出所述上下文预算或所述关键句集全部纳入时停止纳入,形成所述关键句基线。

5.根据权利要求1所述的方法,其特征在于,所述针对每个所述文档片段,根据所述句子相关性得分以及预设的句子得分阈值从所述文档片段中选取关键句,得到每个所述文档片段分别对应的关键句集,包括:

针对每个所述文档片段,将所述文档片段中所述句子相关性得分大于或等于所述句子得分阈值的句子选取为关键句,得到每个所述文档片段分别对应的关键句集;

对于所有句子的句子相关性得分均小于所述句子得分阈值的文档片段,将所述文档片段中所述句子相关性得分最高的句子选取为关键句,得到所述文档片段的关键句集。

6.根据权利要求1所述的方法,其特征在于,所述在预设的上下文预算的约束下,根据所述文档相关性得分将各文档片段对应的关键句集依次纳入所述大语言模型的上下文,形成关键句基线,包括:

若所述上下文预算小于相关性最高的文档片段的关键句集所占用的预算,则根据所述句子相关性得分从所述相关性最高的文档片段中逐句选取句子纳入所述上下文,直至达到所述上下文预算,形成关键句基线;

若所述上下文预算大于或等于相关性最高的文档片段的关键句集所占用的预算,则在预设的上下文预算的约束下,根据所述文档相关性得分将各文档片段对应的关键句集依次纳入所述大语言模型的上下文,形成关键句基线。

7.根据权利要求1所述的方法,其特征在于,所述方法还包括:

获取所述大语言模型针对所述上下文输出的问答结果的质量反馈信息;

根据所述质量反馈信息调整所述句子得分阈值、所述句子相关性得分的相关计算权重以及所述文档相关性得分的相关计算权重的至少一项。

8.一种大语言模型的上下文压缩装置,其特征在于,包括:

收发单元,用于获取用户输入的查询信息;

处理单元,用于基于所述查询信息从知识库中召回多个文档片段;分别计算每个所述文档片段与所述查询信息的文档相关性得分;分别将每个所述文档片段切分为多个句子,并分别计算每个句子与所述查询信息的句子相关性得分;针对每个所述文档片段,根据所述句子相关性得分以及预设的句子得分阈值从所述文档片段中选取关键句,得到每个所述文档片段分别对应的关键句集;在预设的上下文预算的约束下,根据所述文档相关性得分将各文档片段对应的关键句集依次纳入所述大语言模型的上下文,形成关键句基线;在所述关键句基线占用的预算未超过所述上下文预算的情况下,按照所述文档相关性得分从高到低的顺序,依次将已纳入所述关键句基线的关键句集替换为对应的文档片段,直至下一关键句集的替换将导致超出所述上下文预算时停止。

9.一种计算机设备,包括存储器、处理器及存储在所述存储器上并可在所述处理器上运行的计算机程序,其特征在于,所述处理器执行所述计算机程序时实现如权利要求1-7中任一项所述的大语言模型的上下文压缩方法。

10.一种存储介质,其特征在于,所述存储介质存储有计算机程序,所述计算机程序包括程序指令,所述程序指令当被处理器执行时使所述处理器执行如权利要求1-7中任一项所述的大语言模型的上下文压缩方法。

大语言模型的上下文压缩方法、装置、设备及介质

技术领域

[0001] 本申请涉及人工智能技术领域,尤其涉及大语言模型的上下文压缩方法、装置、设备及介质。

背景技术

[0002] 检索增强生成已成为企业大语言模型应用的主流架构。在大模型企业网关的检索增强生成(Retrieval-Augmented Generation,RAG)系统中,每次用户查询需从知识库召回若干相关文档片段,并将其填充至大语言模型的上下文窗口作为生成依据。该架构在工程落地中面临一个核心矛盾:上下文窗口的Token预算有限,而召回片段的总长度往往远超预算,必须对召回内容进行裁剪或压缩。

[0003] 现有方案中,一般基于Top-K截断策略或均匀压缩策略对召回内容进行裁剪或压缩。

[0004] Top-K截断策略按相关性排序后直接截断(取前K篇),然而,该策略存在根本缺陷,高相关片段可能因篇幅较长被部分截断而丢失关键信息;前K篇中的大段背景、引用、过渡等低密度内容占用Token配额却对答案生成无实质贡献;第K+1篇之后即便包含关键事实句也被一刀切丢弃。

[0005] 均匀压缩策略对所有召回片段执行相同压缩率的摘要,然而却忽视了不同片段对答案贡献的本质差异,高相关片段每个Token的边际价值远高于低相关片段,对二者使用相同压缩率,实质是将宝贵的Token配额平均分配给价值悬殊的内容,导致整体信息密度次优,信息分布不合理。

[0006] 可见,通过现有方案对召回内容进行裁剪或压缩,在Token预算有限的情况下,都存在召回信息密度浪费的情况,影响大语言模型的回答质量。

发明内容

[0007] 本申请实施例提供了大语言模型的上下文压缩方法、装置、设备及介质,可以提高召回信息密度,从而提高大语言模型的回答质量。

[0008] 第一方面,本申请实施例提供了一种大语言模型的上下文压缩方法,其包括:

获取用户输入的查询信息,基于所述查询信息从知识库中召回多个文档片段;

分别计算每个所述文档片段与所述查询信息的文档相关性得分;

分别将每个所述文档片段切分为多个句子,并分别计算每个句子与所述查询信息的句子相关性得分;

针对每个所述文档片段,根据所述句子相关性得分以及预设的句子得分阈值从所述文档片段中选取关键句,得到每个所述文档片段分别对应的关键句集;

在预设的上下文预算的约束下,根据所述文档相关性得分将各文档片段对应的关键句集依次纳入所述大语言模型的上下文,形成关键句基线;

在所述关键句基线占用的预算未超过所述上下文预算的情况下,按照所述文档相

关性得分从高到低的顺序,依次将已纳入所述关键句基线的关键句集替换为对应的文档片段,直至下一关键句集的替换将导致超出所述上下文预算时停止。

[0009] 在一些实施例中,所述分别计算每个所述文档片段与所述查询信息的文档相关性得分,包括:

分别计算每个所述文档片段与所述查询信息的向量语义相似度得分、词法相关度得分以及交叉编码器精排得分中的至少一个;

根据所述向量语义相似度得分、所述词法相关度得分以及所述交叉编码器精排得分中的至少一个确定每个所述文档片段的文档相关性得分。

[0010] 在一些实施例中,所述分别计算每个句子与所述查询信息的句子相关性得分,包括:

分别计算每个句子与所述查询信息的语义相关度;

提取所述查询信息中的查询要素,分别计算每个句子对所述查询要素的要素覆盖得分;

根据所述语义相关度和所述要素覆盖得分,分别计算每个句子的所述句子相关性得分。

[0011] 在一些实施例中,所述在预设的上下文预算的约束下,根据所述文档相关性得分将各文档片段对应的关键句集依次纳入所述大语言模型的上下文,形成关键句基线,包括:

按照所述文档相关性得分对每个关键句集从高到低进行排序;

将排序后的所述关键句集依次纳入所述大语言模型的上下文,直至下一关键句集的纳入将导致超出所述上下文预算或所述关键句集全部纳入时停止纳入,形成所述关键句基线。

[0012] 在一些实施例中,所述针对每个所述文档片段,根据所述句子相关性得分以及预设的句子得分阈值从所述文档片段中选取关键句,得到每个所述文档片段分别对应的关键句集,包括:

针对每个所述文档片段,将所述文档片段中所述句子相关性得分大于或等于所述句子得分阈值的句子选取为关键句,得到每个所述文档片段分别对应的关键句集;

对于所有句子的句子相关性得分均小于所述句子得分阈值的文档片段,将所述文档片段中所述句子相关性得分最高的句子选取为关键句,得到所述文档片段的关键句集。

[0013] 在一些实施例中,所述在预设的上下文预算的约束下,根据所述文档相关性得分将各文档片段对应的关键句集依次纳入所述大语言模型的上下文,形成关键句基线,包括:

若所述上下文预算小于相关性最高的文档片段的关键句集所占用的预算,则根据所述句子相关性得分从所述相关性最高的文档片段中逐句选取句子纳入所述上下文,直至达到所述上下文预算,形成关键句基线;

若所述上下文预算大于或等于相关性最高的文档片段的关键句集所占用的预算,则在预设的上下文预算的约束下,根据所述文档相关性得分将各文档片段对应的关键句集依次纳入所述大语言模型的上下文,形成关键句基线。

[0014] 在一些实施例中,所述方法还包括:

获取所述大语言模型针对所述上下文输出的问答结果的质量反馈信息;

根据所述质量反馈信息调整所述句子得分阈值、所述句子相关性得分的相关计算

权重以及所述文档相关性得分的相关计算权重的至少一项。

[0015] 第二方面,本申请实施例还提供了一种大语言模型的上下文压缩装置,其包括:

收发单元,用于获取用户输入的查询信息;

处理单元,用于基于所述查询信息从知识库中召回多个文档片段;分别计算每个所述文档片段与所述查询信息的文档相关性得分;分别将每个所述文档片段切分为多个句子,并分别计算每个句子与所述查询信息的句子相关性得分;针对每个所述文档片段,根据所述句子相关性得分以及预设的句子得分阈值从所述文档片段中选取关键句,得到每个所述文档片段分别对应的关键句集;在预设的上下文预算的约束下,根据所述文档相关性得分将各文档片段对应的关键句集依次纳入所述大语言模型的上下文,形成关键句基线;在所述关键句基线占用的预算未超过所述上下文预算的情况下,按照所述文档相关性得分从高到低的顺序,依次将已纳入所述关键句基线的关键句集替换为对应的文档片段,直至下一关键句集的替换将导致超出所述上下文预算时停止。

[0016] 第三方面,本申请实施例还提供了一种计算机设备,其包括存储器及处理器,所述存储器上存储有计算机程序,所述处理器执行所述计算机程序时实现上述方法。

[0017] 第四方面,本申请实施例还提供了一种计算机可读存储介质,所述存储介质存储有计算机程序,所述计算机程序包括程序指令,所述程序指令当被处理器执行时可实现上述方法。

[0018] 本申请实施例提供了大语言模型的上下文压缩方法、装置、设备及介质。一方面,本申请提供的技术方案采用句子级关键句作为基础承载单元,同等Token预算(上下文预算)下可覆盖更多知识库片段的核心信息,避免高价值短句被一刀切丢弃,可以提高召回信息密度,从而提高大语言模型的回答质量;另一方面,本申请提供的技术方案采用“先铺关键句基线、有余量再恢复原文(关键句集对应的文档片段)”的双层分级压缩逻辑,优先保障召回信息覆盖广度,再优化高相关内容阅读深度,使得纳入模型上下文的信息可以兼顾问答全面性与细节丰富度。

附图说明

[0019] 为了更清楚地说明本申请实施例技术方案,下面将对实施例描述中所需要使用的附图作简单地介绍,显而易见地,下面描述中的附图是本申请的一些实施例,对于本领域普通技术人员来讲,在不付出创造性劳动的前提下,还可以根据这些附图获得其他的附图。

[0020] 图1为本申请实施例提供的大语言模型的上下文压缩方法的流程示意图;

图2为本申请实施例提供的大语言模型的上下文压缩方法的一个子流程示意图;

图3为本申请实施例提供的大语言模型的上下文压缩方法的另一个子流程示意图;

图4为本申请实施例提供的大语言模型的上下文压缩方法的另一个子流程示意图;

图5为本申请实施例提供的大语言模型的上下文压缩装置的示意性框图;

图6为本申请实施例提供的计算机设备的示意性框图。

具体实施方式

[0021] 下面将结合本申请实施例中的附图,对本申请实施例中的技术方案进行清楚、完整地描述,显然,所描述的实施例是本申请的一部分实施例,而不是全部的实施例。基于本申请中的实施例,本领域普通技术人员在没有做出创造性劳动前提下所获得的所有其他实施例,都属于本申请保护的范围。

[0022] 应当说明的是,本申请实施例中若出现了非本公司的AI模型、软件工具或组件,仅仅是用于举例介绍,并不代表实际使用。本申请实施例中涉及到的用户个人信息,均为经相关对象授权(知晓且同意)或者经过各方充分授权的执行主体可以通过各种合法合规的方式获取。所涉及的信息、数据及信号的收集、存储、使用、加工、传输、提供和公开等处理,均遵守相关的法律法规的规定,且不违背公序良俗。

[0023] 应当理解,当在本说明书和所附权利要求书中使用时,术语“包括”和“包含”指示所描述特征、整体、步骤、操作、元素和/或组件的存在,但并不排除一个或多个其它特征、整体、步骤、操作、元素、组件和/或其集合的存在或添加。

[0024] 还应当理解,在本申请说明书中所使用的术语仅仅是出于描述特定实施例的目的而并不意在限制本申请。如在本申请说明书和所附权利要求书中所使用的那样,除非上下文清楚地指明其它情况,否则单数形式的“一”、“一个”及“该”意在包括复数形式。

[0025] 还应当进一步理解,在本申请说明书和所附权利要求书中使用的术语“和/或”是指相关联列出的项中的一个或多个的任何组合以及所有可能组合,并且包括这些组合。

[0026] 本申请实施例提供了大语言模型的上下文压缩方法、装置、设备及介质。

[0027] 该大语言模型的上下文压缩方法的执行主体可以是本申请实施例提供的大语言模型的上下文压缩装置,或者集成了该大语言模型的上下文压缩装置的计算机设备,其中,该大语言模型的上下文压缩装置可以采用硬件或者软件的方式实现,该计算机设备可以为终端或服务器,该计算机设备中部署有RAG系统,具体地,该计算机设备可以为大语言模型(Large Language Model,LLM)网关,如大模型企业网关,该RAG系统部署在LLM网关中。

[0028] 本申请提供的RAG系统用于对召回的文档片段进行差异化压缩,以适配大语言模型的上下文窗口预算,可以在预算有限的情况下,实现召回信息密度最大化,以提高大语言模型的回答质量。

[0029] 具体地,本申请实施例提供的大语言模型的上下文压缩方法应用于RAG系统,以下以RAG系统(以下简称:系统)为执行主体对本申请提供的大语言模型的上下文压缩方法进行描述。

[0030] 图1是本申请实施例提供的大语言模型的上下文压缩方法的流程示意图。如图1所示,该方法包括以下步骤S110-S160。

[0031] S110、获取用户输入的查询信息,基于所述查询信息从知识库中召回多个文档片段。

[0032] 用户向大语言模型提问时,系统获取用户输入的查询信息。为便于表述,将所述查询信息记为Q。

[0033] 系统基于查询信息Q 从知识库中召回与 Q相关的多个文档片段,得到文档片段集合 $D=\{d_1,d_2,\ldots,d_n\}$,其中n 为召回的文档片段总数。每个文档片段d_i是知识库中预先切分好的文本块(Chunk)。

[0034] 在一些实施例中,文本块的切分大小可根据应用场景配置,例如切分大小为512至1024个令牌。每个文档片段还携带元数据,包括但不限于其在原文中的位置信息与来源标识。

[0035] 作为本步骤的一种具体实现方式,系统可以采用向量检索方式从知识库中召回与查询信息语义相关的文档片段。具体地,利用嵌入(Embedding)模型分别对查询信息和知识库中各文档片段进行向量化编码,计算查询向量与各文档片段向量的余弦相似度,按相似度从高到低召回预设数量的文档片段。

[0036] S120、分别计算每个所述文档片段与所述查询信息的文档相关性得分。

[0037] 对于步骤S110中召回的每个文档片段d_i,计算其与查询信息Q 的文档相关性得分$R_{score(di)}$。该得分用于后续步骤中确定各文档片段在预算分配中的优先级:得分越高的文档片段,其关键句集越优先被纳入上下文,且在剩余预算充足时越优先被恢复为原文。

[0038] 在一些实施例中,具体地,请参阅图2,步骤S120包括:

S1201、分别计算每个所述文档片段与所述查询信息的向量语义相似度得分、词法相关度得分以及交叉编码器精排得分中的至少一个。

[0039] 其中,所述向量语义相似度得分为所述查询信息的嵌入向量与所述文档片段的嵌入向量之间的余弦相似度;所述词法相关度得分为BM25相关度。

[0040] S1202、根据所述向量语义相似度得分、所述词法相关度得分以及所述交叉编码器精排得分中的至少一个确定每个所述文档片段的文档相关性得分。

[0041] 具体地,当基于向量语义相似度得分、所述词法相关度得分以及所述交叉编码器精排得分中的其中一个确定文档相关性得分时,将所述向量语义相似度得分、所述词法相关度得分或者所述交叉编码器精排得分作为对应文档片段的文档相关性得分。

[0042] 当基于所述向量语义相似度得分、所述词法相关度得分以及所述交叉编码器精排得分中的其中任意两个或三个确定每个所述文档片段的文档相关性得分时,可以基于对应得分进行加权融合得到文档相关性得分。

[0043] 例如,当需要根据所述向量语义相似度得分、所述词法相关度得分以及所述交叉编码器精排得分确定每个所述文档片段的文档相关性得分时,文档相关性得分 $R_{score(di)}$ 通过将向量语义相似度得分 R_{vec}、词法相关度得分 R_{bm25} 与交叉编码器精排得分 R_{ce}三者进行加权融合得到,具体地:

$$R_{score(di)} = w_1 \cdot R_{vec} + w_2 \cdot R_{bm25} + w_3 \cdot R_{ce};$$

其中,$w_1+w_2+w_3=1$,默认权重取 $(w_1,w_2,w_3)=(0.5,0.2,0.3)$,各维度权重可根据知识库类型独立配置。$R_{score}$作为后续片段选取与原文恢复的排序依据。

[0044] 在一些实施例中,向量语义相似度得分、词法相关度得分以及交叉编码器精排得分的具体计算方式如下:

(1)向量语义相似度得分 R_{vec}:采用双编码器架构,使用预训练的嵌入模型分别将查询信息 Q 和文档片段d_i编码为稠密向量 v_Q 和 v_{di},然后计算两者的余弦相似度确定向量语义相似度得分,具体地:$R_{vec} = \cos(v_Q, v_{di})$。

[0045] 该维度用于捕捉查询与文档片段之间的深层语义相关性。

[0046] (2)词法相关度得分 R_{bm25}:采用BM25算法计算查询信息Q与文档片段 d_i在词法层面的匹配程度。具体地,可以对查询信息进行分词得到词项集合,计算每个词项在文档片段

中的词频与逆文档频率的加权和,得到该词法相关度得分。

[0047] 该维度用于捕捉专有名词、术语等词法层面的精确匹配。

[0048] (3)交叉编码器精排得分 R_{ce}:采用交叉编码器架构,将查询信息Q与文档片段d_i拼接后输入交叉编码器模型,利用模型的注意力机制进行深度交互式语义建模,输出精细的相关性得分。

[0049] 该维度能够捕捉比向量语义相似度更精细的查询-片段语义关系。

[0050] 在计算各维度得分后,由于各维度得分的量纲不同,本步骤需要对各维度得分进行归一化处理(如Min-Max归一化)后再进行加权融合。

[0051] 在一些实施例中,为降低交叉编码器的计算开销,可采用级联排序策略:先利用计算成本较低的向量语义相似度得分与词法相关度得分的线性加权对所有召回片段进行粗排,保留得分最高的Top-K个候选片段(K值可配置,如50),然后仅对该Top-K个候选片段调用交叉编码器计算精排得分。未进入Top-K的片段的交叉编码器精排得分置为全局最小值(如0)。

[0052] S130、分别将每个所述文档片段切分为多个句子,并分别计算每个句子与所述查询信息的句子相关性得分。

[0053] 系统对全部召回的文档片段执行一次性的要素与句子级相关性分析(即计算句子相关性得分),结果在后续所有环节复用,并为每个文档片段构建关键句集、同时保留原文,作为两种可选形态。

[0054] 步骤针对步骤S110中召回的每个文档片段 d_i,进行句子级别的分析与评分。

[0055] 具体地,对于每个文档片段 d_i,首先将其切分为多个句子,得到该文档片段的句子集合 $S(d_i)=\{s_{i1},s_{i2},\ldots,s_{im}\}$,其中 m为文档片段 d_i中的句子总数。

[0056] 然后,对于每个句子s_{ij},计算其与查询信息Q 的句子相关性得分 $KeyScore(s_{ij})$。该得分用于后续步骤中判断该句子是否应作为关键句被纳入关键句集。

[0057] 在一些实施例中,具体地,请参阅图3,步骤S130包括:

S1301、分别计算每个句子与所述查询信息的语义相关度;

S1302、提取所述查询信息中的查询要素,分别计算每个句子对所述查询要素的要素覆盖得分;

S1303、根据所述语义相关度和所述要素覆盖得分,分别计算每个句子的所述句子相关性得分。

[0058] 具体地,首先,计算句子 s与查询信息 Q 的语义相关度 rel(s,Q)。该语义相关度用于衡量句子与查询在语义层面的贴近程度,取值范围为 [0,1]。

[0059] 在一些实施例中,所述语义相关度基于以下至少一种方式计算:向量余弦相似度、词项匹配度、交叉编码器相关性得分。

[0060] 进一步地,将向量余弦相似度$sim_{vec}(s,Q)$、词项匹配度$sim_{lex}(s,Q)$与交叉编码器相关性得分$sim_{ce}(s,Q)$三者进行加权融合得到语义相关度:

$$rel(s,Q)=u_1 \cdot sim_{vec}(s,Q)+u_2 \cdot sim_{lex}(s,Q)+u_3 \cdot sim_{ce}(s,Q);$$

其中$u_1+u_2+u_3=1$,默认 $(u_1,u_2,u_3)=(0.5,0.2,0.3)$。需要说明的是,此处计算语义相关度所用的嵌入模型可与步骤S120中计算向量语义相似度所采用的嵌入模型相同,且查询信息的嵌入向量 v_Q可在步骤S120中计算完成后被缓存,直接复用于本步骤的sim_{vec}计

算,以降低重复计算开销。

[0061] 其次,提取查询信息 Q中的查询要素,得到查询要素集合Q_{elem}。所述查询要素包括但不限于命名实体(如人名、地名、机构名、产品名)、数值与日期(如金额、年份、百分比、日期)。在提取时,问题词(如“什么”、“如何”、“为什么”、“谁”、“哪里”、“何时”)与限定词(如“主要”、“最新”、“最高”、“首次”)不计入查询要素集合,其语义作用由语义相关度维度承担。

[0062] 然后,对于每个句子 s,计算其对查询要素的要素覆盖得elem(s),取值范围为[0,1]。具体地,统计句子 s 中命中的实体类与数值日期类查询要素的去重个|hit(s)|,以及该类查询要素的总数$|Q_{elem_ed}|$,则:

$$elem(s)=|hit(s)|/|Q_{elem_ed}|;$$

当查询中不包含实体类与数值日期类要素时(即$|Q_{elem_ed}|=0$),令elem(s)=0。

[0063] 最后,根据语义相关度rel(s,Q) 和要素覆盖得分elem(s) 确定句子相关性得分KeyScore(s)。

[0064] 将两者进行加权求和:

$$KeyScore(s)=\alpha\cdot rel(s,Q)+\beta\cdot elem(s);$$

其中 $\alpha+\beta=1$,默认 $(\alpha,\beta)=(0.6,0.4)$。

[0065] 该加权求和方式的优点在于:要素覆盖作为加权项而非硬性门槛,既可以使包含关键事实要素的句子获得加分,也可以使不包含离散要素但高度相关的论述性、结论性句子凭借高语义相关度获得足够的综合评分而入选。

[0066] S140、针对每个所述文档片段,根据所述句子相关性得分以及预设的句子得分阈值从所述文档片段中选取关键句,得到每个所述文档片段分别对应的关键句集。

[0067] 本步骤基于步骤S130中计算得到的句子相关性得分 KeyScore(s),从每个文档片段中筛选出关键句,形成该文档片段的关键句集 $KS(d_i)$。

[0068] 在一些实施例中,针对每个所述文档片段,将所述文档片段中所述句子相关性得分大于或等于所述句子得分阈值的句子选取为关键句,得到每个所述文档片段分别对应的关键句集;对于所有句子的句子相关性得分均小于所述句子得分阈值的文档片段,将所述文档片段中所述句子相关性得分最高的句子选取为关键句,得到所述文档片段的关键句集。

[0069] 对于文档片段 d_i中的每个句子s,将其句子相关性得分 KeyScore(s)与预设的句子得分阈值τ_{key} 进行比较(默认$\tau_{key}=0.5$)。将得分大于或等于τ_{key}的句子选取为关键句,纳入关键句集 $KS(d_i)$。

[0070] 考虑到存在某些文档片段中所有句子的相关性得分均低于阈值的情况,本步骤还设置了保底选取机制:对于所有句子的句子相关性得分均小于句子得分阈值的文档片段,将该文档片段中句子相关性得分最高的句子选取为关键句,以确保每个文档片段至少有一个关键句被保留。

[0071] 关键句集 $KS(d_i)$ 中的句子按照其在原始文档片段中的出现顺序排列。记 $KS(d_i)$ 令牌数为 $t_{KS(i)}$,文档片段 d_i的全文令牌数为 $t_{full(i)}$。由此,每个文档片段具备两种形态:关键句集形态(基本态,占用 $t_{KS(i)}$个令牌)与完整原文形态(完整态,占用 $t_{full(i)}$ 个令牌),两种形态的令牌占用均已确定,供后续预算分配步骤使用。

[0072] S150、在预设的上下文预算的约束下,根据所述文档相关性得分将各文档片段对应的关键句集依次纳入所述大语言模型的上下文,形成关键句基线。

[0073] 本步骤开始在预设的上下文预算B_{total}的约束下进行预算分配的第一阶段-关键句基线铺设。该阶段的目的是在预算紧张时,以“尽可能覆盖更多高相关片段的关键信息”为目标,将各文档片段的关键句集纳入上下文。

[0074] 在一些实施例中,具体地,请参阅图4,步骤S150包括:

S1501、按照所述文档相关性得分对每个关键句集从高到低进行排序;

S1502、将排序后的所述关键句集依次纳入所述大语言模型的上下文,直至下一关键句集的纳入将导致超出所述上下文预算或所述关键句集全部纳入时停止纳入,形成所述关键句基线。

[0075] 首先,按照步骤S120中计算得到的文档相关性得分 $R_{score(di)}$,对所有文档片段按得分从高到低进行降序排列。

[0076] 然后,维护当前已用预算B_{used}(初始为0),按照排序后的顺序依次考察各文档片段的关键句集 $KS(d_i)$:若 $B_{used}+t_{KS(i)} \leqslant B_{total}$,则将 $KS(d_i)$ 全量纳入上下文,并更新 $B_{used}=B_{used}+t_{KS(i)}$,继续考察下一个文档片段;若 $B_{used}+t_{KS(i)}>B_{total}$,则停止纳入。

[0077] 当所有文档片段的关键句集均被纳入,或下一关键句集的纳入将导致超出上下文预算时,纳入过程停止,形成关键句基线。设共纳入了前m个文档片段的关键句集,则剩余预算 $B_{rest}=B_{total}-B_{used}$,排序在第m位之后的文档片段的关键句集不纳入当前上下文。

[0078] 在一些实施例中,本方法还针对极端预算场景提供了退化处理机制:若所述上下文预算小于相关性最高的文档片段的关键句集所占用的预算,则根据所述句子相关性得分从所述相关性最高的文档片段中逐句选取句子纳入所述上下文,直至达到所述上下文预算,形成关键句基线;若所述上下文预算大于或等于相关性最高的文档片段的关键句集所占用的预算,则在预设的上下文预算的约束下,根据所述文档相关性得分将各文档片段对应的关键句集依次纳入所述大语言模型的上下文,形成关键句基线。

[0079] 具体地,若上下文预算 B_{total}小于相关性最高的文档片段的关键句集所占用的预算$t_{KS}(1)$,即连相关性最高的文档片段的完整关键句集都无法纳入,则放弃以关键句集为单位的纳入方式,转而根据句子相关性得分KeyScore(s) 从该相关性最高的文档片段中逐句选取句子纳入上下文,直至达到上下文预算B_{total},形成关键句基线。

[0080] 若上下文预算B_{total}大于或等于相关性最高的文档片段的关键句集所占用的预算$t_{KS}(1)$,则按照上述正常流程,以关键句集为单位依次纳入。

[0081] S160、在所述关键句基线占用的预算未超过所述上下文预算的情况下,按照所述文档相关性得分从高到低的顺序,依次将已纳入所述关键句基线的关键句集替换为对应的文档片段,直至下一关键句集的替换将导致超出所述上下文预算时停止。

[0082] 本步骤是预算分配的第二阶段-剩余预算的原文恢复。在关键句基线铺设完成后,如果还有剩余预算 Brest>0,则利用这部分剩余预算将最相关的文档片段从“关键句集形态”升级恢复为“完整原文形态”,以增强最关键内容的上下文完整度。

[0083] 具体地,按照文档相关性得分 R_{score}从高到低的顺序,对已纳入关键句基线的m个文档片段逐个进行考察:

对于当前考察的文档片段 d_i,计算将其从关键句集形态恢复为完整原文形态所

需的增量令牌数：

$\Delta T(i)=t_{full(i)}-t_{KS(i)}$；

若 $\Delta T(i)\leqslant Brest$，则将该文档片段在上下文中的内容由关键句集 $KS(d_i)$ 替换为完整的原文 d_i，并更新剩余预算 $Brest=Brest-\Delta T(i)$，继续考察下一个文档片段。

[0084] 若 $\Delta T(i)>Brest$，则停止恢复过程。此时，已被恢复的文档片段以原文形态呈现，未被恢复的文档片段仍以关键句集形态呈现。

[0085] 整个恢复过程仅单调增加令牌数量(从关键句集增加到完整原文)，不删除任何已有内容，因此严格保证最终输出的上下文总令牌数不超过预设的上下文预算B_{total}。

[0086] 在一些实施例中，所述方法还包括：获取所述大语言模型针对所述上下文输出的问答结果的质量反馈信息；根据所述质量反馈信息调整所述句子得分阈值、所述句子相关性得分的相关计算权重以及所述文档相关性得分的相关计算权重的至少一项。

[0087] 该实施例用于实现领域自适应的阈值与权重调整。

[0088] 具体地，在步骤S160完成后，将最终压缩后的上下文输入大语言模型，由大语言模型基于该上下文生成针对用户查询的问答结果并输出。

[0089] 系统获取该问答结果的质量反馈信息。所述质量反馈信息可以是人工标注的答案满意度评分，也可以是基于自动评估指标(如事实准确性、答案完整性、相关性等)计算得到的量化分数。

[0090] 根据所述质量反馈信息，调整以下至少一项参数：

句子得分阈值τ_{key}(步骤S140中使用的阈值)；

句子相关性得分的相关计算权重，如语义相关度与要素覆盖得分的融合权重α、β(步骤S130中使用的权重)；

文档相关性得分的相关计算权重，如w_1、w_2、w_3(步骤S120中使用的权重)。

[0091] 具体地，若在某知识库或某领域中发现关键句集经常遗漏关键信息，则下调句子得分阈值τ_{key}或上调要素覆盖得分权重β；若发现关键句集中包含过多冗余信息，则上调阈值或下调相应权重。每个知识库可维护独立的配置参数，阈值与权重的变更可先在小比例流量中进行灰度验证，待确认问答质量提升后再全量部署。

[0092] 在一些实施例中，通过本申请还实现与大语言模型供应商提供的提示缓存机制的协同部署。

[0093] 具体地，在向大语言模型发送请求时，系统将构造的上下文显式划分为“稳定部分”与“动态部分”：

稳定部分：包括系统提示(System Prompt)、知识库固定底库等不随用户查询变化的内容。该部分被置于请求前缀位置，作为提示缓存的可缓存前缀，能够命中大语言模型供应商提供的提示缓存，从而降低重复计算成本。

[0094] 动态部分：包括本申请步骤S150和步骤S160输出的关键句基线与恢复的原文，该部分随用户查询动态变化，被置于缓存区之外，不参与提示缓存。

[0095] 由于本申请仅作用于原本就随查询动态变化的召回内容，不改写系统提示、固定知识库底库等稳定前缀，因此不破坏提示缓存的前缀稳定性。提示缓存带来的重复计算成本节省与本申请带来的上下文窗口占用节省两层优化可叠加而互不冲突。

[0096] 综上所述，一方面，本申请提供的技术方案采用句子级关键句作为基础承载单元，

同等Token预算(上下文预算)下可覆盖更多知识库片段的核心信息,避免高价值短句被一刀切丢弃,可以提高召回信息密度,从而提高大语言模型的回答质量;另一方面,本申请提供的技术方案采用“先铺关键句基线、有余量再恢复原文(关键句集对应的文档片段)”的双层分级压缩逻辑,优先保障召回信息覆盖广度,再优化高相关内容阅读深度,使得纳入模型上下文的信息可以兼顾问答全面性与细节丰富度。

[0097] 具体地,通过本申请提供的大语言模型的上下文压缩方法,具有以下有益效果:

有效信息密度最大化:以“要素覆盖且语义相关的关键句”为预算分配的基本单元,在相同Token预算下保留更多对答案有实质贡献的信息,相比单一截断或均匀压缩显著提升信息密度。

[0098] 关键句选取兼顾事实与论述:关键句综合评分将要素覆盖作为加权项而非硬门槛,既保留含实体、数值的事实句,也保留不含离散要素但高度相关的论述、结论句,避免单一标准选句的系统性遗漏。

[0099] 资源投放层次清晰且单调收敛:预算分配先铺设关键句基线(覆盖广度)、再以余量恢复最相关片段原文(关键内容深度),全过程只增不减、单调收敛,严格保证不超预算,工程上稳定、可复现。

[0100] 与提示缓存正交协同:本申请仅压缩动态召回内容、不改写稳定前缀,与供应商提示缓存机制互不冲突且可叠加;这是区别于改写历史前缀类压缩方案的关键工程特征-后者会破坏缓存前缀稳定性、导致缓存失效。

[0101] 领域自适应近零运维:综合评分阈值与权重通过问答质量反馈持续自调整,不同领域知识库自动获得最适配配置,无需人工逐领域调参。

[0102] 与现有 RAG 架构无缝兼容:作为“召回-生成”中间层透明插入,不依赖特定向量库、Embedding模型或大语言模型,企业既有RAG架构无需改造即可获得效果提升。

[0103] 图5是本申请实施例提供的一种大语言模型的上下文压缩装置的示意性框图。如图5所示,对应于以上大语言模型的上下文压缩方法,本申请还提供一种大语言模型的上下文压缩装置500。该大语言模型的上下文压缩装置500包括用于执行上述大语言模型的上下文压缩方法的单元,该大语言模型的上下文压缩装置500可以被配置于终端或服务器中。具体地,请参阅图5,该大语言模型的上下文压缩装置500包括收发单元501以及处理单元502,其中:

收发单元501,用于获取用户输入的查询信息;

处理单元502,用于基于所述查询信息从知识库中召回多个文档片段;分别计算每个所述文档片段与所述查询信息的文档相关性得分;分别将每个所述文档片段切分为多个句子,并分别计算每个句子与所述查询信息的句子相关性得分;针对每个所述文档片段,根据所述句子相关性得分以及预设的句子得分阈值从所述文档片段中选取关键句,得到每个所述文档片段分别对应的关键句集;在预设的上下文预算的约束下,根据所述文档相关性得分将各文档片段对应的关键句集依次纳入所述大语言模型的上下文,形成关键句基线;在所述关键句基线占用的预算未超过所述上下文预算的情况下,按照所述文档相关性得分从高到低的顺序,依次将已纳入所述关键句基线的关键句集替换为对应的文档片段,直至下一关键句集的替换将导致超出所述上下文预算时停止。

[0104] 在一些实施例中,所述处理单元502在执行所述分别计算每个所述文档片段与所

述查询信息的文档相关性得分的步骤时,具体用于:

分别计算每个所述文档片段与所述查询信息的向量语义相似度得分、词法相关度得分以及交叉编码器精排得分中的至少一个;

根据所述向量语义相似度得分、所述词法相关度得分以及所述交叉编码器精排得分中的至少一个确定每个所述文档片段的文档相关性得分。

[0105] 在一些实施例中,所述处理单元502在执行所述分别计算每个句子与所述查询信息的句子相关性得分的步骤时,具体用于:

分别计算每个句子与所述查询信息的语义相关度;

提取所述查询信息中的查询要素,分别计算每个句子对所述查询要素的要素覆盖得分;

根据所述语义相关度和所述要素覆盖得分,分别计算每个句子的所述句子相关性得分。

[0106] 在一些实施例中,所述处理单元502在执行所述在预设的上下文预算的约束下,根据所述文档相关性得分将各文档片段对应的关键句集依次纳入所述大语言模型的上下文,形成关键句基线的步骤时,具体用于:

按照所述文档相关性得分对每个关键句集从高到低进行排序;

将排序后的所述关键句集依次纳入所述大语言模型的上下文,直至下一关键句集的纳入将导致超出所述上下文预算或所述关键句集全部纳入时停止纳入,形成所述关键句基线。

[0107] 在一些实施例中,所述处理单元502在执行所述针对每个所述文档片段,根据所述句子相关性得分以及预设的句子得分阈值从所述文档片段中选取关键句,得到每个所述文档片段分别对应的关键句集的步骤时,具体用于:

针对每个所述文档片段,将所述文档片段中所述句子相关性得分大于或等于所述句子得分阈值的句子选取为关键句,得到每个所述文档片段分别对应的关键句集;

对于所有句子的句子相关性得分均小于所述句子得分阈值的文档片段,将所述文档片段中所述句子相关性得分最高的句子选取为关键句,得到所述文档片段的关键句集。

[0108] 在一些实施例中,所述处理单元502在执行所述在预设的上下文预算的约束下,根据所述文档相关性得分将各文档片段对应的关键句集依次纳入所述大语言模型的上下文,形成关键句基线的步骤时,具体用于:

若所述上下文预算小于相关性最高的文档片段的关键句集所占用的预算,则根据所述句子相关性得分从所述相关性最高的文档片段中逐句选取句子纳入所述上下文,直至达到所述上下文预算,形成关键句基线;

若所述上下文预算大于或等于相关性最高的文档片段的关键句集所占用的预算,则在预设的上下文预算的约束下,根据所述文档相关性得分将各文档片段对应的关键句集依次纳入所述大语言模型的上下文,形成关键句基线。

[0109] 在一些实施例中,所述处理单元502还用于:获取所述大语言模型针对所述上下文输出的问答结果的质量反馈信息;根据所述质量反馈信息调整所述句子得分阈值、所述句子相关性得分的相关计算权重以及所述文档相关性得分的相关计算权重的至少一项。

[0110] 综上所述,一方面,本申请提供的技术方案采用句子级关键句作为基础承载单元,

同等Token预算(上下文预算)下可覆盖更多知识库片段的核心信息,避免高价值短句被一刀切丢弃,可以提高召回信息密度,从而提高大语言模型的回答质量;另一方面,本申请提供的技术方案采用“先铺关键句基线、有余量再恢复原文(关键句集对应的文档片段)”的双层分级压缩逻辑,优先保障召回信息覆盖广度,再优化高相关内容阅读深度,使得纳入模型上下文的信息可以兼顾问答全面性与细节丰富度。

[0111] 需要说明的是,所属领域的技术人员可以清楚地了解到,上述大语言模型的上下文压缩装置和各单元的具体实现过程,可以参考前述方法实施例中的相应描述,为了描述的方便和简洁,在此不再赘述。

[0112] 上述大语言模型的上下文压缩装置可以实现为一种计算机程序的形式,该计算机程序可以在如图6所示的计算机设备上运行。

[0113] 请参阅图6,图6是本申请实施例提供的一种计算机设备的示意性框图。该计算机设备600可以是LLM网关。

[0114] 参阅图6,该计算机设备600包括通过系统总线601连接的处理器602、存储器和网络接口605,其中,存储器可以包括非易失性存储介质603和内存储器604。

[0115] 该非易失性存储介质603可存储操作系统6031和计算机程序6032。该计算机程序6032包括程序指令,该程序指令被执行时,可使得处理器602执行一种大语言模型的上下文压缩方法。

[0116] 该处理器602用于提供计算和控制能力,以支撑整个计算机设备600的运行。

[0117] 该内存储器604为非易失性存储介质603中的计算机程序6032的运行提供环境,该计算机程序6032被处理器602执行时,可使得处理器602执行一种大语言模型的上下文压缩方法。

[0118] 该网络接口605用于与其它设备进行网络通信。本领域技术人员可以理解,图6中示出的结构,仅仅是与本申请方案相关的部分结构的框图,并不构成对本申请方案所应用于其上的计算机设备600的限定,具体的计算机设备600可以包括比图中所示更多或更少的部件,或者组合某些部件,或者具有不同的部件布置。

[0119] 其中,所述处理器602用于运行存储在存储器中的计算机程序6032,以实现如下步骤:

获取用户输入的查询信息,基于所述查询信息从知识库中召回多个文档片段;

分别计算每个所述文档片段与所述查询信息的文档相关性得分;

分别将每个所述文档片段切分为多个句子,并分别计算每个句子与所述查询信息的句子相关性得分;

针对每个所述文档片段,根据所述句子相关性得分以及预设的句子得分阈值从所述文档片段中选取关键句,得到每个所述文档片段分别对应的关键句集;

在预设的上下文预算的约束下,根据所述文档相关性得分将各文档片段对应的关键句集依次纳入所述大语言模型的上下文,形成关键句基线;

在所述关键句基线占用的预算未超过所述上下文预算的情况下,按照所述文档相关性得分从高到低的顺序,依次将已纳入所述关键句基线的关键句集替换为对应的文档片段,直至下一关键句集的替换将导致超出所述上下文预算时停止。

[0120] 应当理解,在本申请实施例中,处理器602可以是中央处理单元 (Central

Processing Unit,CPU),该处理器602还可以是其他通用处理器、数字信号处理器(Digital Signal Processor,DSP)、专用集成电路 (Application Specific Integrated Circuit,ASIC)、现场可编程门阵列 (Field-Programmable Gate Array,FPGA) 或者其他可编程逻辑器件、分立门或者晶体管逻辑器件、分立硬件组件等。其中,通用处理器可以是微处理器或者该处理器也可以是任何常规的处理器等。

[0121] 本领域普通技术人员可以理解的是实现上述实施例的方法中的全部或部分流程,是可以通过计算机程序来指令相关的硬件来完成。该计算机程序包括程序指令,计算机程序可存储于一存储介质中,该存储介质为计算机可读存储介质。该程序指令被该计算机系统中的至少一个处理器执行,以实现上述方法的实施例的流程步骤。

[0122] 因此,本申请还提供一种存储介质。该存储介质可以为计算机可读存储介质。该存储介质存储有计算机程序,其中计算机程序包括程序指令。该程序指令被处理器执行时使处理器执行如下步骤:

获取用户输入的查询信息,基于所述查询信息从知识库中召回多个文档片段;

分别计算每个所述文档片段与所述查询信息的文档相关性得分;

分别将每个所述文档片段切分为多个句子,并分别计算每个句子与所述查询信息的句子相关性得分;

针对每个所述文档片段,根据所述句子相关性得分以及预设的句子得分阈值从所述文档片段中选取关键句,得到每个所述文档片段分别对应的关键句集;

在预设的上下文预算的约束下,根据所述文档相关性得分将各文档片段对应的关键句集依次纳入所述大语言模型的上下文,形成关键句基线;

在所述关键句基线占用的预算未超过所述上下文预算的情况下,按照所述文档相关性得分从高到低的顺序,依次将已纳入所述关键句基线的关键句集替换为对应的文档片段,直至下一关键句集的替换将导致超出所述上下文预算时停止。

[0123] 所述存储介质可以是U盘、移动硬盘、只读存储器(Read-Only Memory,ROM)、磁碟或者光盘等各种可以存储程序代码的计算机可读存储介质。

[0124] 本领域普通技术人员可以意识到,结合本文中所公开的实施例描述的各示例的单元及算法步骤,能够以电子硬件、计算机软件或者二者的结合来实现,为了清楚地说明硬件和软件的可互换性,在上述说明中已经按照功能一般性地描述了各示例的组成及步骤。这些功能究竟以硬件还是软件方式来执行,取决于技术方案的特定应用和设计约束条件。专业技术人员可以对每个特定的应用来使用不同方法来实现所描述的功能,但是这种实现不应认为超出本申请的范围。

[0125] 在本申请所提供的几个实施例中,应该理解到,所揭露的装置和方法,可以通过其它的方式实现。例如,以上所描述的装置实施例仅仅是示意性的。例如,各个单元的划分,仅仅为一种逻辑功能划分,实际实现时可以有另外的划分方式。例如多个单元或组件可以结合或者可以集成到另一个系统,或一些特征可以忽略,或不执行。

[0126] 本申请实施例方法中的步骤可以根据实际需要进行顺序调整、合并和删减。本申请实施例装置中的单元可以根据实际需要进行合并、划分和删减。另外,在本申请各个实施例中的各功能单元可以集成在一个处理单元中,也可以是各个单元单独物理存在,也可以是两个或两个以上单元集成在一个单元中。

[0127] 该集成的单元如果以软件功能单元的形式实现并作为独立的产品销售或使用时，可以存储在一个存储介质中。基于这样的理解，本申请的技术方案本质上或者说对现有技术做出贡献的部分，或者该技术方案的全部或部分可以以软件产品的形式体现出来，该计算机软件产品存储在一个存储介质中，包括若干指令用以使得一台计算机设备(可以是个人计算机，终端，或者网络设备等)执行本申请各个实施例所述方法的全部或部分步骤。

[0128] 以上所述，仅为本申请的具体实施方式，但本申请的保护范围并不局限于此，任何熟悉本技术领域的技术人员在本申请揭露的技术范围内，可轻易想到各种等效的修改或替换，这些修改或替换都应涵盖在本申请的保护范围之内。因此，本申请的保护范围应以权利要求的保护范围为准。

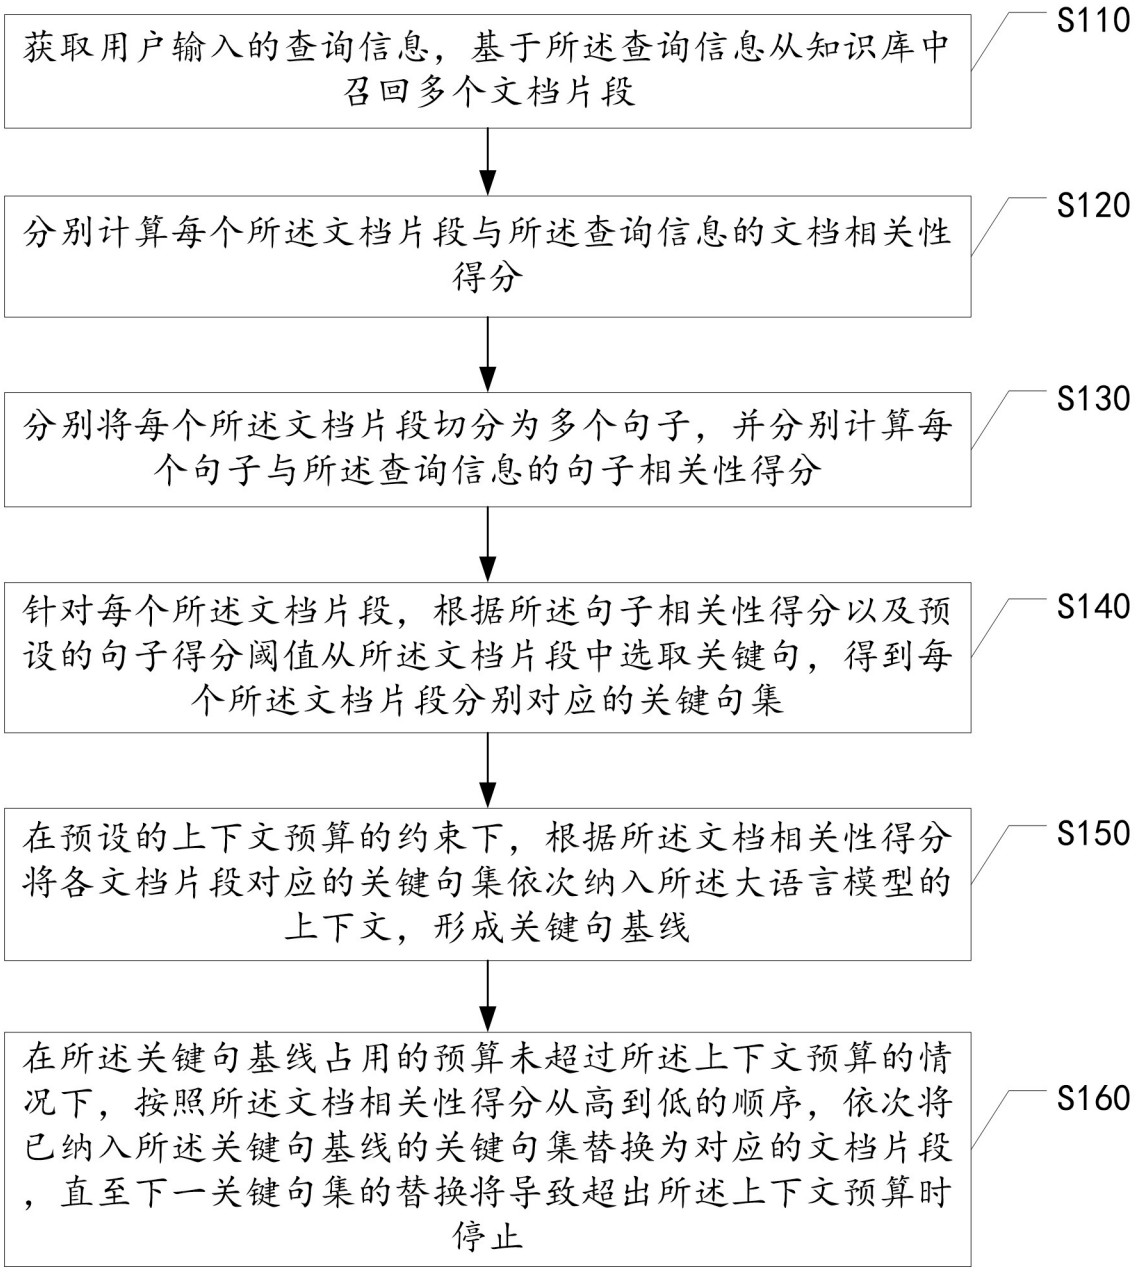

获取用户输入的查询信息，基于所述查询信息从知识库中召回多个文档片段
S110
分别计算每个所述文档片段与所述查询信息的文档相关性得分
S120
分别将每个所述文档片段切分为多个句子，并分别计算每个句子与所述查询信息的句子相关性得分
S130
针对每个所述文档片段，根据所述句子相关性得分以及预设的句子得分阈值从所述文档片段中选取关键句，得到每个所述文档片段分别对应的关键句集
S140
在预设的上下文预算的约束下，根据所述文档相关性得分将各文档片段对应的关键句集依次纳入所述大语言模型的上下文，形成关键句基线
S150
在所述关键句基线占用的预算未超过所述上下文预算的情况下，按照所述文档相关性得分从高到低的顺序，依次将已纳入所述关键句基线的关键句集替换为对应的文档片段，直至下一关键句集的替换将导致超出所述上下文预算时停止
S160

图 1

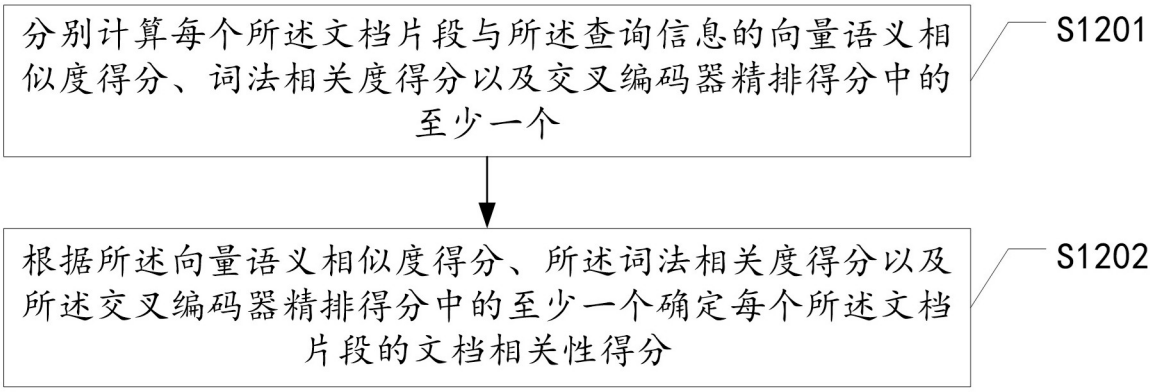

分别计算每个所述文档片段与所述查询信息的向量语义相似度得分、词法相关度得分以及交叉编码器精排得分中的至少一个
S1201
根据所述向量语义相似度得分、所述词法相关度得分以及所述交叉编码器精排得分中的至少一个确定每个所述文档片段的文档相关性得分
S1202

图 2

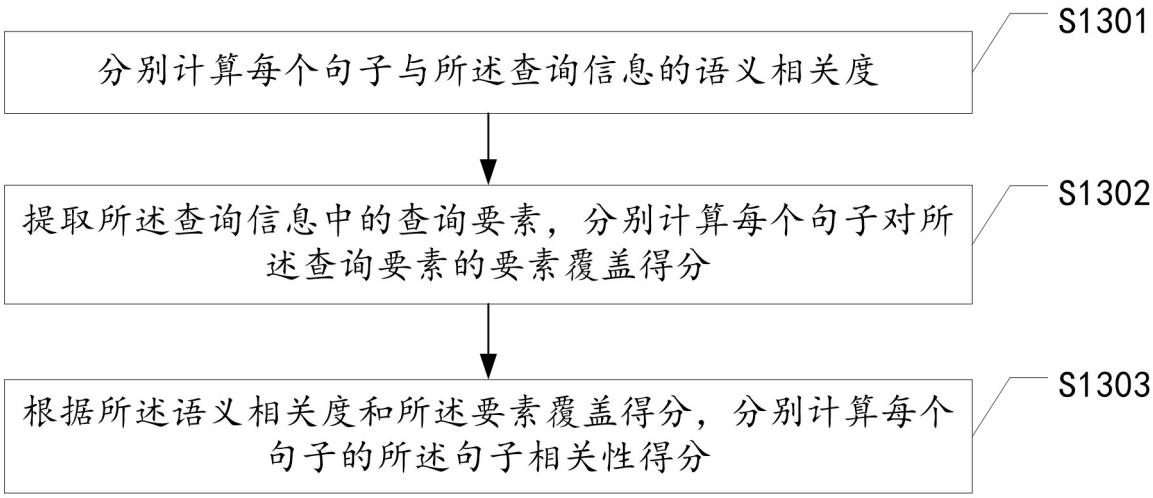

分别计算每个句子与所述查询信息的语义相关度
S1301
提取所述查询信息中的查询要素，分别计算每个句子对所述查询要素的要素覆盖得分
S1302
根据所述语义相关度和所述要素覆盖得分，分别计算每个句子的所述句子相关性得分
S1303

图 3

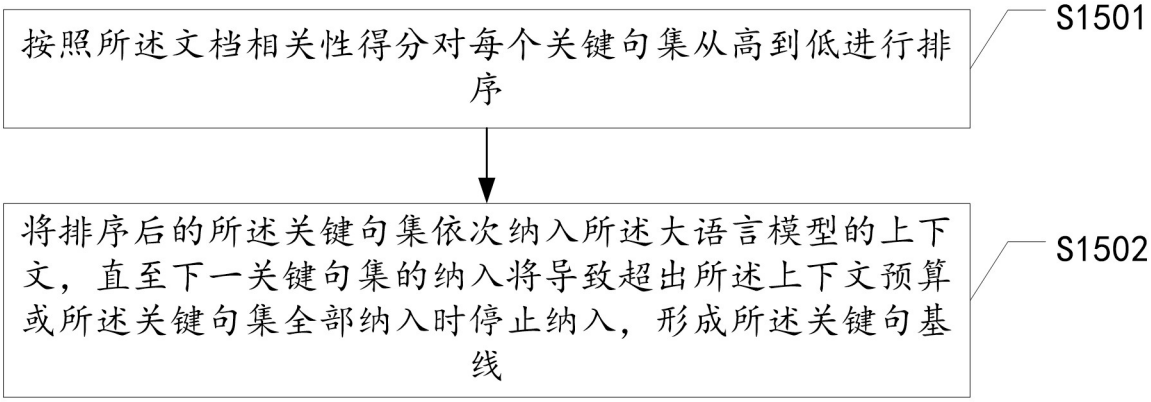

按照所述文档相关性得分对每个关键句集从高到低进行排序
S1501
将排序后的所述关键句集依次纳入所述大语言模型的上下文，直至下一关键句集的纳入将导致超出所述上下文预算或所述关键句集全部纳入时停止纳入，形成所述关键句基线
S1502

图 4

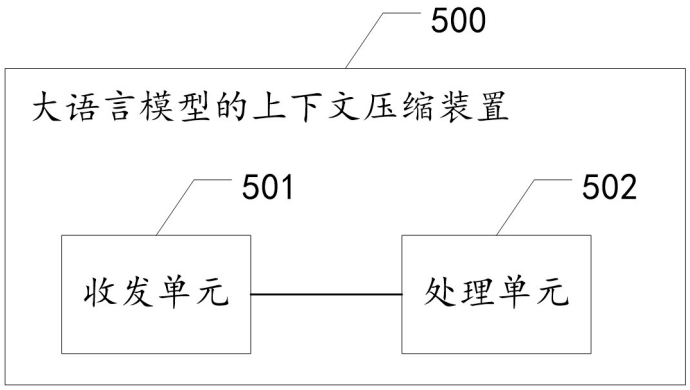

500
大语言模型的上下文压缩装置
501
502
收发单元
处理单元

图 5

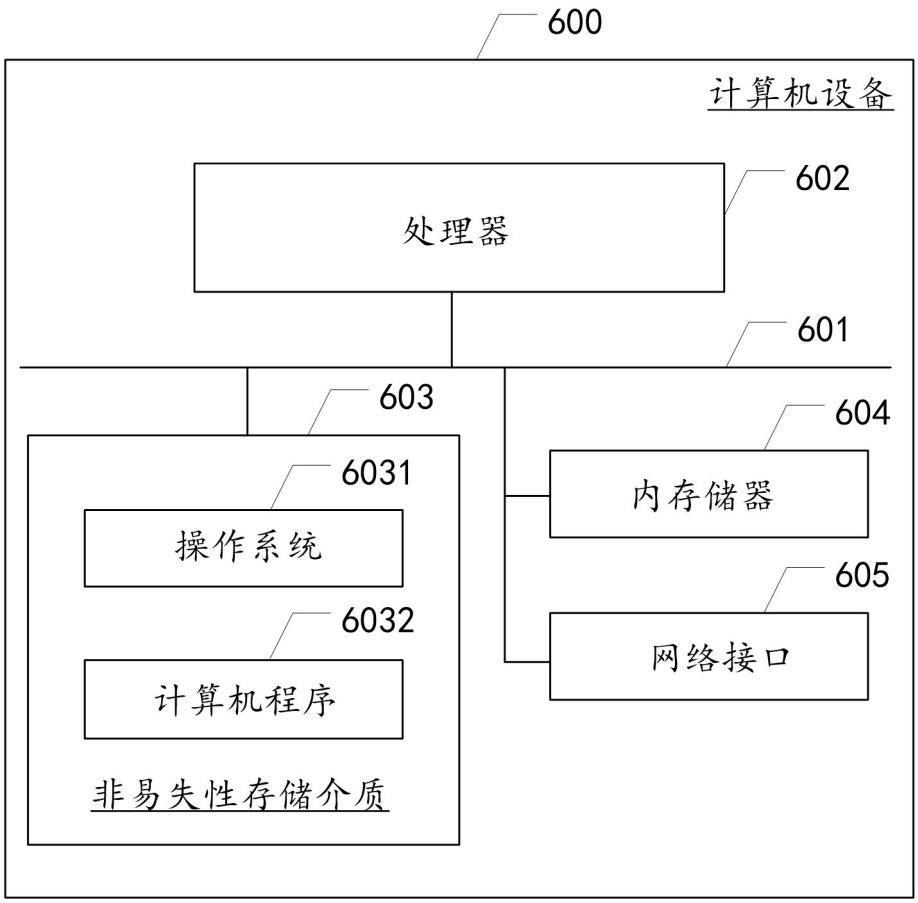

600
计算机设备
602
处理器
601
603
604
6031
内存储器
操作系统
605
6032
网络接口
计算机程序
非易失性存储介质

图 6