(19)国家知识产权局

(12)发明专利申请

(10)申请公布号 CN 122927306 A
(43)申请公布日 2026.10.16

(21)申请号 202611407466.2

(22)申请日 2026.09.11

(71)申请人 中科南京软件技术研究院
地址 211135 江苏省南京市江宁区麒麟科创园创研路266号人工智能产业园4号楼11楼

(72)发明人 吴祥 刘斌

(74)专利代理机构 南京钟山专利代理有限公司 32252
专利代理师 蒋厦

(51)Int.Cl.
G06F 40/30(2020.01)
G06N 3/0442(2023.01)
G06N 3/082(2023.01)
G06N 3/092(2023.01)
G06N 5/04(2023.01)

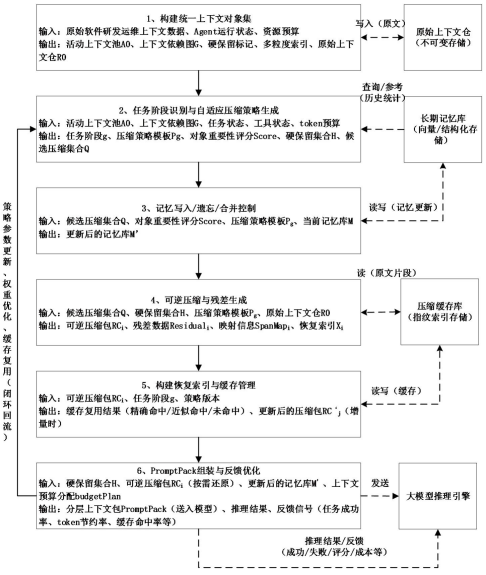
权利要求书3页 说明书24页 附图2页

(54)发明名称

一种阶段感知的大模型上下文可逆压缩与缓存方法及系统

(57)摘要

本发明公开了一种阶段感知的大模型上下文可逆压缩与缓存方法及系统,涉及人工智能及大模型推理优化技术领域。该方法包括:获取原始软件研发运维上下文,执行结构化切分与语义标注,构建上下文依赖图;识别当前任务阶段并匹配压缩策略模板,计算上下文重要性评分,划分硬保留集合与候选压缩集合;通过规则约束与强化学习混合决策架构对候选对象执行记忆操作;对需保留的上下文执行分层可逆压缩,生成支持按需展开和精确恢复的可逆压缩包;基于复合缓存键实现双通道缓存复用与增量更新;组装分层上下文包输入大模型,并根据监控反馈动态调整策略参数。本发明能够根据任务阶段自适应压缩上下文,在保证推理精度的同时显著提升上下文处理效率。



CN 122927306 A

1.一种阶段感知的大模型上下文可逆压缩与缓存方法,其特征在于,包括以下步骤:

S1:获取原始软件研发运维上下文数据并统一表示为上下文对象集合,对上下文对象执行结构化切分与语义标注;建立原始上下文仓与活动上下文池的协同存储机制,构建上下文依赖图;

S2:根据Agent的运行状态识别当前任务阶段,根据识别结果匹配对应的目标压缩策略模板,基于目标压缩策略模板和上下文依赖图,计算每个上下文对象在当前任务阶段下的重要性评分;根据重要性评分和硬保留规则,将上下文对象划分为硬保留集合和候选压缩集合;

S3:对候选压缩集合中的上下文对象,通过规则约束层与强化学习策略网络结合的混合决策架构输出记忆操作动作,根据记忆操作动作更新记忆集;根据目标压缩策略模板和重要性评分,对候选压缩集合中需保留的上下文对象执行分层可逆压缩,生成可逆压缩包;所述可逆压缩包包含用于还原原始内容的恢复信息,支持按需展开以恢复原始片段或原始上下文对象;

S4:根据各上下文对象的特征信息生成缓存键;若缓存键匹配则直接复用缓存,若语义相似度高于预设阈值则基于历史压缩包对差异部分执行增量处理后复用,缓存未命中时执行全量压缩并写入缓存;

S5:将硬保留集合与仅更新后的记忆集及可逆压缩包组装为分层上下文包,输入大模型执行当前任务;在任务执行过程中和任务完成后,根据任务执行结果采集反馈信息,对压缩策略模板的权重参数和混合决策架构的参数进行动态调整。

2.根据权利要求1所述的一种阶段感知的大模型上下文可逆压缩与缓存方法,其特征在于:步骤S1中,所述对上下文对象执行结构化切分与语义标注,包括:根据当前任务阶段或预判的任务阶段确定切分粒度参数和切分策略,对不同模态的上下文对象执行差异化切分,所述模态包括自然语言文本、代码、工具返回结果、图像数据和音频数据;每个切分单元记录其与上一级粒度及下一级粒度之间的聚合映射关系和拆分映射关系,形成多粒度层级索引。

3.根据权利要求1所述的一种阶段感知的大模型上下文可逆压缩与缓存方法,其特征在于:步骤S1中,所述构建上下文依赖图,具体过程为:

以各上下文对象为节点,以上下文对象之间的时间邻接关系、语义相似关系、因果关联关系、引用关系、工具调用链关系或代码依赖关系为边构建上下文依赖图;每个节点维护热度值,所述热度值在节点被成功召回时增加并按时间衰减函数定期更新;当上下文依赖图的节点规模超过预设阈值时,删除满足热度值低于预设阈值、时间衰减超过预设窗口且不属于硬保留集合的节点及其关联边。

4.根据权利要求1所述的一种阶段感知的大模型上下文可逆压缩与缓存方法,其特征在于:步骤S2中,所述基于目标压缩策略模板和上下文依赖图,计算每个上下文对象在当前任务阶段下的重要性评分,具体包括:

基于上下文对象与当前任务目标的任务相关性、上下文对象在上下文依赖图中的关键程度、信息时效性、来源可信度、未来复用概率、信息新颖性、精确保留标记、跨模态对齐相关性和归一化对数token长度的加权和计算重要性评分;

所述当前任务阶段包括检索准备阶段、规划阶段、工具调用阶段、执行阶段、反思纠错

阶段和输出生成阶段;所述Agent的运行状态包括当前系统控制器状态、最近一次模型输出动作类型、是否存在待调用工具、是否存在工具执行失败或异常、当前是否处于总结输出环节、当前token预算余量以及当前任务链路中的子目标完成情况。

5.根据权利要求1所述的一种阶段感知的大模型上下文可逆压缩与缓存方法,其特征在于:

步骤S3中,记忆操作动作包括写入原文记忆、写入压缩记忆、与已有记忆合并、延迟写入、遗忘删除、仅更新索引、记忆升级和记忆降级;

所述可逆压缩包包含关键片段集合、关键片段到原始区间的映射关系、被省略片段的完整残差,或指向不可变原始上下文仓的原文指针、源版本号和起止偏移,以及校验值;在强可逆模式下依靠包内完整残差独立恢复,在标准模式下依靠所述原文指针从不可变原始上下文仓加载对应版本后恢复,支持按需展开,恢复原始片段或原始上下文对象。

6.根据权利要求1所述的一种阶段感知的大模型上下文可逆压缩与缓存方法,其特征在于:步骤S3中,所述规则约束层与强化学习策略网络结合的混合决策架构,具体为:

第一层为规则约束层,用于依据预设安全规则对候选上下文对象进行硬性过滤并强制输出对应的记忆操作动作;

第二层为强化学习策略网络层,用于对通过规则约束层筛选的候选上下文对象由在线Q网络输出各记忆操作动作的Q值并依据ε-贪婪策略选择最终动作;

第三层为后处理校验层,用于对强化学习策略网络层输出的动作执行二次安全校验,若所选动作将导致高价值记忆被遗忘且当前阶段为规划阶段或反思阶段,则强制降级为延迟写入;若所选动作将合并两个冲突记忆,则触发人工校验标记或降级为仅更新索引。

7.根据权利要求1所述的一种阶段感知的大模型上下文可逆压缩与缓存方法,其特征在于:步骤S4中,所述根据各上下文对象的特征信息生成缓存键具体为:对各上下文对象的特征信息执行规范化编码后拼接为字节串,再对字节串进行哈希运算得到复合缓存键;所述各上下文对象的特征信息包括:原始内容哈希、分词器版本、模型版本、压缩策略版本、任务阶段标识、任务目标哈希、预算区间标识、精确保留标记、依赖图签名和数据结构版本号;所述规范化编码包括字段名排序、空值占位、字符集统一和浮点数量化。

8.一种阶段感知的大模型上下文可逆压缩与缓存系统,用于实现如权利要求1~7任一项所述的一种阶段感知的大模型上下文可逆压缩与缓存方法,其特征在于,包括:

上下文采集与结构化管理模块,用于获取原始软件研发运维上下文数据并统一表示为上下文对象集合,对上下文对象执行结构化切分与语义标注;建立原始上下文仓与活动上下文池的协同存储机制,构建上下文依赖图;

任务阶段识别与压缩策略选择模块,用于根据Agent的运行状态识别当前任务阶段,根据识别结果匹配对应的目标压缩策略模板,基于目标压缩策略模板和上下文依赖图,计算每个上下文对象在当前任务阶段下的重要性评分;根据重要性评分和硬保留规则,将上下文对象划分为硬保留集合和候选压缩集合;

记忆调度与压缩模块,用于对候选压缩集合中的上下文对象,通过规则约束层与强化学习策略网络结合的混合决策架构输出记忆操作动作,根据记忆操作动作更新记忆集;根据目标压缩策略模板和重要性评分,对候选压缩集合中需保留的上下文对象执行分层可逆压缩,生成可逆压缩包;所述可逆压缩包包含用于还原原始内容的恢复信息,支持按需展开

以恢复原始片段或原始上下文对象；

缓存管理模块，用于根据各上下文对象的特征信息生成缓存键；若缓存键匹配则直接复用缓存，若语义相似度高于预设阈值则基于历史压缩包对差异部分执行增量处理后复用，缓存未命中时执行全量压缩并写入缓存；

上下文组装与优化模块，用于将硬保留集合与仅更新后的记忆集及可逆压缩包组装为分层上下文包，输入大模型执行当前任务；在任务执行过程中和任务完成后，根据任务执行结果采集反馈信息，对压缩策略模板的权重参数和混合决策架构的参数进行动态调整。

9.一种电子设备，其特征在于，包括：存储器、处理器及存储在存储器上并可在处理器上运行的计算机程序，所述处理器执行计算机程序时，实现如权利要求1~7任一项所述的一种阶段感知的大模型上下文可逆压缩与缓存方法。

10.一种计算机可读存储介质，其上存储有计算机程序，其特征在于：所述计算机程序使计算机执行如权利要求1~7任一项所述的一种阶段感知的大模型上下文可逆压缩与缓存方法。

一种阶段感知的大模型上下文可逆压缩与缓存方法及系统

技术领域

[0001] 本发明涉及人工智能及大模型推理优化技术领域,具体涉及一种阶段感知的大模型上下文可逆压缩与缓存方法及系统。

背景技术

[0002] 大语言模型及多模态大模型在智能体式软件研发运维领域中的应用日益深入,覆盖代码生成、代码修复、代码审查、自动化测试生成、构建部署诊断、缺陷定位、知识库检索、复杂任务规划、工具自动调用、执行结果反思等关键环节。在此类智能体系统中,单次推理所需处理的上下文规模急剧膨胀,且上下文数据不仅包括自然语言描述,还涉及源码文件、函数签名、API契约、测试断言、构建参数、异常堆栈、版本号及补丁差异等结构化程度高、语义密集且对精确性要求极为严格的内容。

[0003] 针对上述问题,工业界主要从三个方向展开探索:一是直接扩展模型的上下文窗口,通过改进注意力机制或位置编码提升模型对长序列的处理能力;二是在输入侧对上下文进行压缩,以摘要或截断的方式缩减上下文长度;三是在模型内部对键值缓存(KV Cache)进行压缩或复用,减少推理过程中的显存占用和计算开销。

[0004] 尽管上述方案在特定场景下取得了一定效果,但在真实业务部署中仍面临若干难以回避的问题。

[0005] 在Agent场景中,不同任务阶段对上下文的需求差异显著,规划阶段更依赖目标定义、约束条件和全局依赖关系,工具调用阶段更关注接口参数、最近观测结果和执行上下文,反思阶段则侧重失败原因、异常轨迹和决策偏差。现有的压缩方案大多采用固定的摘要长度、统一的截断比例或单一的相似度阈值,难以在效率和效果之间取得平衡。

[0006] 具体到智能体式软件研发运维领域,规划阶段通常需要保留需求目标、仓库结构、依赖配置和验收标准,工具调用阶段需要保留工具名称、命令参数、路径、分支、版本号、状态码和异常堆栈,执行阶段需要保留待修改代码块、测试断言、构建脚本和环境变量,反思纠错阶段需要保留失败轨迹、回滚记录、补丁差异和未通过测试信息。

[0007] 在软件研发运维智能体的代码修复、代码审查、自动化测试生成、构建部署诊断及缺陷定位场景中,源代码顺序、函数签名、接口参数、异常堆栈、版本号、测试断言、配置项乃至标点符号都可能直接影响推理结果的正确性。现有方案多采用语义摘要或生成式补全来实现所谓的恢复,本质上仍属于有损压缩,恢复后的内容无法保证与原文在token级别完全一致,引入的信息失真风险在高精度任务中难以接受。

[0008] 当相同或相似的上下文内容在RAG、长会话或循环Agent流程中被反复输入时,现有系统通常重复执行嵌入计算、重要性打分和摘要生成,缺乏对历史压缩结果的有效缓存和增量更新机制,造成明显的算力浪费。

[0009] 多数系统将上下文是否写入长期记忆的决定交由固定阈值或简单规则控制,容易导致低价值信息反复写入、高价值信息却被遗漏,记忆库随任务执行逐渐膨胀而质量持续下降,后续检索的命中率和相关性均受到影响。

发明内容

[0010] 本发明的目的是提供一种阶段感知的大模型上下文可逆压缩与缓存方法及系统，以解决现有大模型上下文管理方案在智能体式软件研发运维领域中，因缺乏任务阶段感知、压缩信息不可精确可逆恢复、缓存与记忆调度机制僵化以及缺少闭环自适应优化，导致推理精度与处理效率难以兼顾的技术问题。

[0011] 为实现上述目的，本发明提供的技术方案是：一种阶段感知的大模型上下文可逆压缩与缓存方法，包括以下步骤：

S1：获取原始软件研发运维上下文数据并统一表示为上下文对象集合，对上下文对象执行结构化切分与语义标注；建立原始上下文仓与活动上下文池的协同存储机制，构建上下文依赖图；

S2：根据Agent的运行状态识别当前任务阶段，根据识别结果匹配对应的目标压缩策略模板，基于目标压缩策略模板和上下文依赖图，计算每个上下文对象在当前任务阶段下的重要性评分；根据重要性评分和硬保留规则，将上下文对象划分为硬保留集合和候选压缩集合；

S3：对候选压缩集合中的上下文对象，通过规则约束层与强化学习策略网络结合的混合决策架构输出记忆操作动作，根据记忆操作动作更新记忆集；根据目标压缩策略模板和重要性评分，对候选压缩集合中需保留的上下文对象执行分层可逆压缩，生成可逆压缩包；所述可逆压缩包包含用于还原原始内容的恢复信息，支持按需展开以恢复原始片段或原始上下文对象；

S4：根据各上下文对象的特征信息生成缓存键；若缓存键匹配则直接复用缓存，若语义相似度高于预设阈值则基于历史压缩包对差异部分执行增量处理后复用，缓存未命中时执行全量压缩并写入缓存；

S5：将硬保留集合与仅更新后的记忆集及可逆压缩包组装为分层上下文包，输入大模型执行当前任务；在任务执行过程中和任务完成后，根据任务执行结果采集反馈信息，对压缩策略模板的权重参数和混合决策架构的参数进行动态调整。

[0012] 为优化上述技术方案，采取的具体措施还包括：

步骤S1中，所述对上下文对象执行结构化切分与语义标注，包括：根据当前任务阶段或预判的任务阶段确定切分粒度参数和切分策略，对不同模态的上下文对象执行差异化切分，所述模态包括自然语言文本、代码、工具返回结果、图像数据和音频数据；每个切分单元记录其与上一级粒度及下一级粒度之间的聚合映射关系和拆分映射关系，形成多粒度层级索引。

[0013] 进一步地，步骤S1中，所述构建上下文依赖图，具体过程为：

以各上下文对象为节点，以上下文对象之间的时间邻接关系、语义相似关系、因果关联关系、引用关系、工具调用链关系或代码依赖关系为边构建上下文依赖图；每个节点维护热度值，所述热度值在节点被成功召回时增加并按时间衰减函数定期更新；当上下文依赖图的节点规模超过预设阈值时，删除满足热度值低于预设阈值、时间衰减超过预设窗口且不属于硬保留集合的节点及其关联边。

[0014] 步骤S2中，所述基于目标压缩策略模板和上下文依赖图，计算每个上下文对象在当前任务阶段下的重要性评分，具体包括：

基于上下文对象与当前任务目标的任务相关性、上下文对象在上下文依赖图中的关键程度、信息时效性、来源可信度、未来复用概率、信息新颖性、精确保留标记、跨模态对齐相关性和归一化对数token长度的加权和计算重要性评分。

[0015] 步骤S2中,所述当前任务阶段包括检索准备阶段、规划阶段、工具调用阶段、执行阶段、反思纠错阶段和输出生成阶段;所述Agent的运行状态包括当前系统控制器状态、最近一次模型输出动作类型、是否存在待调用工具、是否存在工具执行失败或异常、当前是否处于总结输出环节、当前token预算余量以及当前任务链路中的子目标完成情况。

[0016] 进一步地,步骤S2中,所述目标压缩策略模板至少包括压缩粒度、硬保留规则、评分权重参数组、上下文预算分配方案和可逆压缩模式标识;不同任务阶段对应的压缩策略模板采用差异化配置:

在检索准备阶段和所述规划阶段,压缩粒度配置为段落级或文件级,硬保留规则优先保留任务目标、用户约束和全局依赖;

在工具调用阶段,压缩粒度配置为句子级或函数签名级,硬保留规则优先保留工具名称、参数和异常码,可逆压缩模式配置为强可逆模式;

在执行阶段,压缩粒度配置为代码块级或函数级,硬保留规则优先保留可重入的执行上下文、关键观测值和异常现场;

进一步地,在反思纠错阶段,压缩粒度配置为错误传播路径级或语义片段级,硬保留规则优先保留失败轨迹、错误消息和尝试历史,可逆压缩模式配置为强可逆模式;

在输出生成阶段,压缩粒度配置为证据片段级,硬保留规则优先保留结论支撑证据和引用原文。

[0017] 进一步地,步骤S3中,记忆操作动作包括写入原文记忆、写入压缩记忆、与已有记忆合并、延迟写入、遗忘删除、仅更新索引、记忆升级和记忆降级;

所述可逆压缩包包含关键片段集合、关键片段到原始区间的映射关系、被省略片段的完整残差,或指向不可变原始上下文仓的原文指针、源版本号和起止偏移,以及校验值;在强可逆模式下依靠包内完整残差独立恢复,在标准模式下依靠所述原文指针从不可变原始上下文仓加载对应版本后恢复,支持按需展开,恢复原始片段或原始上下文对象。

[0018] 步骤S3中,所述规则约束层与强化学习策略网络结合的混合决策架构,具体为:

第一层规则约束层,用于依据预设安全规则对候选上下文对象进行硬性过滤并强制输出对应的记忆操作动作;

第二层强化学习策略网络层,用于对通过规则约束层筛选的候选上下文对象由在线Q网络输出各记忆操作动作的Q值并依据ε-贪婪策略选择最终动作;

进一步地,第三层后处理校验层,用于对强化学习策略网络层输出的动作执行二次安全校验,若所选动作将导致高价值记忆被遗忘且当前阶段为规划阶段或反思阶段,则强制降级为延迟写入;若所选动作将合并两个冲突记忆,则触发人工校验标记或降级为仅更新索引。

[0019] 步骤S3中,所述强化学习策略网络层采用双重深度Q网络结构,包括在线Q网络和目标Q网络;在线Q网络基于经验回放样本更新参数并用于选择下一动作,目标Q网络用于计算时序差分目标值并每隔预设步数从在线Q网络同步参数;所述奖励基于任务成功率、检索命中效果、节约的token数量、缓存复用效果、因压缩导致的错误推理代价、按需还原的额外

延迟和噪声记忆累积程度中的多项综合计算。

[0020] 步骤S3中,记忆操作动作包括写入原文记忆、写入压缩记忆、与已有记忆合并、延迟写入、遗忘删除、仅更新索引、记忆升级和记忆降级;

所述可逆压缩包包含关键片段集合、关键片段到原始区间的映射关系、被省略片段的完整残差,或指向不可变原始上下文仓的原文指针、源版本号和起止偏移,以及校验值;在强可逆模式下依靠包内完整残差独立恢复,在标准模式下依靠所述原文指针从不可变原始上下文仓加载对应版本后恢复,支持按需展开,恢复原始片段或原始上下文对象。

[0021] 进一步地,步骤S3中,所述记忆集包括短期运行记忆、阶段性情节记忆、长期语义记忆、工具经验记忆和错误模式记忆;所述记忆集支持双向迁移,短期运行记忆中被频繁召回的条目可升级至阶段性情节记忆,阶段性情节记忆中被多次验证为稳定知识的条目可抽象后写入长期语义记忆,长期语义记忆中的经验条目如被多次修正则降级至错误模式记忆。

[0022] 步骤S3中,所述分层可逆压缩包括以下层级:

第一层片段级筛选:仅对候选压缩集合中的每个切分单元执行保留、压缩或载荷省略判定;局部重要性评分高于第一阈值的切分单元完整保留,介于第一阈值与第二阈值之间的切分单元进入第二层压缩,低于第二阈值的切分单元仅从模型推理载荷中省略;对载荷省略单元,强可逆模式将其完整残差写入可逆压缩包,标准模式将其原文指针、源版本号、起止偏移和校验值写入可逆压缩包;

进一步地,第二层单元内压缩:对进入第二层的切分单元采用关键要素抽取、结构保留性摘要、去重与合并、参数精简或差分编码中的至少一种方式进行内容压缩;

第三层跨单元引用压缩:对存在依赖关系的多个切分单元,若单元间内容相似度高于预设阈值,则其中之一存储完整内容,其余单元存储指向该单元的引用指针及差异补丁。

[0023] 步骤S3中,所述可逆压缩包的恢复信息根据压缩模式和内容类型自适应编码:强可逆模式存储全部省略内容的完整残差,实现包内自包含恢复;标准模式至少存储指向不可变原始上下文仓的原文指针、源版本号、起止偏移和校验值,实现依赖原始上下文仓的系统级可逆恢复。

[0024] 对自然语言文本采用原文指针加被删片段起止位置偏移量或差分编码加位置映射;

进一步地,对代码采用原文指针加被删代码行行号范围或逐token差分编码加AST节点位置映射;

对结构化数据采用被删字段的路径加默认值标记或完整字段级位置映射加值变化日志;

对日志或时序数据采用首项加差异序列的差分编码。

[0025] 进一步地,步骤S3中,所述可逆压缩包支持按需展开,恢复原始片段或原始上下文对象,具体为:

所述片段级恢复为:根据被请求片段的标识在映射关系中定位目标片段在压缩包中的存储位置,从残差存储或原文指针中提取对应内容,与关键片段集合中的相关内容拼接后返回;

所述上下文对象级恢复为:按位置编码记录的顺序将关键片段集合中的片段与残差存储中的残差片段依次拼接,通过结构标签恢复结构层级,重建完整的原始上下文对象;

恢复完成后通过所述校验值进行一致性校验,若校验不通过则回退至原始上下文仓中对应的原文版本。

[0026] 步骤S4中,所述增量压缩包括:

基于滚动哈希定位差异片段;基于Diff算法提取新增、删除或修改片段生成差异描述;仅对差异描述中的新增片段或修改片段执行重要性评分和压缩,生成增量压缩包;将增量压缩包中的映射关系和残差存储与历史压缩包的对应结构进行合并,更新位置偏移量和引用指针,并递增版本号。

[0027] 进一步地,步骤S4中,所述根据各上下文对象的特征信息生成缓存键具体为:对各上下文对象的特征信息执行规范化编码后拼接为字节串,再对字节串进行哈希运算得到复合缓存键;所述各上下文对象的特征信息包括:原始内容哈希、分词器版本、模型版本、压缩策略版本、任务阶段标识、任务目标哈希、预算区间标识、精确保留标记、依赖图签名和数据结构版本号;所述规范化编码包括字段名排序、空值占位、字符集统一和浮点数量化。

[0028] 若两个上下文块原始内容相同,但分词器版本、模型版本、压缩策略版本、任务目标哈希、预算区间标识、精确保留标记、依赖图签名或数据结构版本中任一项不同,则禁止进入精确命中通道。

[0029] 步骤S5中,所述分层上下文包按以下优先级顺序组装;硬保留集合中的对象按其内容类型仅装载至L1系统约束层、L2任务目标层或L4工具调用、关键观测与精确保留层中的一个对应层,不再重复装载至更新后的记忆集或可逆压缩包对应层:

L1系统约束层,包含系统角色定义、安全边界和输出格式规范,由硬保留集合中的系统级约束项构成,优先级最高且不参与压缩;

L2任务目标层,包含用户原始意图、任务完成判据和显式要求;

L3核心活动记忆层,包含根据当前任务阶段从更新后的记忆集中检索的高相关性记忆条目;

L4工具调用、关键观测与精确保留层,包含最近一次工具调用的输入参数、返回关键值、状态码和异常信息,以及无法归入L1或L2但命中硬保留规则的关键证据、代码片段、API契约、测试断言、构建参数、异常堆栈或版本号;H中的对象在本层完整装载且不参与压缩;

L5压缩证据层,包含可逆压缩包中的关键片段集合;

L6可逆索引附录层,包含可逆压缩包中的映射关系、残差存储和位置编码;

进一步地,当累积token数超过当前阶段预算上限时,从L5层开始进行二次压缩,L1至L4层不参与二次压缩。

[0030] 进一步地,步骤S5中,所述根据任务执行结果采集反馈信息包括以下触发条件及对应操作:

当模型输出置信度低于预设阈值时,触发片段级按需展开;

当工具返回错误码或异常时,将失败轨迹写入错误模式记忆并触发上下文对象级按需展开;

当模型输出声称引用但压缩包中无对应映射关系时,触发一致性校验,校验失败

则回退至原始上下文仓中的原文;

进一步地,当检测到参数冲突时,触发冲突对应片段的按需展开并将冲突记录写入错误模式记忆;当缓存连续多次未命中时,触发缓存预热机制。

[0031] 步骤S5中,所述对压缩策略模板的权重参数和混合决策架构的参数进行动态调整包括:

基于任务成功率、答案正确率、token节约率、缓存命中率、按需展开恢复次数和用户修订次数中的一项或多项指标,更新压缩策略模板中的评分权重参数组和预算分配方案,以及更新强化学习策略网络的奖励函数参数。

[0032] 作为另一个重要的技术方案,本发明还提供一种阶段感知的大模型上下文可逆压缩与缓存系统,实现如上所述的一种阶段感知的大模型上下文可逆压缩与缓存方法,包括:

上下文采集与结构化管理模块,用于获取原始软件研发运维上下文数据并统一表示为上下文对象集合,对上下文对象执行结构化切分与语义标注;建立原始上下文仓与活动上下文池的协同存储机制,构建上下文依赖图;

任务阶段识别与压缩策略选择模块,用于根据Agent的运行状态识别当前任务阶段,根据识别结果匹配对应的目标压缩策略模板,基于目标压缩策略模板和上下文依赖图,计算每个上下文对象在当前任务阶段下的重要性评分;根据重要性评分和硬保留规则,将上下文对象划分为硬保留集合和候选压缩集合;

记忆调度与压缩模块,用于对候选压缩集合中的上下文对象,通过规则约束层与强化学习策略网络结合的混合决策架构输出记忆操作动作,根据记忆操作动作更新记忆集;根据目标压缩策略模板和重要性评分,对候选压缩集合中需保留的上下文对象执行分层可逆压缩,生成可逆压缩包;所述可逆压缩包包含用于还原原始内容的恢复信息,支持按需展开以恢复原始片段或原始上下文对象;

缓存管理模块,用于根据各上下文对象的特征信息生成缓存键;若缓存键匹配则直接复用缓存,若语义相似度高于预设阈值则基于历史压缩包对差异部分执行增量处理后复用,缓存未命中时执行全量压缩并写入缓存;

上下文组装与优化模块,用于将硬保留集合与仅更新后的记忆集及可逆压缩包组装为分层上下文包,输入大模型执行当前任务;在任务执行过程中和任务完成后,根据任务执行结果采集反馈信息,对压缩策略模板的权重参数和混合决策架构的参数进行动态调整。

[0033] 本发明还提出了一种电子设备,包括:存储器、处理器及存储在存储器上并可在处理器上运行的计算机程序,所述处理器执行计算机程序时,实现如上所述的一种阶段感知的大模型上下文可逆压缩与缓存方法。

[0034] 本发明还提出了一种计算机可读存储介质,存储有计算机程序,所述计算机程序使计算机执行如上所述的一种阶段感知的大模型上下文可逆压缩与缓存方法。

[0035] 与现有技术相比,本发明的有益效果是:

本发明通过规划阶段优先保留目标与约束,工具调用阶段侧重参数与异常码,反思阶段聚焦失败轨迹,输出生成阶段保留证据原文,相比统一压缩方式,该机制在同等token预算下有效避免了关键约束丢失、参数缺失和证据断裂,提升了长链任务执行的稳定性与准确性。

[0036] 本发明基于时间邻接、因果关联、引用关系及工具调用链构建上下文依赖图,结合阶段差异化权重综合评估上下文价值,能够识别短小但承载关键约束的信息,也能过滤冗长低价值的背景内容,为压缩和记忆调度提供可解释的决策依据,提升预算利用效率。

[0037] 本发明将记忆分层管理,由规则约束保障硬保留内容的安全底线,由强化学习策略网络根据任务成功率、检索命中率、token节约等奖励信号自主决策写入、合并、延迟或遗忘,并通过后处理校验兜底,有效抑制了记忆库的无序膨胀,使系统在长周期运行中保持高价值记忆的召回质量。

[0038] 本发明通过片段级筛选、单元内压缩和跨单元引用压缩三层结构生成可逆压缩包,支持片段级或对象级按需展开精确恢复原文,并通过校验值与原始仓回退保障一致性。适用于代码审查、代码修复、自动化测试生成、构建部署诊断及缺陷定位等智能体式软件研发运维高精度场景既能享受压缩带来的效率提升,又可在需要时精确还原原文,消除有损压缩的推理偏差风险。

[0039] 本发明融合任务阶段、目标哈希、依赖图签名等维度生成复合缓存键实现精确命中;对相似内容仅对变化部分执行增量压缩并与历史包合并复用,有效避免了重复压缩的计算开销,同时通过版本控制防止模型或策略变更导致的错误复用。

[0040] 本发明将任务执行与结果反馈形成闭环,基于成功率、缓存命中率、节约率、恢复次数及用户修订频次等指标持续更新策略权重和奖励参数,随部署时间增长,系统持续自适应优化,具备较强的工程落地价值。

[0041] 在智能体式软件研发运维系统中,本发明将代码仓库、持续集成流水线、测试平台、缺陷管理系统和接口文档库中的上下文对象纳入同一可逆压缩与缓存链路,使工具调用参数、构建日志、异常堆栈、测试断言和补丁差异能够被阶段化保留、压缩、缓存和按需恢复,从而降低长链自动化研发任务中的重复计算、错误复用和关键技术细节丢失风险。

附图说明

[0042] 图1为本发明实施例中的流程示意图。

[0043] 图2为本发明实施例中构建可逆压缩包流程示意图。

具体实施方式

[0044] 以下通过具体实施方式的形式对本发明的上述内容再作进一步的详细说明,但不应将此理解为本发明上述主题的范围仅限于以下的实施例,凡基于本发明上述内容所实现的技术均属于本发明的范围。

[0045] 在以下实施方式中,原始软件研发运维上下文数据具体为智能体式软件研发运维领域的软件研发运维智能体上下文数据,所述软件研发运维智能体用于在代码仓库、持续集成流水线、缺陷管理系统、接口文档库和测试平台之间执行代码生成、代码修复、自动化测试、构建部署诊断及缺陷定位任务。

[0046] 在一些实施方式中,如图1所示,本发明提供了一种阶段感知的大模型上下文可逆压缩与缓存方法,包括以下步骤:

S1:获取原始软件研发运维上下文数据并统一表示为上下文对象集合,对上下文对象执行结构化切分与语义标注;建立原始上下文仓与活动上下文池的协同存储机制,构

建上下文依赖图;

S2:根据Agent的运行状态识别当前任务阶段,根据识别结果匹配对应的目标压缩策略模板,基于目标压缩策略模板和上下文依赖图,计算每个上下文对象在当前任务阶段下的重要性评分;根据重要性评分和硬保留规则,将上下文对象划分为硬保留集合和候选压缩集合;

S3:对候选压缩集合中的上下文对象,通过规则约束层与强化学习策略网络结合的混合决策架构输出记忆操作动作,根据记忆操作动作更新记忆集;根据目标压缩策略模板和重要性评分,对候选压缩集合中需保留的上下文对象执行分层可逆压缩,生成可逆压缩包;可逆压缩包包含用于还原原始内容的恢复信息,支持按需展开以恢复原始片段或原始上下文对象;

S4:根据各上下文对象的特征信息生成缓存键;若缓存键匹配则直接复用缓存,若语义相似度高于预设阈值则基于历史压缩包对差异部分执行增量处理后复用,缓存未命中时执行全量压缩并写入缓存;

S5:将硬保留集合与仅更新后的记忆集及可逆压缩包组装为分层上下文包,输入大模型执行当前任务;在任务执行过程中和任务完成后,根据任务执行结果采集反馈信息,对压缩策略模板的权重参数和混合决策架构的参数进行动态调整。

[0047] 在一些实施方式中,步骤S1中获取原始软件研发运维上下文数据由软件研发运维智能体的数据接入层通过代码仓库连接器、持续集成流水线连接器、缺陷管理系统连接器、测试平台连接器、接口文档库连接器以及工具调用监听器获取多源上下文数据。其中,代码仓库连接器通过代码托管平台的提交记录、分支快照、文件读取接口或本地仓库工作区读取源码文件、目录结构、函数签名、补丁差异和提交说明;持续集成流水线连接器通过流水线事件回调、构建任务接口或日志采集接口获取构建脚本、依赖配置、环境变量、状态码、构建日志和部署结果;缺陷管理系统连接器通过缺陷单接口获取缺陷标题、复现步骤、影响版本、异常堆栈、处理状态和历史修复记录;测试平台连接器通过测试任务接口或测试报告文件获取测试用例、测试断言、覆盖率结果、失败用例和断言差异;接口文档库连接器通过文档检索接口获取接口说明、参数约束、返回码、版本说明和变更记录;工具调用监听器在Agent调用编译、测试、检索、代码分析或部署工具前后记录工具名称、输入参数、执行时间、返回结果和异常信息。

[0048] 在一些实施方式中,原始软件研发运维上下文数据的获取由任务触发、事件触发和周期同步触发方式启动:当用户提交代码生成、代码修复、构建失败分析或缺陷定位任务时,系统根据任务目标解析仓库地址、分支、文件路径、缺陷编号、流水线编号或测试任务编号并生成采集计划;当代码提交、流水线完成、测试失败或缺陷状态变化事件到达时,系统通过事件消息或Webhook增量拉取受影响对象;当长期任务持续运行时,系统按预设周期同步与当前任务相关的仓库、测试和缺陷数据。采集到的数据经权限校验、格式识别、字符集统一、脱敏过滤、时间戳标记和版本快照处理后,生成原始内容哈希、来源类型、源系统标识、源版本号、访问权限范围和原文指针,并将未经压缩的原始内容写入不可变的原始上下文仓R0,同时将与当前任务相关的对象引用写入活动上下文池A0,以供后续结构化切分、语义标注、依赖图构建和可逆恢复使用。

[0049] 步骤S1中,上下文对象集合$C=\{c_1,c_2,...,c_n\}$中每个上下文对象c_i携带若干元信息字

段,用于支撑后续的压缩、缓存和恢复决策,具体为:

在一些实施方式中,软件研发运维智能体上下文对象按照来源进一步划分为需求类对象、代码类对象、接口类对象、测试类对象、构建部署类对象、缺陷类对象和工具观测类对象;其中,代码类对象包括源码文件、函数、类、代码块和补丁差异,构建部署类对象包括构建脚本、依赖配置、环境变量、流水线步骤、状态码和构建日志,缺陷类对象包括缺陷标题、复现步骤、异常堆栈、影响版本和修复记录。

[0050] 原始内容(rawContent)、来源类型(sourceType,如系统消息、用户消息、检索结果、工具返回等)、时间戳(timestamp)、初始任务阶段标签(stageTag)、依赖关系集合(dependency,预埋的因果关联、引用关系或调用链关系)、置信度(confidence,表示该对象内容本身的可信程度,由来源可信度与内容一致性共同决定,用于后续重要性评分中的置信度维度)、精确保留标记(exactFlag,布尔值,为真时表示该对象不可丢失,直接影响硬保留判定、压缩模式选择和缓存键生成)、指向原始上下文仓RO中对应原始版本的指针(rawPointer,用于延迟加载、残差存储以及恢复回退)、原始内容预计算哈希(cachePreHash,该哈希在上下文对象被采集进入原始上下文仓时立即计算并持久化,后续所有哈希相关操作均复用该值,避免重复计算)、任务目标哈希(taskGoalHash)、预算区间标识(budgetBand)、依赖图签名(dependencySig)和数据结构版本号(schemaVer)。

[0051] 在一些实施方式中,每个上下文对象c_i通过嵌入模型生成对应的语义嵌入向量e_i,用于构建上下文依赖图时计算节点间语义相似度,以及计算重要性评分时衡量任务相关性。

[0052] 上下文对象还包含唯一标识(ID)、模态类型(modality)、token起止位置(tokenRange)、逻辑一致性签名(consistencySignature,通过对上下文对象中的关键参数对(key-value)进行排序后哈希生成,用于快速比对不同对象间是否存在参数取值冲突)和恢复策略标识(restorePolicy)等扩展字段,以支持更精细的控制。

[0053] 对上下文对象执行结构化切分与多维度语义标注时,系统根据当前任务阶段或预判的任务阶段确定切分粒度参数和切分策略,对不同模态的上下文对象执行差异化切分:

在一些实施方式中,模态类型包括软件需求文本、缺陷描述、接口文档、代码、工具返回结果、构建日志、测试报告以及由截图或录屏提取的图像/OCR数据。具体而言,对自然语言文本按句、段、标题层级或语义片段切分;对代码按文件、类、函数、代码块或调用链节点切分;对工具返回结果按字段、参数组或状态码切分;对图像数据按区域、目标框或OCR文本块切分;对音频数据按时间片或说话轮次切分。

[0054] 切分粒度随任务阶段动态调整,具体为:规划阶段优先采用段落级切分,工具调用阶段优先采用句子级或函数签名级切分,反思纠错阶段优先采用错误传播路径级切分;文件级切分适用于初始加载阶段或token预算极度紧张时的兜底策略;token级切分适用于高精度恢复场景或强可逆模式下的最小恢复单位;切分粒度按从粗到细划分为多个等级,包括文件级、段落级/标题级、句子级/语义片段级、token级,段落级相对于句子级为上一级(粗粒度),句子级相对于段落级为下一级(细粒度),提升一级表示向更粗的粒度方向调整,降低一级表示在一些实施方式中,向更细的粒度方向调整。

[0055] 若当前可用token预算低于预设阈值θ_{budget},系统可提前调整切分粒度,将切分粒度提升一级(向更粗粒度方向调整)以降低管理开销。

[0056] 每个切分单元记录其与上一级粒度及下一级粒度之间的聚合映射关系和拆分映射关系,形成多粒度层级索引,上一级粒度的切分单元称为该单元的父对象(父节点),下一级粒度的切分单元称为子对象(子节点),该索引采用树形结构存储,根节点为原始上下文对象,子节点为不同粒度的切分单元,用于后续按粒度选择压缩基准和按需恢复时定位目标片段。。

[0057] 对切分后的每个最小粒度切分单元补充多维度语义标签,包括:结构标签(描述切分单元在原文中的结构角色,如标题、段落、函数定义)、实体标签(记录抽取的关键实体,如人名、函数名、参数名,采用命名实体识别模型对文本类切分单元抽取,采用抽象语法树解析对代码类切分单元提取)、关键词标签、主题标签(通过主题数K经轮廓系数确定的LDA模型,或采用预设主题标签集合且置信度阈值θ_{topic}默认为0.7的零样本分类器预测切分单元的高层主题类别,如工具调用、错误处理、参数验证,用于重要性评分中主题与当前任务阶段的匹配度计算)、任务关联标签(标注与任务目标的具体关联类型,如目标约束、证据支撑,用于硬保留集合的筛选,关联类型为目标约束或工具参数的切分单元优先加入硬保留集合)、证据标签(标识该片段是否可作为推理证据,计算证据可信度等级,用于按需展开的触发判断以及分层上下文包中压缩证据层的筛选)和版本标签。

[0058] 建立原始上下文仓与活动上下文池的协同存储机制时,将未经压缩的原始上下文写入不可变的原始上下文仓R0,用于后续可逆恢复时的回退。

[0059] 在一些实施方式中,R0是数据库、对象存储、文档仓、向量库附属原文仓或缓存存储中的一种,但需支持基于指针和校验值定位原始片段,其中每个上下文对象维护一个版本链表,指向所有基于该对象派生出的活动上下文池表示及下游压缩包。以写时复制方式将当前待参与推理的上下文对象写入活动上下文池A0,A0中的每个对象存储指向R0的指针及差异覆盖层,该覆盖层记录相对于原始版本的修改指令、裁剪指令或压缩指令;A0中的对象继承生成的所有标签和预埋的依赖关系,这些标签和依赖关系用于构建上下文依赖图。

[0060] 写时复制方式具体过程为:活动上下文池A0中的上下文对象初始时仅持有指向原始上下文仓R0中原始内容的只读引用(即指针),不实际复制原始数据;当需要对该上下文对象执行修改、裁剪或压缩时,系统才在A0中为该对象创建一份独立的数据副本,并在该副本上记录修改指令、裁剪指令或压缩指令(即差异覆盖层),原始上下文仓R0中的内容始终保持不变,通过延迟数据复制减少内存占用,并保证原始数据的不可变性,以支持后续的精确恢复和回退。

[0061] 在一些实施方式中,待参与推理的上下文对象是指即将被输入大模型、参与当前任务的一次模型调用所需的全部上下文数据。在智能体式软件研发运维领域中,所述当前任务包括规划、工具选择、工具调用、结果判断、反思纠错、生成回复、生成代码、生成测试用例、分析构建失败、定位缺陷、生成修复补丁或生成代码审查意见等Agent执行环节;所述上下文数据包括当前轮次的用户需求输入、系统提示、代码仓库片段、接口文档、测试用例、构建日志、缺陷单、工具返回结果、历史对话及从原始上下文仓中加载的相关内容。

[0062] 构建上下文依赖图时,以各上下文对象为节点,以上下文对象之间的时间邻接关系、语义相似关系、因果关联关系、引用关系、工具调用链关系或代码依赖关系为边,构建上下文依赖图G。每个上下文对象c_i对应一个节点v_i,节点属性包括:原始内容指针、语义嵌入向量e_i、时间戳t_i、热度值h_i和硬保留集合归属(若该节点属于硬保留集合H,则在剪枝时不

可删除)。

[0063] 热度值h_i初始为1.0,每次该节点被成功召回时增加δ_{inc}(默认0.1,上限1.0),并按时间衰减函数定期更新:

$$h_i \leftarrow h_i \cdot e^{-\lambda_h \cdot \Delta t};$$

其中,λ_h为热度衰减系数(默认0.05);Δt为距离上次更新的时间间隔(以天为单位,或按推理轮次折算)。

[0064] 节点间的边表示依赖、引用、补充、冲突或对齐关系,每条边的依赖强度值w_{ij}计算公式为:

$$w_{ij} = \alpha_1 \cdot e^{-\lambda_t |t_i - t_j|} + \alpha_2 \cdot \frac{e_i \cdot e_j}{\|e_i\| \|e_j\|} + \alpha_3 \cdot 1_{ref(i,j)} + \alpha_4 \cdot causal(i,j);$$

其中,λ_t为时间衰减系数(默认0.1);$1_{ref(i,j)}$为指示函数;当dependency字段显式引用时为1,否则为0;$causal(i,j)$为因果路径强度(若c_i与c_j处于同一调用链或依赖路径中,则取路径长度的倒数,否则为0);$\alpha_1+\alpha_2+\alpha_3+\alpha_4=1$表示默认权重:$\alpha_1=0.2$,$\alpha_2=0.4$,$\alpha_3=0.3$,$\alpha_4=0.1$;仅当$w_{ij} > \theta_{edge}$(默认0.35)时,在图中建立边。

[0065] 在一些实施方式中,当新上下文对象c_{new}到达时,以dependency字段显式指向的有效节点集合,与根据语义嵌入向量从现有有效节点中检索得到的Top-K近邻集合的并集作为候选节点集合;系统仅对候选节点计算显式依赖有效性、语义相似度及边权重wij,边权重高于阈值θedge时建立边;对既无显式dependency关系又未进入Top-K近邻集合的节点,不执行边权重计算。

[0066] 与遍历全图计算两两语义相似度的方式相比,显式依赖候选与向量Top-K近邻候选的并集既保留了未预埋dependency字段的语义相似边,又将增量构图的计算范围限定在候选节点集合内。

[0067] 当上下文依赖图的节点规模超过预设阈值θ_{nodes}(默认1000)时,删除满足以下全部条件的节点及其关联边:热度值h_i低于θ_{hot}(默认0.2);时间衰减超过预设窗口(默认7天);不属于硬保留集合H。

[0068] 在一些实施方式中,被删除节点的语义嵌入向量及边连接关系被聚合为一个超级节点,该超级节点的语义嵌入向量按各被删除节点的热度值对所有被删除节点的嵌入向量进行加权平均计算;超级节点与被保留节点之间的边权重取原边权重的最大值;超级节点记为灰色节点,在后续依赖计算中仅作为弱连接占位符,即仅用于表示该位置曾存在被删除节点、维持图拓扑结构完整性,不参与节点孤立度的预计算,也不作为语义相似度计算的有效节点。

[0069] 为每个节点预计算孤立度$isolationScore(v_i)$:

$$isolationScore(v_i) = \frac{1}{|V|-1} \sum_{v_i \neq v_j} shortestPathLength(v_i, v_j);$$

其中,$shortestPathLength(v_i, v_j)$为图中$v_i$到$v_j$的最短路径边数;若$v_i$与$v_j$不连通,路径长度取图直径的最大值加1;最终孤立度归一化到[0,1]区间,值越高表示节点越孤立。该孤立度用于指导优先剪枝(按孤立度从高到低优先剪除非硬保留节点)、触发主动展开或补充上下文(当检测到当前上下文缺失关键依赖信息时,定位孤立度较低的节点并从原始上下文仓加载原文),以及作为记忆合并的候选依据(当多个高孤立度节点语义相似时合并为

一条代表性记忆)。

[0070] 弱连接占位符表示超级节点在上下文依赖图中仅用于表示该位置曾存在被删除的节点,以维持图的拓扑结构完整性(即保持被删除节点原有邻居之间的连通关系),但不参与任何实际的计算操作,包括节点孤立度预计算、语义相似度计算、热度值传递或边权重更新。其弱连接的含义在于:该节点虽然存在于图中,但仅起结构占位作用,不具备活跃节点的功能属性,后续新节点加入时也不会将该超级节点作为有效的语义邻居进行关联。

[0071] 在一些实施方式中,指导优先剪枝具体流程为:在上下文依赖图节点规模超过预设阈值θ_{nodes}时,系统按各节点的孤立度从高到低排序,优先剪除孤立度较高的非硬保留节点(即与图中其他节点连接稀疏、位于图边缘的节点),因为这些节点对整体上下文结构的贡献度最低,剪除后对剩余节点的依赖关系和语义连通性影响最小。

[0072] 触发主动展开或补充上下文是指:当模型推理过程中检测到当前上下文缺失关键依赖信息时,系统定位该信息所对应的孤立度较低的节点(即与图中其他节点连接紧密、位于图中心区域的节点),主动从原始上下文仓R0中加载该节点的完整原文内容并加入活动上下文池A0,以补充上下文完整性。此外,当两个或多个高孤立度节点在语义上高度相似时,系统将其作为记忆合并的候选依据,即将这些节点对应的记忆条目合并为一条代表性记忆,以减少冗余存储。

[0073] 在一些实施方式中,根据Agent的运行状态识别当前任务阶段;Agent的运行状态包括:当前系统控制器状态(如初始化(INIT)、规划中(PLANNING)、执行动作(ACTION)、观测结果(OBSERVE)、反思(REFLECT)、输出(OUTPUT)等)、最近一次模型输出动作类型(如生成计划文本(PLAN)、调用工具(TOOL_CALL)、生成最终回复(RESPONSE)、生成反思总结(REFLECT_SUMMARY)、生成代码(CODE_GEN)等)、是否存在待调用工具、是否存在工具执行失败或异常、当前是否处于总结输出环节、当前token预算余量以及当前任务链路中的子目标完成情况(COMPLETED、IN_PROGRESS、FAILED、PENDING等)。

[0074] 在一些实施方式中,任务阶段包括检索准备阶段(G1)、规划阶段(G2)、工具调用阶段(G3)、执行阶段(G4)、反思纠错阶段(G5)和输出生成阶段(G6)。基于上述运行状态要素,按以下规则判定当前任务阶段:系统处于数据检索或文档加载状态且尚未调用模型时识别为G1;控制器状态为PLANNING,或最近输出为计划文本且无待调用工具时识别为G2;模型输出包含tool_calls字段且工具尚未执行时识别为G3;工具正在执行中,或最近输出为工具执行结果且仍有待处理动作时识别为G4;工具返回错误码,或模型输出包含重试、错误、失败等关键词时识别为G5;模型输出为最终回复、无待处理工具动作且不存在异常时识别为G6。当多个条件同时满足时,先匹配G5;其次在存在未完成工具动作时按调用状态匹配G3或G4;再匹配G2和G1;仅在不存在未完成动作和异常时匹配G6。

[0075] 根据识别结果g,匹配对应的目标压缩策略模板Pg,该模板至少包括:压缩粒度(granularity)、硬保留规则(retainRule)、评分权重参数组(scoreWeight)、上下文预算分配方案(budgetPlan)、可逆压缩模式标识(reversibleMode)、记忆写入倾向(memoryPolicy)、缓存键构成规则(cacheKeyPolicy)、恢复模式(restorePolicy)和缓存失效条件(invalidPolicy)。

[0076] 不同任务阶段的压缩策略模板采用差异化配置:

当识别结果是规划阶段(G2)时,压缩粒度配置为段落级或标题级,硬保留规则优

先保留任务目标、约束条件、完成判据、全局依赖和关键决策点,可逆压缩模式为标准模式,缓存键规则至少引入taskGoalHash和dependencySig,失效条件规定当taskGoalHash或dependencySig发生变化时触发缓存失效;工具调用阶段(G3)的压缩粒度配置为句子级或函数签名级,硬保留规则优先保留工具名称、参数、schema、最近观测值、异常码和依赖参数链,可逆压缩模式为强可逆模式(针对参数部分),缓存键规则至少引入exactFlag和最近工具参数签名,失效条件规定当taskGoalHash、工具参数签名或schema版本发生变化时触发缓存失效;反思纠错阶段(G5)的压缩粒度配置为错误传播路径级或语义片段级,硬保留规则优先保留失败轨迹、错误消息、尝试历史、假设偏差和证据冲突项,可逆压缩模式为强可逆模式(完整启用),记忆写入倾向为高写入倾向,缓存键规则至少引入失败轨迹签名和错误码签名,失效条件规定当错误码签名或失败轨迹签名发生变化时触发缓存失效。

[0077] 在一些实施方式中,基于目标压缩策略模板和上下文依赖图,计算活动上下文池中每个上下文对象在当前任务阶段下的重要性评分,该评分综合多个维度,计算公式为:

$$Score_i^g=\alpha_g\cdot Rel_i+\beta_g\cdot Dep_i+\gamma_g\cdot Fresh_i+\delta_g\cdot Trust_i+\varepsilon_g\cdot Reuse_i+\zeta_g\cdot Novel_i+\eta_g\cdot Exact_i$$

[0078] $$+\kappa_g\cdot ModalAlign_i-\lambda_g\cdot Length_i;$$

其中,Rel_i表示上下文对象与当前任务目标的任务相关性,基于对象c_i的语义嵌入向量e_i与当前任务目标嵌入向量e_{goal}的余弦相似度计算:

$$Rel_i=\frac{e_i\cdot e_{goal}}{\|e_i\|\|e_{goal}\|};$$

其中,e_{goal}由taskGoalHash对应内容经嵌入模型编码得到;Rel_i值越高,表示该对象与当前任务目标的语义关联越紧密。

[0079] Dep_i表示上下文对象在上下文依赖图中的关键程度,基于构建的上下文依赖图G,计算节点v_i的度中心性$deg(v_i)$及介数中心性$betw(v_i)$的加权和;

$$Dep_i=\omega_{deg}\cdot\frac{deg(v_i)}{|V|-1}+\omega_{betw}\cdot betw(v_i);$$

其中,$|V|$为节点总数,$\omega_{deg}+\omega_{betw}=1$,默认$\omega_{deg}=0.6$,$\omega_{betw}=0.4$;$Dep_i$值越高,表示该节点在依赖图中的结构重要性越强。

[0080] $Fresh_i$表示信息时效性,基于时间戳t_i与当前时间t_{now}的指数衰减函数计算;

$$Fresh_i=exp\left(-\lambda_{fresh}\cdot(t_{now}-t_i)\right);$$

其中,λ_{fresh}为时效衰减系数(默认0.1,以天为单位)。

[0081] $Trust_i$表示来源可信度,基于sourceType字段查表获得预置可信度;

$$Trust_i=preTrust(sourceType);$$

示例预置值:系统消息=1.0,用户消息=0.9,检索结果=0.7,工具结果=0.8,历史记忆=0.6。

[0082] $Reuse_i$表示未来复用概率,基于历史召回频率h_i(同热度值)及孤立度$isolationScore(v_i)$的联合预测;

$$Reuse_i=\sigma\left(\eta_{recall}\cdot\frac{h_i}{1+h_{max}}-\eta_{iso}\cdot isolationScore(v_i)\right);$$

其中,$\sigma(\cdot)$为sigmoid归一化函数,h_{max}为当前所有节点的最大召回次数,η_{recall}和

η_{iso}为调节系数(默认均为1.0)。

[0083] $Novel_i$表示信息新颖性,基于对象嵌入向量e_i与已有记忆集M中所有记忆项的嵌入向量的最大余弦相似度的补集计算;

$$Novel_i=1-\max_{m_j\in M}\frac{e_i\cdot e_{m_j}}{\|e_i\|\|e_{m_j}\|};$$

其中,M为空或最大相似度低于阈值(默认0.5),则$Novel_i=1$。

[0084] $Exact_i$表示精确保留标记,由动态赋值的exactFlag决定;

$$Exact_i=\begin{cases}1, if\ exactFlag=1\\ 0, otherwise\end{cases};$$

$ModalAlign_i$表示跨模态对齐相关性,计算上下文对象c_i的模态特征与当前任务所关注模态m_{task}的互信息量;

$$ModalAlign_i=\frac{MI(c_i,m_{task})}{MI_{max}};$$

其中,$MI(\cdot)$为互信息函数,MI_{max}为归一化常数(默认取模态特征维度的对数)。对纯文本场景,该值默认设为0.5。

[0085] $Length_i$表示上下文对象c_i的原始的原始token长度的归一化对数值,计算公式为:

$$Length_i=\log(1+tokenCount(rawContent_i))/\log(1+L_{max});$$

其中,L_{max}为当前压缩策略模板允许的最大对象token数;$Length_i$被限制在[0,1]区间,在保持长度惩罚单调性的同时与其他归一化评分维度保持同一量纲;α_g、β_g、γ_g、δ_g、ε_g、ζ_g、η_g、κ_g和λ_g表示动态权重系数,满足$\alpha_g+\beta_g+\gamma_g+\delta_g+\varepsilon_g+\zeta_g+\eta_g+\kappa_g+\lambda_g=1$,各维度对应的权重系数随当前任务阶段的不同而动态变化,通过反馈闭环持续优化。例如,在规划阶段提高α_g与β_g;在工具调用阶段提高η_g与γ_g;在反思阶段提高ζ_g与ε_g。

[0086] 在一些实施方式中,根据硬保留规则,从活动上下文池A0中优先筛选出不可丢失的上下文对象形成硬保留集合H,其余对象形成候选压缩集合Q,且H与Q互斥。H中的对象绕过步骤S3的记忆动作决策和压缩流程,由步骤S5按内容类型仅装载一次;Q中的对象用于后续记忆决策、分层压缩、摘要或延迟装载。硬保留规则至少包括:用户明确要求不可省略的信息;当前任务目标、约束条件和完成判据;最近一次工具调用的输入参数与返回关键值;尚未解决的异常、冲突和待办项;exactFlag为真的关键证据、代码片段、API契约、测试断言、构建参数、异常堆栈和版本号。

[0087] 对候选压缩集合Q中的上下文对象,通过规则约束层与强化学习策略网络相结合的混合决策架构,动态决定执行何种记忆操作动作,以更新多层次记忆集并控制其质量。

[0088] 在一些实施方式中,硬保留集合H中的上下文对象不进入强化学习策略网络,不写入更新后的记忆集M',也不写入候选对象的可逆压缩包;系统仅保留其原文引用及层级归属,由步骤S5直接装载。仅候选压缩集合Q中的对象通过本步骤的混合决策架构确定记忆操作动作。

[0089] 在一些实施方式中,将记忆划分为以下五个层次:

M1(短期运行记忆):存储当前任务轮次内的瞬时状态,生命周期限于单次推理过程。

[0090] M2(阶段性情节记忆):存储特定任务阶段的完整执行轨迹,有效保留期跨越同一

任务的多个推理轮次。

[0091] M3(长期语义记忆):存储跨任务、跨会话的抽象知识和事实,有效保留期跨任务、跨会话,直至来源版本失效、连续未召回达到预设窗口或一致性校验失败时失效。

[0092] M4(工具经验记忆):存储特定工具调用的成功模式与失败模式,用于加速后续工具选择。

[0093] M5(错误模式记忆):存储异常轨迹、冲突模式及修正历史,用于反思阶段的快速检索。

[0094] 各记忆层次之间支持双向迁移,具体为:M1中频繁被召回的条目可升级至M2;M2中被多次验证为稳定知识的条目可抽象后写入M3;M3中的经验条目如被多次修正则可降级至M5。

[0095] 在一些实施方式中,记忆操作动作集合A包括:写入原文记忆(a1)、写入压缩记忆(a2)、与已有记忆合并(a3)、延迟写入(a4)、遗忘删除(a5)、仅更新索引(a6)、记忆升级(a7)和记忆降级(a8)。

[0096] 任务轮次是指从模型接收一次输入到产生对应输出的一次完整调用过程,在一次任务轮次中可能涉及多个Agent执行阶段(如规划、工具调用、执行、反思等),但通常不跨越多轮对话或多轮工具调用链。一个任务轮次由一次模型推理请求及其对应的响应构成。

[0097] 生命周期是指记忆条目在系统中保留的有效时间范围。短期运行记忆(M1)的生命周期限于单次任务轮次,即模型单次调用完成后,该记忆条目即被清除或标记为失效,不延续至后续轮次;阶段性情节记忆(M2)的生命周期跨越同一任务的多个推理轮次;长期语义记忆(M3)的生命周期持久,跨任务、跨会话保留。

[0098] 在一些实施方式中,工具选择是指Agent在工具调用阶段(G3)从多个可用工具中确定具体调用哪一个工具或哪一组工具的过程;工具经验记忆(M4)通过存储历史上各工具调用的成功模式(如参数配置、调用链顺序、返回结果特征)与失败模式(如常见错误码、触发异常的参数组合、超时场景),使Agent在后续遇到相似任务需求时,能够优先选择成功率较高的工具及其参数配置,避免重复尝试已知的失败路径,从而加速工具调用决策。

[0099] 异常轨迹是指从错误或异常发生的起点到终点的完整执行路径记录,包括:触发异常的操作或调用、异常传播过程中经过的函数调用链、各节点的输入参数及返回值、以及最终的异常类型和错误消息。

[0100] 在一些实施方式中,冲突模式是指上下文或记忆库中出现的逻辑不一致的典型形式,包括:同一约束条件在不同位置被赋予相互矛盾的取值、同一工具调用链中出现循环依赖、当前推理结果与历史已确认结论之间存在逻辑违背。

[0101] 修正历史是指针对上述异常或冲突所采取的纠正操作的完整记录,包括:修正时间、修正方式(如覆盖、回退、合并)、修正前后的内容对比、以及修正是否成功的结果。

[0102] 在一些实施方式中,强化学习策略网络在时刻t的状态s_t包括:当前任务阶段g;上下文对象的重要性评分记为$Score_i^g$;信息新颖性$Novel_i$;与现有记忆的相似度,基于向量余弦相似度或局部敏感哈希计算;历史被召回次数;对任务成功的贡献度,基于历史推理中该记忆被使用时任务是否成功的加权统计;冲突风险,基于逻辑一致性签名判断;时效衰减值,基于时间戳与当前时刻的指数衰减;压缩成本(压缩耗时与压缩过程峰值内存的归一化加权和)及恢复成本(按需恢复耗时、读取字节量与校验失败率的归一化加权和);缓存命中

概率,基于缓存命中历史统计;所有特征经归一化后拼接为固定维度的向量。

[0103] 为了更准确衡量记忆长期保留价值,本申请引入基于时间衰减和召回行为的可召回估计函数$Precall_{i(t)}$:

$$Precall_{i(t)}=\exp(-\rho\cdot\Delta t_i)\times\frac{(1+recall_i)}{1+m_i+conflict_i};$$

其中,Δt_i为记忆项距当前时刻的时间间隔;$recall_i$为该记忆项的历史成功召回次数;m_i为被合并次数;$conflict_i$为该记忆项的冲突或修正次数;ρ为时间衰减系数,可选地为阶段自适应系数,不同任务阶段采用不同的ρ值。$Precall_{i(t)}$越高,表示该记忆未来再次被召回的可能性越高;$Precall_{i(t)}$越低,表示该记忆可优先遗忘或仅保留索引。

[0104] 在一些实施方式中,强化学习策略网络的奖励函数包括以下目标,并对各项指标执行归一化与量纲对齐,以提升策略训练稳定性与可复现性:

$$rt=\mu1\cdot TaskGain_t+\mu2\cdot RetrievalHit_t+\mu3\cdot TokenSave_t+\mu4\cdot CacheHit_t$$

[0105] $$-\mu5\cdot Hallucination_t-\mu6\cdot RestoreLatency_t-\mu7\cdot NoiseAccum_t;$$

其中,$TaskGain_t$表示对任务成功率、正确率或完成度的提升;$RetrievalHit_t$表示后续检索命中效果,基于Top-K召回准确率计算;$TokenSave_t$表示节约的上下文token数量;$CacheHit_t$表示压缩缓存复用效果;$Hallucination_t$表示因压缩或记忆不当导致的错误推理代价,具体基于模型输出中包含的幻觉内容(即输出中声称存在但压缩包中无对应映射关系或与原始事实不符的内容)占输出总token的比例计算,并结合后续自动校验(如一致性签名校验)中发现的错误引用次数加权统计;$RestoreLatency_t$表示从触发按需还原至校验完成的耗时与不执行还原时基线耗时之差,并按预设延迟上限归一化;$NoiseAccum_t$表示噪声记忆累积程度,基于低召回条目占总条目的比例计算。

[0106] 在一些实施方式中,强化学习算法具体采用双重深度Q网络(DDQN),以在线Q网络负责动作选择、目标Q网络负责目标值评估,从而降低动作价值过估计并与下述双网络更新流程保持一致。

[0107] 规则约束层与强化学习策略网络结合的混合决策架构,具体为:

第一层:规则约束层(规则沙箱),对每个候选对象,首先根据预设规则判定其是否属于不可由强化学习决策的范围:

规则约束层的输入限定为候选压缩集合Q中的对象;若检测到对象属于硬保留集合H,则停止a1至a8的动作决策并将该对象返回H,由步骤S5直接装载。

[0108] 若c_i的exactFlag=1,则禁止执行合并(a3)和写入压缩记忆(a2);

若当前阶段为强可逆模式且c_i包含代码或API契约、测试断言或构建配置,则禁止执行遗忘删除(a5)和写入压缩记忆(a2);

在一些实施方式中,若上述规则均未触发,则将决策权交由第二层强化学习策略网络。

[0109] 第二层RL策略网络(软决策层),对于通过规则沙箱筛选的候选对象,由在线Q网络输出各动作的Q值,并依据ε-贪婪策略选择最终动作:

$$a_t=\arg\max_{a\in A}Q_\theta(s_t,a);$$

$$a_t\sim\mathrm{Uniform}(A),p=\varepsilon;$$

其中，s_t为强化学习状态向量；$A=\{a_1,a_2,\ldots,a_8\}$为记忆操作集合；$Q_\theta(s_t,a)$为在线Q网络对状态s_t下动作a的价值估计；ε为探索率，初始值为0.1并按训练步数衰减至0.01。智能体以$1-\varepsilon$的概率选择Q值最大的动作，以ε的概率从A中随机选择动作。

[0110] 在一些实施方式中，DDQN包括在线Q网络Q_θ、目标Q网络Q_θ-和经验回放池。每次交互将$(s_t,a_t,r_t,s_{t+1},d_t)$写入经验回放池，并随机采样小批量样本更新在线$Q$网络，其中$d_t$表示终止状态标记。

[0111] $y_t=r_t+\gamma(1-d_t)Q_\theta\text{-}(s_{t+1},\arg\max_{a'\in A}Q_\theta(s_{t+1},a'))$；

其中，在线Q网络Q_θ选择下一状态下的最优动作，目标Q网络Q_θ-评估该动作价值；γ为折扣因子，默认0.95；终止状态$d_t=1$时，目标值y_t等于即时奖励r_t。

[0112] 在线Q网络通过最小化以下时序差分损失更新参数θ：

$L(\theta)=\mathrm{E}[(y_t-Q_\theta(s_t,a_t))^2]$；

目标网络参数θ^-每N_{sync}步从在线网络参数θ同步一次，N_{sync}默认100步；在两次同步之间目标网络参数保持固定。

[0113] 在一些实施方式中，在线Q网络和目标Q网络采用相同结构：输入层接收状态特征向量s_t，隐藏层为256和128个神经元的两层全连接网络并采用ReLU激活；输出层为线性层，对动作集合A中的a_1至a_8分别输出一个Q值，不使用softmax概率输出。

[0114] 第三层：后处理校验层，对强化学习策略网络层输出的动作执行二次安全校验：

若所选动作将导致高价值记忆（召回次数h_i>阈值θ_{recall}）被遗忘，且当前阶段为规划阶段或反思阶段，则强制降级为a4（延迟写入）而非a5（遗忘删除）；若所选动作将合并两个冲突记忆（冲突程度$Conflict_i$>阈值$\theta_{conflict}$），则触发人工校验标记或降级为a6（仅更新索引）。

[0115] 在一些实施方式中，基于混合决策架构输出记忆操作动作，具体为：

当信息高价值、高新颖、高复用概率时，执行a1（写入原文记忆）或a2（写入压缩记忆），并将记忆项与当前任务阶段、时间戳、依赖关系一同存储；

当信息与已有记忆高度相似时，执行a3（合并操作），形成记忆簇，保留簇内代表性样本及差异性摘要；

当信息短时有效但长期价值低时，执行a4（延迟写入），将记忆暂存于待写入队列，若在预设时间窗口内未被再次触发则自动降级为a5（遗忘）；

当信息已过时、低召回概率、冲突过多时，执行a5（遗忘删除）或降级保留（从M2/M3迁移至M1/M5）。

[0116] 当信息价值无法确定时，执行a6（仅更新索引），将元数据写入索引但不存储完整内容，待后续被检索到时再从原始上下文仓$R0$延迟加载；

当记忆被频繁成功召回时，执行a7（记忆升级），从M1迁移至M2或从M2抽象后写入M3；

当记忆长期未被召回或与大量新信息冲突时，执行a8（记忆降级），从M3迁移至M5或标记为待遗忘。

[0117] 经该步骤后，生成更新后的记忆集M'，更新各记忆项的召回次数h_i、合并次数m_i、冲突次数c_i及时间戳。

[0118] 在一些实施方式中，如图2所示，本步骤仅对候选压缩集合Q中的上下文对象执行

分层可逆压缩,在满足当前阶段token预算的前提下,形成用于模型推理的紧凑表达及用于精确恢复的索引映射;标准模式实现依赖不可变原始上下文仓RO的系统级可逆恢复,强可逆模式实现压缩包内自包含恢复。

[0119] 基于计算得到的重要性评分$Score_i^g$,通过评分-压缩率映射函数确定每个上下文对象的目标压缩率r_i:

$$r_i=f\left(Score_i^g\right)=r_{min}+\left(r_{max}-r_{min}\right)\times\left(1-\sigma\left(Score_i^g\right)\right);$$

其中,r_{min}为预设的最低压缩率(保留最多内容);r_{max}为最高压缩率(保留最少内容);$\sigma(Score_i^g)$为sigmoid归一化函数,将重要性评分映射至[0,1]区间;$Score_i^g$越高,压缩率r_i越低(保留更多内容);$Score_i^g$越低,压缩率r_i越高(丢弃更多内容)。

[0120] 在一些实施方式中,映射函数还受当前阶段预算约束$budgetPlan$的校正:若当前已用token预算超过计划值,则对所有r_i乘以压缩增强因子$\eta_{compress}$($\eta_{compress}>1$),以进一步降低总体占用;若预算充裕,则乘以η_{relax}($\eta_{relax}<1$),以保留更多细节。

[0121] 对于每个待压缩对象c_i,其原始token序列记为$X_i=\{x_1,x_2,...,x_m\}$,压缩后生成可逆压缩包RC_i,RC_i至少包括以下六类字段:$Anchor_i$:按原始序列顺序存储的关键token或关键片段集合,每个片段包含唯一标识anchorId和片段内容;$SpanMap_i$:由每个Anchor片段的anchorId、原始区间[start,end)、前驱/后继片段标识及跨段跳转指针组成的映射表;$Residual_i$:按被省略片段逐段存储的差分字节串,或由rawPointer、原始版本号和起止偏移组成的原文指针;Pos_i:记录各Anchor片段和Residual片段原始序号的有序表;$Struct_i$:记录各片段的结构类型、层级路径和字段路径,用于恢复原始层级;$Checksum_i$:对规范化后的原始对象按SHA-256计算的摘要及哈希算法标识,用于恢复后逐字节一致性校验。

[0122] 在一些实施方式中,可逆压缩包RC_i支持分级压缩模式:

标准压缩模式:Anchori保留语义关键点,Residuali至少存储rawPointer、源版本号、被省略片段的起止偏移和Checksumi;恢复时从不可变原始上下文仓RO加载对应版本的原文片段,属于依赖RO的系统级可逆模式;

强可逆压缩模式:Anchori保留token级关键序列,Residuali存储全部被省略内容的完整差分编码,SpanMapi记录逐token精确索引,使可逆压缩包不依赖RO即可独立重建原始对象,适用于代码片段、API契约、测试断言、构建配置、异常堆栈和版本号等智能体式软件研发运维高精度场景。

[0123] 压缩模式的选择依据策略模板输出的reversibleMode标志及动态赋值的exactFlag共同决定:当reversibleMode为强可逆或exactFlag=1时,强制启用强可逆压缩模式。

[0124] 在一些实施方式中,分层可逆压缩操作与多粒度切分结构保持严格对齐,确保压缩后的片段可追溯至原始切分单元,包括以下层级:

第一层片段级筛选:仅针对候选压缩集合Q,基于目标压缩率r_i,对每个切分单元(按最小粒度)执行保留/压缩或丢弃的三分类判定,其中丢弃指载荷省略,不表示删除恢复信息:

对于候选压缩集合Q中的切分单元,根据该单元的局部重要性评分(由其所属上下文对象的$Score_i^g$及归一化的任务相似度、实体或关键词命中率、证据可信度、结构角色权重

和token长度的归一化对数值加权计算)及目标压缩率r_i,作出以下三选一判定:

保留:当局部重要性评分高于第一阈值θ_{keep}(默认0.7)时,该单元不压缩,完整保留;

压缩:当局部重要性评分介于第一阈值θ_{keep}与第二阈值$\theta_{discard}$(默认0.3)之间时,对该单元执行第二层的单元内压缩;

载荷省略:当局部重要性评分低于第二阈值θdiscard(默认0.3)时,该单元仅从模型推理载荷中省略,但保留恢复信息;强可逆模式将该单元的完整残差写入可逆压缩包,标准模式将rawPointer、源版本号、起止偏移和校验值写入可逆压缩包。

[0125] 其中,第一阈值θ_{keep}和第二阈值$\theta_{discard}$根据当前任务阶段和token预算动态调整。

[0126] 在一些实施方式中,第二层单元内压缩:针对第一层中的"压缩"判定结果(即局部重要性评分介于θ_{keep}与$\theta_{discard}$之间的单元),采用以下至少一种方式执行内容压缩:

保留关键句、关键字段、关键代码行、关键参数与关键证据锚点,删除冗余说明、重复观测、低相关背景信息;

对长文档保留章节标题、段落首句、核心数据点,并记录其原始位置索引;

将多轮重复描述合并为一次结构化表达,记录重复次数及首次出现位置,维护跨轮引用关系;

对结构化数据仅保留决定性字段和值,删除默认值、辅助字段,保留字段级位置与来源映射;

对连续相似内容(如日志序列、传感器数据),保留首项及后续项的差异值(diff),替代完整存储。

[0127] 第三层跨单元引用压缩:对存在依赖关系(*dependency*字段记录的关联)的多个切分单元,执行跨单元引用压缩:

若单元B与单元A内容高度相似(相似度>阈值θ_{sim}),且B依赖于A,则B仅存储指向A的引用指针和差异补丁,不存储完整内容;恢复时,根据引用指针定位A的内容,叠加差异补丁重建B。

[0128] 在一些实施方式中,步骤S4中,可逆压缩包的残差存储或原文指针的编码方式根据内容类型及压缩模式自适应选择:

对于自然语言文本,标准压缩模式下采用原文指针加被删片段的起止位置偏移量,强可逆压缩模式下采用差分编码加逐句位置映射。

[0129] 对于代码,标准压缩模式下采用原文指针加被删代码行的行号范围,强可逆压缩模式下采用逐token差分编码加AST节点位置映射。

[0130] 对于结构化数据(JSON/XML),标准压缩模式下采用被删字段的XPath路径加默认值标记,强可逆压缩模式下采用字段级位置映射加值变化日志。

[0131] 对于图像或音频描述,标准压缩模式下采用模态指针加描述片段索引。

[0132] 对于日志或时序数据,标准压缩模式下采用差分编码(首项加差异序列)。

[0133] 当需要恢复原始内容时,根据压缩包中的$SpanMap_i$、$Residual_i$、Pos_i和$Struct_i$对原始序列执行重建:

$$X_i^{rec}=Recover(Anchor_i,SpanMap_i,Residual_i,Pos_i,Struct_i);$$

其中,X_i^{rec}表示恢复后得到的原始token序列。

[0134] 在一些实施方式中,恢复过程支持多粒度恢复:

仅恢复被请求的特定片段(如某个代码行、某个条款),而非整个对象,通过$SpanMap_i$定位目标片段在压缩包中的存储位置,从$Residual_i$中提取对应残差,与$Anchor_i$中相关内容拼接后返回;恢复完整的原始对象,按Pos_i记录的顺序将$Anchor_i$片段与$Residual_i$中的残差片段依次拼接,通过$Struct_i$恢复结构层级。

[0135] 恢复完成后,通过$Checksum_i$进行一致性校验。计算恢复后内容的哈希值$H_{recovered}$;若$H_{recovered}==Checksum_i$,则校验通过,确认恢复后的内容与原始内容一致;若校验不通过,则可回退至原始上下文仓$R0$中对应rawPointer指向的原文版本,并记录本次校验失败事件,用于触发安全回退及策略优化。

[0136] 在一些实施方式中,对生成的残差和恢复索引执行完整性检查,包括残差数据完整性、索引完整性及层级一致性;若校验未通过,则触发错误处理,包括回退、重压缩或修复索引和残差,确保压缩包可恢复。

[0137] 在完成分层压缩、可逆编码、残差生成及一致性校验后,将Anchori、SpanMapi、Residuali、Posi、Structi、Checksumi、rawPointer、压缩模式标识、源版本号及数据结构版本号整合,形成最终的分层可逆压缩包。

[0138] 该压缩包支持缓存复用、增量更新和按需展开恢复;强可逆模式依据包内完整残差独立精确重构原始上下文,标准模式依据rawPointer从不可变原始上下文仓R0加载匹配源版本并经Checksumi校验后精确重构。

[0139] 在模型生成、工具调用或结果核验过程中,当满足以下任一条件时,触发按需展开:当前输出要求引用原文证据;模型输出的置信度低于预设阈值;基于consistencySignature检测到关键参数冲突;当前任务标记为智能体式软件研发运维高精度任务(如代码生成、代码修复、自动化测试生成、构建部署诊断或缺陷定位);用户要求查看原文、原代码或原始记录。

[0140] 按需展开既可以是对象级展开(展开完整对象),也可以是片段级展开(仅展开被请求的特定片段),由触发条件及当前token预算共同决定展开深度。展开后的内容临时加入活动上下文池A0,但不修改原始压缩包RC_i,以保证压缩结果的稳定性和可复用性。

[0141] 在一些实施方式中,步骤S5中,生成复合缓存键具体过程为:

$$Key_j=Hash(cachePreHash_j \| tokenizerVer \| modelVer \| policyVer \| stageLabel$$

[0142] $$\| domainLabel \| taskGoalHash \| budgetBand \| exactFlag \| dependencySig \| schemaVer);$$

其中,$cachePreHash_j$表示原始内容$rawBlock_j$的预计算哈希值;$tokenizerVer$表示分词器版本;$modelVer$表示模型版本;$policyVer$表示压缩策略版本;当阶段模板评分权重、预算方案、奖励函数参数、规则约束或DDQN网络参数发生实际变更时递增;$stageLabel$表示任务阶段标识;$domainLabel$表示领域标识;taskGoalHash表示任务目标、用户显式约束和系统硬约束经规范化编码后的哈希值;budgetBand表示当前token预算所属的离散预算区间标识;exactFlag表示是否要求精确保留或强可逆恢复的标记;dependencySig表示与该上下文对象相关的依赖边集合及边权重形成的依赖图签名;schemaVer表示上下文对象、压缩包和缓存条目的数据结构版本。公式中的‖表示规范化字节串拼接符。缓存键生成前,系统对参与计算的字段执行规范化编码(CanonicalEncode),规范化编码包括字段名排序、空值占位、字符集统一、浮点或权重量化、时间字段归一化和权限作用域写入。各字段之间的

拼接采用长度前缀编码或等价的确定性结构化编码。

[0143] 缓存键Key_j的生成过程中,原始内容$rawBlock_j$的哈希值直接复用中预计算的*cachePreHash*字段,避免重复计算;*tokenizerVer*、*modelVer*、*policyVer*从系统配置中读取,*stageLabel*由当前阶段g确定,*domainLabel*从上下文元数据中提取。

[0144] 在一些实施方式中,将Key_j与对应压缩包、评分结果、版本号及有效性标签一起存入缓存库Cache。

[0145] 若两个上下文块原始内容相同但taskGoalHash、budgetBand、exactFlag或dependencySig不同,则禁止进入精确命中通道;仅当近似通道满足相似度阈值且通过版本校验时,才允许基于历史压缩包执行增量压缩。通过该约束,能够避免同一文本在不同任务阶段或不同预算区间下被误用为同一压缩结果。

[0146] 当新输入到达时,系统首先根据缓存键Key_j从缓存库Cache中查询;若命中则直接复用压缩包及其校验信息。

[0147] 在一些实施方式中,若Key_j完全一致,则直接复用对应的压缩包和评分结果;若Key_j不存在,但语义相似度或局部敏感哈希匹配度高于阈值,则判定为近似命中,进入增量复用流程,并绑定历史版本引用指针。若不存在可复用缓存(既无精确匹配也无近似匹配),则执行新的全量压缩流程,并将压缩结果写入缓存库,同时记录策略版本与模型版本。

[0148] 当从精确命中通道复用缓存时,系统仍需校验以下条件:

当前*tokenizerVer*与缓存记录中的*tokenizerVer*一致;当前*modelVer*与缓存记录中的*modelVer*一致;

当前*policyVer*与缓存记录中的*policyVer*一致;当前阶段g与缓存记录中的*stageLabel*匹配;压缩包RC_i的$Checksum_i$与预期值一致。

[0149] 若任一校验失败,则降级至近似命中通道或全量压缩流程。

[0150] 在一些实施方式中,对于与历史内容高度相似的新上下文,计算其与历史版本之间的差异片段Δ_j,仅对Δ_j执行评分、压缩和索引映射,并将其与原有压缩包合并,形成更新后的压缩包RC'_j。

[0151] 增量压缩包括以下子步骤:

基于滚动哈希(如Rsync算法)定位未变化片段,并可结合依赖图G识别受变化影响的关联节点,缩小差异搜索空间。滚动哈希以步骤S1中的切分单元为基本操作单位,在每个切分单元内部进一步按固定窗口计算哈希值,以定位单元内部的变化位置;若整个切分单元未变化,则整个单元不参与增量压缩。

[0152] 基于*Diff*算法或编辑脚本(如Myer‘sdiff算法)提取新增、删除、修改片段,生成差异描述Δ_j。

[0153] 仅对Δ_j中的新增片段或修改片段,复用重要性评分流程计算$Score^{g}_{\Delta}$。

[0154] 基于评分-压缩率映射函数和分层压缩策略,对Δ_j执行压缩,生成增量压缩包ΔRC_j。

[0155] 将ΔRC_j中的$SpanMap_j$和$Residual_j$与历史压缩包的对应结构进行合并,更新位置偏移量和引用指针。

[0156] 将ΔRC_j与历史压缩包RC_j合并,形成更新后的压缩包RC'_j,并递增版本号。

[0157] 更新$Checksum_j$,恢复校验机制。

[0158] 在一些实施方式中,在以下情形下,对缓存条目进行失效、重建或降级处理:

原始文档版本变化或原始内容哈希变化;*tokenizer*版本变化;大模型版本变化或推理内核变化;压缩策略版本policyVer变化;其中阶段模板评分权重或预算方案、奖励函数参数、规则约束或DDQN网络参数发生变化时,系统先递增policyVer,再使旧policyVer的缓存条目失效;存在校验失败、恢复异常或跨版本不一致风险。

[0159] 通过上述机制并结合加权LRU-LFU与压缩成本因子进行淘汰控制,保证缓存复用的正确性、一致性与资源效率。

[0160] 在一些实施方式中,步骤S5按以下优先级组装分层上下文包;H中的对象依据内容类型映射至L1、L2或L4中的一个对应层且仅装载一次,M'和RCi均仅包含Q的处理结果:

L1系统约束层,包含系统消息中定义的Agent身份、权限范围和职责边界、安全边界和输出格式规范,由硬保留集合中的系统级约束项构成,优先级最高且不参与压缩;

L2任务目标层,包含用户原始意图、任务完成判据和显式要求;命中硬保留规则的任务目标类对象从H中仅在本层完整装载一次,其余内容从活动上下文池A0提取,必要时通过rawPointer从R0加载原文;

L3核心活动记忆层,包含根据当前任务阶段从更新后的记忆集M'中检索的高相关性记忆条目;M'仅含Q的记忆决策结果,并排除已由H装载至L1、L2或L4的对象;

L4工具调用、关键观测与精确保留层,包含最近一次工具调用的输入参数、返回关键值、状态码和异常信息,以及无法归入L1或L2但命中硬保留规则的关键证据、代码片段、API契约、测试断言、构建参数、异常堆栈或版本号;H中的对象仅在本层完整装载一次且不压缩,其余Q中工具类或高精度对象采用强可逆模式压缩后装载;

L5压缩证据层,仅包含对候选压缩集合Q生成的可逆压缩包中的关键片段集合,根据评分-压缩率映射函数确定保留比例;

L6可逆索引附录层,包含可逆压缩包以及按需展开的触发条件和回退指针;按需展开触发条件不在缓存键中编码,因为其属于运行时策略行为,不影响压缩结果的正确性;缓存仅存储压缩数据本身,触发条件由本步骤的上下文组装与反馈优化模块根据当前阶段和监控状态实时判定;该层内容仅在需要执行按需展开时被访问,不参与常规推理的token计算。

[0161] 当累积token数超过当前阶段预算上限时,从L5层开始进行二次压缩,L1至L4层不参与二次压缩。

[0162] 步骤S5中,根据任务执行结果采集反馈信息包括以下触发条件及对应操作:

当模型输出置信度低于预设阈值时,触发片段级按需展开;

当工具返回错误码或异常时,将失败轨迹写入错误模式记忆并触发上下文对象级按需展开;

当模型输出声称引用但压缩包中无对应映射关系时,触发一致性校验,校验失败则回退至原始上下文仓中的原文;

在一些实施方式中,比较当前推理结果中的参数取值与上下文依赖图中记录的同一参数的历史取值,若二者不同且逻辑上不能共存,则判定为参数冲突,当检测到参数冲突时,触发冲突对应片段的按需展开并将冲突记录写入错误模式记忆;

当缓存连续多次未命中时,触发缓存预热机制:系统主动将当前任务阶段最可能

用到的上下文对象(基于重要性评分排序前K个,K值根据当前可用计算资源动态确定)预先执行压缩并写入缓存。

[0163] 在一些实施方式中,步骤S5中,对压缩策略模板的权重参数和混合决策架构的参数进行动态调整包括:

在任务完成后,汇总以下指标作为强化学习策略网络和阶段压缩策略模板的更新依据:

任务成功率,即任务目标是否达成(取值为0或1),用于更新强化学习策略网络的奖励函数。

[0164] 答案正确率,即正确答案比例(取值0到1),用于更新强化学习策略网络的奖励函数。

[0165] token节约率,即1减去压缩后token数与原始token数的比值,用于更新压缩策略模板中的评分权重参数组和评分-压缩率映射函数。

[0166] 缓存命中率,即命中次数与总查询次数的比值,用于更新缓存复用策略和缓存淘汰策略的权重。

[0167] 恢复次数,即按需展开的总次数,用于更新压缩策略模板中的预算分配方案,当恢复次数较高时提高压缩证据层的预算比例。

[0168] 用户修订次数,即用户对模型输出的修改次数,用于向强化学习策略网络的奖励函数提供负向奖励信号。

[0169] 基于上述指标,系统动态更新压缩策略模板中的评分权重参数α_g,β_g, …,λ_g和预算分配方案 budgetPlan,同时更新强化学习策略网络的奖励函数参数$\mu1$,$\mu2$, …,$\mu7$;每当上述权重、预算方案或奖励参数实际变更时,先递增policyVer并使旧版本缓存条目失效,再启用新策略,形成持续优化闭环。

[0170] 本发明在另一实施方式中提出了一种阶段感知的大模型上下文可逆压缩与缓存系统,实现如上的一种阶段感知的大模型上下文可逆压缩与缓存方法,包括:

上下文采集与结构化管理模块,用于获取原始软件研发运维上下文数据并统一表示为上下文对象集合,对上下文对象执行结构化切分与语义标注;建立原始上下文仓与活动上下文池的协同存储机制,构建上下文依赖图;

任务阶段识别与压缩策略选择模块,用于根据Agent的运行状态识别当前任务阶段,根据识别结果匹配对应的目标压缩策略模板,基于目标压缩策略模板和上下文依赖图,计算每个上下文对象在当前任务阶段下的重要性评分;根据重要性评分和硬保留规则,将上下文对象划分为硬保留集合和候选压缩集合;

记忆调度与压缩模块,用于对候选压缩集合中的上下文对象,通过规则约束层与强化学习策略网络结合的混合决策架构输出记忆操作动作,根据记忆操作动作更新记忆集;根据目标压缩策略模板和重要性评分,对候选压缩集合中需保留的上下文对象执行分层可逆压缩,生成可逆压缩包;所述可逆压缩包包含用于还原原始内容的恢复信息,支持按需展开以恢复原始片段或原始上下文对象;

缓存管理模块,用于根据各上下文对象的特征信息生成缓存键;若缓存键匹配则直接复用缓存,若语义相似度高于预设阈值则基于历史压缩包对差异部分执行增量处理后复用,缓存未命中时执行全量压缩并写入缓存;

上下文组装与优化模块,用于将硬保留集合与仅更新后的记忆集及可逆压缩包组装为分层上下文包,输入大模型执行当前任务;在任务执行过程中和任务完成后,根据任务执行结果采集反馈信息,对压缩策略模板的权重参数和混合决策架构的参数进行动态调整。

[0171] 本发明在另一实施方式中提出了一种电子设备,包括:存储器、处理器及存储在存储器上并可在处理器上运行的计算机程序,处理器执行计算机程序时,实现如上所述的一种阶段感知的大模型上下文可逆压缩与缓存方法。

[0172] 本发明在另一实施方式中提出了一种计算机可读存储介质,存储有计算机程序,所述计算机程序使计算机执行如上所述的一种阶段感知的大模型上下文可逆压缩与缓存方法。

[0173] 在本申请所公开的实施例中,计算机存储介质可以是有形的介质,其可以包含或存储以供指令执行系统、装置或设备使用或与指令执行系统、装置或设备结合使用的程序。计算机存储介质可以包括但不限于电子的、磁性的、光学的、电磁的、红外的、或半导体系统、装置或设备,或者上述内容的任何合适组合。计算机存储介质的更具体示例会包括基于一个或多个线的电气连接、便携式计算机盘、硬盘、随机存取存储器(RAM)、只读存储器(ROM)、可擦除可编程只读存储器(EPROM或快闪存储器)、光纤、便捷式紧凑盘只读存储器(CD-ROM)、光学储存设备、磁储存设备、或上述内容的任何合适组合。

[0174] 以上所述,仅是本发明的较佳实施例,并非对本发明作任何形式上的限制,任何熟悉本专业的技术人员,在不脱离本发明技术方案范围内,依据本发明的技术实质,对以上实施例所作的任何简单的修改、等同替换与改进等,均仍属于本发明技术方案的保护范围之内。

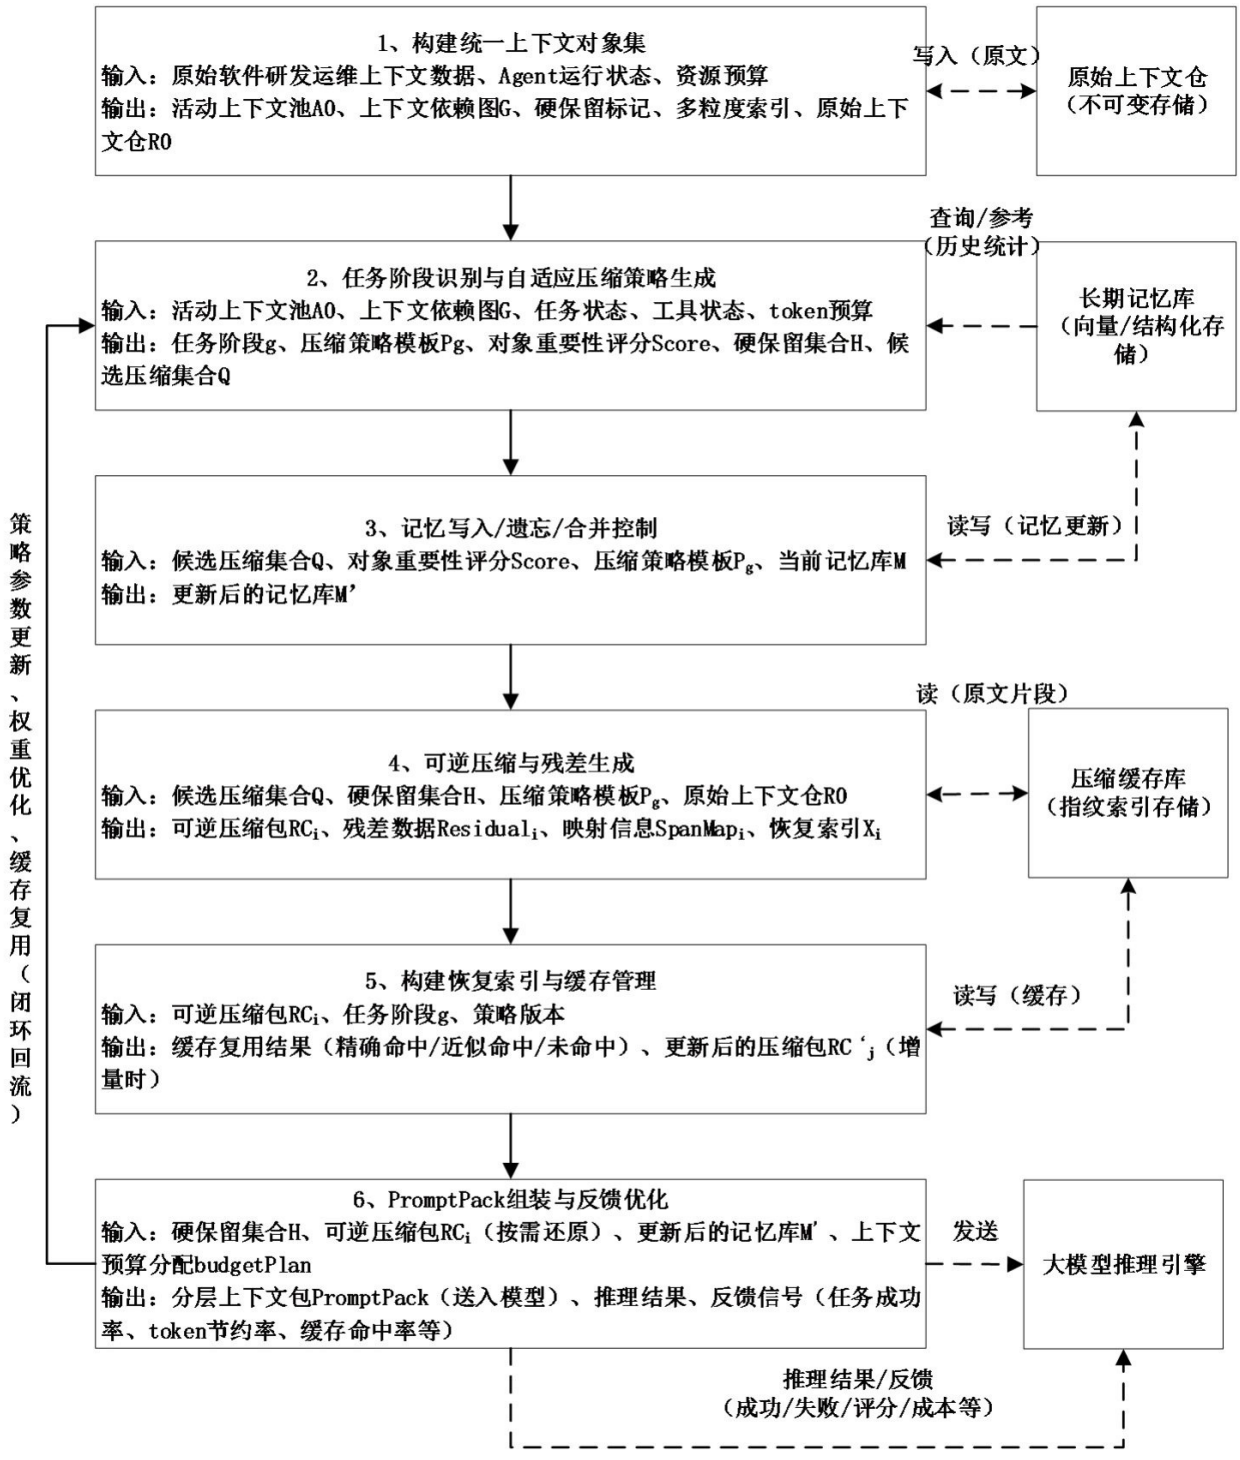

1、构建统一上下文对象集
输入：原始软件研发运维上下文数据、Agent运行状态、资源预算
输出：活动上下文池A0、上下文依赖图G、硬保留标记、多粒度索引、原始上下文仓R0
写入（原文）
原始上下文仓（不可变存储）
查询/参考（历史统计）
2、任务阶段识别与自适应压缩策略生成
输入：活动上下文池A0、上下文依赖图G、任务状态、工具状态、token预算
输出：任务阶段g、压缩策略模板Pg、对象重要性评分Score、硬保留集合H、候选压缩集合Q
长期记忆库（向量/结构化存储）
3、记忆写入/遗忘/合并控制
输入：候选压缩集合Q、对象重要性评分Score、压缩策略模板P_g、当前记忆库M
输出：更新后的记忆库M'
读写（记忆更新）
读（原文片段）
4、可逆压缩与残差生成
输入：候选压缩集合Q、硬保留集合H、压缩策略模板P_g、原始上下文仓R0
输出：可逆压缩包RC_i、残差数据$Residual_i$、映射信息$SpanMap_i$、恢复索引X_i
压缩缓存库（指纹索引存储）
5、构建恢复索引与缓存管理
输入：可逆压缩包RC_i、任务阶段g、策略版本
输出：缓存复用结果（精确命中/近似命中/未命中）、更新后的压缩包RC‘$_j$（增量时）
读写（缓存）
6、PromptPack组装与反馈优化
输入：硬保留集合H、可逆压缩包RC_i（按需还原）、更新后的记忆库M'、上下文预算分配budgetPlan
输出：分层上下文包PromptPack（送入模型）、推理结果、反馈信号（任务成功率、token节约率、缓存命中率等）
发送
大模型推理引擎
推理结果/反馈（成功/失败/评分/成本等）
策略参数更新、权重优化、缓存复用（闭环回流）

图1

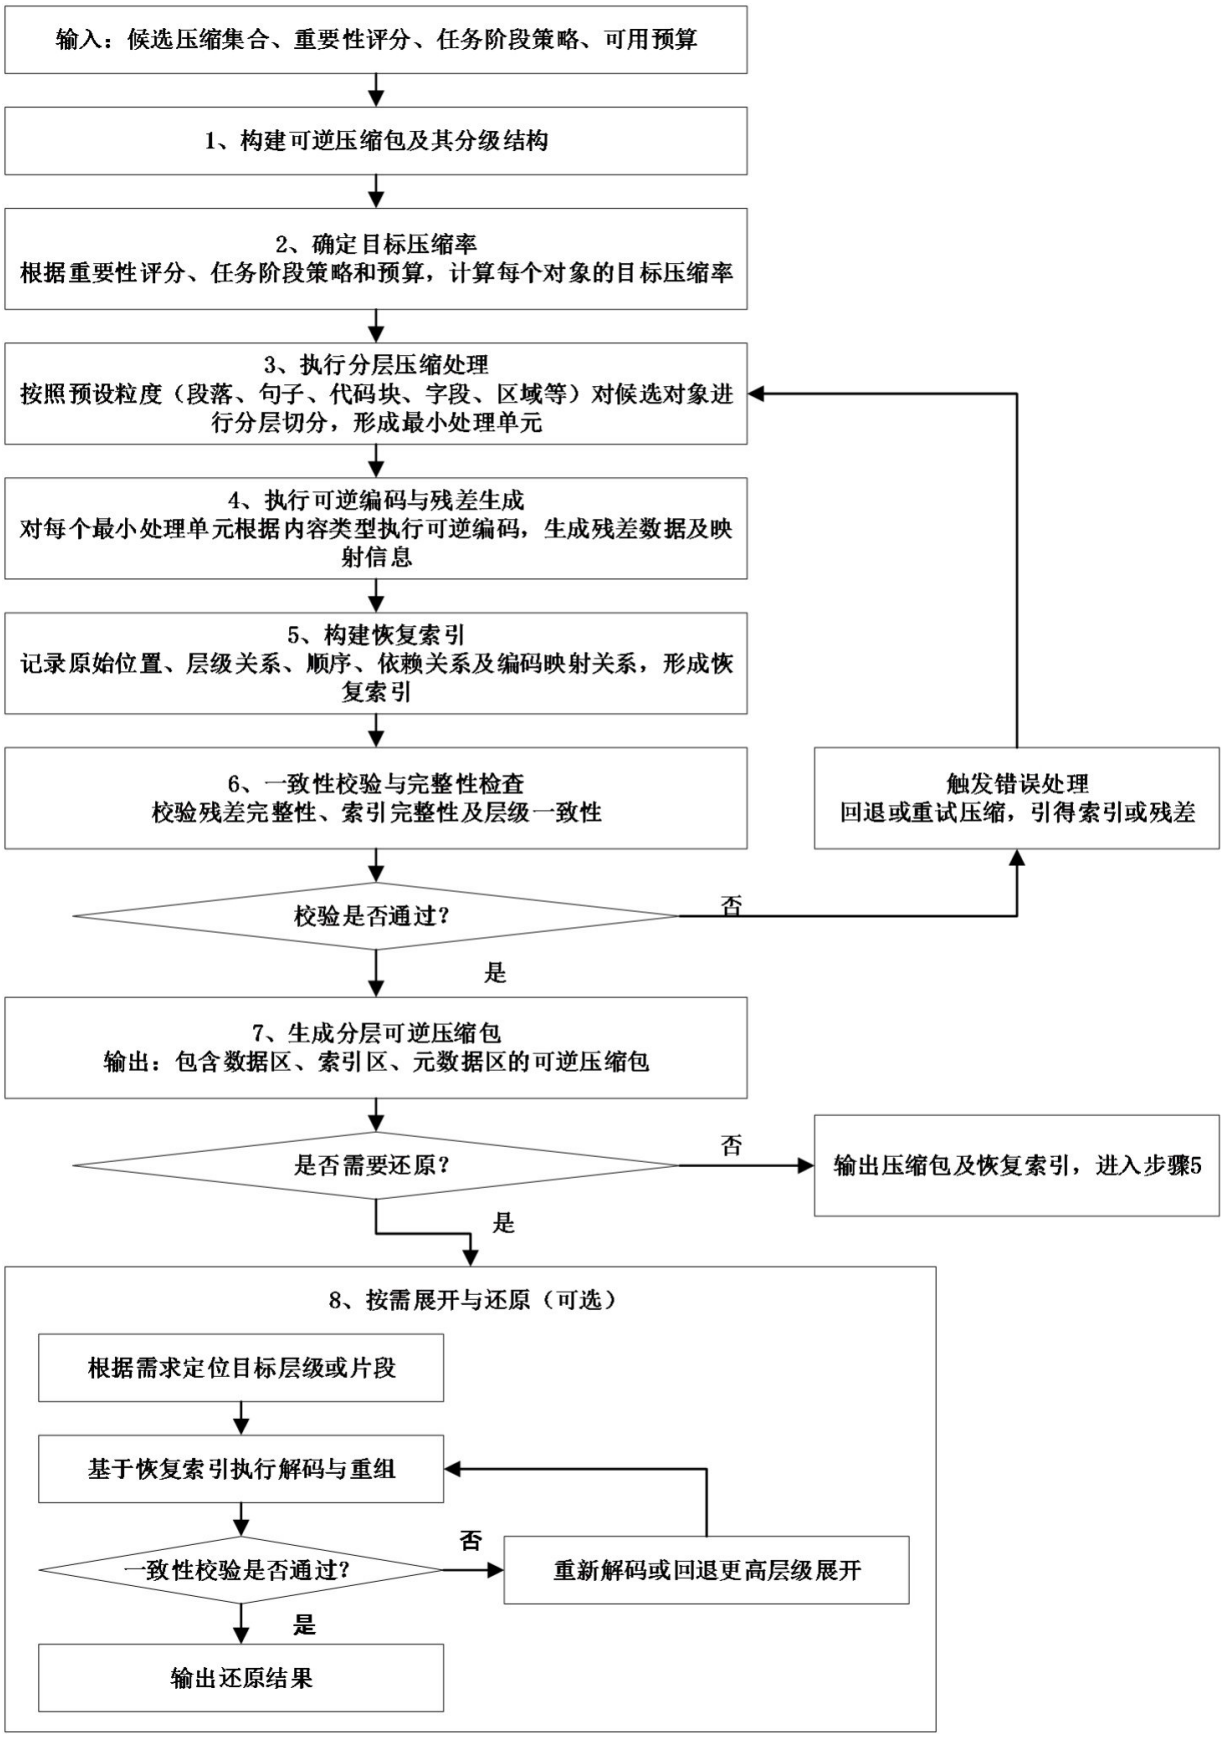

输入：候选压缩集合、重要性评分、任务阶段策略、可用预算
1、构建可逆压缩包及其分级结构
2、确定目标压缩率
根据重要性评分、任务阶段策略和预算，计算每个对象的目标压缩率
3、执行分层压缩处理
按照预设粒度（段落、句子、代码块、字段、区域等）对候选对象进行分层切分，形成最小处理单元
4、执行可逆编码与残差生成
对每个最小处理单元根据内容类型执行可逆编码，生成残差数据及映射信息
5、构建恢复索引
记录原始位置、层级关系、顺序、依赖关系及编码映射关系，形成恢复索引
6、一致性校验与完整性检查
校验残差完整性、索引完整性及层级一致性
触发错误处理
回退或重试压缩，引得索引或残差
校验是否通过？
否
是
7、生成分层可逆压缩包
输出：包含数据区、索引区、元数据区的可逆压缩包
是否需要还原？
否
输出压缩包及恢复索引，进入步骤5
是
8、按需展开与还原（可选）
根据需求定位目标层级或片段
基于恢复索引执行解码与重组
一致性校验是否通过？
否
重新解码或回退更高层级展开
是
输出还原结果

图2