(19)国家知识产权局

(12)发明专利申请

(10)申请公布号 CN 121388182 A
(43)申请公布日 2026.01.23

(21)申请号 202511487654.6

(22)申请日 2025.10.17

(71)申请人 无锡百商众望数据科技有限公司
地址 214000 江苏省无锡市惠山区洛社镇无锡西站物流园区洛南大道8-418

(72)发明人 杨骁锋 刘方明 魏冬冬

(74)专利代理机构 北京智沃律师事务所 11620
专利代理师 李笑丹

(51)Int.Cl.
*G06F 16/36*(2019.01)
*G06F 16/3329*(2025.01)
*G06N 5/04*(2023.01)
*G06N 5/022*(2023.01)

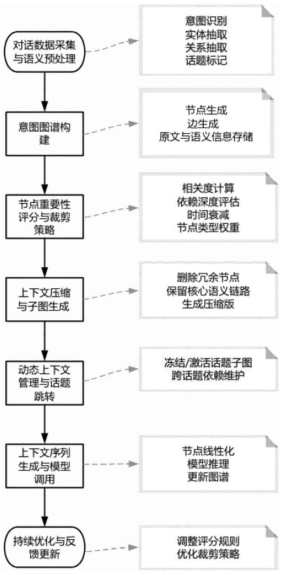
权利要求书2页 说明书7页 附图1页

(54)发明名称

一种基于多轮对话意图图谱构建的上下文压缩方法

(57)摘要

本发明提供一种基于多轮对话意图图谱构建的上下文压缩方法,包括以下步骤:S1:对话数据采集与预处理,对每个会话单元进行自然语言处理;S2:意图图谱构建,通过节点设计和边设计实现,每个节点包含原文内容及结构化语义信息;S3:上下文压缩与图结构裁剪,仅保留构成核心语义链路的子图;S4:动态上下文管理与话题跳转处理,在多话题对话中,当用户跳转或切换至新的话题,系统记录当前活跃话题的子图,并冻结非活跃话题的上下文节点;S5:上下文序列生成与模型输入,将裁剪后的子图中的节点内容按依赖链路顺序线性化,生成压缩后的上下文序列,将该上下文序列与当前用户输入一并传递给大语言模型进行推理;S6:持续更新与反馈优化。




CN 121388182 A

1.一种基于多轮对话意图图谱构建的上下文压缩方法,包括以下步骤:

S1:对话数据采集与预处理,将多轮对话的每一轮用户消息输入与系统回复输出进行分割,形成基本的会话单元,对每个会话单元进行自然语言处理,包括分词、意图识别、实体抽取、关系抽取;

S2:意图图谱构建,通过节点设计和边设计实现,每个节点包含原文内容及结构化语义信息,确保在压缩后依然可追溯原文细节;

S3:上下文压缩与图结构裁剪,通过设定重要性评分规则对节点进行打分,按照重要性评分对图谱进行裁剪,删除冗余节点与无关边,实现上下文压缩,仅保留构成核心语义链路的子图;

S4:动态上下文管理与话题跳转处理,在多话题对话中,当用户跳转或切换至新的话题,系统记录当前活跃话题的子图,并冻结非活跃话题的上下文节点;当用户回到之前话题或跨话题引用历史信息时,快速激活对应子图并恢复相关上下文,并将其与当前子图进行合并或部分合并;在不同话题间切换时,保留必要的跨图依赖关系,确保回答的连贯性与准确性;

S5:上下文序列生成与模型输入,将裁剪后的子图中的节点内容按依赖链路顺序线性化,生成压缩后的上下文序列,将该上下文序列与当前用户输入一并传递给大语言模型进行推理,将模型输出作为系统响应,同时将响应节点加入意图图谱中,完成一次对话循环;

S6:持续更新与反馈优化。

2.根据权利要求1所述的基于多轮对话意图图谱构建的上下文压缩方法,其特征在于:步骤S1包括以下步骤:

具体包括以下步骤:

S11:接收来自用户与系统的多轮对话数据流,按时间顺序记录每一轮会话,将多轮对话的每一轮输入与输出进行分割,形成基本的会话单元;

S12:对会话文本进行自然语言处理,包括意图识别、实体抽取、关系抽取和话题标记;

所述意图识别是指识别用户输入的目标意图,包括提问、请求、命令;

所述实体抽取是指识别涉及的实体信息,包括人名、地点、数值、时间;

所述关系抽取是指识别对话中意图、实体与上下文之间的逻辑关系;

所述话题标记是指为每条会话单元打上话题标签,用于后续话题追踪与跳转处理。

3.根据权利要求1所述的基于多轮对话意图图谱构建的上下文压缩方法,其特征在于:步骤S2中,所述意图图谱构建是以意图、实体、响应为节点,以语义依赖、引用关系、时间顺序等为边,构建多轮对话的意图图谱;所述节点属性包含节点类型、时间戳、原文内容、语义向量表示,所述边属性包含关系类型、权重值。

4.根据权利要求1所述的基于多轮对话意图图谱构建的上下文压缩方法,其特征在于:步骤S2中,所述节点设计包括用户意图节点、系统响应节点和辅助信息节点,节点生成包括根据意图识别结果生成用户意图节点,根据系统返回内容生成系统响应节点,对涉及的背景信息、上下文状态生成辅助信息节点;所述用户意图节点表示用户的需求、问题、指令,系统响应节点表示系统返回的回答、执行结果,辅助信息节点表示背景知识、上下文状态、限制条件。

5.根据权利要求1所述的基于多轮对话意图图谱构建的上下文压缩方法,其特征在于:

步骤S2中,所述边设计包括因果关系边、话题延续边和依赖关系边,边生成包括根据连接用户意图节点与对应系统响应节点生成因果关系边,根据连接同一话题下的相邻节点生成话题延续边,根据连接当前节点与其依赖的历史节点生成依赖关系边;所述因果关系边描述某一用户意图与对应系统响应之间的直接关联,所述话题延续边表示同一话题下多轮对话的延续关系,所述依赖关系边表示当前节点引用或依赖的历史信息。

6.根据权利要求1所述的基于多轮对话意图图谱构建的上下文压缩方法,其特征在于:步骤S3中,包括以下步骤:

S21:按裁剪策略删除冗余节点及其相关边;

S22:保留构成核心语义链路的子图,确保因果关系与依赖链完整不被破坏;

S23:生成该子图对应的上下文压缩版本,为后续模型调用准备输入。

7.根据权利要求1所述的基于多轮对话意图图谱构建的上下文压缩方法,其特征在于:步骤S3中,所述评分规则包括相关度、依赖深度、时间衰减和节点类型权重,所述相关度是指节点与当前用户意图的语义匹配度;所述依赖深度是指节点在引用链路中的位置及其对当前语义的贡献度;所述时间衰减是指根据节点创建时间给予权重衰减;所述节点类型权重是将关键信息节点优先保留。

8.根据权利要求1所述的基于多轮对话意图图谱构建的上下文压缩方法,其特征在于:步骤S6中,持续更新与反馈优化是指在对话过程中动态更新意图图谱结构,确保上下文压缩始终基于最新对话状态;根据模型输出质量及用户反馈,动态调整节点以及优化重要性评分规则与裁剪策略,通过持续迭代优化,提高上下文压缩的准确性和模型推理效果。

# 一种基于多轮对话意图图谱构建的上下文压缩方法

## 技术领域

[0001] 本发明涉及一种对话意图图谱,尤其是涉及一种基于多轮对话意图图谱构建的上下文压缩方法。

## 背景技术

[0002] 随着大语言模型(LLM)在多轮对话、智能客服、虚拟助理等场景中的广泛应用,上下文管理成为影响模型推理质量与性能的关键环节。在多轮对话中,系统需要结合当前用户输入与历史会话内容,才能生成准确、连贯的回答。然而,长对话带来两个突出挑战:

[0003] (1)历史上下文信息冗余且线性存储;对话历史往往包含大量与当前问题无关的信息,若全部传入模型,不仅增加Token消耗,还会拉低模型响应速度。传统的线性会话存储方式缺乏语义结构化表示,使得筛选关键上下文变得低效。

[0004] (2)多话题跳转与跨轮依赖处理困难;用户在自然对话中可能频繁切换话题,并在后续再次引用之前的内容。如果上下文筛选机制不能准确恢复相关信息,就会导致回答缺失关键信息或出现逻辑错误。

[0005] (3)现有方法在信息保留与压缩之间的平衡不足;Embedding检索和摘要法是目前最常用的上下文压缩手段,但各自存在不足:

[0006] 1)基于embedding检索的方案;原理是将历史对话片段向量化,通过相似度匹配找出与当前问题最相关的内容。局限性:无法显式建模跨轮引用与因果关系,导致当用户问题依赖多个非连续片段时,检索结果不完整。对话主题发生跳转时,检索容易忽略隐含的上下文链路。

[0007] 2)基于摘要的方案;原理是对历史对话进行概括,生成较短的文本传入模型。局限性:摘要过程不可避免地丢失细节信息,如具体数字、限定条件等。摘要结果缺乏可追溯性,难以在后续推理中复原被压缩掉的内容。

[0008] 现有实现方案:

[0009] 当前业内已有尝试结合“语义分块+重要性评分”进行上下文过滤的方案,即先将对话分成片段,再计算每个片段的重要度,保留重要片段作为上下文输入。但这类方案本质上仍是线性片段筛选,缺乏对对话意图结构的显式建模,无法准确捕捉跨话题引用、因果关系和依赖链路,也无法在压缩后保证语义的完整性与可追溯性。

[0010] 现有实现方案的缺陷:现有的多轮对话上下文处理方法主要包括基于embedding的检索法和基于摘要的压缩法,以及少量结合重要性评分的线性片段筛选方案。这些方法存在如下缺陷:

[0011] (1)上下文结构缺失,难以捕捉跨轮语义依赖;embedding检索仅基于向量相似度匹配片段,忽略了多轮对话中“意图—响应—依赖”的显式关系,无法准确处理跨话题跳转或非连续引用的场景。

[0012] (2)信息保留与压缩效率难以兼顾;摘要法虽然能降低输入长度,但会丢失细节信息(如数值、限定条件、具体事实),且缺乏可追溯性,一旦丢失无法恢复。线性片段筛选虽然

保留原文,但筛选粒度粗,压缩效率低,冗余信息依旧占用大量上下文空间。

[0013] (3)对话上下文管理粒度过粗,动态性不足;现有方法大多采用一次性静态压缩或检索,不能根据当前活跃话题动态调整保留信息范围,导致无关内容被带入或关键内容被丢弃。

[0014] (4)计算资源消耗大,影响推理性能;在长对话场景中,冗余的上下文输入直接导致Token数量增加,推理延迟加大,运行成本上升。

## 发明内容

[0015] 本发明提供了一种基于多轮对话意图图谱构建的上下文压缩方法,用于解决以下问题:

[0016] (1)上下文信息冗余,计算成本高;

[0017] 在长对话场景中,系统通常将大量历史对话原文直接传递给模型,导致输入Token数量急剧增加,推理延迟与计算成本显著上升。

[0018] (2)语义依赖关系缺失,跨话题理解能力不足;

[0019] 基于向量相似度的embedding检索方法虽然能够找到相关片段,但难以捕捉对话中的因果链与跨轮引用关系,尤其在用户多次跳转话题时容易漏检关键上下文。

[0020] (3)摘要法导致关键信息丢失与不可追溯性;

[0021] 传统文本摘要方法将历史对话压缩为短文,但会丢失具体事实、约束条件等细节,使得模型在后续推理中缺乏精确可追溯的依据。

[0022] (4)缺乏对多轮对话的结构化语义建模;

[0023] 现有方法大多采用线性对话记忆,没有显式建模“意图—响应—依赖”之间的关系,无法在压缩时保留必要的逻辑链路。

[0024] 其技术方案如下所述:

[0025] 一种基于多轮对话意图图谱构建的上下文压缩方法,包括以下步骤:

[0026] S1:对话数据采集与预处理,将多轮对话的每一轮用户消息输入与系统回复输出进行分割,形成基本的会话单元,对每个会话单元进行自然语言处理,包括分词、意图识别、实体抽取、关系抽取;

[0027] S2:意图图谱构建,通过节点设计和边设计实现,每个节点包含原文内容及结构化语义信息,确保在压缩后依然可追溯原文细节;

[0028] S3:上下文压缩与图结构裁剪,通过设定重要性评分规则对节点进行打分,按照重要性评分对图谱进行裁剪,删除冗余节点与无关边,实现上下文压缩,仅保留构成核心语义链路的子图;

[0029] S4:动态上下文管理与话题跳转处理,在多话题对话中,当用户跳转或切换至新的话题,系统记录当前活跃话题的子图,并冻结非活跃话题的上下文节点;当用户回到之前话题或跨话题引用历史信息时,快速激活对应子图并恢复相关上下文,并将其与当前子图进行合并或部分合并;在不同话题间切换时,保留必要的跨图依赖关系,确保回答的连贯性与准确性;

[0030] S5:上下文序列生成与模型输入,将裁剪后的子图中的节点内容按依赖链路顺序线性化,生成压缩后的上下文序列,将该上下文序列与当前用户输入一并传递给大语言模

型进行推理,将模型输出作为系统响应,同时将响应节点加入意图图谱中,完成一次对话循环;

[0031] S6:持续更新与反馈优化。

[0032] 进一步的,步骤S1包括以下步骤:

[0033] 具体包括以下步骤:

[0034] S11:接收来自用户与系统的多轮对话数据流,按时间顺序记录每一轮会话,将多轮对话的每一轮输入与输出进行分割,形成基本的会话单元;

[0035] S12:对会话文本进行自然语言处理,包括意图识别、实体抽取、关系抽取和话题标记;

[0036] 所述意图识别是指识别用户输入的目标意图,包括提问、请求、命令;

[0037] 所述实体抽取是指识别涉及的实体信息,包括人名、地点、数值、时间;

[0038] 所述关系抽取是指识别对话中意图、实体与上下文之间的逻辑关系;

[0039] 所述话题标记是指为每条会话单元打上话题标签,用于后续话题追踪与跳转处理。

[0040] 进一步的,步骤S2中,所述意图图谱构建是以意图、实体、响应为节点,以语义依赖、引用关系、时间顺序等为边,构建多轮对话的意图图谱;所述节点属性包含节点类型、时间戳、原文内容、语义向量表示,所述边属性包含关系类型、权重值。

[0041] 进一步的,步骤S2中,所述节点设计包括用户意图节点、系统响应节点和辅助信息节点,节点生成包括根据意图识别结果生成用户意图节点,根据系统返回内容生成系统响应节点,对涉及的背景信息、上下文状态生成辅助信息节点;所述用户意图节点表示用户的需求、问题、指令,系统响应节点表示系统返回的回答、执行结果,辅助信息节点表示背景知识、上下文状态、限制条件。

[0042] 进一步的,步骤S2中,所述边设计包括因果关系边、话题延续边和依赖关系边,边生成包括根据连接用户意图节点与对应系统响应节点生成因果关系边,根据连接同一话题下的相邻节点生成话题延续边,根据连接当前节点与其依赖的历史节点生成依赖关系边;所述因果关系边描述某一用户意图与对应系统响应之间的直接关联,所述话题延续边表示同一话题下多轮对话的延续关系,所述依赖关系边表示当前节点引用或依赖的历史信息。

[0043] 进一步的,步骤S3中,包括以下步骤:

[0044] S21:按裁剪策略删除冗余节点及其相关边;

[0045] S22:保留构成核心语义链路的子图,确保因果关系与依赖链完整不被破坏;

[0046] S23:生成该子图对应的上下文压缩版本,为后续模型调用准备输入。

[0047] 进一步的,步骤S3中,所述评分规则包括相关度、依赖深度、时间衰减和节点类型权重,所述相关度是指节点与当前用户意图的语义匹配度;所述依赖深度是指节点在引用链路中的位置及其对当前语义的贡献度;所述时间衰减是指根据节点创建时间给予权重衰减;所述节点类型权重是将关键信息节点优先保留。

[0048] 进一步的,步骤S6中,持续更新与反馈优化是指在对话过程中动态更新意图图谱结构,确保上下文压缩始终基于最新对话状态;根据模型输出质量及用户反馈,动态调整节点以及优化重要性评分规则与裁剪策略,通过持续迭代优化,提高上下文压缩的准确性和模型推理效果。

[0049] 所述基于多轮对话意图图谱构建的上下文压缩方法,通过将对话历史转化为结构化的意图图谱,并在此基础上进行图结构裁剪与动态上下文管理,实现在保留核心语义链路和跨话题依赖的前提下,显著减少上下文输入长度,支持多轮、多话题跳转场景下的准确语义恢复,提升大语言模型的推理效率与响应准确性。

[0050] 本发明通过引入意图图谱(Intent Graph)结构,将多轮对话中的用户意图、系统响应及其关联关系建模为图数据;通过图结构裁剪实现上下文压缩,在保留跨轮依赖链路的同时删除冗余节点,兼顾信息保留率与压缩效率;支持话题跳转场景下的快速语义恢复,从而提升模型的上下文利用率与推理准确性。

[0051] 本发明的目的在于:

[0052] 1.提出一种基于多轮对话意图图谱构建的上下文压缩方法,将历史会话建模为包含用户意图、系统响应及其关联关系的意图图谱(Intent Graph)。

[0053] 2.实现结构化压缩:通过图结构裁剪方式,在保留跨话题依赖链路的同时,删除无关节点和冗余信息,既保证语义完整性,又显著减少上下文输入长度。

[0054] 3.支持多轮话题跳转下的动态上下文管理:当用户回到之前话题或引用历史信息时,可快速恢复相关语义链路,避免检索遗漏与摘要丢失。

[0055] 4.提升推理效率与准确性:在不牺牲信息可追溯性的前提下,降低大语言模型的Token消耗和计算成本,提升响应速度与结果的正确性。

## 附图说明

[0056] 图1是所述基于多轮对话意图图谱构建的上下文压缩方法的流程示意图。

## 具体实施方式

[0057] 所述基于多轮对话意图图谱构建的上下文压缩方法,核心思想是将对话历史从线性文本转化为结构化的意图图谱(Intent Graph),并基于该图谱进行图结构裁剪与动态上下文管理,从而在保留关键语义链路的同时,显著减少输入大语言模型的上下文长度,提高推理效率与准确性。

[0058] 如图1所示,所述基于多轮对话意图图谱构建的上下文压缩方法,包括以下步骤:

[0059] S1:对话数据采集与预处理,将多轮对话的每一轮输入(用户消息)与输出(系统回复)进行分割,形成基本的会话单元;对每个会话单元进行自然语言处理,包括分词、意图识别、实体抽取、关系抽取等;

[0060] 具体包括以下步骤:

[0061] S11:接收来自用户与系统的多轮对话数据流,按时间顺序记录每一轮会话。将多轮对话的每一轮输入(用户消息)与输出(系统回复)进行分割,形成基本的会话单元。

[0062] S12:对会话文本进行自然语言处理,包括:

[0063] 意图识别:识别用户输入的目标意图(如提问、请求、命令等);

[0064] 实体抽取:识别涉及的实体信息(如人名、地点、数值、时间等);

[0065] 关系抽取:识别对话中意图、实体与上下文之间的逻辑关系;

[0066] 话题标记:为每条会话单元打上话题标签,用于后续话题追踪与跳转处理。

[0067] S2:意图图谱构建,通过节点设计和边设计实现,每个节点包含原文内容及结构化

语义信息,确保在压缩后依然可追溯原文细节;

[0068] 所述节点设计包括用户意图节点、系统响应节点和辅助信息节点,节点生成包括:根据意图识别结果生成用户意图节点;根据系统返回内容生成系统响应节点;对涉及的背景信息、上下文状态生成辅助信息节点。节点中同时保存原始对话内容与结构化语义信息,以支持后续可追溯性。

[0069] 所述用户意图节点:表示用户的需求、问题、指令等。系统响应节点:表示系统返回的回答、执行结果等。辅助信息节点:表示背景知识、上下文状态、限制条件等。

[0070] 所述边设计包括因果关系边、话题延续边和依赖关系边。边生成包括:根据连接用户意图节点与对应系统响应节点生成因果关系边,根据连接同一话题下的相邻节点生成话题延续边,根据连接当前节点与其依赖的历史节点生成依赖关系边。

[0071] 所述因果关系边(Intent→Response):描述某一用户意图与对应系统响应之间的直接关联。话题延续边:表示同一话题下多轮对话的延续关系。依赖关系边:表示当前节点引用或依赖的历史信息。

[0072] S3:上下文压缩与图结构裁剪,通过设定重要性评分规则(如与当前用户输入的语义相关度、依赖深度、时间衰减系数等)对节点进行打分;按照重要性评分对图谱进行裁剪,删除冗余节点与无关边,实现上下文压缩,仅保留构成核心语义链路的子图,在压缩过程中优先保证因果链路与依赖链路的完整性,防止信息断裂。

[0073] 所述设定节点评分规则,综合考虑以下因素:与当前用户输入的语义相关度;节点在依赖链路中的深度(依赖越多的重要性越高);节点距离当前会话的时间衰减系数;节点类型权重(意图节点权重通常高于辅助信息节点)。根据评分结果生成图裁剪策略,确定保留节点与删除节点的集合。

[0074] 其中,上下文压缩与子图生成包括以下步骤:

[0075] S21:按裁剪策略删除冗余节点及其相关边;

[0076] S22:保留构成核心语义链路的子图,确保因果关系与依赖链完整不被破坏。

[0077] S23:生成该子图对应的上下文压缩版本,为后续模型调用准备输入。

[0078] S4:动态上下文管理与话题跳转处理,在多话题对话中,当用户跳转或切换至新的话题,系统记录当前活跃话题的子图,并冻结非活跃话题的上下文节点;当用户回到之前话题或跨话题引用历史信息时,快速激活对应子图并恢复相关上下文,并将其与当前子图进行合并或部分合并;在不同话题间切换时,保留必要的跨图依赖关系,确保回答的连贯性与准确性

[0079] S5:上下文序列生成与模型输入,将裁剪后的子图中的节点内容按依赖链路顺序线性化,生成压缩后的上下文序列,将该上下文序列与当前用户输入一并传递给大语言模型进行推理,将模型输出作为系统响应,同时将响应节点加入意图图谱中,完成一次对话循环。作为大语言模型输入,该上下文序列在保证语义完整性的同时,大幅减少了Token数量,降低了计算开销。

[0080] S6:持续更新与反馈优化,在对话过程中动态更新意图图谱结构,确保上下文压缩始终基于最新对话状态。可引入用户或模型的反馈结果,根据模型输出质量及用户反馈,动态调整节点以及优化重要性评分规则与裁剪策略,通过持续迭代优化,提高上下文压缩的准确性和模型推理效果。

[0081] 通过上述技术方案,本发明在信息可追溯性、跨话题依赖处理和压缩效率之间取得平衡,克服了现有embedding检索和摘要法的局限,实现了长对话场景下的高效、精准上下文管理。本方法通过“意图图谱构建+图结构裁剪+动态上下文管理”,在长对话、多话题跳转场景中,能有效保留必要的跨轮依赖信息,同时显著减少上下文输入长度,实现高效、准确的对话生成。

[0082] 在实施例中,本发明包括以下步骤:

[0083] 步骤一:对话数据采集与语义预处理;获取多轮人机对话的原始文本数据,数据来源可以是即时交互对话、历史聊天记录或多模态输入的转写结果。

[0084] 对每轮对话进行语义预处理,包括:

[0085] 意图识别:利用分类模型或规则引擎判断用户输入的主要意图类别。

[0086] 实体抽取:识别出语句中的实体(人名、地名、时间、产品名称等)。

[0087] 关系抽取:分析意图与实体之间的关系,形成语义三元组。

[0088] 话题标记:为每一轮对话分配唯一的话题ID或话题标签。

[0089] 步骤二:意图图谱构建;以意图、实体、响应等为节点,以语义依赖、引用关系、时间顺序等为边,构建多轮对话的意图图谱。

[0090] 节点属性包含:节点类型、时间戳、原文内容、语义向量表示等。

[0091] 边属性包含:关系类型(依赖/引用/顺序)、权重值。

[0092] 将意图图谱存储于可查询的数据结构中,支持后续裁剪与检索。

[0093] 步骤三:节点重要性评分与图裁剪策略生成,为每个节点计算重要性评分,评分规则可包括:

[0094] 相关度:节点与当前用户意图的语义匹配度;

[0095] 依赖深度:节点在引用链路中的位置及其对当前语义的贡献度;

[0096] 时间衰减:根据节点创建时间给予权重衰减;

[0097] 节点类型权重:如关键信息节点优先保留。

[0098] 根据评分结果,生成图裁剪策略,明确需要保留与删除的节点集合。

[0099] 步骤四:上下文压缩与子图生成,按照裁剪策略,从原意图图谱中删除冗余节点与低相关度节点。保留与当前任务高度相关的语义链路,形成结构化的上下文子图。对子图进行线性化处理,得到压缩后的上下文序列。

[0100] 动态上下文管理与话题跳转处理,当用户话题发生跳转时,激活对应话题的历史子图,并根据依赖关系补充相关节点。当话题暂时中止时,冻结其对应子图,避免无关信息持续占用上下文空间。

[0101] 步骤五:上下文序列生成与大语言模型调用,将子图节点按照时间与依赖顺序线性化为文本序列。将序列输入大语言模型(LLM)进行推理,生成响应。将该响应及相关语义节点写入意图图谱,形成持续更新的会话知识结构。

[0102] 步骤六:持续优化与反馈更新,通过模型推理结果与用户反馈,更新节点评分规则和裁剪策略。对意图图谱的结构与权重分配进行优化,以提升后续压缩与检索的准确性和效率。

[0103] 本发明具有以下特点:

[0104] 1.基于意图图谱的上下文表示结构;

[0105] 采用由意图节点、实体节点、响应节点等构成的图结构表示多轮对话语义,而非传统的线性文本或向量序列。图结构中包含显式的语义关系边(依赖、引用、顺序),并附带节点与边的多维属性(时间戳、权重、节点类型等)。

[0106] 2.节点重要性多维评分机制;

[0107] 同时考虑语义相关度、依赖深度、时间衰减与节点类型权重等因素,对节点进行综合评分。根据评分动态生成上下文裁剪策略,而非依赖固定长度截断或简单关键词匹配。

[0108] 3.图裁剪驱动的上下文压缩方法;

[0109] 基于评分策略在图谱上执行节点裁剪,保留核心语义链路生成子图,实现对话上下文的高效压缩。保证压缩后仍能保持跨轮、多话题依赖的完整性。

[0110] 4.动态上下文管理与话题跳转机制;

[0111] 支持多轮对话中跨话题的切换、回溯与冻结操作,通过激活/冻结不同子图实现高效上下文管理。跨话题调用时可自动恢复相关依赖链,避免信息丢失。

[0112] 5.压缩上下文的结构化线性化生成;

[0113] 将子图节点按依赖关系与时间顺序线性化为上下文序列,用于大语言模型输入。在保证信息完整性的同时减少冗余,提升推理效率。

[0114] 与现有技术相比,本发明具有以下优点:

[0115] 1.多轮对话意图图谱构建实现更精准的上下文理解;

[0116] 传统的对话系统往往仅基于单轮或简单上下文展开,难以准确捕捉用户多轮交互中的意图演变和上下文关联。本发明通过构建多轮对话意图图谱,有效梳理和表达多轮对话中的意图结构和转移关系,提升了对话上下文的理解深度和准确性。

[0117] 2.上下文压缩机制有效降低计算和存储资源消耗;

[0118] 通过基于意图图谱的上下文压缩方法,能够在保证语义完整性的前提下,去除冗余和重复信息,显著降低上下文信息的存储规模和传输负担,提高系统响应速度和运行效率。

[0119] 3.提升对话系统的实时性和交互体验;

[0120] 压缩后的上下文信息减少了系统处理的输入长度,减少了模型推理时间,从而加快了系统响应速度,改善用户的交互体验。

[0121] 4.适应多场景、多领域对话应用;

[0122] 本发明的意图图谱构建和压缩方法具备较好的通用性和扩展性,能够适应不同领域和多种复杂多轮对话场景,提升系统的适用范围和实用价值。

[0123] 5.增强对话上下文的稳定性和连贯性;

[0124] 通过对意图图谱的动态维护和更新,本发明保证了对话上下文在多轮交互中的连贯性和一致性,避免了因上下文冗余或混乱导致的对话偏离和理解错误。

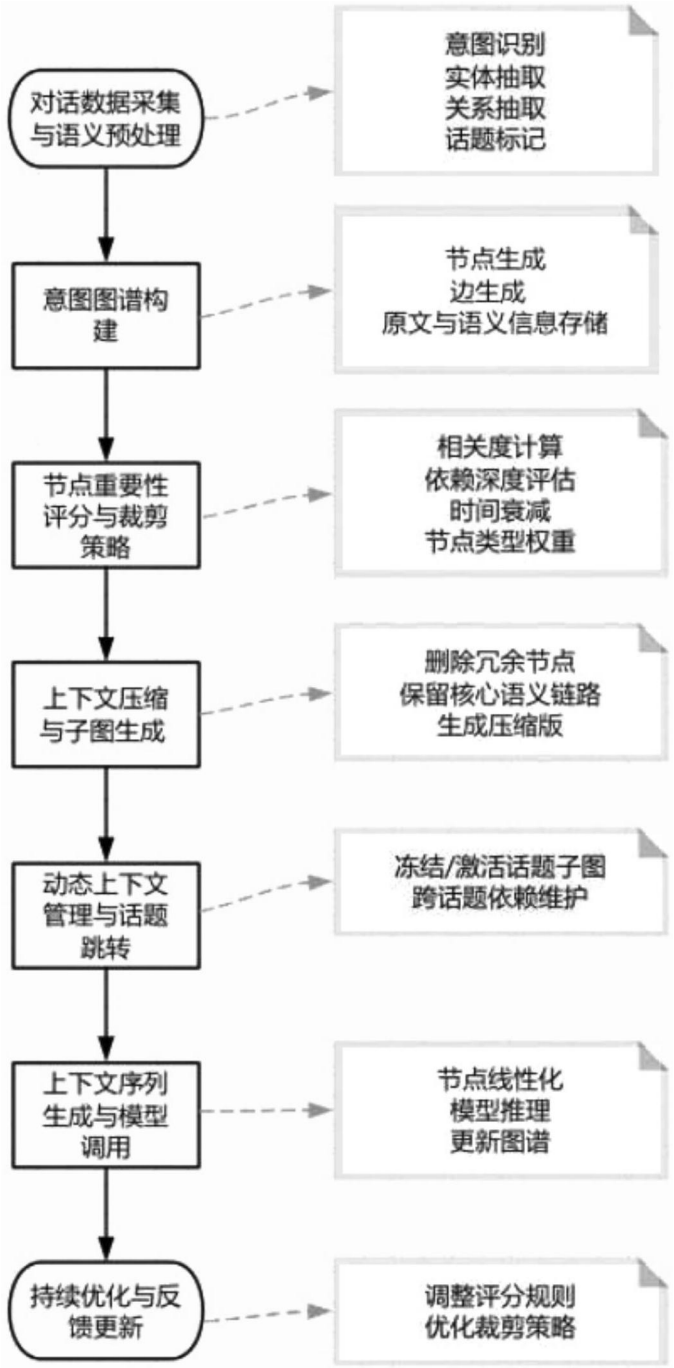

对话数据采集与语义预处理
意图识别
实体抽取
关系抽取
话题标记
意图图谱构建
节点生成
边生成
原文与语义信息存储
节点重要性评分与裁剪策略
相关度计算
依赖深度评估
时间衰减
节点类型权重
上下文压缩与子图生成
删除冗余节点
保留核心语义链路
生成压缩版
动态上下文管理与话题跳转
冻结/激活话题子图
跨话题依赖维护
上下文序列生成与模型调用
节点线性化
模型推理
更新图谱
持续优化与反馈更新
调整评分规则
优化裁剪策略

图1