(19)国家知识产权局

(12)发明专利申请

(10)申请公布号 CN 122734001 A
(43)申请公布日 2026.09.11

(21)申请号 202610889174.0

(22)申请日 2026.06.18

(71)申请人 北京百度网讯科技有限公司
地址 100085 北京市海淀区上地十街10号百度大厦2层

(72)发明人 陈一言 牛万鹏 张立理 罗正昕 彭云鹏 徐晓强 陈泽 杜代忠 范欣 龚平 胡新家 覃耀辉 邵杰 孙浩 田明 王申宇 王旭 吴昊 于启迪 张炳斐 朱志强 宗亚锋

(74)专利代理机构 北京鸿德海业知识产权代理有限公司 11412
专利代理师 苏伟

(51)Int.Cl.
G06F 16/31(2019.01)
G06F 16/3329(2025.01)
G06F 16/334(2025.01)
G06N 3/006(2023.01)
G06N 5/04(2023.01)

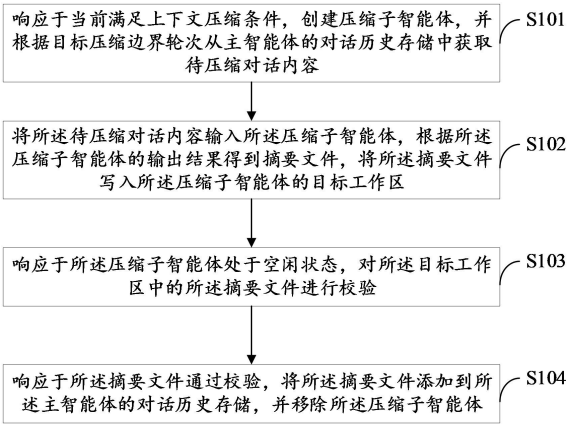
权利要求书2页 说明书12页 附图4页

(54)发明名称

面向智能体的上下文压缩方法、装置、电子设备

(57)摘要

本公开提供一种面向智能体的上下文压缩方法,涉及智能体、深度学习、自然语言处理、大模型等人工智能技术领域。面向智能体的上下文压缩方法包括:响应于当前满足上下文压缩条件创建压缩子智能体,根据目标压缩边界轮次从主智能体的对话历史存储中获取待压缩对话内容;将待压缩对话内容输入压缩子智能体,根据压缩子智能体的输出结果得到摘要文件,将摘要文件写入压缩子智能体的目标工作区;响应于压缩子智能体处于空闲状态,对目标工作区中的摘要文件进行校验;响应于摘要文件通过校验,将摘要文件添加到主智能体的对话历史存储,并所述压缩子智能体。本公开一方面使得主智能体在上下文压缩过程中不会暂停,另一方面能够提升上下文的压缩灵活性。



CN 122734001 A

1.一种面向智能体的上下文压缩方法,包括:

响应于当前满足上下文压缩条件,创建压缩子智能体,并根据目标压缩边界轮次从主智能体的对话历史存储中获取待压缩对话内容;

将所述待压缩对话内容输入所述压缩子智能体,根据所述压缩子智能体的输出结果得到摘要文件,将所述摘要文件写入所述压缩子智能体的目标工作区;

响应于所述压缩子智能体处于空闲状态,对所述目标工作区中的所述摘要文件进行校验;

响应于所述摘要文件通过校验,将所述摘要文件添加到所述主智能体的对话历史存储,并移除所述压缩子智能体。

2.根据权利要求1所述的方法,其中,所述创建压缩子智能体包括:

对所述主智能体执行派生操作,得到初始子智能体;

将压缩任务指令注入所述初始子智能体,得到所述压缩子智能体。

3.根据权利要求1所述的方法,其中,所述根据目标压缩边界轮次从主智能体的对话历史存储中获取待压缩对话内容包括:

从所述主智能体的对话历史存储中获取对应前一次压缩任务的历史压缩边界轮次;

根据所述目标压缩边界轮次与所述历史压缩边界轮次,确定对话轮次范围;

从所述主智能体的对话历史存储中获取对应所述对话轮次范围的对话内容,作为所述待压缩对话内容。

4.根据权利要求1所述的方法,还包括,

获取所述主智能体生成的压缩边界轮次,作为所述目标压缩边界轮次。

5.根据权利要求1所述的方法,其中,所述将所述待压缩对话内容输入所述压缩子智能体,根据所述压缩子智能体的输出结果得到摘要文件包括:

使用所述压缩子智能体对所述待压缩对话内容进行分类,得到所述待压缩对话内容的分类结果;

由所述压缩子智能体调用与所述分类结果对应的工具处理所述待压缩对话内容,根据处理结果得到所述摘要文件。

6.根据权利要求5所述的方法,其中,所述由所述压缩子智能体调用与所述分类结果对应的工具处理所述待压缩对话内容,根据处理结果得到所述摘要文件包括:

响应于所述分类结果为重要内容,由所述压缩子智能体调用文件读写工具,获取对应所述待压缩对话内容的原始数据;

将所述原始数据作为所述待压缩对话内容的处理结果。

7.根据权利要求5所述的方法,其中,所述由所述压缩子智能体调用与所述分类结果对应的工具处理所述待压缩对话内容,根据处理结果得到所述摘要文件包括:

响应于所述分类结果为非重要内容,由所述压缩子智能体调用文件读写工具,获取对应所述待压缩对话内容的原始数据;

在从所述原始数据中提取关键信息之后,由所述压缩子智能体调用代码执行工具,对所述关键信息进行程序化组装;

将所得到的组装结果作为所述待压缩对话内容的处理结果。

8.根据权利要求1所述的方法,其中,所述将所述待压缩对话内容输入所述压缩子智能

体,根据所述压缩子智能体的输出结果得到摘要文件包括:

获取所述主智能体生成的压缩提示;

将所述压缩提示与所述待压缩对话内容输入所述压缩子智能体,根据所述压缩子智能体的输出结果得到所述摘要文件。

9.根据权利要求5所述的方法,还包括,

获取所述摘要文件的剩余容量;

响应于所述处理结果的大小超过所述剩余容量、且所述处理结果为重要内容,由所述压缩子智能体,通过消息传递的方式将所述处理结果发送到所述主智能体。

10.根据权利要求1所述的方法,还包括,

响应于所述摘要文件未通过校验,获取所述压缩子智能体的重试次数;

响应于所述重试次数小于预设次数阈值,根据校验错误类型信息生成重试指令;

将所述重试指令发送到所述压缩子智能体,所述重试指令用于所述压缩子智能体结合所述校验错误类型信息重新执行压缩任务以得到新的摘要文件。

11.根据权利要求1所述的方法,还包括,

从所述压缩子智能体中获取所述主智能体的持久记忆信息;

生成包括所述持久记忆信息的压缩完成通知,将所述压缩完成通知发送到所述主智能体。

12.一种面向智能体的上下文压缩装置,包括:

创建单元,用于响应于当前满足上下文压缩条件,创建压缩子智能体,并根据目标压缩边界轮次从主智能体的对话历史存储中获取待压缩对话内容;

压缩单元,用于将所述待压缩对话内容输入所述压缩子智能体,根据所述压缩子智能体的输出结果得到摘要文件,将所述摘要文件写入所述压缩子智能体的目标工作区;

校验单元,用于响应于所述压缩子智能体处于空闲状态,对所述目标工作区中的所述摘要文件进行校验;

处理单元,用于响应于所述摘要文件通过校验,将所述摘要文件添加到所述主智能体的对话历史存储,并移除所述压缩子智能体。

13.一种电子设备,包括:

至少一个处理器;以及

与所述至少一个处理器通信连接的存储器;其中,

所述存储器存储有可被所述至少一个处理器执行的指令,所述指令被所述至少一个处理器执行,以使所述至少一个处理器能够执行权利要求1-11中任一项所述的方法。

14.一种存储有计算机指令的非瞬时计算机可读存储介质,其中,所述计算机指令用于使所述计算机执行权利要求1-11中任一项所述的方法。

15.一种计算机程序产品,包括计算机程序,所述计算机程序在被处理器执行时实现根据权利要求1-11中任一项所述的方法。

面向智能体的上下文压缩方法、装置、电子设备

技术领域

[0001] 本公开涉及互联网技术领域,尤其涉及智能体、深度学习、自然语言处理、大模型等人工智能技术领域。提供了一种面向智能体的上下文压缩方法、装置、电子设备与可读存储介质。

背景技术

[0002] 基于大模型的智能体在执行长程任务(例如代码开发、文档处理、多轮对话等)时,随着对话历史的累积,上下文窗口会逐渐饱和,从而导致智能体的推理能力下降、计算成本增加、上下文溢出等问题。

[0003] 现有技术通常采用由当前智能体来执行上下文压缩任务,从而导致当前智能体的推理循环在压缩期间完全暂停;且在执行压缩任务时,明确禁止当前智能体调用任何工具,仅凭注入的提示词来生成文本格式的压缩结果,从而导致所得到的压缩结果存在信息失真的问题,降低了压缩准确性。

发明内容

[0004] 根据本公开的第一方面,提供了一种面向智能体的上下文压缩方法,包括:响应于当前满足上下文压缩条件,创建压缩子智能体,并根据目标压缩边界轮次从主智能体的对话历史存储中获取待压缩对话内容;将所述待压缩对话内容输入所述压缩子智能体,根据所述压缩子智能体的输出结果得到摘要文件,将所述摘要文件写入所述压缩子智能体的目标工作区;响应于所述压缩子智能体处于空闲状态,对所述目标工作区中的所述摘要文件进行校验;响应于所述摘要文件通过校验,将所述摘要文件添加到所述主智能体的对话历史存储,并移除所述压缩子智能体。

[0005] 根据本公开的第二方面,提供了一种面向智能体的上下文压缩装置,包括:创建单元,用于响应于当前满足上下文压缩条件,创建压缩子智能体,并根据目标压缩边界轮次从主智能体的对话历史存储中获取待压缩对话内容;压缩单元,用于将所述待压缩对话内容输入所述压缩子智能体,根据所述压缩子智能体的输出结果得到摘要文件,将所述摘要文件写入所述压缩子智能体的目标工作区;校验单元,用于响应于所述压缩子智能体处于空闲状态,对所述目标工作区中的所述摘要文件进行校验;处理单元,用于响应于所述摘要文件通过校验,将所述摘要文件添加到所述主智能体的对话历史存储,并移除所述压缩子智能体。

[0006] 根据本公开的第三方面,提供了一种电子设备,包括:至少一个处理器;以及与所述至少一个处理器通信连接的存储器;其中,所述存储器存储有可被所述至少一个处理器执行的指令,所述指令被所述至少一个处理器执行,以使所述至少一个处理器能够执行如上所述的方法。

[0007] 根据本公开的第四方面,提供了一种存储有计算机指令的非瞬时计算机可读存储介质,其中,所述计算机指令用于使所述计算机执行如上所述的方法。

[0008] 根据本公开的第五方面,提供了一种计算机程序产品,包括计算机程序,所述计算机程序在被处理器执行时实现如上所述的方法。

[0009] 根据本公开的第六方面,提供了一种自动驾驶车辆,包括如上所述的电子设备。

[0010] 应当理解,本部分所描述的内容并非旨在标识本公开的实施例的关键或重要特征,也不用于限制本公开的范围。本公开的其它特征将通过以下的说明书而变得容易理解。

附图说明

[0011] 附图用于更好地理解本方案,不构成对本公开的限定。其中:

[0012] 图1是根据本公开第一实施例的示意图;

[0013] 图2是根据本公开第二实施例的示意图;

[0014] 图3是根据本公开第三实施例的示意图;

[0015] 图4是根据本公开第四实施例的示意图;

[0016] 图5是用来实现本公开实施例的面向智能体的上下文压缩方法的电子设备的框图。

具体实施方式

[0017] 以下结合附图对本公开的示范性实施例作出说明,其中包括本公开实施例的各种细节以助于理解,应当将它们认为仅仅是示范性的。因此,本领域普通技术人员应当认识到,可以对这里描述的实施例做出各种改变和修改,而不会背离本公开的范围和精神。同样,为了清楚和简明,以下的描述中省略了对公知功能和机构的描述。

[0018] 图1是根据本公开第一实施例的示意图。如图1所示,本实施例的面向智能体的上下文压缩方法,具体包括如下步骤:

[0019] S101、响应于当前满足上下文压缩条件,创建压缩子智能体,并根据目标压缩边界轮次从主智能体的对话历史存储中获取待压缩对话内容;

[0020] S102、将所述待压缩对话内容输入所述压缩子智能体,根据所述压缩子智能体的输出结果得到摘要文件,将所述摘要文件写入所述压缩子智能体的目标工作区;

[0021] S103、响应于所述压缩子智能体处于空闲状态,对所述目标工作区中的所述摘要文件进行校验;

[0022] S104、响应于所述摘要文件通过校验,将所述摘要文件添加到所述主智能体的对话历史存储,并移除所述压缩子智能体。

[0023] 本实施例的面向智能体的上下文压缩方法,在确定主智能体当前需要进行上下文压缩的情况下,创建一个独立的、专门用于执行上下文压缩任务的压缩子智能体,从而实现使用压缩子智能体对从主智能体的对话历史中获取的待压缩对话内容进行压缩的目的,一方面通过由压缩子智能体异步执行压缩任务的方式,使得主智能体在上下文压缩过程中不会暂停,避免了因压缩任务阻塞主智能体继续执行推理任务的问题,另一方面使用创建的压缩子智能体独立执行压缩任务,能够提升上下文的压缩灵活性。

[0024] 本实施例在执行S101时,可以在确定当前主智能体的对话历史存储中包括的历史对话内容超过预设容量阈值的情况下,确定当前满足上下文压缩条件,也可以在确定当前主智能体进行的对话轮次超过预设轮次阈值的情况下,确定当前满足上下文压缩条件,还

可以在确定接收到压缩指令的情况下,确定当前满足上下文压缩条件。

[0025] 本实施例在执行S101确定当前满足上下文压缩条件之后,创建压缩子智能体,本实施例创建的压缩子智能体独立于主智能体,专门用于执行主智能体的上下文压缩任务。

[0026] 其中,本实施例在执行S101创建压缩子智能体时,可以采用的实现方式为:对主智能体执行派生(Fork)操作,得到初始子智能体;将压缩任务指令注入所得到的初始子智能体,得到压缩子智能体(Compression Sub-Agent),本实施例中的压缩任务指令中包括摘要文件的输出路径、输出格式要求、摘要文件的内容上限、摘要文件的内容要求等。

[0027] 本实施例在执行S101时,还可以将主智能体的持久记忆(Persistent Memory)信息、工具/技能索引(Skill Index)信息以及角色定义(Role Prompt)信息等,同步复制到压缩子智能体,使得压缩子智能体能够结合上述信息,更加准确地执行主智能体的上下文压缩任务。

[0028] 也就是说,本实施例通过派生操作创建一个独立的压缩子智能体,使得原本需要由主智能体执行的上下文压缩任务,转而由新创建的压缩子智能体来异步执行,有效地解决了现有的主智能体因要执行压缩任务而无法继续执行推理任务的问题,避免了“压缩”阻塞主智能体的“推理”,从而能够提升系统的整体吞吐量。

[0029] 另外,由于本实施例中的压缩子智能体可以看作是一个独立运行的大模型智能体,因此该压缩子智能体还具备工具调用能力来完成压缩任务的执行,例如调用代码执行工具、文件读写工具等。

[0030] 本实施例在执行S101完成压缩子智能体的创建之后,根据目标压缩边界轮次从主智能体的对话历史存储中获取待压缩对话内容。

[0031] 在本实施例中,主智能体的对话历史存储以结构化文件的形式,持久存储于文件系统;对话历史存储中包括对话轮次及其对应的对话内容,每个对话内容包括当前对话轮次所对应的用户消息文件以及智能体响应文件。

[0032] 在本实施例中,压缩边界轮次(Compression Boundary Turn)用于表示本次压缩任务所覆盖的最大对话轮次,位于该压缩边界轮次之后的对话内容不参与压缩。

[0033] 本实施例在执行S101时,可以根据主智能体的当前最新对话轮次,来确定目标压缩边界轮次,即本实施例可以采用默认方式来确定目标压缩边界轮次;其中,所确定的目标压缩边界轮次为对应(当前最新对话轮次-1)的对话轮次,例如当前最新对话轮次为10,本实施例执行S101确定的目标压缩边界轮次为9,即本次压缩任务仅对前9轮的对话内容进行压缩。

[0034] 另外,本实施例在执行S101时,还可以获取主智能体生成的压缩边界轮次,作为目标压缩边界轮次;其中,主智能体可以根据对当前任务结构的语义理解,自主生成压缩边界轮次,使得位于所生成的压缩边界轮次之后的对话内容以原始形式保留,而不参与压缩。

[0035] 具体地,本实施例在执行S101根据目标压缩边界轮次从主智能体的对话历史存储中获取待压缩对话内容时,可以采用的实现方式为:从主智能体的对话历史存储中获取对应前一次压缩任务的历史压缩边界轮次,本实施例可以将每次压缩得到的摘要文件作为上下文快照(Context Checkpoint)添加到对话历史存储中,从而获取对话历史存储中最新上下文快照所对应的目标压缩边界轮次,作为历史压缩边界轮次;根据目标压缩边界轮次与所获取的历史压缩边界轮次,确定对话轮次范围;从主智能体的对话历史存储中获取对应

所确定的对话轮次范围的对话内容,作为待压缩对话内容。

[0036] 也就是说,本实施例结合对应本次压缩任务的目标压缩边界轮次以及对应前一次压缩任务的历史压缩边界轮次,从主智能体的对话历史存储中获取待压缩对话内容,避免重复压缩对话内容的问题,能够提升所获取的待压缩对话内容的准确性,进而提升压缩准确性。

[0037] 本实施例在执行S101获取待压缩对话内容之后,执行S102将待压缩对话内容输入压缩子智能体,根据压缩子智能体的输出结果得到摘要文件,将摘要文件写入压缩子智能体的目标工作区。

[0038] 也就是说,本实施例中的压缩子智能体作为一个独立的大模型智能体运行,其将所输入的待压缩对话内容作为执行压缩任务时所使用的推理上下文,从而自主对待压缩对话内容进行理解,根据理解结果输出作为压缩结果的摘要文件。

[0039] 本实施例执行S102得到的摘要文件中,包括对应重要内容的原始对话以及对应非重要内容的对话压缩结果;即压缩子智能体可以根据从主智能体同步复制的持久记忆信息、角色定义信息等,对待压缩对话内容中的重要内容与非重要内容进行区分,从而采用“保留重要内容”以及“压缩非重要内容”方式来得到摘要文件。

[0040] 具体地,本实施例在执行S102将待压缩对话内容输入压缩子智能体,根据压缩子智能体的输出得到摘要文件时,可以包括以下内容:使用压缩子智能体对待压缩对话内容进行分类,得到待压缩对话内容的分类结果,本实施例中的分类结果为重要内容与非重要内容中的一种;由压缩子智能体调用与所得到的分类结果对应的工具处理待压缩对话内容,根据所得到的处理结果得到摘要文件。

[0041] 可以理解的是,若本实施例中的待压缩对话内容中包括多个对话轮次的对话内容,则压缩子智能体会分别对每个对话内容进行分类,进而根据不同对话内容的分类结果,得到多个处理结果。

[0042] 其中,本实施例在执行S102时,响应于分类结果为重要内容,由压缩子智能体调用文件读写工具,获取对应待压缩对话内容的原始数据,将所获取的原始数据作为待压缩对话内容的处理结果。

[0043] 本实施例在执行S102时,响应于分类结果为非重要内容,由压缩子智能体调用文件读写工具,获取对应待压缩对话内容的原始数据,在从所获取的原始数据中提取关键信息之后,由压缩子智能体调用代码执行工具(例如Python脚本)对所提取的关键信息进行程序化组装,将所得到的组装结果作为待压缩对话内容的处理结果。

[0044] 也就是说,本实施例中的压缩子智能体根据待压缩对话内容的分类结果,借助自身所具备的工具调用能力,通过调用与分类结果对应的工具完成待压缩对话内容的处理,有效地避免了处理过程中所出现的特殊字符转义错误、压缩信息失真等问题,能够提升所得到的处理结果的准确性。

[0045] 本实施例在执行S102时,压缩子智能体通过调用文件读写工具获取的原始数据,可以为待压缩对话内容的原始对话记录,还可以包括该原始对话记录中所引用的外部工作区文件。

[0046] 可以理解的是,本实施例在执行S102由压缩子智能体对关键信息进行程序化组装时,响应于关键信息的大小超过预设大小阈值,使用关键信息的路径引用代替关键信息之

后,再进行程序化组装。

[0047] 本实施例在执行S102时,还可以包括以下内容:获取主智能体生成的压缩提示(Compression Hint),本实施例的压缩提示中包括主智能体指定的本次压缩时应当保留的信息类型或者信息主题,本实施例中的主智能体可以根据对当前任务结构的语义理解,来生成压缩提示;将所获取的压缩提示与待压缩对话内容输入压缩子智能体,根据压缩子智能体的输出结果得到摘要文件。

[0048] 也就是说,本实施例中的压缩子智能体,可以将由主智能体生成的压缩提示作为指引来完成本次的压缩任务,使得所得到的压缩结果与当前任务高度相关,进一步提升了压缩结果的准确性。

[0049] 本实施例在执行S102根据所得到的处理结果得到摘要文件时,还可以包括以下内容:获取摘要文件的剩余容量,本实施例在每次写入处理结果之后对摘要文件的剩余容量进行更新;响应于所得到的处理结果的大小超过所获取的剩余容量、且处理结果为重要内容,由压缩子智能体通过消息传递的方式将处理结果发送到主智能体,例如压缩子智能体通过消息传递窗口将当前处理结果发送到主智能体的消息队列。

[0050] 也就是说,本实施例将摘要文件无法容纳但是具有重要性的内容,由压缩子智能体直接发送到主智能体,使得主智能体在后续推理过程中可以直接使用该重要内容,避免了因摘要文件的容量有限而无法将重要内容传递给主智能体的问题。

[0051] 在本实施例中,目标工作区为对应压缩子智能体的工作区,该目标工作区用于存放所得到的摘要文件。

[0052] 本实施例在执行S102得到摘要文件并将其写入压缩子智能体的目标工作区之后,执行S103响应于压缩子智能体处于空闲状态,对目标工作区中的摘要文件进行校验。

[0053] 本实施例在执行S103时,可以通过异步轮询的方式,以固定的时间间隔(例如2s)对压缩子智能体的运行状态进行轮询,若压缩子智能体还未完成压缩任务,则其运行状态为“压缩中”,若压缩子智能体已完成压缩任务,则其运行状态为“空闲状态”。

[0054] 本实施例在执行S103确定轮询得到的运行状态为空闲状态之后,对目标工作区中的摘要文件进行校验,校验项可以包括文件存在性校验、结构化格式合法性校验、必要元数据字段完整性校验(例如校验是否包括目标压缩边界轮次)、内容长度校验(即校验摘要文件所包括内容的长度是否大于预设长度)。

[0055] 也就是说,本实施例在由压缩子智能体得到摘要文件之后,引入校验机制对目标工作区中的摘要文件进行校验,避免因摘要文件中存在格式错误的压缩结果而影响后续对话历史的正确加载。

[0056] 本实施例在执行S103对目标工作区中的摘要文件进行校验之后,执行S104响应于摘要文件通过校验,将摘要文件添加到主智能体的对话历史存储,并移除压缩子智能体。

[0057] 本实施例在执行S104时,在确定目标工作区中的摘要文件通过校验的情况下,可以以原子操作(Atomic Operation)的方式,将摘要文件从目标工作区移动到主智能体的对话历史存储,将该摘要文件作为本次压缩任务的上下文快照。

[0058] 本实施在执行S104将摘要文件添加到主智能体的对话历史存储之后,对所创建的压缩子智能体进行移除,从而回收为该压缩子智能体所分配的计算资源。

[0059] 本实施例在执行S104移除压缩子智能体之前,还可以包括以下内容:从压缩子智

能体中获取主智能体的持久记忆信息;生成包括所获取的持久记忆信息的压缩完成通知,将所生成的压缩完成通知发送到主智能体,本实施例可以采用延迟方式发送压缩完成通知。

[0060] 也就是说,本实施例在确定压缩子智能体完成上下文压缩任务之后,为了避免因在压缩过程中对主智能体的持久记忆信息进行压缩所导致的持久记忆信息无法保持连续性的问题,生成包括持久记忆信息的压缩完成通知并发送给主智能体,从而使得主智能体不会遗失持久记忆信息,保证了持久记忆信息在跨上下文窗口场景下的连贯性。

[0061] 图2是根据本公开第二实施例的示意图。如图2所示,本实施例在执行S104时,还可以包括以下内容:

[0062] S201、响应于所述摘要文件未通过校验,获取所述压缩子智能体的重试次数;

[0063] S202、响应于所述重试次数小于预设次数阈值,根据校验错误类型信息生成重试指令;

[0064] S203、将所述重试指令发送到所述压缩子智能体,所述重试指令用于所述压缩子智能体结合所述校验错误类型信息重新执行压缩任务以得到新的摘要文件。

[0065] 也就是说,本实施例在确定目标工作区中的摘要文件未通过校验的情况下,由压缩子智能体执行自我纠错机制,以重新执行压缩任务来得到新的摘要文件,能够提升压缩成功率,另外本实施例还会对压缩子智能体的重试次数进行检测,防止在无法得到准确摘要文件的情况下的无效重试。

[0066] 本实施例在执行S203将包括校验错误类型信息的重试指令发送到压缩子智能体之后,压缩子智能体的运行状态由“空闲状况”转换为“压缩中”,以重新进行摘要文件的生成,进而在轮询时确定压缩子智能体为“空闲状态”时,再对目标工作区中的摘要文件进行校验,以此循环进行,直至确定校验通过或者重试次数达到预设次数阈值。

[0067] 可以理解的是,本实施例在执行S202时,响应于所获取的重试次数达到预设次数阈值,生成压缩失败通知,将所生成的压缩失败通知发送到主智能体,以通知主智能体未能够完成本次压缩。

[0068] 本实施例在执行S203得到新的摘要文件之后,可以使用新的摘要文件替换目标工作区中的摘要文件。

[0069] 图3是根据本公开第三实施例的示意图。如图3所示,本实施例示出了面向智能体的上下文压缩系统的结构图:本实施例中的上下文压缩系统包括主智能体、压缩协调模块与压缩子智能体,智能体以实例的形式进行管理,每个智能体实例拥有独立的工作目录,包括对话历史、持久记忆、工具索引等组件。

[0070] 在本实施例中,压缩协调模块在确定主智能体当前满足上下文压缩条件的情况下,以主智能体为源而派生出压缩子智能体,并基于目标压缩边界轮次从主智能体的对话历史存储中获取待压缩对话内容;压缩协调模块将所获取的待压缩对话内容发送到压缩子智能体,压缩子智能体对待压缩对话内容进行压缩,将所得到的摘要文件写入目标工作区;压缩协调模块对目标工作区中的摘要文件进行校验,校验通过之后,将目标工作区中的摘要文件移动至主智能体的对话历史存储。

[0071] 可以理解的是,本实施例中的压缩协调模块在确定摘要文件未通过验证的情况下,还可以向压缩子智能体发送重试指令,以使得压缩子智能体重新执行压缩任务并得到

新的摘要文件,压缩协调模块继续对所得到的新的摘要文件进行验证。

[0072] 图4是根据本公开第四实施例的示意图。如图4所示,本实施例的面向智能体的上下文压缩装置400,包括:

[0073] 创建单元401、用于响应于当前满足上下文压缩条件,创建压缩子智能体,并根据目标压缩边界轮次从主智能体的对话历史存储中获取待压缩对话内容;

[0074] 压缩单元402、用于将所述待压缩对话内容输入所述压缩子智能体,根据所述压缩子智能体的输出结果得到摘要文件,将所述摘要文件写入所述压缩子智能体的目标工作区;

[0075] 校验单元403、用于响应于所述压缩子智能体处于空闲状态,对所述目标工作区中的所述摘要文件进行校验;

[0076] 处理单元404、用于响应于所述摘要文件通过校验,将所述摘要文件添加到所述主智能体的对话历史存储,并移除所述压缩子智能体。

[0077] 创建单元401可以在确定当前主智能体的对话历史存储中包括的历史对话内容超过预设容量阈值的情况下,确定当前满足上下文压缩条件,也可以在确定当前主智能体进行的对话轮次超过预设轮次阈值的情况下,确定当前满足上下文压缩条件,还可以在确定接收到压缩指令的情况下,确定当前满足上下文压缩条件。

[0078] 创建单元401在确定当前满足上下文压缩条件之后,创建压缩子智能体,创建单元401创建的压缩子智能体独立于主智能体,专门用于执行主智能体的上下文压缩任务。

[0079] 其中,创建单元401在创建压缩子智能体时,可以采用的实现方式为:对主智能体执行派生(Fork)操作,得到初始子智能体;将压缩任务指令注入所得到的初始子智能体,得到压缩子智能体(Compression Sub-Agent),本实施例中的压缩任务指令中包括摘要文件的输出路径、输出格式要求、摘要文件的内容上限、摘要文件的内容要求等。

[0080] 创建单元401还可以将主智能体的持久记忆(Persistent Memory)信息、工具/技能索引(Skill Index)信息以及角色定义(Role Prompt)信息等,同步复制到压缩子智能体,使得压缩子智能体能够结合上述信息,更加准确地执行主智能体的上下文压缩任务。

[0081] 也就是说,创建单元401通过派生操作创建一个独立的压缩子智能体,使得原本需要由主智能体执行的上下文压缩任务,转而由新创建的压缩子智能体来异步执行,有效地解决了现有的主智能体因要执行压缩任务而无法继续执行推理任务的问题,避免了“压缩”阻塞主智能体的“推理”,从而能够提升系统的整体吞吐量。

[0082] 另外,由于本实施例中的压缩子智能体可以看作是一个独立运行的大模型智能体,因此该压缩子智能体还具备工具调用能力来完成压缩任务的执行,例如调用代码执行工具、文件读写工具等。

[0083] 创建单元401在完成压缩子智能体的创建之后,根据目标压缩边界轮次从主智能体的对话历史存储中获取待压缩对话内容。

[0084] 在本实施例中,主智能体的对话历史存储以结构化文件的形式,持久存储于文件系统;对话历史存储中包括对话轮次及其对应的对话内容,每个对话内容包括当前对话轮次所对应的用户消息文件以及智能体响应文件。

[0085] 在本实施例中,压缩边界轮次(Compression Boundary Turn)用于表示本次压缩任务所覆盖的最大对话轮次,位于该压缩边界轮次之后的对话内容不参与压缩。

[0086] 创建单元401可以根据主智能体的当前最新对话轮次,来确定目标压缩边界轮次,即创建单元401可以采用默认方式来确定目标压缩边界轮次;其中,所确定的目标压缩边界轮次为对应(当前最新对话轮次-1)的对话轮次。

[0087] 另外,创建单元401还可以获取主智能体生成的压缩边界轮次,作为目标压缩边界轮次;其中,主智能体可以根据对当前任务结构的语义理解,自主生成压缩边界轮次,使得位于所生成的压缩边界轮次之后的对话内容以原始形式保留,而不参与压缩。

[0088] 具体地,创建单元401在根据目标压缩边界轮次从主智能体的对话历史存储中获取待压缩对话内容时,可以采用的实现方式为:从主智能体的对话历史存储中获取对应前一次压缩任务的历史压缩边界轮次;根据目标压缩边界轮次与所获取的历史压缩边界轮次,确定对话轮次范围;从主智能体的对话历史存储中获取对应所确定的对话轮次范围的对话内容,作为待压缩对话内容。

[0089] 也就是说,创建单元401结合对应本次压缩任务的目标压缩边界轮次以及对应前一次压缩任务的历史压缩边界轮次,从主智能体的对话历史存储中获取待压缩对话内容,避免重复压缩对话内容的问题,能够提升所获取的待压缩对话内容的准确性,进而提升压缩准确性。

[0090] 本实施例在由创建单元401创建压缩智能体病获取待压缩对话内容之后,由压缩单元402将待压缩对话内容输入压缩子智能体,根据压缩子智能体的输出结果得到摘要文件,将摘要文件写入压缩子智能体的目标工作区。

[0091] 也就是说,本实施例中的压缩子智能体作为一个独立的大模型智能体运行,其将所输入的待压缩对话内容作为执行压缩任务时所使用的推理上下文,从而自主对待压缩对话内容进行理解,根据理解结果输出作为压缩结果的摘要文件。

[0092] 压缩单元402得到的摘要文件中,包括对应重要内容的原始对话以及对应非重要内容的对话压缩结果;即压缩子智能体可以根据从主智能体同步复制的持久记忆信息、角色定义信息等,对待压缩对话内容中的重要内容与非重要内容进行区分,从而采用“保留重要内容”以及“压缩非重要内容”方式来得到摘要文件。

[0093] 具体地,压缩单元402在将待压缩对话内容输入压缩子智能体,根据压缩子智能体的输出得到摘要文件时,可以包括以下内容:使用压缩子智能体对待压缩对话内容进行分类,得到待压缩对话内容的分类结果,本实施例中的分类结果为重要内容与非重要内容中的一种;由压缩子智能体调用与所得到的分类结果对应的工具处理待压缩对话内容,根据所得到的处理结果得到摘要文件。

[0094] 可以理解的是,若本实施例中的待压缩对话内容中包括多个对话轮次的对话内容,则压缩子智能体会分别对每个对话内容进行分类,进而根据不同对话内容的分类结果,得到多个处理结果。

[0095] 其中,响应于分类结果为重要内容,压缩单元402由压缩子智能体调用文件读写工具,获取对应待压缩对话内容的原始数据,将所获取的原始数据作为待压缩对话内容的处理结果。

[0096] 响应于分类结果为非重要内容,压缩单元402由压缩子智能体调用文件读写工具,获取对应待压缩对话内容的原始数据,在从所获取的原始数据中提取关键信息之后,由压缩子智能体调用代码执行工具(例如Python脚本)对所提取的关键信息进行程序化组装,将

所得到的组装结果作为待压缩对话内容的处理结果。

[0097] 也就是说,压缩单元402根据待压缩对话内容的分类结果,由压缩子智能体借助自身所具备的工具调用能力,通过调用与分类结果对应的工具完成待压缩对话内容的处理,有效地避免了处理过程中所出现的特殊字符转义错误、压缩信息失真等问题,能够提升所得到的处理结果的准确性。

[0098] 压缩单元402中由压缩子智能体通过调用文件读写工具获取的原始数据,可以为待压缩对话内容的原始对话记录,还可以包括该原始对话记录中所引用的外部工作区文件。

[0099] 可以理解的是,压缩单元402在由压缩子智能体对关键信息进行程序化组装时,响应于关键信息的大小超过预设大小阈值,使用关键信息的路径引用代替关键信息之后,再进行程序化组装。

[0100] 压缩单元402还可以执行以下内容:获取主智能体生成的压缩提示;将所获取的压缩提示与待压缩对话内容输入压缩子智能体,根据压缩子智能体的输出结果得到摘要文件。

[0101] 也就是说,本实施例中的压缩子智能体,可以将由主智能体生成的压缩提示作为指引来完成本次的压缩任务,使得所得到的压缩结果与当前任务高度相关,进一步提升了压缩结果的准确性。

[0102] 压缩单元402在根据所得到的处理结果得到摘要文件时,还可以包括以下内容:获取摘要文件的剩余容量;响应于所得到的处理结果的大小超过所获取的剩余容量、且处理结果为重要内容,由压缩子智能体通过消息传递的方式将处理结果发送到主智能体。

[0103] 也就是说,压缩单元402将摘要文件无法容纳但是具有重要性的内容,由压缩子智能体直接发送到主智能体,使得主智能体在后续推理过程中可以直接使用该重要内容,避免了因摘要文件的容量有限而无法将重要内容传递给主智能体的问题。

[0104] 在本实施例中,目标工作区为对应压缩子智能体的工作区,该目标工作区用于存放所得到的摘要文件。

[0105] 本实施例在由压缩单元402得到摘要文件并将其写入压缩子智能体的目标工作区之后,由校验单元403响应于压缩子智能体处于空闲状态,对目标工作区中的摘要文件进行校验。

[0106] 校验单元403可以通过异步轮询的方式,以固定的时间间隔(例如2s)对压缩子智能体的运行状态进行轮询,若压缩子智能体还未完成压缩任务,则其运行状态为“压缩中”,若压缩子智能体已完成压缩任务,则其运行状态为“空闲状态”。

[0107] 校验单元403在确定轮询得到的运行状态为空闲状态之后,对目标工作区中的摘要文件进行校验,校验项可以包括文件存在性校验、结构化格式合法性校验、必要元数据字段完整性校验(例如校验是否包括目标压缩边界轮次)、内容长度校验(即校验摘要文件所包括内容的长度是否大于预设长度)。

[0108] 也就是说,本实施例在由压缩子智能体得到摘要文件之后,引入校验机制对目标工作区中的摘要文件进行校验,避免因摘要文件中存在格式错误的压缩结果而影响后续对话历史的正确加载。

[0109] 本实施例在由校验单元403对目标工作区中的摘要文件进行校验之后,由处理单

元404响应于摘要文件通过校验,将摘要文件添加到主智能体的对话历史存储,并移除压缩子智能体。

[0110] 处理单元404在确定目标工作区中的摘要文件通过校验的情况下,可以以原子操作(Atomic Operation)的方式,将摘要文件从目标工作区移动到主智能体的对话历史存储,将该摘要文件作为本次压缩任务的上下文快照。

[0111] 处理单元404在将摘要文件添加到主智能体的对话历史存储之后,对所创建的压缩子智能体进行移除,从而回收为该压缩子智能体所分配的计算资源。

[0112] 处理单元404在移除压缩子智能体之前,还可以包括以下内容:从压缩子智能体中获取主智能体的持久记忆信息;生成包括所获取的持久记忆信息的压缩完成通知,将所生成的压缩完成通知发送到主智能体,本实施例可以采用延迟方式发送压缩完成通知。

[0113] 也就是说,处理单元404在确定压缩子智能体完成上下文压缩任务之后,为了避免因在压缩过程中对主智能体的持久记忆信息进行压缩所导致的持久记忆信息无法保持连续性的问题,生成包括持久记忆信息的压缩完成通知并发送给主智能体,从而使得主智能体不会遗失持久记忆信息,保证了持久记忆信息在跨上下文窗口场景下的连贯性。

[0114] 处理单元404还可以执行以下内容:响应于摘要文件未通过校验,获取压缩子智能体的重试次数;响应于重试次数小于预设次数阈值,根据校验错误类型信息生成重试指令;将重试指令发送到压缩子智能体,重试指令用于压缩子智能体结合校验错误类型信息重新执行压缩任务以得到新的摘要文件。

[0115] 也就是说,处理单元404在确定目标工作区中的摘要文件未通过校验的情况下,由压缩子智能体执行自我纠错机制,以重新执行压缩任务来得到新的摘要文件,能够提升压缩成功率,另外本实施例还会对压缩子智能体的重试次数进行检测,防止在无法得到准确摘要文件的情况下的无效重试。

[0116] 处理单元404在将包括校验错误类型信息的重试指令发送到压缩子智能体之后,压缩子智能体的运行状态由“空闲状况”转换为“压缩中”,以重新进行摘要文件的生成,进而在轮询时确定压缩子智能体为“空闲状态”时,再对目标工作区中的摘要文件进行校验,以此循环进行,直至确定校验通过或者重试次数达到预设次数阈值。

[0117] 可以理解的是,响应于所获取的重试次数达到预设次数阈值,处理单元404生成压缩失败通知,将所生成的压缩失败通知发送到主智能体,以通知主智能体未能够完成本次压缩。

[0118] 处理单元404在得到新的摘要文件之后,可以使用新的摘要文件替换目标工作区中的摘要文件。

[0119] 本公开的技术方案中,所涉及的各种类型用户个人信息的获取,存储和应用等,均符合相关法律法规的规定,且不违背公序良俗。

[0120] 根据本公开的实施例,本公开还提供了一种电子设备、一种可读存储介质和一种计算机程序产品。

[0121] 如图5所示,是根据本公开实施例的面向智能体的上下文压缩方法的电子设备的框图。电子设备旨在表示各种形式的数字计算机,诸如,膝上型计算机、台式计算机、工作台、个人数字助理、服务器、刀片式服务器、大型计算机、和其它适合的计算机。电子设备还可以表示各种形式的移动装置,诸如,个人数字处理、蜂窝电话、智能电话、可穿戴设备和其

它类似的计算装置。本文所示的部件、它们的连接和关系、以及它们的功能仅仅作为示例，并且不意在限制本文中描述的和/或者要求的本公开的实现。

[0122] 如图5所示，设备500包括计算单元501，其可以根据存储在只读存储器(ROM)502中的计算机程序或者从存储单元508加载到随机访问存储器(RAM)503中的计算机程序，来执行各种适当的动作和处理。在RAM503中，还可存储设备500操作所需的各种程序和数据。计算单元501、ROM502以及RAM503通过总线504彼此相连。输入/输出(I/O)接口505也连接至总线504。

[0123] 设备500中的多个部件连接至I/O接口505，包括：输入单元506，例如键盘、鼠标等；输出单元507，例如各种类型的展示器、扬声器等；存储单元508，例如磁盘、光盘等；以及通信单元509，例如网卡、调制解调器、无线通信收发机等。通信单元509允许设备500通过诸如因特网的计算机网络和/或各种电信网络与其他设备交换信息/数据。

[0124] 计算单元501可以是各种具有处理和计算能力的通用和/或专用处理组件。计算单元501的一些示例包括但不限于中央处理单元(CPU)、图形处理单元(GPU)、各种专用的人工智能(AI)计算芯片、各种运行机器学习模型算法的计算单元、数字信号处理器(DSP)、以及任何适当的处理器、控制器、微控制器等。计算单元501执行上文所描述的各个方法和处理，例如面向智能体的上下文压缩方法。例如，在一些实施例中，面向智能体的上下文压缩方法可被实现为计算机软件程序，其被有形地包含于机器可读介质，例如存储单元508。

[0125] 在一些实施例中，计算机程序的部分或者全部可以经由ROM502和/或通信单元509而被载入和/或安装到设备500上。当计算机程序加载到 RAM503并由计算单元501执行时，可以执行上文描述的面向智能体的上下文压缩方法的一个或多个步骤。备选地，在其他实施例中，计算单元501可以通过其他任何适当的方式(例如，借助于固件)而被配置为执行面向智能体的上下文压缩方法。

[0126] 此处描述的系统和技术的各种实施方式可以在数字电子电路系统、集成电路系统、场可编程门阵列(FPGA)、专用集成电路(ASIC)、专用标准产品(ASSP)、芯片上系统的系统(SOC)、复杂可编程逻辑设备(CPLD)、计算机硬件、固件、软件、和/或它们的组合中实现。这些各种实施方式可以包括：实施在一个或者多个计算机程序中，该一个或者多个计算机程序可在包括至少一个可编程处理器的可编程系统上执行和/或解释，该可编程处理器可以是专用或者通用可编程处理器，可以从存储系统、至少一个输入装置、和至少一个输出装置接收数据和指令，并且将数据和指令传输至该存储系统、该至少一个输入装置、和该至少一个输出装置。

[0127] 用于实施本公开的方法的程序代码可以采用一个或多个编程语言的任何组合来编写。这些程序代码可以提供给通用计算机、专用计算机或其他可编程面向智能体的上下文压缩装置的处理器或控制器，使得程序代码当由处理器或控制器执行时使流程图和/或框图中所规定的功能/操作被实施。程序代码可完全在机器上执行、部分地在机器上执行，作为独立软件包部分地在机器上执行且部分地在远程机器上执行或完全在远程机器或服务器上执行。

[0128] 在本公开的上下文中，机器可读介质可以是有形的介质，其可以包含或存储以供指令执行系统、装置或设备使用或与指令执行系统、装置或设备结合地使用的程序。机器可读介质可以是机器可读信号介质或机器可读储存介质。机器可读介质可以包括但不限于电

子的、磁性的、光学的、电磁的、红外的、或半导体系统、装置或设备，或者上述内容的任何合适组合。机器可读存储介质的更具体示例会包括基于一个或多个线的电气连接、便携式计算机盘、硬盘、随机存取存储器(RAM)、只读存储器(ROM)、可擦除可编程只读存储器(EPROM或快闪存储器)、光纤、便捷式紧凑盘只读存储器(CD-ROM)、光学储存设备、磁储存设备、或上述内容的任何合适组合。

[0129] 为了提供与用户的交互，可以在计算机上实施此处描述的系统和技术，该计算机具有：用于向用户展示信息的展示装置(例如，CRT(阴极射线管)或者LCD(液晶展示器)监视器)；以及键盘和指向装置(例如，鼠标或者轨迹球)，用户可以通过该键盘和该指向装置来将输入提供给计算机。其它种类的装置还可以用于提供与用户的交互；例如，提供给用户的反馈可以是任何形式的传感反馈(例如，视觉反馈、听觉反馈、或者触觉反馈)；并且可以用任何形式(包括声输入、语音输入或者、触觉输入)来接收来自用户的输入。

[0130] 可以将此处描述的系统和技术实施在包括后台部件的计算系统(例如，作为数据服务器)、或者包括中间件部件的计算系统(例如，应用服务器)、或者包括前端部件的计算系统(例如，具有图形用户界面或者网络浏览器的用户计算机，用户可以通过该图形用户界面或者该网络浏览器来与此处描述的系统和技术的实施方式交互)、或者包括这种后台部件、中间件部件、或者前端部件的任何组合的计算系统中。可以通过任何形式或者介质的数字数据通信(例如，通信网络)来将系统的部件相互连接。通信网络的示例包括：局域网(LAN)、广域网(WAN)和互联网。

[0131] 计算机系统可以包括客户端和服务器。客户端和服务器一般远离彼此并且通常通过通信网络进行交互。通过在相应的计算机上运行并且彼此具有客户端-服务器关系的计算机程序来产生客户端和服务器的关系。服务器可以是云服务器，又称为云计算服务器或云主机，是云计算服务体系中的一项主机产品，以解决了传统物理主机与VPS服务(“Virtual Private Server”，或简称“VPS”)中，存在的管理难度大，业务扩展性弱的缺陷。服务器也可以为分布式系统的服务器，或者是结合了区块链的服务器。

[0132] 应该理解，可以使用上面所示的各种形式的流程，重新排序、增加或删除步骤。例如，本公开中记载的各步骤可以并行地执行也可以顺序地执行也可以不同的次序执行，只要能够实现本公开公开的技术方案所期望的结果，本文在此不进行限制。

[0133] 上述具体实施方式，并不构成对本公开保护范围的限制。本领域技术人员应该明白的是，根据设计要求和其他因素，可以进行各种修改、组合、子组合和替代。任何在本公开的精神和原则之内所作的修改、等同替换和改进等，均应包含在本公开保护范围之内。

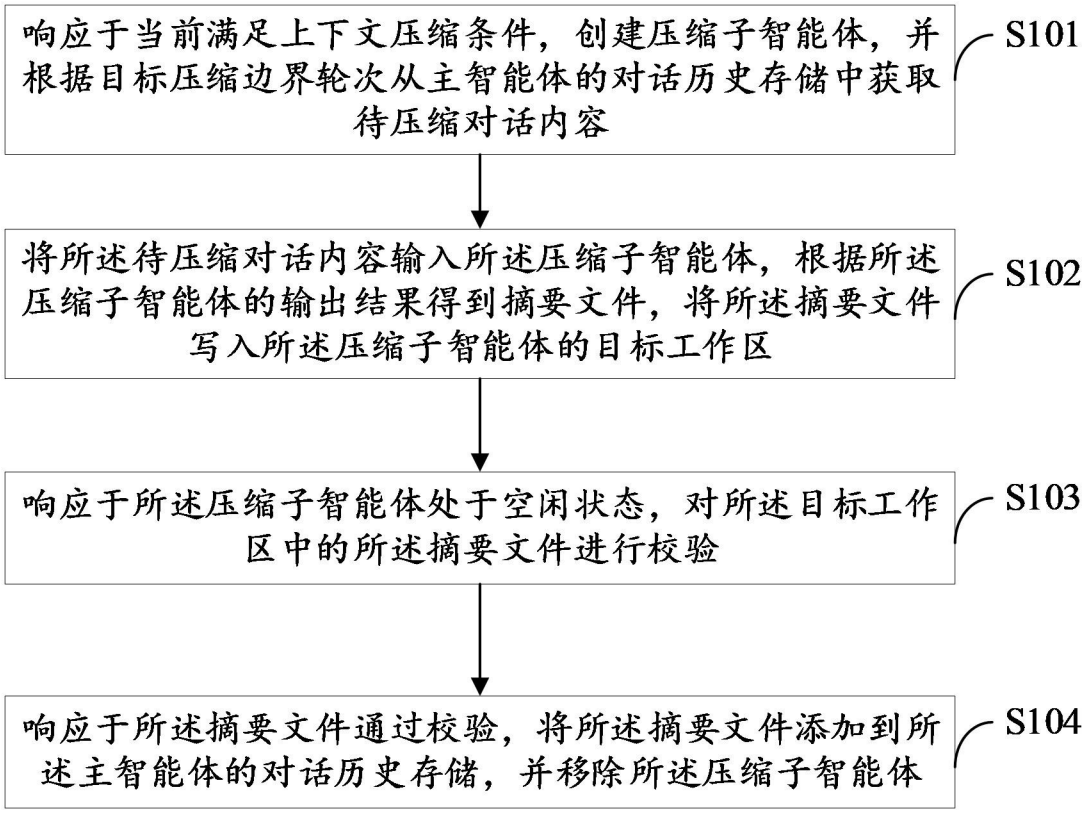

响应于当前满足上下文压缩条件，创建压缩子智能体，并根据目标压缩边界轮次从主智能体的对话历史存储中获取待压缩对话内容
S101
将所述待压缩对话内容输入所述压缩子智能体，根据所述压缩子智能体的输出结果得到摘要文件，将所述摘要文件写入所述压缩子智能体的目标工作区
S102
响应于所述压缩子智能体处于空闲状态，对所述目标工作区中的所述摘要文件进行校验
S103
响应于所述摘要文件通过校验，将所述摘要文件添加到所述主智能体的对话历史存储，并移除所述压缩子智能体
S104

图1

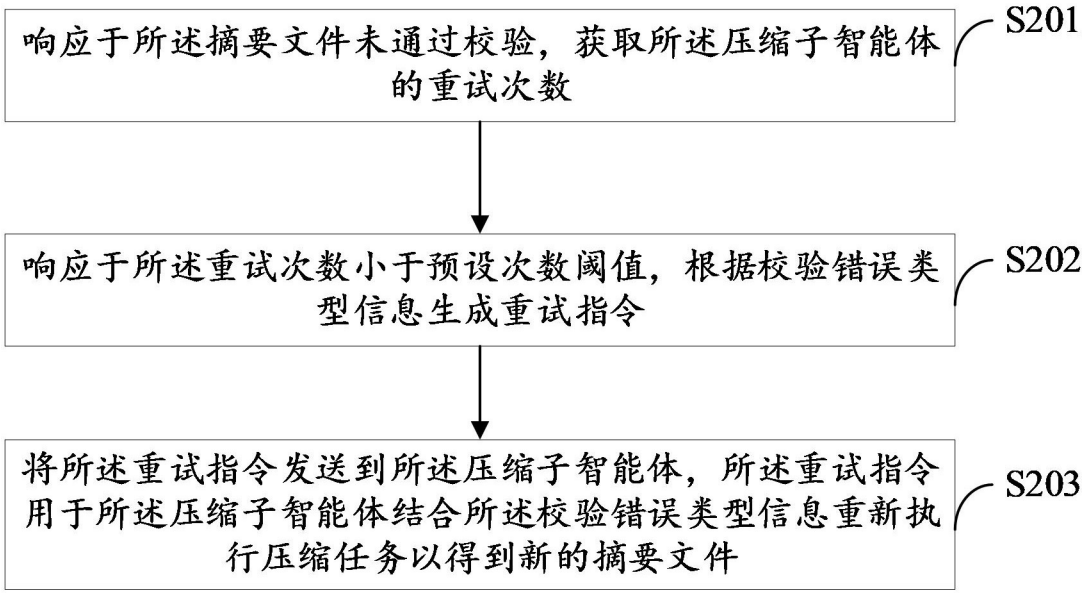

响应于所述摘要文件未通过校验，获取所述压缩子智能体的重试次数
S201
响应于所述重试次数小于预设次数阈值，根据校验错误类型信息生成重试指令
S202
将所述重试指令发送到所述压缩子智能体，所述重试指令用于所述压缩子智能体结合所述校验错误类型信息重新执行压缩任务以得到新的摘要文件
S203

图2

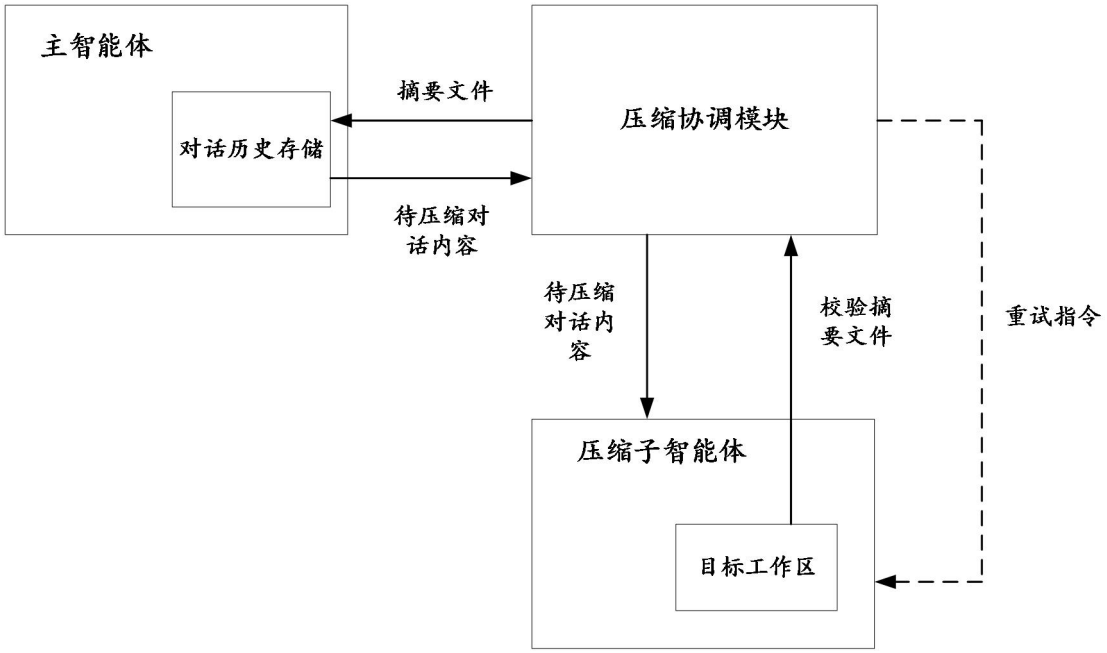

主智能体
对话历史存储
摘要文件
待压缩对话内容
压缩协调模块
待压缩对话内容
校验摘要文件
重试指令
压缩子智能体
目标工作区

图3

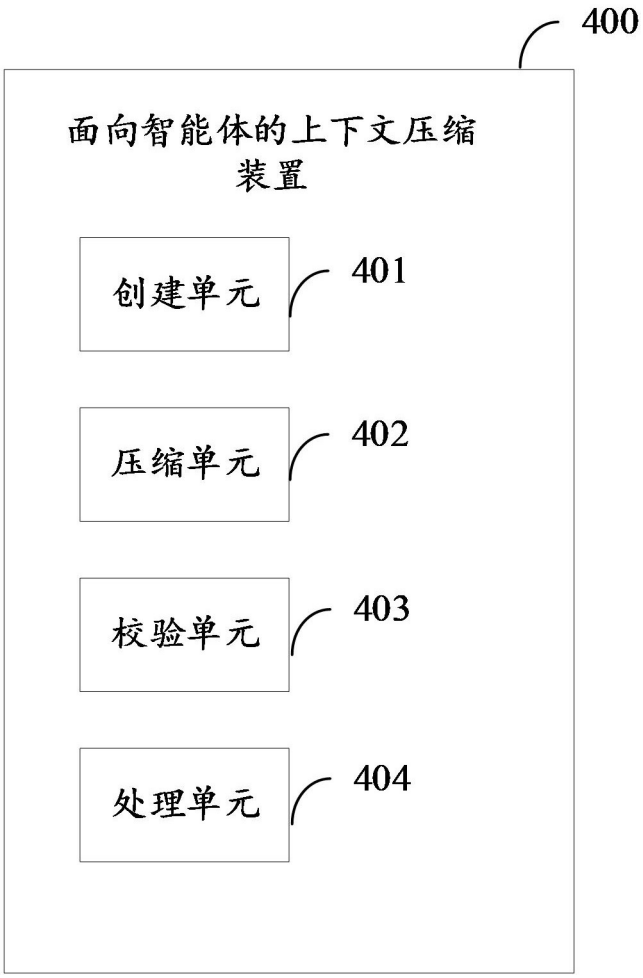


图4

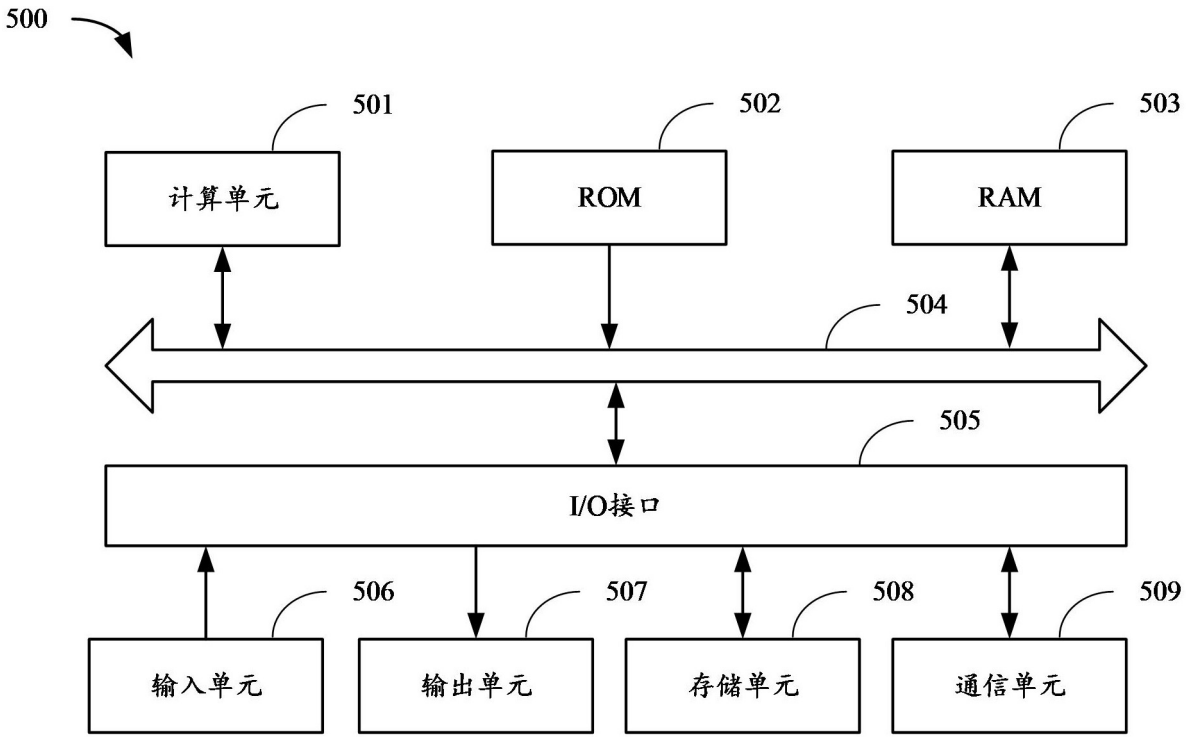

500
501
502
503
计算单元
ROM
RAM
504
505
I/O接口
506
507
508
509
输入单元
输出单元
存储单元
通信单元

图5