(19)国家知识产权局

(12)发明专利申请

(10)申请公布号 CN 122759151 A
(43)申请公布日 2026.09.15

(21)申请号 202611068192.9
(22)申请日 2026.07.17
(71)申请人 北京哇嘶嗒科技有限公司
地址 100083 北京市海淀区中关村东路8号东升大厦C座三层301单元
(72)发明人 夏梓良 梁鼎
(74)专利代理机构 北京正元瑞驰知识产权代理事务所(普通合伙) 16090
专利代理师 刘亭
(51)Int.Cl.
G06F 40/30(2020.01)
G06F 40/205(2020.01)
G06F 16/31(2019.01)
G06F 16/36(2019.01)
G06N 5/022(2023.01)
G06N 5/04(2023.01)

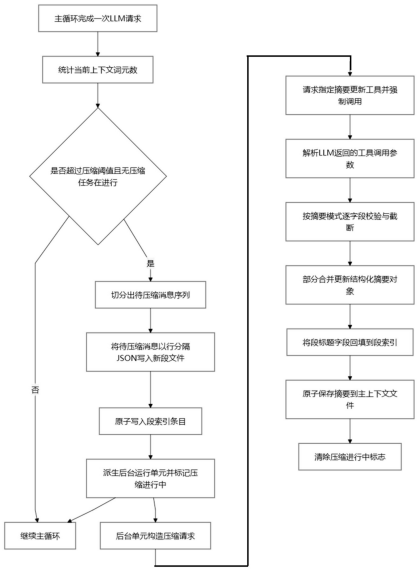
权利要求书2页 说明书11页 附图2页

(54)发明名称

由结构化模式驱动的后台异步会话上下文压缩与分段归档方法、设备及存储介质

(57)摘要

本发明提供了一种由结构化模式驱动的后台异步会话上下文压缩与分段归档方法、设备及存储介质。其中,方法,包括:当检测到词元数超过预设的压缩阈值,且无正在进行的压缩任务时,派生后台运行单元;将待压缩的原始消息序列写入段文件,并在段索引文件中追加对应的索引条目;利用预定义的摘要模式,强制大语言模型以工具调用的形式输出结构化摘要对象;对结构化摘要对象进行字段级校验与截断,并将校验后的字段值合并更新至主上下文的结构化摘要对象中;将合并更新后主上下文的结构化摘要对象的段标题字段值回填至段索引文件中对应的索引条目。实现了消除摘要自由漂移,提高字段边界稳定和长度可控性,以及保障用户交互的流畅性的目的。



CN 122759151 A

1.一种由结构化模式驱动的后台异步会话上下文压缩与分段归档方法,其特征在于,包括:

当智能体循环检测到当前上下文词元数超过预设的压缩阈值,且无正在进行的压缩任务时,派生后台运行单元;

在所述后台运行单元执行压缩之前,先将待压缩的原始消息序列写入段文件,并在段索引文件中追加对应的索引条目;

所述后台运行单元利用预定义的摘要模式,强制大语言模型以工具调用的形式输出结构化摘要对象;

对所述结构化摘要对象进行字段级校验与截断,并将校验后的字段值合并更新至主上下文的结构化摘要对象中;

将合并更新后主上下文的结构化摘要对象的段标题字段值回填至所述段索引文件中对应的索引条目。

2.根据权利要求1所述的由结构化模式驱动的后台异步会话上下文压缩与分段归档方法,其特征在于,

所述预定义的摘要模式为用户在项目配置目录下提供的模式文件,模式文件以表格条目方式声明若干字段,每个字段至少包含名称、描述、类型、长度或数量上限;所述类型为字符串或列表。

3.根据权利要求1所述的由结构化模式驱动的后台异步会话上下文压缩与分段归档方法,其特征在于,所述强制大语言模型以工具调用的形式输出结构化摘要对象,包括:

将摘要模式转换为具名工具的定义,得到摘要更新工具;

在压缩请求中,将具名工具的定义作为请求参数提交给大语言模型,并设置工具选择参数为强制调用摘要更新工具,从而迫使大语言模型以工具调用参数的形式输出结构化数据。

4.根据权利要求1所述的由结构化模式驱动的后台异步会话上下文压缩与分段归档方法,其特征在于,所述将待压缩的原始消息序列写入段文件,并在段索引文件中追加对应的索引条目,包括:

为待压缩的原始消息序列分配新的段标识,并以行分隔JSON格式写入段文件;

在段索引文件中追加新段元数据,新段元数据至少包括段标识、创建时间戳和消息条数;

段文件和段索引文件均采用临时文件加原子改名的模式写入。

5.根据权利要求1所述的由结构化模式驱动的后台异步会话上下文压缩与分段归档方法,其特征在于,所述字段级校验与截断,包括:

对于字符串型字段,若长度超过设定上限,则按字符边界安全截断至上限;

对于列表型字段,若元素数量超过设定上限,则取前若干项,丢弃其余项;

丢弃所述结构化摘要对象中未被摘要模式声明的字段,对缺失的字段,按摘要模式中的默认值或空值进行填充。

6.根据权利要求1所述的由结构化模式驱动的后台异步会话上下文压缩与分段归档方法,其特征在于,

所述合并更新采用部分更新策略,即仅对所述后台运行单元输出的结构化摘要对象中

存在的字段进行覆盖,对未提及的旧字段保持原值不变。

7.根据权利要求1所述的由结构化模式驱动的后台异步会话上下文压缩与分段归档方法,其特征在于,将合并更新后结构化摘要对象的段标题字段值回填至所述段索引文件中对应的索引条目的步骤之后,还包括:

在后续每一轮大语言模型请求时,将合并更新后主上下文的结构化摘要对象渲染为固定格式的前言文本;

将前言文本作为用户角色消息,插入到当前消息序列以前的位置,供大语言模型在处理当前轮次之前读取。

8.根据权利要求1所述的由结构化模式驱动的后台异步会话上下文压缩与分段归档方法,其特征在于,所述段索引文件记录的段元数据在后续会话启动时被加载,通过段标题或首条消息预览定位历史段,并通过逐行扫描对应段文件恢复消息细节。

9.一种电子设备,其特征在于,所述电子设备包括:

至少一个处理器;以及,

与所述至少一个处理器通信连接的存储器;其中,

所述存储器存储有可被所述至少一个处理器执行的指令,所述指令被所述至少一个处理器执行,以使所述至少一个处理器能够执行权利要求1-8任一所述的由结构化模式驱动的后台异步会话上下文压缩与分段归档方法。

10.一种计算机可读存储介质,其特征在于,该计算机可读存储介质存储计算机指令,该计算机指令用于使计算机执行权利要求1-8任一所述的由结构化模式驱动的后台异步会话上下文压缩与分段归档方法。

由结构化模式驱动的后台异步会话上下文压缩与分段归档方法、设备及存储介质

技术领域

[0001] 本发明属于大语言模型技术领域,尤其是涉及一种由结构化模式驱动的后台异步会话上下文压缩与分段归档方法、设备及存储介质。

背景技术

[0002] 大语言模型在应用到智能体中需要对数据进行语义处理和语法分析等,采用大语言模型作为核心推理引擎的智能体在持续工作过程中会不断累积消息,消息总量最终将超出模型允许的上下文窗口或超出经济合理的词元(token)预算。现有的上下文压缩方案存在如下问题:

第一,多数方案采用滑动窗口丢弃法,即直接删除最旧的若干条消息。这会永久丢失早期决策、中间结论和前期探索线索,使后续推理失去依据。

[0003] 第二,部分方案采用一次性裸文本摘要,即让模型生成一段自由格式的摘要文本追加到系统提示末尾。这种形式的摘要字段边界模糊、长度不可控、关键项容易被模型自主合并或丢弃,且后续轮次在此摘要基础上继续压缩时容易产生累积漂移。

[0004] 第三,现有方案通常在主智能体循环内同步执行压缩,阻塞主循环数秒到数十秒,严重影响交互体验。

[0005] 第四,压缩过程若发生进程崩溃,被截断的原始消息无法恢复,历史知识完全丢失。

发明内容

[0006] 针对现有技术中存在上述问题,本发明提供了一种由结构化模式驱动的后台异步会话上下文压缩与分段归档方法、设备及存储介质。

[0007] 第一方面,本公开实施例提供了一种由结构化模式驱动的后台异步会话上下文压缩与分段归档方法,包括:

当智能体循环检测到当前上下文词元数超过预设的压缩阈值,且无正在进行的压缩任务时,派生后台运行单元;

在所述后台运行单元执行压缩之前,先将待压缩的原始消息序列写入段文件,并在段索引文件中追加对应的索引条目;

所述后台运行单元利用预定义的摘要模式,强制大语言模型以工具调用的形式输出结构化摘要对象;

对所述结构化摘要对象进行字段级校验与截断,并将校验后的字段值合并更新至主上下文的结构化摘要对象中;

将合并更新后主上下文的结构化摘要对象的段标题字段值回填至所述段索引文件中对应的索引条目。

[0008] 可选的,所述预定义的摘要模式为用户在项目配置目录下提供的模式文件,模式

文件以表格条目方式声明若干字段,每个字段至少包含名称、描述、类型、长度或数量上限;所述类型为字符串或列表。

[0009] 可选的,所述强制大语言模型以工具调用的形式输出结构化摘要对象,包括:

将摘要模式转换为具名工具的定义,得到摘要更新工具;

在压缩请求中,将具名工具的定义作为请求参数提交给大语言模型,并设置工具选择参数为强制调用摘要更新工具,从而迫使大语言模型以工具调用参数的形式输出结构化数据。

[0010] 可选的,所述将待压缩的原始消息序列写入段文件,并在段索引文件中追加对应的索引条目,包括:

为待压缩的原始消息序列分配新的段标识,并以行分隔JSON格式写入段文件;

在段索引文件中追加新段元数据,新段元数据至少包括段标识、创建时间戳和消息条数;

段文件和段索引文件均采用临时文件加原子改名的模式写入。

[0011] 可选的,所述字段级校验与截断,包括:

对于字符串型字段,若长度超过设定上限,则按字符边界安全截断至上限;

对于列表型字段,若元素数量超过设定上限,则取前若干项,丢弃其余项;

丢弃所述结构化摘要对象中未被摘要模式声明的字段,对缺失的字段,按摘要模式中的默认值或空值进行填充。

[0012] 可选的,所述合并更新采用部分更新策略,即仅对所述后台运行单元输出的结构化摘要对象中存在的字段进行覆盖,对未提及的旧字段保持原值不变。

[0013] 可选的,将合并更新后结构化摘要对象的段标题字段值回填至所述段索引文件中对应的索引条目的步骤之后,还包括:

在后续每一轮大语言模型请求时,将合并更新后主上下文的结构化摘要对象渲染为固定格式的前言文本;

将前言文本作为用户角色消息,插入到当前消息序列以前的位置,供大语言模型在处理当前轮次之前读取。

[0014] 可选的,所述段索引文件记录的段元数据在后续会话启动时被加载,通过段标题或首条消息预览定位历史段,并通过逐行扫描对应段文件恢复消息细节。

[0015] 第二方面,本公开实施例还提供了一种电子设备,该电子设备包括:

至少一个处理器;以及,

与所述至少一个处理器通信连接的存储器;其中,

所述存储器存储有能被所述至少一个处理器执行的指令,所述指令被所述至少一个处理器执行,以使所述至少一个处理器能够执行第一方面任一所述的由结构化模式驱动的后台异步会话上下文压缩与分段归档方法。

[0016] 第三方面,本公开实施例还提供了一种计算机可读存储介质,该计算机可读存储介质存储计算机指令,该计算机指令用于使计算机执行第一方面任一所述的由结构化模式驱动的后台异步会话上下文压缩与分段归档方法。

[0017] 本发明提供的由结构化模式驱动的后台异步会话上下文压缩与分段归档方法,通过预定义的摘要模式文件驱动LLM(大语言模型)以强制工具调用的形式输出结构化摘要对

象,从根本上消除了传统自由文本摘要中格式漂移、字段缺失或内容溢出的问题。通过在智能体循环检测到上下文超阈值时派生后台运行单元执行压缩,使耗时的LLM压缩调用与主智能体的对话处理流程异步解耦,避免了压缩过程阻塞主循环,保障了用户交互的流畅性。从而达到消除摘要自由漂移,提高字段边界稳定和长度可控性,以及保障用户交互的流畅性的目的。

附图说明

[0018] 通过结合附图对本公开示例性实施例进行更详细的描述,本公开的上述以及其它目的、特征和优势将变得更加明显,其中,在本公开示例性实施例中,相同的参考标号通常代表相同部件。

[0019] 图1为本公开实施例提供的一种由结构化模式驱动的后台异步会话上下文压缩与分段归档方法的流程图;

图2为本公开实施例提供的一种电子设备的原理框图。

具体实施方式

[0020] 下面结合附图对本公开实施例进行详细描述。

[0021] 应当明确,以下通过特定的具体实例说明本公开的实施方式,本领域技术人员可由本说明书所揭露的内容轻易地了解本公开的其他优点与功效。显然,所描述的实施例仅仅是本公开一部分实施例,而不是全部的实施例。本公开还可以通过另外不同的具体实施方式加以实施或应用,本说明书中的各项细节也可以基于不同观点与应用,在没有背离本公开的精神下进行各种修饰或改变。需说明的是,在不冲突的情况下,以下实施例及实施例中的特征可以相互组合。基于本公开中的实施例,本领域普通技术人员在没有作出创造性劳动前提下所获得的所有其他实施例,都属于本公开保护的范围。

[0022] 需要说明的是,本文中所描述的方面可体现于广泛多种形式中,且本文中所描述的任何特定结构及/或功能仅为说明性的。基于本公开,所属领域的技术人员应了解,本文中所描述的一个方面可与任何其它方面独立地实施,且可以各种方式组合这些方面中的两者或两者以上。举例来说,可使用本文中所阐述的任何数目个方面来实施设备及/或实践方法。另外,可使用除了本文中所阐述的方面中的一或多者之外的其它结构及/或功能性实施此设备及/或实践此方法。

[0023] 还需要说明的是,以下实施例中所提供的图示仅以示意方式说明本公开的基本构想,图示中仅显示与本公开中有关的组件而非按照实际实施时的组件数目、形状及尺寸绘制,其实际实施时各组件的型态、数量及比例可为一种随意的改变,且其组件布局型态也可能更为复杂。

[0024] 另外,在以下描述中,提供具体细节是为了便于透彻理解实例。然而,所属领域的技术人员将理解,可在没有这些特定细节的情况下实践所述方面。

[0025] 摘要模式(summary schema):是指用户配置的字段声明文件,规定压缩产出的字段名、描述、类型与约束;

摘要更新工具(update-summary tool):是指由摘要模式转换得到的具名工具定义,用于在压缩请求中强制大语言模型以工具调用形式产出结构化摘要;

结构化摘要对象(structured summary):是指按摘要模式组织的键值对集合,是主上下文中的摘要承载体;

会话段(conversation segment):是指一次压缩中被截断的原始消息序列,以独立文件形式保存,并在索引中占一条目;

段索引(segment index):是指登记全部段元数据(段标识、创建时间、消息条数、段标题、首条用户消息预览等)的清单文件;

压缩阈值(compression threshold):是指触发压缩的词元数值。

[0026] 本实施例涉及基于大语言模型的智能体运行环境领域,尤其涉及在智能体长时间持续工作场景下,对会话上下文进行压缩、归档与摘要更新的方法,可用于人工智能持续产出游戏代码等需要跨多轮、跨多日持续运行的工程化场景。

[0027] 本实施例主要解决以下问题:

如何使摘要生成结果的结构、字段含义与长度可由用户按项目需要配置,并强制大语言模型产出符合模式的结构化数据;

如何在主智能体循环持续响应用户的同时,后台并行执行压缩,避免阻塞;

如何在压缩发生前将被截断的原始消息安全落盘,使得压缩失败或进程崩溃时数据仍可恢复;

如何使被归档的原始消息可以按段检索,支持后续跨会话的知识再利用。

[0028] 如图1所示,本实施例公开了一种由结构化模式驱动的后台异步会话上下文压缩与分段归档方法,包括:

当智能体循环检测到当前上下文词元数超过预设的压缩阈值,且无正在进行的压缩任务时,派生后台运行单元;

在所述后台运行单元执行压缩之前,先将待压缩的原始消息序列写入段文件,并在段索引文件中追加对应的索引条目;

所述后台运行单元利用预定义的摘要模式,强制大语言模型以工具调用的形式输出结构化摘要对象;

对所述结构化摘要对象进行字段级校验与截断,并将校验后的字段值合并更新至主上下文的结构化摘要对象中;

将合并更新后主上下文的结构化摘要对象的段标题字段值回填至所述段索引文件中对应的索引条目。

[0029] 在一个具体的应用场景中,由结构化模式驱动的后台异步会话上下文压缩与分段归档方法包括以下技术手段:

手段一:结构化模式定义,用户在项目配置目录下提供一份摘要模式文件,以表格条目方式声明若干字段,每个字段至少含名称、描述、类型(字符串或列表)、长度或数量上限,以及可选的默认值;整份模式可附加一条自定义提示文本,作为传递给大语言模型的压缩指令前言。

[0030] 手段二:工具调用强制输出,调度器将摘要模式转换为一个具名工具的定义(本文称摘要更新工具),在压缩调用时把该工具作为请求参数提交给大语言模型,并显式设置工具选择参数为强制调用该工具;由此迫使大语言模型以工具调用参数的形式输出结构化摘要,字段命名与类型严格受控。

[0031] 手段三:先落盘后压缩,在调用大语言模型之前,先把待压缩的原始消息序列以行分隔JSON(NDJSON)形式写入段文件,并追加该段的索引条目到索引文件;索引文件的写入采用临时文件加原子改名模式,确保崩溃时索引与段文件互不出现半成品。原子改名指 文件系统提供的、不可分割的重命名(或移动)操作 :该操作要么 完全成功 (目标路径立即可见新文件且原路径消失),要么 完全失败 (原文件保持不变), 不存在中间状态 ,且在并发或多进程环境下 不会被其他操作打断或观察到部分生效 。

[0032] 手段四:后台异步执行,主智能体循环检测到上下文词元数超过阈值且当前没有压缩任务在进行时,通过异步运行时派生一个独立的后台运行单元执行压缩,同时立即返回主循环继续响应用户;主循环仅保留一个压缩进行中标志,避免并发重复压缩。

[0033] 手段五:字段级校验与截断,后台运行单元拿到大语言模型返回的工具调用参数后,按照摘要模式逐字段校验:字符串型字段若超过长度上限,按字符边界安全截断;列表型字段若超过元素数量上限,取前若干项;未声明字段被丢弃;缺失字段以默认值或空值填充。

[0034] 手段六:段标题回填,校验通过后,将摘要结构化地合并回主上下文摘要对象(部分字段更新,不覆盖未变化字段),并将摘要字段中用作段标题的短文本回写到索引文件中对应段的标题字段,使该段在后续列出或检索时带有由大语言模型生成的可读标签。

[0035] 手段七:摘要前言注入。后续每一轮大语言模型请求,主智能体循环将主上下文摘要对象渲染为一段约定格式的前言文本(例如以方括号[CONTEXT SUMMARY]开头,随后逐字段列出名称与值),作为一条用户角色消息插入到消息序列靠前位置,使大语言模型在处理当前轮次之前即可读取全部历史摘要要点。

[0036] 在具体的场景中,预定义的摘要模式为用户在项目配置目录下提供的模式文件,模式文件以表格条目方式声明若干字段,每个字段至少包含名称、描述、类型、长度或数量上限;所述类型为字符串或列表。

[0037] 强制大语言模型以工具调用的形式输出结构化摘要对象,包括:

将摘要模式转换为具名工具的定义,得到摘要更新工具;

在压缩请求中,将具名工具的定义作为请求参数提交给大语言模型,并设置工具选择参数为强制调用摘要更新工具,从而迫使大语言模型以工具调用参数的形式输出结构化数据。

[0038] 将摘要模式转换为具名工具的定义,即为将由用户自定义的摘要模式配置文件,转化为大语言模型(LLM)原生支持的工具调用(Function Calling / Tool Use)协议格式,从而实现对LLM输出的精确约束。

[0039] 具名工具的定义是指将由大语言模型(LLM)调用的功能,包装成一个带有唯一名称、功能描述和输入参数规范的标准化数据结构,并将其注册给LLM的过程。就是告诉LLM:这里有一个名叫XXX的功能,如果需要使用它,就按规定的格式填写参数来调用。

[0040] 将待压缩的原始消息序列写入段文件,并在段索引文件中追加对应的索引条目,包括:

为待压缩的原始消息序列分配新的段标识,并以行分隔JSON格式写入段文件;

在段索引文件中追加新段元数据,新段元数据至少包括段标识、创建时间戳和消息条数;

段文件和段索引文件均采用临时文件加原子改名的模式写入。

[0041] 字段级校验与截断,包括:

对于字符串型字段,若长度超过设定上限,则按字符边界安全截断至上限;

对于列表型字段,若元素数量超过设定上限,则取前若干项,丢弃其余项;

丢弃所述结构化摘要对象中未被摘要模式声明的字段,对缺失的字段,按摘要模式中的默认值或空值进行填充。

[0042] 合并更新采用部分更新策略,即仅对所述后台运行单元输出的结构化摘要对象中存在的字段进行覆盖,对未提及的旧字段保持原值不变。

[0043] 将合并更新后结构化摘要对象的段标题字段值回填至所述段索引文件中对应的索引条目的步骤之后,还包括:

在后续每一轮大语言模型请求时,将合并更新后主上下文的结构化摘要对象渲染为固定格式的前言文本;

将前言文本作为用户角色消息,插入到当前消息序列以前的位置,供大语言模型在处理当前轮次之前读取。

[0044] 段索引文件记录的段元数据在后续会话启动时被加载,通过段标题或首条消息预览定位历史段,并通过逐行扫描对应段文件恢复消息细节。

[0045] 本实施摘要模式的结构如下:

一份摘要模式文件至少应具备以下结构:

顶层区:可选的自定义提示文本,将在压缩请求时作为传给大语言模型的前言;

字段数组区:逐条声明字段,每条至少包括:

字段名:字符串,唯一;

字段描述:自然语言说明,指导大语言模型如何填充;

字段类型:取值为字符串或列表;

长度或数量上限:字符串型取字符数上限,列表型取元素数量上限;

可选默认值。

[0046] 本实施方式推荐包含的典型字段有:段标题(segment_title,字符串,上限约六十字符)、已完成事项(completed,列表)、待办事项(pending,列表)和关键信息(key_info,列表)。该实施例列举的字段仅用于解释说明,并不仅限于这些字段,字段集合由用户按项目需要配置,不限于上述四项。

[0047] 在一个具体的场景中,本实施例的方法具体如下:

压缩触发条件:

主智能体循环在每次大语言模型请求完成后,统计当前上下文的词元总数,其等于系统提示开销、工具定义开销、全部消息的估算词元数之和。若该总数超过压缩阈值,且压缩进行中标志为假,则进入触发分支;否则继续主循环。

[0048] 压缩阈值为可配置参数,典型值在两万到十万词元之间,具体数值应综合考虑所用模型的最大上下文窗口、经济合理的词元预算、以及用户对交互延迟的要求。

[0049] 待压缩消息的切分:

触发分支内,切分算法从消息序列前部选取一段连续消息作为待压缩序列,保留尾部若干条消息不动(典型值为保留最后两条或最后一轮完整交互),以避免截断进行中的

对话或尚未收到响应的工具调用。待压缩序列既进入后续压缩流程,也被从主上下文消息列表中移除以释放词元。

[0050] 先落盘:段文件与段索引的原子写入:

在启动后台运行单元之前,首先执行以下两步写入:

第一步,为待压缩消息序列分配新的段标识(典型采用三位递增数字),建立段文件,以行分隔JSON的形式逐条写入消息对象,每行一条。该文件先以临时名写入,全部写完后通过原子改名落至最终文件名。

[0051] 第二步,在段索引文件中追加一条新段元数据,至少包括段标识、创建时间戳、消息条数、首条用户消息预览(以字符数上限截断的短文本),段标题此时尚未由大语言模型生成,置为空或占位。段索引同样采用临时文件加原子改名模式写入。

[0052] 由此,即使后续后台压缩失败或进程崩溃,段文件与段索引仍然完整地保留了被截断的原始消息,支持后续会话或人工恢复。

[0053] 后台异步派生:

主线程通过异步运行时创建一个独立的后台运行单元,将待压缩消息序列、当前结构化摘要对象、摘要模式、专用的大语言模型客户端句柄以及新段标识作为参数传入;同时将压缩进行中标志置真,使该标志在后台单元未完成之前阻止新一轮触发。

[0054] 后台运行单元拥有独立的大语言模型客户端引用,不与主循环争抢网络连接或限流配额。主循环在派生后台单元后立即返回,继续处理后续用户输入与工具调用,实现压缩不阻塞主循环。

[0055] 压缩请求与工具强制调用:

后台运行单元构造一次压缩请求,其请求体由以下部分组成:

提示前言:若摘要模式顶层指定了自定义提示则使用之,否则使用默认提示,说明任务目标(更新结构化摘要)、可用字段与约束、以及必须通过调用摘要更新工具输出结果;

当前结构化摘要对象:格式化为可读文本,作为参考上文;

待压缩会话段:格式化为可读文本,按角色与内容列出;

工具定义列表:仅含摘要更新工具一项,其参数模式由摘要模式的字段数组转换得到;

工具选择参数:设置为强制调用摘要更新工具。

[0056] 大语言模型收到请求后,以工具调用的形式返回参数对象;即便模型倾向于输出自由文本,工具选择参数的强制约束使其必须以结构化形式作答。

[0057] 字段级校验与截断:

后台运行单元收到工具调用参数后,按摘要模式逐字段处理:

对每个声明字段,在参数对象中查找对应键;

若为字符串型且长度超过上限,按字符边界(避免切开多字节字符)截断到上限;

若为列表型且元素数量超过上限,取前若干项丢弃其余;

若参数对象中存在摘要模式未声明的字段,丢弃之;

若参数对象缺失某字段,按摘要模式填入默认值或置空。

[0058] 该步骤完全在本地执行,不再调用大语言模型。

[0059] 结构化摘要的部分合并更新:

校验后的字段值被合并进主上下文的结构化摘要对象。合并采用部分更新策略：对新参数对象中存在的字段进行覆盖；对新参数对象未提及的旧字段保持不变。这使得一次压缩仅更新与本次被截断段落相关的字段，避免其他字段被意外清空。

[0060] 段标题回填：

摘要模式通常声明一个段标题字段。校验后该字段值被提取，通过段索引的更新接口写回到之前创建的段元数据的标题位置，形成由大语言模型生成的段标题。段索引再次以临时文件加原子改名模式落盘。

[0061] 主上下文的原子保存：

结构化摘要对象合并更新后，主上下文文件（含消息序列、结构化摘要对象等）以临时文件加原子改名模式整体落盘。至此压缩流程结束，清除压缩进行中标志。

[0062] 摘要前言注入：

主智能体循环在构造下一次大语言模型请求时，调用一个前言构造函数，将结构化摘要对象渲染为一段固定格式的文本，例如以方括号包围的[CONTEXT SUMMARY]标签开头，随后逐字段列出字段名与值，列表型字段以短横线条目呈现。该前言作为一条用户角色消息被插入到当前消息序列靠前位置，使大语言模型在处理当前轮次之前即可读取历史摘要要点。

[0063] 跨会话再利用：

段索引记录的全部段元数据在后续会话启动时被加载。用户或智能体可通过段标题或首条消息预览定位历史段，并按需通过逐行扫描对应段文件恢复任意消息细节。段标题由前次压缩中的大语言模型生成，语义化程度高，便于检索。

[0064] 本实施例公开的由结构化模式驱动的后台异步会话上下文压缩与分段归档方法，包括：

(1)加载用户配置的摘要模式，所述摘要模式声明若干字段，每字段至少包括字段名、字段描述、字段类型与长度或数量上限；

(2)在智能体循环的每次大语言模型请求之后，统计当前上下文词元数，当其超过压缩阈值且无压缩任务在进行时，切分出待压缩消息序列；

(3)在调用大语言模型前，先将待压缩消息序列以行分隔JSON写入段文件，并以临时文件加原子改名方式追加段索引条目；

(4)派生后台异步运行单元，以压缩进行中标志阻止并发压缩，主循环立即返回；

(5)后台运行单元将所述摘要模式转换为具名的摘要更新工具定义，在压缩请求中通过强制工具选择迫使大语言模型以工具调用参数形式产出结构化摘要；

(6)对工具调用参数按所述摘要模式逐字段校验与截断，将结果部分合并回主上下文的结构化摘要对象；

(7)将结构化摘要中用作段标题的字段值回写到段索引对应条目，并以临时文件加原子改名方式保存主上下文。

[0065] 切分保留消息序列尾部若干条消息不参与压缩，以避免截断进行中的对话或未完成的工具调用对。

[0066] 后台运行单元有独立的大语言模型客户端引用，不与主智能体循环共用连接。

[0067] 在后续每一轮大语言模型请求中，将结构化摘要对象渲染为约定格式的前言文

本,作为用户角色消息插入到消息序列靠前位置。

[0068] 结构化摘要对象的合并更新采用部分更新策略:仅覆盖工具调用参数中存在的字段,其他字段保持不变。

[0069] 本实施具有以下效果:

1、通过预定义的摘要模式文件驱动LLM以强制工具调用的形式输出结构化摘要对象,从根本上消除了传统自由文本摘要中格式漂移、字段缺失或内容溢出的问题。模式文件以表格条目方式声明每个字段的名称、描述、类型及长度或数量上限,使得每次压缩输出的摘要对象字段边界清晰、长度可控,为后续的字段级校验与自动化合并更新提供了可靠的结构化数据基础。

[0070] 2、通过在主智能体循环检测到上下文超阈值时派生后台运行单元执行压缩,使耗时的LLM压缩调用与主智能体的对话处理流程异步解耦,避免了压缩过程阻塞主循环,保障了用户交互的流畅性。同时在压缩执行前先将待压缩的原始消息序列以行分隔JSON格式写入段文件,并采用临时文件加原子改名的写入模式,确保即使压缩过程因异常中断,原始数据也不会丢失,实现了压缩操作的高可用性与数据完整性保障。

[0071] 3、通过分段归档机制,每次压缩前先将待压缩的原始消息序列分配新的段标识并写入独立的段文件,同时在段索引文件中追加对应的索引条目。即使某段消息已被压缩并从主上下文中移除,仍可通过段索引文件记录的段标识、创建时间戳、消息条数等元数据快速定位,并通过逐行扫描对应段文件恢复消息细节。不仅支持在同一会话内回溯历史详情,还可跨会话检索和复用已归档的知识片段,有效扩展了长对话系统中历史信息的利用边界。

[0072] 4、在后台运行单元完成压缩后,将结构化摘要对象中的段标题字段值回填至段索引文件中对应的索引条目。这一操作为每个历史段赋予了语义化的标题标签,使得无论是用户通过可视化界面浏览历史,还是智能体在后续推理中检索相关段落,均可凭借段标题快速定位目标段落,无需逐条扫描消息内容,大幅提升了历史信息的定位效率与用户体验。

[0073] 5、通过将主上下文中的结构化摘要对象渲染为固定格式的前言文本,并以用户角色消息的形式插入当前轮次消息序列的靠前位置,使得LLM在处理当前用户输入之前即可直接读取到经过压缩精炼的历史摘要要点。避免了LLM在海量原始消息中自行归纳历史信息的开销,显著降低了每轮推理中重新理解上下文的计算成本与Token消耗,同时保持了历史关键信息的可访问性与连续性。

[0074] 本实施例公开的电子设备包括存储器和处理器。该存储器用于存储非暂时性计算机可读指令。具体地,存储器可以包括一个或多个计算机程序产品,该计算机程序产品可以包括各种形式的计算机可读存储介质,例如易失性存储器和/或非易失性存储器。该易失性存储器例如可以包括随机存取存储器(RAM)和/或高速缓冲存储器(cache)等。该非易失性存储器例如可以包括只读存储器(ROM)、硬盘、闪存等。

[0075] 该处理器可以是中央处理单元(CPU)或者具有数据处理能力和/或指令执行能力的其它形式的处理单元,并且可以控制电子设备中的其它组件以执行期望的功能。在本公开的一个实施例中,该处理器用于运行该存储器中存储的该计算机可读指令,使得该电子设备执行前述的本公开各实施例的由结构化模式驱动的后台异步会话上下文压缩与分段归档方法全部或部分步骤。

[0076] 本领域技术人员应能理解,为了解决如何获得良好用户体验效果的技术问题,本实施例中也可以包括诸如通信总线、接口等公知的结构,这些公知的结构也应包含在本公开的保护范围之内。

[0077] 如图2为本公开实施例提供的一种电子设备的结构示意图。其示出了适于用来实现本公开实施例中的电子设备的结构示意图。图2示出的电子设备仅仅是一个示例,不应对本公开实施例的功能和使用范围带来任何限制。

[0078] 如图2所示,电子设备可以包括处理装置(例如中央处理器、图形处理器等),其可以根据存储在只读存储器(ROM)中的程序或者从存储装置加载到随机访问存储器(RAM)中的程序而执行各种适当的动作和处理。在RAM中,还存储有电子设备操作所需的各种程序和数据。处理装置、ROM以及RAM通过总线彼此相连。输入/输出(I/O)接口也连接至总线。

[0079] 通常,以下装置可以连接至I/O接口:包括例如传感器或者视觉信息采集设备等的输入装置;包括例如显示屏等的输出装置;包括例如磁带、硬盘等的存储装置;以及通信装置。通信装置可以允许电子设备与其他设备(比如边缘计算设备)进行无线或有线通信以交换数据。虽然图2示出了具有各种装置的电子设备,但是应理解的是,并不要求实施或具备所有示出的装置。可以替代地实施或具备更多或更少的装置。

[0080] 特别地,根据本公开的实施例,上文参考流程图描述的过程可以被实现为计算机软件程序。例如,本公开的实施例包括一种计算机程序产品,其包括承载在非暂态计算机可读介质上的计算机程序,该计算机程序包含用于执行流程图所示的方法的程序代码。在这样的实施例中,该计算机程序可以通过通信装置从网络上被下载和安装,或者从存储装置被安装,或者从ROM被安装。在该计算机程序被处理装置执行时,执行本公开实施例的由结构化模式驱动的后台异步会话上下文压缩与分段归档方法的全部或部分步骤。

[0081] 有关本实施例的详细说明可以参考前述各实施例中的相应说明,在此不再赘述。

[0082] 根据本公开实施例的计算机可读存储介质,其上存储有非暂时性计算机可读指令。当该非暂时性计算机可读指令由处理器运行时,执行前述的本公开各实施例的由结构化模式驱动的后台异步会话上下文压缩与分段归档方法的全部或部分步骤。

[0083] 上述计算机可读存储介质包括但不限于:光存储介质(例如:CD—ROM和DVD)、磁光存储介质(例如:MO)、磁存储介质(例如:磁带或移动硬盘)、具有内置的可重写非易失性存储器的媒体(例如:存储卡)和具有内置ROM的媒体(例如:ROM盒)。

[0084] 有关本实施例的详细说明可以参考前述各实施例中的相应说明,在此不再赘述。

[0085] 以上结合具体实施例描述了本公开的基本原理,但是,需要指出的是,在本公开中提及的优点、优势、效果等仅是示例而非限制,不能认为这些优点、优势、效果等是本公开的各个实施例必须具备的。另外,上述公开的具体细节仅是为了示例的作用和便于理解的作用,而非限制,上述细节并不限制本公开为必须采用上述具体的细节来实现。

[0086] 在本公开中,诸如第一和第二等之类的关系术语仅仅用来将一个实体或者操作与另一个实体或操作区分开来,而不一定要求或者暗示这些实体或操作之间存在任何这种实际的关系或者顺序,本公开中涉及的器件、装置、设备、系统的方框图仅作为例示性的例子并且不意图要求或暗示必须按照方框图示出的方式进行连接、布置、配置。如本领域技术人员将认识到的,可以按任意方式连接、布置、配置这些器件、装置、设备、系统。诸如“包括”、“包含”、“具有”等等的词语是开放性词汇,指“包括但不限于”,且可与其互换使用。这里所

使用的词汇“或”和“和”指词汇“和/或”,且可与其互换使用,除非上下文明确指示不是如此。这里所使用的词汇“诸如”指词组“诸如但不限于”,且可与其互换使用。

[0087] 另外,如在此使用的,在以“至少一个”开始的项的列举中使用的“或”指示分离的列举,以便例如“A、B或C的至少一个”的列举意味着A或B或C,或AB或AC或BC,或ABC(即A和B和C)。此外,措辞“示例的”不意味着描述的例子是优选的或者比其他例子更好。

[0088] 还需要指出的是,在本公开的系统和方法中,各部件或各步骤是可以分解和/或重新组合的。这些分解和/或重新组合应视为本公开的等效方案。

[0089] 可以不脱离本实施例定义的教导的技术而进行对在此所述的技术的各种改变、替换和更改。此外,本本实施例的范围不限于以上所述的处理、机器、制造、事件的组成、手段、方法和动作的具体方面。可以利用与在此所述的相应方面进行基本相同的功能或者实现基本相同的结果的当前存在的或者稍后要开发的处理、机器、制造、事件的组成、手段、方法或动作。因而,本实施例包括在其范围内的这样的处理、机器、制造、事件的组成、手段、方法或动作。

[0090] 提供所公开的方面的以上描述以使本领域的任何技术人员能够做出或者使用本公开。对这些方面的各种修改对于本领域技术人员而言是非常显而易见的,并且在此定义的一般原理可以应用于其他方面而不脱离本公开的范围。因此,本公开不意图被限制到在此示出的方面,而是按照与在此公开的原理和新颖的特征一致的最宽范围。

[0091] 为了例示和描述的目的已经给出了以上描述。此外,此描述不意图将本公开的实施例限制到在此公开的形式。尽管以上已经讨论了多个示例方面和实施例,但是本领域技术人员将认识到其某些变型、修改、改变、添加和子组合。

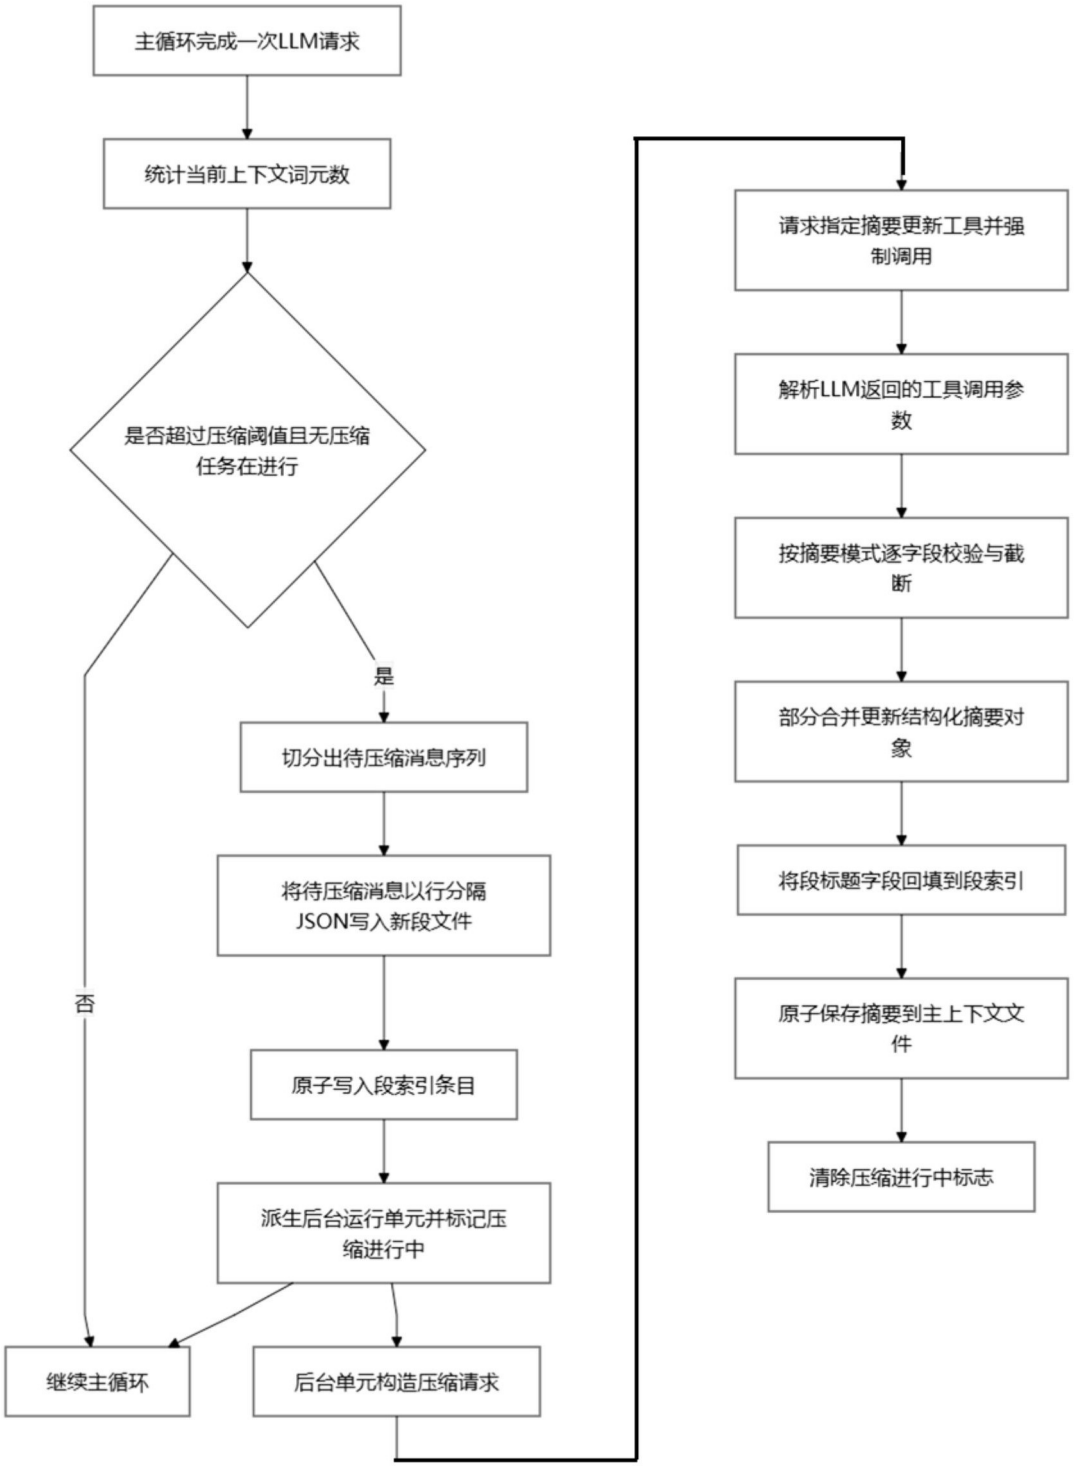

主循环完成一次LLM请求
统计当前上下文词元数
是否超过压缩阈值且无压缩任务在进行
是
否
切分出待压缩消息序列
将待压缩消息以行分隔JSON写入新段文件
原子写入段索引条目
派生后台运行单元并标记压缩进行中
继续主循环
后台单元构造压缩请求
请求指定摘要更新工具并强制调用
解析LLM返回的工具调用参数
按摘要模式逐字段校验与截断
部分合并更新结构化摘要对象
将段标题字段回填到段索引
原子保存摘要到主上下文文件
清除压缩进行中标志

图1

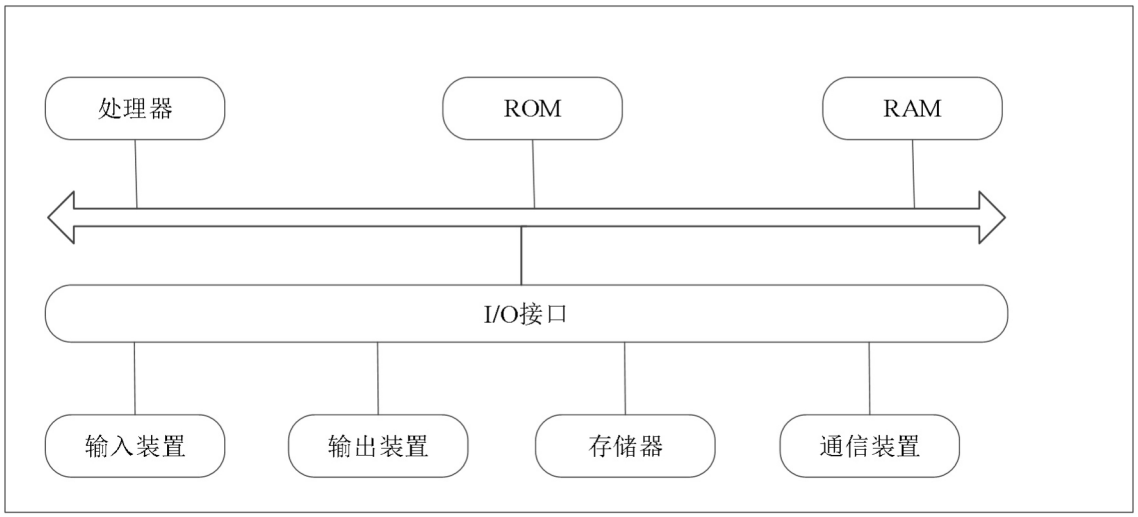


图2